2.5 กรอบแนวคิดของการให้คะแนนและการตัดสินใจเชื่อมโยงข้อมูล

ทฤษฎีในส่วนเพิ่มเติมนี้ใช้รองรับการพัฒนานโยบายด้วย GA ที่อธิบายไว้ในบทที่ 3 โดยเชื่อมจากปัญหาการเชื่อมโยงอัตลักษณ์เดิมไปสู่การตัดสินใจภายใต้ข้อมูลไม่ครบและต้นทุนที่แตกต่างกัน เนื้อหาครอบคลุมบทบาทของการสร้างคู่ การให้คะแนน การตัดสินใจสามทาง การคำนวณต้นทุน การค้นหาพารามิเตอร์ และการประเมินผล เพื่อให้เห็นเหตุผลของการออกแบบแต่ละส่วนก่อนพิจารณาวิธีดำเนินงานจริง

2.5.1 ความสัมพันธ์ระหว่าง Candidate Generation, Pair Scoring และ Decision Policy

กระบวนการเชื่อมโยงข้อมูลสามารถพิจารณาเป็นสามหน้าที่ต่อเนื่องกัน ขั้นแรกคือการเลือกคู่ที่มีโอกาสเกี่ยวข้องกันเพื่อส่งไปเปรียบเทียบ ขั้นที่สองคือการให้คะแนนแต่ละคู่จากคุณลักษณะที่มี และขั้นที่สามคือการกำหนดการดำเนินการจากคะแนนและหลักฐาน หน้าที่ทั้งสามเกี่ยวข้องกันแต่ตอบคำถามต่างกัน การสร้างคู่ตอบว่าควรเปรียบเทียบใครกับใคร การให้คะแนนตอบว่าคู่นั้นมีแนวโน้มเป็นบุคคลเดียวกันเพียงใด และนโยบายตอบว่าระบบควรทำอะไรต่อ

Papadakis และคณะ [9] จัดกลุ่มแนวทางเพิ่มประสิทธิภาพของ entity resolution เป็น blocking, filtering และแนวทางผสม โดย blocking ลดการเปรียบเทียบให้เหลือคู่ที่มีแนวโน้มตรงกัน ส่วน filtering ใช้เงื่อนไขเพื่อตัดคู่ที่ไม่น่าผ่านเกณฑ์ความคล้าย แนวคิดนี้รองรับการแยกขั้นคัดคู่จากขั้นตัดสินใจ และทำให้ต้องพิจารณาความครอบคลุมของคู่ควบคู่กับจำนวนคู่ที่ลดลง

สำหรับโครงงานนี้ ความสัมพันธ์ดังกล่าวมีผลต่อการอ่านผลโดยตรง หากคู่จริงไม่ผ่านเข้ามาในชุดผู้สมัคร นโยบายปลายทางไม่มีโอกาสตัดสินคู่นั้น แม้ GA จะเลือกพารามิเตอร์ที่เหมาะสมกับคู่ที่ได้รับก็ตาม ในทางกลับกัน หากคู่ถูกส่งเข้ามาแล้วแต่ตัดสินผิด ปัญหานั้นอยู่ในขอบเขตการให้คะแนนหรือการตัดสินใจ การแยกสองกรณีช่วยระบุว่าควรปรับปรุงระบบที่ขั้นใด

2.5.2 คะแนนความคล้าย คะแนนโมเดล และคำตัดสิน

คะแนนความคล้ายเป็นค่าที่คำนวณจากข้อมูลเฉพาะด้าน เช่น ชื่อหรือข้อความ คะแนนสูงจึงสะท้อนความสอดคล้องตามวิธีวัดนั้น แต่ไม่ได้ยืนยันความเป็นบุคคลเดียวกันโดยลำพัง ชื่อที่เหมือนกันอาจเป็นชื่อทั่วไป ขณะที่ชื่อที่ต่างกันอาจเป็นชื่อย่อหรือนามแฝงของบุคคลเดียวกัน

คะแนนโมเดลเป็นผลที่ได้จากการพิจารณาคุณลักษณะหลายตัวร่วมกัน ส่วนคำตัดสินเป็นผลจากกฎที่นำคะแนนไปใช้ ความแตกต่างนี้สำคัญเพราะคะแนนเดิมสามารถนำไปสู่คำตัดสิน

ต่างกันได้เมื่อเปลี่ยนเกณฑ์หรือต้นทุน การประเมินโมเดลจึงไม่เท่ากับการประเมินนโยบายที่ใช้งานโมเดลนั้น

ในนโยบายที่พัฒนาขึ้น คะแนนโมเดลเป็นหลักฐานหนึ่งที่นำมารวมกับข้อมูลด้านอื่น แม้คะแนนรวมสุดท้ายอยู่ระหว่าง 0 ถึง 1 ก็ยังเป็นคะแนนสำหรับตัดสินใจตามสูตรที่กำหนด การตีความเป็นโอกาสถูกต้องร้อยละใดต้องมีการตรวจสอบการปรับเทียบรองรับอีกขั้นหนึ่ง

2.6 การตัดสินใจสามทางและบทบาทของการตรวจสอบโดยมนุษย์

2.6.1 แนวคิดการยอมรับ ปฏิเสธ และรอการตรวจสอบ

การตัดสินใจสามทางเปิดทางให้ระบบแยกกรณีที่ยังไม่แน่ชัดออกจากกรณีที่ตัดสินอัตโนมัติได้ Ouyang และคณะ [10] ศึกษา record linkage โดยใช้ granular descriptors อธิบายบริเวณข้อมูลที่ไม่แน่นอน และส่งกรณีเหล่านั้นให้ตรวจสอบเพิ่มเติม แนวคิดนี้แสดงว่าการมีสถานะรอตรวจสอบเป็นองค์ประกอบของวิธีจัดการความไม่แน่นอนในงานเชื่อมโยงข้อมูล ไม่ใช่เพียงผลลัพธ์ที่ระบบประมวลผลไม่สำเร็จ

ในโครงงานนี้กำหนดชื่อผลลัพธ์เป็น MATCH, REVIEW และ NO_MATCH โดยใช้เกณฑ์บนและเกณฑ์ล่างของคะแนน ถ้าให้ z_i เป็นคะแนนที่ใช้ตัดสินคู่ที่ i กฎพื้นฐานเขียนได้ดังนี้

$$D_i = \begin{cases} \text{MATCH}, & z_i \geq t_m, \\ \text{REVIEW}, & t_r \leq z_i < t_m, \\ \text{NO_MATCH}, & z_i < t_r, \end{cases} \qquad 0 \leq t_r \leq t_m \leq 1.$$

เมื่อ t_m และ t_r ห่างกันมากขึ้น พื้นที่สำหรับ REVIEW จะกว้างขึ้น แต่จำนวนคู่ที่ย้ายสถานะจริงยังขึ้นอยู่กับการกระจายคะแนน หากไม่มีคู่ใดอยู่ในช่วงที่เปลี่ยนเกณฑ์ จำนวนคำตัดสินอาจไม่เปลี่ยนเลย การประเมินจึงต้องคำนวณกับข้อมูลจริง แทนการพิจารณาระยะห่างของเกณฑ์เพียงอย่างเดียว

2.6.2 REVIEW เป็นภาระงานที่ต้องมีปลายทางรองรับ

สถานะ REVIEW หมายถึงระบบยังไม่ยืนยันการรวมและยังไม่ปฏิเสธคู่ในขั้นอัตโนมัติ หากนำไปใช้งาน เจ้าหน้าที่ต้องได้รับข้อมูลที่เพียงพอสำหรับตรวจสอบ เช่น โปรไฟล์ทั้งสองฝั่ง หลักฐานที่มี คะแนน และเหตุผลที่ถูกส่งเข้าคิว รวมถึงมีการบันทึกผลเมื่อพิจารณาเสร็จแล้ว

การส่ง REVIEW มากขึ้นอาจเปิดโอกาสให้คนช่วยแก้คู่ยาก แต่ไม่ได้แปลว่าคู่เหล่านั้นถูกแก้ไขถูกต้องแล้ว ในการทดลองที่ยังไม่มีผลตรวจจากเจ้าหน้าที่ คู่ REVIEW จึงยังเป็นงานค้าง และไม่ควรถูกรวมเป็นจำนวนคู่ที่ระบบจับคู่สำเร็จโดยอัตโนมัติ การแยกสถานะนี้ทำให้รายงานความสามารถของระบบกับภาระของผู้ปฏิบัติงานได้ตรงกัน

อีกประเด็นหนึ่งคือความสามารถในการตรวจสอบภายในเวลาที่กำหนด หากคิวมีคู่ 10,000 คู่และสมมติให้ใช้เวลาคู่ละ 1 นาที จะคิดเป็นเวลาทำงานประมาณ 166.7 ชั่วโมง ตัวอย่างนี้เป็นการคำนวณประกอบความเข้าใจ ไม่ใช่ผลที่วัดจากเจ้าหน้าที่ของโครงงาน และยังไม่รวมเวลาพัก การประสานงาน หรือกรณีที่ซับซ้อนกว่าปกติ

2.6.3 ความต่างระหว่าง Human Review และ Active Learning

Human review เป็นขั้นตอนให้คนช่วยตัดสินหรือยืนยันข้อมูล ส่วน active learning เป็นวิธีเลือกตัวอย่างที่จะขอฉลากเพิ่มเติมเพื่อช่วยการเรียนรู้ของโมเดล สองแนวคิดอาจทำงานร่วมกันได้ แต่การมีคิว REVIEW เพียงอย่างเดียวไม่ได้แสดงว่าระบบทำ active learning แล้ว

สำหรับนโยบายที่ศึกษาในรอบนี้ การค้นหาใช้ฉลากและคะแนนที่เตรียมไว้ การนำผลตรวจของคนกลับไปเลือกตัวอย่างหรือฝึกโมเดลใหม่เป็นขั้นตอนต่อยอดที่ต้องออกแบบและประเมินแยกต่างหาก จึงต้องแยกสถานะงานที่ทำแล้วออกจากความสามารถที่คาดว่าจะเพิ่มในอนาคต

2.7 การตัดสินใจโดยคำนึงถึงต้นทุนความผิดพลาด

2.7.1 เหตุผลที่ความผิดพลาดแต่ละประเภทมีน้ำหนักต่างกัน

Elkan [12] อธิบายการเรียนรู้และการตัดสินใจเมื่อความผิดพลาดแต่ละประเภทมีบทลงโทษต่างกัน โดยชี้ให้เห็นความสำคัญของการกำหนดต้นทุนให้สอดคล้องกับความหมายทางเศรษฐศาสตร์ แนวคิดนี้ช่วยให้การเลือกคำตอบพิจารณาผลของการกระทำเพิ่มเติมจากโอกาสจำแนกถูกเพียงอย่างเดียว

ในการเชื่อมโยงโปรไฟล์ การรวมคนละคนกับการไม่รวมคนเดียวกันอาจใช้เวลาแก้ไขต่างกัน ขณะเดียวกัน การส่งให้คนตรวจสอบมีต้นทุนแม้สุดท้ายจะได้คำตอบถูกต้อง การออกแบบนโยบายของโครงงานจึงกำหนดน้ำหนักให้การกระทำทั้งสามประเภทอย่างเปิดเผยแทนการซ่อนสมมติฐานดังกล่าวไว้ในจุดตัดของคะแนน

2.7.2 ตารางต้นทุนที่ใช้ในโครงงาน

กำหนดให้ $y = 1$ หมายถึงคู่ที่เป็นบุคคลเดียวกัน และ $y = 0$ หมายถึงคู่ที่เป็นคนละคน ตารางต้นทุนอย่างง่ายสำหรับนโยบายของโครงงานเป็นดังตารางที่ 2.3 โดยถือว่าการตัดสินอัตโนมัติที่ถูกต้องไม่มีต้นทุนความผิดพลาดในฟังก์ชันนี้

คำตัดสิน	คู่จริงเป็นคนเดียวกัน	คู่จริงเป็นคนละคน
MATCH	0	c_{FP}
REVIEW	c_R	c_R
NO_MATCH	c_{FN}	0

ตารางที่ 2.3 โครงสร้างต้นทุนการตัดสินใจสามทางของโครงงาน

ต้นทุนรวมจึงเขียนได้เป็น $C = c_{FP}FP + c_{FN}FN + c_R R$ โดย FP นับคู่ลบที่เป็น MATCH, FN นับคู่บวกที่เป็น NO_MATCH และ R นับทุกคู่ที่เป็น REVIEW ตารางนี้เป็นแบบจำลองต้นทุนของการตัดสินใจขั้นปัจจุบัน ยังไม่ได้คำนวณความผิดพลาดที่เจ้าหน้าที่อาจทำภายหลังหรือผลกระทบทางธุรกิจทั้งหมด

เมื่อใช้สมมติฐานค่าแรง 100 บาทต่อชั่วโมง เวลาตรวจ 1 นาที เวลาแก้การรวมผิด 20 นาที และเวลาจัดการคู่ตกหล่น 10 นาที จะได้อัตราส่วนต้นทุน $c_{FP} : c_{FN} : c_R = 2 : 1 : 0.1$ หลังปรับหน่วยให้ต้นทุนคู่ตกหล่นเท่ากับ 1 ดังนั้นฟังก์ชันที่ใช้ค้นหาในโครงงานคือ $C = 2FP + FN + 0.1R$ อัตราส่วนนี้มาจากสมมติฐานของโครงงาน ไม่ใช่ค่ามาตรฐานที่กำหนดโดยงานอ้างอิง [12]

2.7.3 ความสัมพันธ์ระหว่างความน่าจะเป็นกับการเลือกการกระทำ

เพื่ออธิบายหลักการ สมมติว่า p เป็นความน่าจะเป็นที่คู่หนึ่งเป็นบุคคลเดียวกันและสะท้อนข้อมูลได้เหมาะสม ภายใต้ตารางต้นทุนข้างต้น ต้นทุนคาดหมายของการกระทำแต่ละแบบเขียนได้เป็น

$$L_{\text{MATCH}} = c_{FP}(1-p), \qquad L_{\text{NO_MATCH}} = c_{FN}p, \qquad L_{\text{REVIEW}} = c_R.$$

ตัวอย่างเมื่อ $p = 0.60$ และใช้อัตราส่วน 2:1:0.1 จะได้ต้นทุนคาดหมายของ MATCH เท่ากับ 0.80 ของ NO_MATCH เท่ากับ 0.60 และของ REVIEW เท่ากับ 0.10 การรอตรวจจึงมีต้นทุนคาดหมายต่ำที่สุดภายใต้สมมติฐานนี้ ตัวอย่างดังกล่าวแสดงเหตุผลว่าทำไมการเลือกการกระทำอาจต่างจากการเลือกคลาสที่มีโอกาสมากที่สุด

ในนโยบายแบบถ่วงน้ำหนักของโครงงาน คะแนนรวมไม่ได้ถูกยืนยันว่าเป็นความน่าจะเป็นที่ปรับเทียบแล้ว จึงไม่ได้แทนค่าคะแนนรวมนั้นลงในสูตรต้นทุนคาดหมายเพื่อสรุปเกณฑ์เชิงทฤษฎีโดยตรง แต่ใช้ GA ประเมินต้นทุนที่เกิดจากคำตัดสินบน validation วิธีอธิบายสองแบบนี้จึงต้องแยกกัน คือสูตรข้างต้นใช้ทำความเข้าใจหลักการ ส่วนวิธีในบทที่ 3 เป็นการค้นหาจากผลบนข้อมูล

2.7.4 ข้อควรพิจารณาเมื่อเปรียบเทียบต้นทุน

ต้นทุนรวมเพิ่มตามจำนวนคู่ จึงเปรียบเทียบโดยตรงได้เมื่อใช้นโยบายต่างกันบนคู่ชุดเดียวกัน หากเปรียบเทียบคนละชุด ควรรายงานจำนวนคู่ สัดส่วนคู่บวก และต้นทุนเฉลี่ยต่อคู่ร่วมด้วย แม้ต้นทุนเฉลี่ยเท่ากัน สัดส่วนความผิดพลาดอาจต่างกันได้

การเปลี่ยนน้ำหนักต้นทุนยังอาจทำให้เลือกนโยบายคนละชุด หากต้องการศึกษาความไวต่อสมมติฐาน ต้องกำหนดสถานการณ์ต้นทุนใหม่และเลือกนโยบายบน validation อีกครั้ง ส่วนการนำพารามิเตอร์เดิมไปคำนวณต้นทุนใหม่ตอบได้เพียงว่านโยบายเดิมมีค่าใช้จ่ายเท่าใดภายใต้สมมติฐานใหม่ ไม่ได้ยืนยันว่าเป็นคำตอบที่เหมาะสมที่สุดของสถานการณ์นั้น

2.8 ขั้นตอนวิธีเชิงพันธุกรรมสำหรับค้นหานโยบาย

2.8.1 แนวคิดและองค์ประกอบพื้นฐาน

GA เป็นวิธีค้นหาที่ปรับปรุงคำตอบหลายชุดผ่านกระบวนการคัดเลือกและสร้างคำตอบรุ่นถัดไป แนวคิดพื้นฐานและการประยุกต์กับปัญหาการค้นหาสามารถศึกษาได้จาก Mitchell [18] สำหรับโครงงานนี้ คำตอบหนึ่งชุดแทนนโยบายหนึ่งนโยบาย และคุณภาพของคำตอบวัดด้วยต้นทุนบน validation รายละเอียดต่อไปนี้อธิบายความหมายขององค์ประกอบ GA ตามการออกแบบที่ใช้ในโครงงาน

โครโมโซม (Chromosome) คือ ชุดพารามิเตอร์ของนโยบาย ยีน (Gene) คือพารามิเตอร์แต่ละตำแหน่ง ประชากร (Population) คือกลุ่มนโยบายที่ประเมินในรอบเดียวกัน และรุ่น (Generation) คือรอบการประเมินและสร้างประชากรใหม่ คำว่า fitness ใช้เรียกค่าประเมินคุณภาพของคำตอบ ในงานนี้ใช้ต้นทุนเป็นเกณฑ์จัดอันดับโดยตรงและให้ค่าต่ำเป็นคำตอบที่ดีกว่า

2.8.2 การแทนคำตอบเป็นค่าจริงและการกำหนดพื้นที่ค้นหา

พารามิเตอร์ของนโยบายประกอบด้วยเกณฑ์และน้ำหนักซึ่งเป็นค่าจริง จึงสามารถแทนโครโมโซมเป็นเวกเตอร์ตัวเลขได้โดยตรง นโยบายแบบถ่วงน้ำหนักมีโครงสร้างเป็น

$$\boldsymbol{g} = [t_m, t_r, w_1, w_2, \ldots, w_8].$$

การแทนคำตอบต้องมาพร้อมเงื่อนไข เช่น เกณฑ์ REVIEW ไม่สูงกว่าเกณฑ์ MATCH น้ำหนักไม่ติดลบ และผลรวมน้ำหนักเท่ากับ 1 หากกลุ่มข้อมูลใดไม่มีหลักฐานพร้อมใช้ จะกำหนดน้ำหนักเป็นศูนย์ เงื่อนไขเหล่านี้จำกัดการค้นหาให้ได้คำตอบที่นำไปใช้กับกฎการตัดสินใจได้จริง

ตัวอย่างเช่น น้ำหนักดิบ 2, 3 และ 5 สามารถปรับเป็น 0.2, 0.3 และ 0.5 โดยหารด้วยผลรวม 10 ขั้นตอนนี้ทำให้ตีความน้ำหนักเป็นสัดส่วนได้ แต่ไม่ได้ทำให้ข้อมูลที่สัมพันธ์กันกลายเป็นหลักฐานอิสระ จึงยังต้องระวังการตีความว่าน้ำหนักแต่ละตัวบอกคุณค่าของข้อมูลด้านนั้นโดยแยกขาดจากด้านอื่น

2.8.3 การคัดเลือก การผสม และการกลายพันธุ์

การคัดเลือกทำให้คำตอบที่มีต้นทุนต่ำมีบทบาทในการสร้างประชากรรุ่นถัดไป ในตัวค้นหาของโครงงาน ระบบเก็บกลุ่มอันดับต้นไว้ แล้วเลือกพ่อแม่จากกลุ่มนั้นเพื่อสร้างลูก การเก็บคำตอบที่ดีไว้โดยตรงเรียกว่า elitism และช่วยไม่ให้คำตอบที่ดีที่สุดที่พบในรอบก่อนหายไปทั้งหมดเมื่อสร้างประชากรใหม่

การผสมแบบ uniform crossover เลือกแต่ละยีนจากพ่อหรือแม่ด้วยโอกาสเท่ากัน ทำให้ลูกสามารถได้รับเกณฑ์จากคำตอบหนึ่งและน้ำหนักบางส่วนจากอีกคำตอบหนึ่ง หลังผสมแล้วอาจได้ค่าที่ต้องปรับให้อยู่ในเงื่อนไข เช่น เกณฑ์สลับลำดับหรือผลรวมน้ำหนักไม่เท่ากับ 1

การกลายพันธุ์เพิ่มการเปลี่ยนแปลงเล็กน้อยให้ยีนบางตัว เพื่อให้ประชากรสำรวจบริเวณที่ต่างจากพ่อแม่ ในโครงงานใช้ค่ารบกวนแบบปกติกับยีนที่ถูกเลือกให้กลายพันธุ์ แล้วตรวจขอบเขตและปรับน้ำหนักอีกครั้ง การกลายพันธุ์มากหรือน้อยเกินไปอาจทำให้ลักษณะการค้นหาต่างกัน จึงต้องบันทึกการตั้งค่าไว้ร่วมกับผลทดลอง

2.8.4 ความเหมาะสมกับฟังก์ชันต้นทุนของนโยบาย

ต้นทุนของนโยบายคำนวณจากจำนวนคู่ที่ถูกตัดสินเป็นแต่ละสถานะ เมื่อขยับเกณฑ์เพียงเล็กน้อยแต่ยังไม่มีคู่ใดเปลี่ยนสถานะ ต้นทุนจะไม่เปลี่ยน แต่เมื่อเกณฑ์ข้ามคะแนนของคู่บางคู่ ต้นทุนจะกระโดดตามจำนวนและชนิดของคู่ที่เปลี่ยนคำตัดสิน ฟังก์ชันนี้จึงมีลักษณะเป็นช่วงคงที่และเปลี่ยนแบบไม่ต่อเนื่องในหลายบริเวณ

GA ประเมินคำตอบจากค่าต้นทุนได้โดยไม่ต้องหาอนุพันธ์ของฟังก์ชัน และค้นหาเกณฑ์กับน้ำหนักร่วมกันได้ จึงเป็นทางเลือกที่นำมาศึกษาในงานนี้ อย่างไรก็ตาม การค้นหาแบบกริด การสุ่ม หรือวิธีอื่นอาจเหมาะกับปัญหาบางรูปแบบได้เช่นกัน การใช้ GA ในโครงงานไม่ได้เป็นหลักฐานว่า GA มีประสิทธิภาพเหนือทุกวิธี หากยังไม่ได้เปรียบเทียบภายใต้งบประมาณการค้นหาที่เท่ากัน

2.8.5 การหยุดค้นหาและความแปรปรวนจากการสุ่ม

โครงงานกำหนดจำนวนรุ่นเป็นเงื่อนไขหยุด แล้วเลือกคำตอบที่ดีที่สุดจากประชากรที่ประเมิน การใช้จำนวนรุ่นแน่นอนช่วยควบคุมขอบเขตการทดลอง แต่จำนวนรุ่นเท่ากันไม่ได้ทำให้เวลาใช้จริงเท่ากันเสมอ เพราะแต่ละนโยบายมีต้นทุนการคำนวณต่อคำตอบต่างกัน

ผล GA ยังขึ้นกับ seed ที่กำหนดประชากรเริ่มต้นและการสุ่มในแต่ละรุ่น การทำซ้ำหลาย seed จึงช่วยให้เห็นความเปลี่ยนแปลงของต้นทุนและพารามิเตอร์ หากหลายชุดพารามิเตอร์ให้ผลใกล้กัน ไม่ควรอธิบายน้ำหนักของคำตอบเพียงชุดเดียวว่าเป็นค่าที่จำเป็นตายตัวของปัญหา และการพบคำตอบเดิมหลายครั้งก็ยังไม่ใช่ข้อพิสูจน์ว่าพบคำตอบดีที่สุดทั่วพื้นที่ค้นหา

2.9 การรวมหลักฐานหลายด้านและการจัดการข้อมูลที่ขาดหาย

2.9.1 ความคล้ายเชิงตัวอักษรและเชิงความหมาย

ข้อมูลชื่อและข้อความอาจให้หลักฐานต่างลักษณะกัน ความคล้ายเชิงตัวอักษรช่วยจับรูปสะกดที่ใกล้กัน ส่วนความคล้ายเชิงความหมายช่วยพิจารณาข้อความที่ใช้คำต่างกันแต่สื่อความใกล้เคียง Reimers และ Gurevych [14] เสนอ Sentence-BERT เพื่อสร้างเวกเตอร์ประโยคที่นำมาเปรียบเทียบด้วย cosine similarity ได้ แนวคิดนี้รองรับการเพิ่มหลักฐานจากข้อความสั้น เช่น ประวัติย่อในโปรไฟล์

ในโครงงาน การที่ประวัติย่อมีความหมายคล้ายกันเป็นหลักฐานประกอบการจับคู่ เพราะคนละคนอาจเขียนถึงอาชีพ งานอดิเรก หรือสถานที่เดียวกันได้ ตัวอย่างเช่น โปรไฟล์สองคนระบุว่าเป็นนักออกแบบและชอบถ่ายภาพ ข้อความอาจคล้ายกันมากแต่ยังไม่เพียงพอสำหรับยืนยันตัวตน การใช้หลายด้านร่วมกันจึงต้องอ่านทั้งความสอดคล้องและข้อจำกัดของข้อมูลแต่ละประเภท

2.9.2 Missingness และ Availability Mask

ค่าความคล้ายศูนย์อาจหมายถึงข้อมูลสองฝั่งไม่ตรงกัน แต่ช่องที่ไม่มีข้อมูลไม่สามารถให้ข้อสรุปเดียวกันได้ โครงงานจึงใช้ availability mask แยกว่าคะแนนด้านนั้นมีหลักฐานพร้อมใช้งานหรือไม่ โดยให้ $m_{ik} = 1$ เมื่อช่องที่ k ของคู่ที่ i ใช้ได้ และให้เป็น 0 เมื่อใช้ไม่ได้

คำว่าใช้ได้ต้องมีนิยามตามชนิดข้อมูล เช่น ความคล้ายของประวัติย่ออาจต้องมีข้อความที่ใช้งานได้ทั้งสองฝั่ง ส่วนกลุ่มภาพอาจอาศัยภาพหรือคำบรรยายภาพตามที่ตารางคุณลักษณะรองรับ การใช้ mask จึงไม่ได้แก้ปัญหาข้อมูลหายทุกชนิดโดยอัตโนมัติ แต่ทำให้สูตรตัดสินใจรู้ว่าค่าใดควรถูกนำมาคิด

2.9.3 การถ่วงน้ำหนักตามหลักฐานที่มีในแต่ละคู่

ให้ s_{ik} เป็นคะแนนหลักฐาน และ w_k เป็นน้ำหนักของนโยบาย โครงงานคำนวณคะแนนรวมเฉพาะช่องที่พร้อมใช้ด้วยสูตร

$$S_i = \frac{\sum_{k=1}^{8} w_k m_{ik} s_{ik}}{\sum_{k=1}^{8} w_k m_{ik}}.$$

เมื่อไม่มีช่องที่มีน้ำหนักพร้อมใช้งาน ผลรวมในตัวหารเท่ากับศูนย์และระบบกำหนด REVIEW แทนการคำนวณคะแนน สูตรนี้เป็นข้อกำหนดของนโยบายที่พัฒนาขึ้นในโครงงาน ส่วนค่าของน้ำหนักและเกณฑ์ค้นหาจาก validation ตามวิธีในบทที่ 3

ตัวอย่างสมมติมีน้ำหนักคะแนนโมเดล 0.2 ชื่อ 0.5 และประวัติย่อ 0.3 คู่หนึ่งมีคะแนนโมเดล 0.9 คะแนนชื่อ 0.8 แต่ไม่มีประวัติย่อ คะแนนที่ใช้ตัดสินจะเท่ากับ $(0.2 \times 0.9 + 0.5 \times 0.8)/0.7$ หรือประมาณ 0.829 หากแทนประวัติย่อที่หายด้วยศูนย์และยังหารด้วย 1 จะเหลือ 0.58 ซึ่งลดลงจากการไม่มีข้อมูล ตัวอย่างนี้แสดงผลของการแยก mask ออกจากคะแนนอย่างเป็นรูปธรรม

แม้วิธีนี้ไม่ลงโทษข้อมูลขาดด้วยศูนย์โดยตรง แต่คะแนนอาจพึ่งหลักฐานเพียงไม่กี่ด้านเมื่อข้อมูลเหลือน้อย จึงต้องตรวจความผิดพลาดแยกตามความพร้อมใช้งานด้วย การปรับตัวหารเป็นการแก้ความหมายของคะแนน ไม่ใช่การรับประกันว่าคู่ที่มีข้อมูลน้อยจะตัดสินได้แม่นยำเท่าคู่ที่มีข้อมูลครบ

2.9.4 Coverage, Support และน้ำหนักที่มีผลจริง

Coverage ของกลุ่มข้อมูลเป็นสัดส่วนคู่ที่มีหลักฐานกลุ่มนั้นพร้อมใช้งาน ส่วน positive support เป็นจำนวนคู่บวกที่มีหลักฐานดังกล่าว ทั้งสองค่าช่วยบอกขนาดข้อมูลที่รองรับการประเมินกลุ่มนั้น หลักฐานที่มีความแม่นยำสูงในตัวอย่างเพียงไม่กี่คู่ยังไม่เพียงพอสำหรับสรุปความน่าเชื่อถือของทั้งกลุ่ม

น้ำหนักที่มีผลจริงต่อคู่หนึ่งคำนวณได้เป็น

$$\widetilde{w}_{ik} = \frac{w_k m_{ik}}{\sum_j w_j m_{ij}}.$$

เมื่อข้อมูลครบ น้ำหนักที่มีผลจริงตรงกับน้ำหนักรวมที่ปรับผลรวมแล้ว แต่เมื่อบางช่องหาย สัดส่วนของช่องที่เหลือจะเพิ่มขึ้น การรายงานเฉพาะน้ำหนักรวมจึงยังไม่อธิบายการตัดสินใจของทุกคู่ และน้ำหนักเป็นศูนย์ต้องแยกว่าเกิดจากการปิดช่องเพราะไม่มีข้อมูล หรือเกิดจาก GA เลือกไม่ใช้ช่องที่มีข้อมูล

2.9.5 น้ำหนักนโยบายกับความสำคัญของคุณลักษณะ

น้ำหนักนโยบายบอกสัดส่วนที่ใช้ในสูตรตัดสินใจ ส่วน feature importance อธิบายบทบาทของคุณลักษณะในแบบจำลองตามวิธีวิเคราะห์นั้น ทั้งสองอย่างอาจไม่ตรงกัน เพราะคะแนนโมเดลที่นำมาเป็นหนึ่งช่องอาจรวมผลของคุณลักษณะหลายตัวไว้แล้ว

หากคะแนนโมเดลและคะแนนชื่อให้ข้อมูลสัมพันธ์กัน GA อาจลดน้ำหนักช่องหนึ่งและเพิ่มอีกช่องหนึ่งโดยยังให้ผลตัดสินใกล้เดิม จึงไม่สามารถอ่านน้ำหนักว่าเป็นสัดส่วนสาเหตุของการเป็นบุคคลเดียวกัน หรือสรุปว่ากลุ่มที่น้ำหนักต่ำไม่มีประโยชน์ในทุกบริบท การอธิบายผลควรใช้ทั้งความครอบคลุม ความแปรปรวนของน้ำหนัก และการทดลองตัดกลุ่มข้อมูลออกตามขอบเขตที่มีหลักฐาน

2.10 การปรับเทียบคะแนนและการแยกข้อมูลเพื่อประเมินผล

2.10.1 ความหมายของ Probability Calibration

การปรับเทียบพิจารณาว่าค่าความน่าจะเป็นที่โมเดลให้สอดคล้องกับความถี่ของเหตุการณ์จริงหรือไม่ Guo และคณะ [13] ศึกษาประเด็นนี้ในโครงข่ายประสาทเทียมสมัยใหม่ และแสดงว่าความแม่นยำของการจำแนกกับคุณภาพการปรับเทียบเป็นคนละประเด็น งานดังกล่าวจึงรองรับการตรวจคะแนนก่อนนำไปตีความเป็นความมั่นใจ แต่ไม่ได้ยืนยันว่าเทคนิคเดียวกันให้ผลเหมือนกันกับข้อมูลโปรไฟล์ในโครงงาน

เอกสาร scikit-learn [15] อธิบายว่า หากกลุ่มตัวอย่างได้รับคะแนนใกล้ 0.8 และโมเดลปรับเทียบได้เหมาะสม สัดส่วนตัวอย่างบวกในกลุ่มนั้นควรใกล้ร้อยละ 80 การตรวจด้วย reliability diagram เปรียบเทียบค่าเฉลี่ยคะแนนกับสัดส่วนบวกในแต่ละช่วง และต้องดูจำนวนตัวอย่างประกอบ โดยเฉพาะช่วงที่มีข้อมูลน้อย

โครงงานเดิมมีขั้นปรับเทียบคะแนนก่อนตัดสินใจ แต่เมื่อเพิ่มสูตรคะแนนถ่วงน้ำหนักคะแนนที่ได้เป็นตัวแปรใหม่ การปรับเทียบคะแนนโมเดลเดิมจึงไม่ถ่ายทอดมาเป็นคุณสมบัติของคะแนนรวมโดยอัตโนมัติ ประเด็นนี้เป็นเหตุผลให้ใช้คำว่า “คะแนนนโยบาย” แยกจาก “ความน่าจะเป็นของโมเดล” ในรายงาน

2.10.2 บทบาทของ Train, Calibration, Validation และ Test

ข้อมูลแต่ละส่วนมีหน้าที่ต่างกัน Train ใช้เรียนรู้แบบจำลอง Calibration ใช้เรียนรู้การแปลงคะแนนเมื่อมีขั้นดังกล่าว Validation ใช้เลือกพารามิเตอร์หรือเปรียบเทียบนโยบาย และ Test ใช้ประเมินหลังการเลือกสิ้นสุด เอกสาร scikit-learn [15] ระบุว่าข้อมูลสำหรับเรียนรู้ตัวปรับเทียบควรเป็นอิสระจากข้อมูลที่ใช้ฝึกตัวจำแนก เพื่อหลีกเลี่ยงความมั่นใจที่เอนเอียงจากการประเมินข้อมูลที่โมเดลเคยเห็นแล้ว

การแบ่งบทบาทไม่ได้แปลว่าทุกรอบทดลองในโครงงานมีไฟล์สี่ชุดที่แยกกันเหมือนกันทั้งหมด วิธีที่ใช้จริงต้องตรวจจากกระบวนการสร้างคะแนนและข้อมูลแบ่งกลุ่มของรอบนั้น สำหรับการค้นหา GA รอบข้อมูลเต็ม ข้อกำหนดที่ใช้คือเลือกนโยบายจาก validation และบันทึกก่อนขั้นอ่าน test ส่วนความเป็นอิสระของคะแนนต้นทางต้องตรวจสอบย้อนกลับไปยังการฝึกโมเดลด้วย

2.10.3 การรั่วไหลของข้อมูลในงานที่หนึ่งบุคคลมีหลายโปรไฟล์

การรั่วไหลเกิดขึ้นเมื่อข้อมูลที่ไม่ควรมีในช่วงฝึกหรือเลือกพารามิเตอร์เข้ามามีผลต่อการสร้างระบบ ทำให้ผลประเมินดูดีเกินกว่าการใช้งานกับข้อมูลใหม่ เอกสารแนวปฏิบัติ scikit-learn [16] เน้นการแยกข้อมูลก่อนเรียนรู้กระบวนการแปลงและไม่ใช้ test ในการ fit ขั้นตอนของระบบ

สำหรับโครงงานเชื่อมโยงตัวตน ต้องพิจารณาว่าคู่หลายคู่สามารถมีโปรไฟล์หรือบุคคลเดียวกันร่วมกันได้ การสุ่มแยกแถวคู่จึงอาจทำให้ข้อมูลของบุคคลเดียวกันอยู่ทั้งสองชุด หากต้องการทดสอบการทำงานกับบุคคลที่ไม่เคยเห็น ต้องแบ่งกลุ่มตามตัวตนและตรวจคู่ที่ข้ามกลุ่มด้วย ส่วนนี้เป็นเงื่อนไขของการตีความผล ไม่ใช่สิ่งที่ยืนยันได้จากชื่อคอลัมน์ train หรือ test เพียงอย่างเดียว

การใช้ผล test หลายครั้งเพื่อเลือกโครงสร้างนโยบายก็ทำให้ข้อมูลทดสอบมีอิทธิพลต่อการออกแบบ แม้จะไม่ได้ส่ง test เข้าไปในฟังก์ชัน GA โดยตรง การตรึงพารามิเตอร์ก่อนทดสอบหนึ่งรอบจึงเป็นหลักฐานของลำดับการเลือกในรอบนั้น ส่วนการอ้างว่า test ไม่เคยถูกใช้ในการพัฒนามาก่อนต้องมีประวัติการทดลองรองรับเพิ่มเติม

2.11 ตัวชี้วัดสำหรับนโยบายสามทาง

2.11.1 การนับคำตัดสินให้ครอบคลุมสถานะ REVIEW

การประเมินนโยบายสามทางต้องแยกผลจริงสองกลุ่มออกจากคำตัดสินสามสถานะ ตารางที่ 2.4 แสดงชื่อจำนวนที่ใช้ในส่วนเพิ่มเติมนี้ เพื่อไม่ให้สับสนระหว่างคู่บวกที่ปฏิเสธแล้วกับคู่บวกที่ยังรอตรวจสอบ

ผลจริง	MATCH / REVIEW	NO_MATCH
เป็นคนเดียวกัน	TP / R_+	FN_N
เป็นคนละคน	FP / R_-	TN

ตารางที่ 2.4 สัญลักษณ์การนับผลจริงและคำตัดสินสามทาง

กำหนดให้ R_+ เป็นคู่บวกใน REVIEW, R_- เป็นคู่ลบใน REVIEW และ FN_N เป็นคู่บวกที่ถูกตัดสิน NO_MATCH ดังนั้นจำนวนคู่บวกทั้งหมดในชุดประเมินคือ $TP + R_+ + FN_N$ และ

จำนวน REVIEW คือ $R_+ + R_-$ นิยามนี้เป็นการขยายการนับสำหรับนโยบายของโครงงานจากตัวชี้วัดการจำแนกพื้นฐาน [17]

2.11.2 Precision, Recall และ F1 ของการรวมอัตโนมัติ

Precision ของการรวมอัตโนมัติพิจารณาว่าคู่ที่ระบบเลือกเป็น MATCH ถูกต้องเท่าใด ส่วน recall พิจารณาว่าคู่บวกทั้งหมดถูกนำไปเป็น MATCH แล้วเท่าใด คู่บวกที่อยู่ใน REVIEW ยังไม่ถือว่ารวมสำเร็จ สูตรที่ใช้จึงเป็น

$$P = \frac{TP}{TP + FP}, \qquad R = \frac{TP}{TP + R_+ + FN_N}, \qquad F1 = \frac{2PR}{P + R}.$$

ตัวอย่างมีคู่บวก 100 คู่ แบ่งเป็น MATCH 70 คู่ REVIEW 20 คู่ และ NO_MATCH 10 คู่ จะได้ recall ของการรวมอัตโนมัติเท่ากับร้อยละ 70 ไม่ใช่ $70/(70+10)$ เพราะยังมีคู่บวกที่รอตรวจอยู่ 20 คู่ ขณะที่ในฟังก์ชันต้นทุน คู่ REVIEW ถูกคิดเป็นต้นทุนตรวจและไม่คิดซ้ำเป็น FN_N การระบุนิยามทำให้ต้นทุนกับ recall ใช้ร่วมกันได้โดยไม่ขัดแย้ง

หากไม่มีคู่ MATCH ค่า precision ไม่มีตัวอย่างรองรับ หากไม่มีคู่บวก ค่า recall ก็ไม่มีตัวหารที่มีความหมาย โปรแกรมอาจเติมศูนย์เพื่อให้ตารางคำนวณต่อได้ แต่รายงานต้องบอกข้อจำกัดของกลุ่มนั้นด้วย

2.11.3 ภาระตรวจสอบและความครอบคลุมของระบบ

Review rate คำนวณจากจำนวน REVIEW หารด้วยจำนวนคู่ทั้งหมดในชุดที่ประเมิน ส่วนอัตราการตัดสินอัตโนมัติคำนวณจากจำนวน MATCH รวมกับ NO_MATCH หารด้วยจำนวนคู่ทั้งหมด ตัวชี้วัดนี้บอกสัดส่วนงานที่ระบบจัดการเอง แต่ต้องอ่านพร้อมความผิดพลาด เพราะระบบที่ตัดสินทุกคู่เองอาจมีอัตราอัตโนมัติสูงแม้คุณภาพต่ำ

ในระดับต้นทาง ให้ N_+^{all} เป็นจำนวนคู่บวกในขอบเขตอ้างอิงทั้งหมด และ N_+^{cand} เป็นคู่บวกที่เข้าสู่ชุดผู้สมัคร ความครอบคลุมคู่บวกของขั้นสร้างคู่คือ N_+^{cand}/N_+^{all} หากระบบปลายทางตัดสินได้เฉพาะคู่ผู้สมัคร recall ของการรวมอัตโนมัติเมื่อวัดกับคู่บวกทั้งหมดจะไม่เกินสัดส่วนนี้ ภายใต้ขอบเขตอ้างอิงและนิยามคู่ที่ตรงกัน

การประเมินบน candidate pairs กับการประเมินตลอดกระบวนการจึงใช้ตัวหารต่างกัน การเพิ่มความแม่นยำของนโยบายในชุด candidate ไม่ได้แสดงว่าระบบแก้คู่ที่หลุดจากการสร้างคู่แล้ว ต้องรายงานทั้งสองระดับแยกกัน

2.11.4 การอ่านผลหลายตัวชี้วัดร่วมกัน

AP และ ROC-AUC ใช้ศึกษาคุณภาพการจัดอันดับของคะแนนตามนิยามของแต่ละตัวชี้วัด [17] ส่วนจำนวน REVIEW และต้นทุนขึ้นกับนโยบายที่เลือกใช้คะแนน การเปลี่ยน threshold บนคะแนนเดิมจึงอาจเปลี่ยนต้นทุนและ F1 โดยไม่เปลี่ยนลำดับคะแนน หากเปลี่ยนเป็นคะแนนรวมแบบถ่วงน้ำหนัก ลำดับอาจเปลี่ยนด้วยและต้องประเมินใหม่

เมื่อรายงานผลควรระบุชื่อชุดข้อมูล จำนวนคู่ จำนวนคู่บวก และว่ารวม Exact-First หรือไม่ หากรวมคู่ Exact-First ผลที่ได้สะท้อนทั้งกฎเดิมและนโยบายที่พัฒนาใหม่ การแยกผลบนคู่ที่โมเดลให้คะแนนช่วยให้เห็นส่วนที่ GA มีอิทธิพลได้ชัดกว่า ส่วนผลรวมช่วยอธิบายผลลัพธ์ของกระบวนการที่นำไปใช้กับข้อมูลทั้งหมด

2.12 งานวิจัยเพิ่มเติมและความเกี่ยวข้องกับโครงงาน

2.12.1 งานด้านการลดจำนวนคู่เปรียบเทียบ

งานสำรวจของ Papadakis และคณะ [9] ให้กรอบจัดหมวดวิธีลดภาระการเปรียบเทียบใน entity resolution ความเกี่ยวข้องกับโครงงานคือการใช้กรอบนี้แยกคำถามด้านการคัดคู่ให้ครอบคลุมออกจากคำถามด้านการตัดสินคู่ที่คัดมาแล้ว งานดังกล่าวเป็นพื้นฐานเชิงระบบ ไม่ได้เป็นผลเปรียบเทียบโดยตรงกับ GA ที่ใช้ในโครงงาน

2.12.2 งานด้านการตัดสินใจสามทาง

Ouyang และคณะ [10] เสนอวิธีใช้ granular descriptors เพื่อจำแนกบริเวณที่ไม่แน่นอนและส่งตรวจเพิ่มเติม จุดที่นำมาสนับสนุนงานนี้คือการให้สถานะไม่ตัดสินทันทีมีบทบาทชัดเจนใน record linkage ส่วนวิธีของโครงงานใช้คะแนนและเกณฑ์ที่ GA ค้นหาภายใต้ต้นทุนที่กำหนด จึงไม่ได้ทำซ้ำกลไก granular computing ของงานอ้างอิง

2.12.3 งานด้าน GA สำหรับ Entity Resolution

Sun และคณะ [11] ศึกษาการใช้ GA เรียนรู้กฎจับคู่ที่ผสานการเปรียบเทียบหลายคุณลักษณะและเกณฑ์ที่เหมาะสม พร้อมใช้ active learning ลดภาระการติดฉลาก งานนี้แสดงตัวอย่างการประยุกต์ evolutionary search กับ entity resolution สำหรับโครงงานปัจจุบัน ความต่างอยู่ที่การค้นหานโยบายหลังได้คะแนนจากโมเดลที่ตรึงไว้ และยังไม่ได้ใช้วงจรขอฉลากใหม่แบบ active learning ในการค้นหานโยบายรอบนี้

2.12.4 งานด้านต้นทุน การปรับเทียบ และข้อความเชิงความหมาย

Elkan [12] ให้พื้นฐานเรื่องการตัดสินใจเมื่อความผิดพลาดมีต้นทุนต่างกัน Guo และคณะ [13] ศึกษาคุณภาพของค่าความมั่นใจของโมเดล และ Reimers กับ Gurevych [14] พัฒนาเวกเตอร์ประโยคเพื่อเปรียบเทียบความหมาย งานทั้งสามเกี่ยวข้องกับคนละส่วนของระบบ ได้แก่ วัตถุประสงค์ของการตัดสินใจ ความหมายของคะแนน และการสร้างหลักฐานจากข้อความ

การนำแนวคิดเหล่านี้มาประกอบกันในโครงงานยังต้องตรวจสอบผลกับข้อมูลที่ใช้จริง งานอ้างอิงไม่ได้ให้ค่าต้นทุน 2:1:0.1 ไม่ได้ยืนยันผลการปรับเทียบของคะแนนรวม และไม่ได้รับรองว่าประวัติย่อที่มีความหมายคล้ายกันเป็นบุคคลเดียวกัน ข้อสรุปเหล่านี้ต้องมาจากการกำหนดขอบเขตและการทดลองของโครงงานเอง

งานอ้างอิง	ประเด็นที่ใช้รองรับ	สิ่งที่โครงงานต้องศึกษาเอง
Papadakis และคณะ [9]	การแยกขั้นลดคู่จากการเปรียบเทียบคู่	ขอบเขตคู่ที่ GA เปลี่ยนคำตัดสินได้
Ouyang และคณะ [10]	การจัดการความไม่แน่นอนด้วยการตัดสินใจสามทาง	เกณฑ์และภาระ REVIEW ของข้อมูลโครงงาน
Sun และคณะ [11]	การค้นหากฎเชื่อมโยงด้วย GA	นโยบายบนคะแนนที่ตรึงไว้และผลของการถ่วงน้ำหนัก
Elkan [12]	การพิจารณาต้นทุนความผิดพลาด	สมมติฐานต้นทุนและผลแลกเปลี่ยนของนโยบาย
Guo และคณะ [13]	การแยกความแม่นยำจากการปรับเทียบ	คุณภาพคะแนนของโมเดลและคะแนนนโยบายที่ใช้จริง
Reimers และ Gurevych [14]	หลักฐานความคล้ายเชิงความหมายของข้อความ	ประโยชน์ของข้อความต่อการระบุตัวตนในชุดข้อมูลนี้

ตารางที่ 2.5 ความเชื่อมโยงระหว่างงานวิจัยเพิ่มเติมกับโครงงาน

2.13 การสังเคราะห์แนวคิดสู่กรอบการพัฒนาของโครงงาน

จากทฤษฎีและงานที่ทบทวน การตัดสินใจสามทางและการใช้ GA ใน entity resolution มีพื้นฐานจากงานก่อนหน้าแล้ว จุดที่โครงงานศึกษาต่อคือวิธีประกอบคะแนนโมเดล หลักฐานที่มีไม่ครบ ต้นทุนที่กำหนด และกระบวนการเลือกนโยบายให้ทำงานร่วมกันในข้อมูลโปรไฟล์ที่เตรียมไว้ จึงวางข้อเสนอของงานเป็นการออกแบบและประเมินนโยบายในขอบเขตนี้ โดยไม่อ้างว่าเป็นผู้ริเริ่ม GA หรือการตัดสินใจสามทางในงานเชื่อมโยงข้อมูล

กรอบการพัฒนาประกอบด้วยข้อมูลนำเข้าเป็นคู่ผู้สมัครและคะแนนที่ตรึงไว้ ส่วนประมวลผลเป็นการรวมหลักฐานตามความพร้อมใช้งานและค้นหาเกณฑ์กับน้ำหนักบน validation

ส่วนผลลัพธ์เป็นคำตัดสินสามทางพร้อมต้นทุนและตัวชี้วัด หลังเลือกเสร็จจึงตรึงนโยบายและประเมิน test ก่อนรายงานปริมาณงานบนคู่ทั้งหมด

ข้อเชื่อมโยงสำคัญมีสามประการ ประการแรก การคงคะแนนและชุดคู่เดิมช่วยให้แยกผลของนโยบายได้ ประการที่สอง การแยก mask ออกจากคะแนนทำให้ความหมายของข้อมูลขาดชัดเจน และประการที่สาม การแยกผล validation, test และข้อมูลรวมช่วยไม่ให้ผลเลือกพารามิเตอร์ถูกนำไปตีความเป็นผลกับข้อมูลใหม่ หลักการเหล่านี้นำไปสู่ขั้นตอนปฏิบัติและผลส่งออกที่อธิบายไว้ในหัวข้อ 3.6–3.8