3.6 การพัฒนานโยบายการตัดสินใจด้วยขั้นตอนวิธีเชิงพันธุกรรม

งานในส่วนนี้เป็นการพัฒนาต่อจากกระบวนการเชื่อมโยงอัตลักษณ์ที่อธิบายไว้ในหัวข้อ 3.1–3.5 โดยยังใช้การเตรียมข้อมูล การสร้างคู่ผู้สมัคร และคะแนนจากแบบจำลองเป็นพื้นฐานเดิม สิ่งที่เพิ่มเติมคือวิธีนำคะแนนและหลักฐานของแต่ละคู่มาใช้ตัดสินใจว่า ควรรวมข้อมูลอัตโนมัติ ส่งให้เจ้าหน้าที่ตรวจสอบ หรือไม่รวมข้อมูล ผู้วิจัยจึงเพิ่มขั้นตอนการค้นหานโยบายการตัดสินใจด้วยขั้นตอนวิธีเชิงพันธุกรรม (Genetic Algorithm: GA) เพื่อให้การเลือกเกณฑ์มีหลักฐานจากชุดข้อมูลตรวจสอบรองรับ และสะท้อนภาระงานที่เกิดขึ้นในระบบ CRM ได้ชัดเจนขึ้น

การพัฒนาส่วนนี้อยู่ภายใต้กรอบ CRISP-DM เดิม โดยขยายรายละเอียดในขั้นการสร้างแบบจำลองและการประเมินผล รวมถึงเตรียมผลการตัดสินใจสำหรับกระบวนการปลายทาง ขอบเขตของงานที่เพิ่มจึงครอบคลุมการออกแบบนโยบาย การค้นหาพารามิเตอร์ การทดสอบ และการส่งออกผลรายคู่ ส่วนผลเชิงตัวเลขจากการเปรียบเทียบนโยบายควรนำเสนอในบทผลการทดลองแยกจากวิธีดำเนินงานนี้

3.6.1 เหตุผลและขอบเขตของการพัฒนาเพิ่มเติม

ในระบบเดิม แบบจำลองให้คะแนนว่าคู่โปรไฟล์มีแนวโน้มเป็นบุคคลเดียวกันมากน้อยเพียงใด จากนั้นจึงใช้เกณฑ์สองระดับแบ่งคำตัดสินเป็น MATCH, REVIEW และ NO_MATCH วิธีนี้ทำให้ระบบมีทางเลือกสำหรับคู่ที่ยังไม่แน่ชัด อย่างไรก็ตาม การกำหนดเกณฑ์ด้วยค่าคงที่อาจยังไม่สอดคล้องกับสัดส่วนข้อมูล ความผิดพลาด และจำนวนคู่ที่เจ้าหน้าที่ต้องตรวจสอบในแต่ละชุดข้อมูล

ตัวอย่างเช่น การลดเกณฑ์ MATCH อาจทำให้ระบบเชื่อมโยงคู่ที่ถูกต้องได้มากขึ้น แต่ก็อาจรวมคนละคนเข้าด้วยกันมากขึ้นด้วย ในทางกลับกัน การเพิ่มเกณฑ์อาจลดการรวมผิดแต่ทำให้คู่จำนวนมากค้างอยู่ใน REVIEW การเลือกนโยบายจึงต้องพิจารณาทั้งความถูกต้องของการรวมข้อมูลและภาระงานที่ตามมา ผู้วิจัยใช้ GA ค้นหาชุดพารามิเตอร์ที่ทำให้ต้นทุนการตัดสินใจบนชุด validation ต่ำลง แล้วจึงตรวจสอบผลด้วยตัวชี้วัดด้านความแม่นยำและปริมาณงานร่วมกัน

ในการเปรียบเทียบนโยบาย ผู้วิจัยตรึงคะแนนจากแบบจำลองไว้ เพื่อให้ความแตกต่างของผลลัพธ์อธิบายได้จากการเปลี่ยนชั้นการตัดสินใจ ส่วนการปรับคุณลักษณะหรือฝึกแบบจำลองในสายการทดลองอื่นถือเป็นงานอีกส่วนหนึ่ง น้ำหนักที่ GA ค้นหาในขั้นตอนนี้จึงเป็นน้ำหนักของนโยบายการตัดสินใจ ไม่ใช่น้ำหนักภายในแบบจำลอง Gradient Boosting และไม่ใช่ค่าความสำคัญของคุณลักษณะจากแบบจำลองโดยตรง

3.6.2 ลำดับการพัฒนาจากกฎเดิมสู่นโยบายแบบถ่วงน้ำหนัก

ผู้วิจัยพัฒนานโยบายเป็นลำดับ โดยเริ่มจากกฎที่ใช้คะแนนจากแบบจำลองและเกณฑ์สองระดับเป็นฐานเปรียบเทียบ จากนั้นเพิ่มการใช้ความคล้ายของชื่อช่วยตัดสินคู่ที่อยู่ในช่วง REVIEW และจึงขยายไปสู่นโยบายที่รวมหลักฐานหลายด้านเป็นคะแนนเดียว ตารางที่ 3.18 สรุปความแตกต่างของแนวทางที่ใช้ในการศึกษา

แนวทาง	สิ่งที่ใช้ตัดสินใจ	บทบาทในการทดลอง
เกณฑ์ สอง ระดับ จาก คะแนนโมเดล	คะแนน โมเดลและเกณฑ์ MATCH กับ REVIEW	ใช้ ตรวจ ว่าการ ปรับ เกณฑ์ เพียง อย่างเดียวเพียงพอหรือไม่
GA ที่ใช้ชื่อช่วยตัดสิน	คะแนนโมเดล เกณฑ์สองระดับ และ เกณฑ์ความคล้ายของชื่ออีกสองค่า	เป็น แนวทาง ต่อย อด ระยะ แรก และ ฐานเปรียบเทียบของนโยบายใหม่
GA แบบ ถ่วง น้ำ หนัก ขั้นเดียว	คะแนน โมเดลร่วม กับ หลัก ฐาน ที่ มี ข้อมูล ของ แต่ละ คู่ และ เกณฑ์ สอง ระดับ	ค้นหา น้ำ หนัก และ เกณฑ์ ร่วม กัน แล้วตัดสินจากคะแนนรวมครั้งเดียว

ตารางที่ 3.18 ลำดับการพัฒนานโยบายการตัดสินใจ

นโยบายที่ใช้ชื่อช่วยตัดสินมีโครโมโซม 4 ค่า ได้แก่ เกณฑ์ MATCH เกณฑ์ REVIEW เกณฑ์ความ คล้าย ของ ชื่อ สำหรับ เลื่อน คู่ ขึ้น เป็น MATCH และเกณฑ์สำหรับ ลด คู่ ลง เป็น NO_MATCH โดยเกณฑ์ของชื่อทำงานเฉพาะคู่ที่คะแนนโมเดลอยู่ในช่วง REVIEW เท่านั้น ข้อจำกัดของแนวทางนี้คือ ชื่อถูกกำหนด ให้เป็นหลักฐานหลักตั้งแต่ก่อนเริ่มค้นหา GA จึงเลือกค่าจุดตัดของชื่อได้ แต่ยังไม่ได้เปรียบเทียบว่าหลักฐานชนิดอื่นเหมาะสมกว่าหรือไม่

เพื่อศึกษาข้อจำกัดดังกล่าว ผู้วิจัยเพิ่มการทดลองใช้หลักฐานแต่ละกลุ่มเป็นตัวช่วยตัดสินและต่อยอดเป็นนโยบายแบบถ่วงน้ำหนักขั้นเดียว (One-Stage Weighted Policy) ซึ่งรวมคะแนนโมเดลและหลักฐานที่มีอยู่ก่อนเปรียบเทียบกับเกณฑ์ MATCH และ REVIEW แนวทางนี้ไม่มีเกณฑ์เลื่อนขึ้นและลดลงของชื่อซ้อนอยู่ในช่วง REVIEW อีกชั้นหนึ่ง แต่ยังเปิดให้ GA เลือกน้ำหนักของชื่อได้ตามผลบน validation

3.6.3 การเตรียมข้อมูลสำหรับชั้นการตัดสินใจ

ข้อมูลสำหรับนโยบายต้องอ้างอิงคู่เดียวกับที่ระบบให้คะแนนไว้จริง ผู้วิจัยจึงจัดเตรียมตารางคุณลักษณะสำหรับการตัดสินใจ โดยเก็บรหัสโปรไฟล์ทั้งสองฝั่ง คะแนนโมเดล กลุ่มข้อมูลที่ใช้ประเมิน ค่าความจริงสำหรับคำนวณผล และหลักฐานแต่ละด้านไว้ด้วยกัน พร้อมตัวบ่งชี้ว่าหลักฐานด้านนั้นใช้งานได้หรือไม่ การมีรหัสคู่ช่วยตรวจสอบว่าคะแนนและคุณลักษณะไม่ได้ถูกนำไปจับกับคู่ผิดระหว่างการประมวลผลแบบแบ่งส่วน

โครงสร้างนโยบายกำหนดช่องข้อมูลไว้ 8 ช่อง ได้แก่ คะแนนโมเดล ชื่อ ประวัติย่อ ลิงก์ตำแหน่งที่อยู่ สัญญาณทางสังคม ภาพ และรูปแบบการเขียน ดังตารางที่ 3.19 ค่าหลักฐาน

ถูกจัดให้อยู่ในช่วง 0 ถึง 1 และมีทิศทางเดียวกัน คือค่าสูงแสดงความสอดคล้องมากกว่า ส่วนคุณลักษณะที่เดิมเป็นค่าความแตกต่างต้องแปลงทิศทางก่อนนำมาใช้

กลุ่มข้อมูล	ความหมายในขั้นการตัดสินใจ
คะแนนโมเดล	คะแนนความเป็นบุคคลเดียวกันจากแบบจำลองที่ตรึงไว้
ชื่อ	ความคล้ายของชื่อผู้ใช้หรือชื่อที่แสดงในโปรไฟล์
ประวัติย่อ	ความคล้ายของข้อความหรือความหมายในประวัติย่อ
ลิงก์	ความสอดคล้องของ URL หรือโดเมนที่อ้างอิง
ตำแหน่งที่อยู่	ความคล้ายของข้อมูลสถานที่เมื่อมีข้อมูลที่ใช้งานได้
สัญญาณทางสังคม	ความสอดคล้องของการกล่าวถึงบัญชีหรือแฮชแท็กในคุณลักษณะที่เตรียมไว้
ภาพ	หลักฐานจากภาพหรือข้อความประกอบภาพตามที่มีในตารางคุณลักษณะ
รูปแบบการเขียน	ความสอดคล้องของลักษณะการเขียน เช่น ความยาวและการใช้เครื่องหมาย

ตารางที่ 3.19 กลุ่มข้อมูลที่โครงสร้างนโยบายรองรับ

การรองรับ 8 ช่องไม่ได้หมายความว่าทุกรอบทดลองใช้ข้อมูลได้ครบทั้ง 8 ด้าน ในรอบข้อมูลเต็มวันที่ 14 กันยายน 2569 ตารางคุณลักษณะไม่มีช่อง social และไม่มีรายการ location ที่พร้อมใช้งาน จึงปิดการใช้งานสองด้านนี้และกำหนดน้ำหนักเป็นศูนย์ตั้งแต่เริ่มค้นหา ส่วนกลุ่มที่มีข้อมูลให้ใช้เปิดให้ GA ค้นหาน้ำหนักได้ตามการตั้งค่าของรอบนั้น การเปิดใช้งานในรอบนี้พิจารณาว่ามีหลักฐานด้านนั้นปรากฏใน validation หรือไม่ โดยไม่ได้กำหนดเกณฑ์ขั้นต่ำด้านสัดส่วนความครอบคลุมและจำนวนคู่บวกเพิ่มเติม

ผู้วิจัยตรวจสอบสัดส่วนคู่ที่มีหลักฐานพร้อมใช้งานควบคู่กับน้ำหนักที่ได้ เพื่อแยกกรณี “ไม่มีข้อมูลให้ใช้” ออกจากกรณี “มีข้อมูล แต่ GA เลือกน้ำหนักเป็นศูนย์” นอกจากนี้ หลักฐานกลุ่มภาพอาจรวมสัญญาณจากคำบรรยายภาพด้วย สัดส่วนความพร้อมของกลุ่มภาพจึงไม่ควรตีความเป็นสัดส่วนคู่ที่มีภาพจริงครบทั้งสองฝั่งโดยอัตโนมัติ

3.6.4 การคำนวณคะแนนเมื่อข้อมูลแต่ละคู่มีไม่ครบ

โปรไฟล์แต่ละคู่มีข้อมูลไม่เท่ากัน หากแทนข้อมูลที่ขาดด้วยศูนย์แล้วเฉลี่ยทุกด้านเท่ากัน คู่ที่ไม่มีประวัติย่อหรือภาพอาจได้คะแนนต่ำลงเพียงเพราะไม่มีข้อมูล ผู้วิจัยจึงแยกค่าหลักฐานออกจากตัวบ่งชี้ความพร้อมใช้งาน และปรับสัดส่วนน้ำหนักตามข้อมูลที่มีจริงในแต่ละคู่

กำหนดให้ s_{ik} เป็นค่าหลักฐานช่องที่ k ของคู่ที่ i, m_{ik} เป็นตัวบ่งชี้ความพร้อมใช้งาน โดยมีค่า 1 เมื่อใช้ได้และ 0 เมื่อใช้ไม่ได้ และ w_k เป็นน้ำหนักที่ GA ค้นหา คะแนนรวมของแต่ละคู่คำนวณได้ดังนี้

$$S_i = \frac{\sum_{k=1}^{8} w_k m_{ik} s_{ik}}{\sum_{k=1}^{8} w_k m_{ik}}, \qquad w_k \geq 0, \quad \sum_{k=1}^{8} w_k = 1$$

สูตรนี้ ใช้เมื่อผลรวมน้ำหนักของช่องที่พร้อมใช้งานมากกว่าศูนย์ ตัวอย่างเช่น หากนโยบายให้น้ำหนักคะแนนโมเดล 0.2 ชื่อ 0.5 และประวัติย่อ 0.3 แต่คู่หนึ่งไม่มีประวัติย่อ ระบบจะหารด้วย 0.7 ซึ่งเป็นน้ำหนักรวมของสองด้านที่ยังใช้ได้ แทนการหารด้วย 1 จึงไม่ลดคะแนนเพราะการขาดประวัติย่อเพียงอย่างเดียว หากไม่มีหลักฐานที่มีน้ำหนักให้ใช้เลย ระบบกำหนดคู่นั้นเป็น REVIEW

จากนั้นระบบเปรียบเทียบคะแนนรวมกับเกณฑ์สองระดับเพียงครั้งเดียว ดังนี้

$$D_i = \begin{cases} \text{MATCH}, & S_i \geq t_{\text{match}}, \\ \text{NO_MATCH}, & S_i < t_{\text{review}}, \\ \text{REVIEW}, & t_{\text{review}} \leq S_i < t_{\text{match}}. \end{cases}$$

MATCH หมายถึงคู่ที่ผ่านเกณฑ์สำหรับการเชื่อมโยงอัตโนมัติ REVIEW หมายถึงคู่ที่ยังต้องตรวจสอบเพิ่มเติม และ NO_MATCH หมายถึงคู่ที่ไม่ผ่านเกณฑ์การเชื่อมโยงในรอบนั้น คะแนน S_i เป็นคะแนนรวมของนโยบาย จึงไม่ควรเรียกว่าเป็นความน่าจะเป็นที่ผ่านการปรับเทียบแล้ว เว้นแต่มีการประเมินการปรับเทียบของคะแนนรวมนี้เพิ่มเติม

3.6.5 การกำหนดโครโมโซมและเงื่อนไขการค้นหา

โครโมโซมของนโยบายแบบถ่วงน้ำหนักประกอบด้วย 10 ค่า คือเกณฑ์สองระดับและน้ำหนักอีก 8 ค่า เรียงตามลำดับดังนี้

$$\boldsymbol{g} = [t_m, t_r, w_p, w_n, w_b, w_u, w_l, w_s, w_i, w_y]$$

โดย t_m และ t_r แทนเกณฑ์ MATCH และ REVIEW ส่วนน้ำหนัก w_p ถึง w_y แทนคะแนนโมเดล ชื่อ ประวัติย่อ ลิงก์ ตำแหน่งที่อยู่ สัญญาณทางสังคม ภาพ และรูปแบบการเขียนตามลำดับ

การค้นหาในโค้ดกำหนดให้ $0.50 \leq t_m \leq 0.999$ และ $0.05 \leq t_r \leq t_m$ น้ำหนักทุกค่าต้องไม่ติดลบ และปรับผลรวมให้เท่ากับ 1 หลังสร้างหรือเปลี่ยนแปลงโครโมโซม กลุ่มข้อมูลที่ไม่ได้เปิดใช้งานมีน้ำหนักเป็นศูนย์ตลอดการค้นหา เงื่อนไขเหล่านี้ช่วยให้โครโมโซมทุกชุดนำไปตัดสินใจได้จริงและคงลำดับของเกณฑ์สองระดับไว้เสมอ

3.6.6 การกำหนดต้นทุนสำหรับประเมินนโยบาย

ผู้วิจัยประเมินนโยบายด้วยต้นทุนสามประเภท ได้แก่ การรวมโปรไฟล์ของคนละคนเข้าด้วยกัน การไม่รวมคู่ที่เป็นคนเดียวกัน และการส่งคู่ให้เจ้าหน้าที่ตรวจสอบ โดยใช้สมมติฐานค่าแรง 100 บาทต่อชั่วโมง เวลาตรวจสอบคู่ละ 1 นาที เวลาแก้ไขการรวมผิด 20 นาที และเวลาจัดการคู่ที่ตกหล่น 10 นาที สมมติฐานเหล่านี้เป็นค่าที่กำหนดสำหรับการทดลอง ยังไม่ใช่ต้นทุนที่วัดจากการใช้งาน CRM จริง

เมื่อคิดเฉพาะค่าแรง จะได้ต้นทุนประมาณ 33.33 บาทต่อการรวมผิดหนึ่งคู่ 16.67 บาทต่อคู่ที่ตกหล่นหนึ่งคู่ และ 1.67 บาทต่อการตรวจสอบหนึ่งคู่ เมื่อนำต้นทุนคู่ที่ตกหล่นมาเป็นหน่วยอ้างอิง จะได้อัตราส่วน 2 ต่อ 1 ต่อ 0.1 และกำหนดฟังก์ชันต้นทุนดังนี้

$$C(\boldsymbol{g}) = 2\,FP + FN + 0.1\,R$$

ในสมการนี้ FP คือจำนวนคู่คนละคนที่ถูกตัดสินเป็น MATCH, FN คือจำนวนคู่คนเดียวกันที่ถูกตัดสินเป็น NO_MATCH และ R คือจำนวนคู่ทั้งหมดที่ถูกส่งเป็น REVIEW การนับ FN ในต้นทุนจึงหมายถึงการปฏิเสธคู่ที่ควรเชื่อมโยงโดยตรง ส่วนคู่บวกที่อยู่ใน REVIEW ถูกคิดเป็นต้นทุนการตรวจสอบ และไม่ได้ถูกคิดซ้ำเป็น FN ในสมการเดียวกัน

GA ค้นหานโยบายที่ทำให้ต้นทุนดังกล่าวต่ำที่สุดบน validation การลดต้นทุนอาจมาพร้อมกับการเปลี่ยนแปลงของ precision, recall และจำนวน REVIEW จึงต้องรายงานตัวชี้วัดเหล่านี้ร่วมกัน ไม่สามารถสรุปจากต้นทุนเพียงค่าเดียวว่านโยบายดีกว่าในทุกด้าน และไม่ควรแปลงผลต้นทุนเป็นเงินที่องค์กรประหยัดได้จริงโดยไม่มีข้อมูลการปฏิบัติงานรองรับ

3.6.7 ขั้นตอนการค้นหานโยบายด้วย GA

การค้นหาเริ่มจากสร้างประชากรของชุดพารามิเตอร์หลายชุด แต่ละชุดแทนนโยบายที่เป็นไปได้หนึ่งนโยบาย ผู้วิจัยสุ่มค่าเกณฑ์และน้ำหนักเริ่มต้น แล้วปรับให้อยู่ภายใต้เงื่อนไขที่กำหนด จากนั้นนำทุกนโยบายไปตัดสินคู่ใน validation และคำนวณต้นทุนของแต่ละชุด

ในแต่ละรุ่น ระบบเรียงประชากรตามต้นทุนจากน้อยไปมาก สำหรับตัวค้นหานโยบายแบบถ่วงน้ำหนัก หากต้นทุนเท่ากันจะพิจารณา precision ที่สูงกว่า จำนวน FP ที่น้อยกว่า recall ที่สูงกว่า และจำนวน REVIEW ที่น้อยกว่าตามลำดับ แล้วเก็บนโยบายอันดับต้นไว้เป็นกลุ่มชั้นนำเพื่อใช้สร้างรุ่นถัดไป

การสร้างลูกใช้การเลือกยีนแต่ละตำแหน่งจากพ่อหรือแม่ด้วยโอกาสเท่ากัน จากนั้นกลายพันธุ์แต่ละยีนด้วยความน่าจะเป็น 0.30 โดยเพิ่มค่ารบกวนจากการแจกแจงปกติ ส่วนเบี่ยงเบนมาตรฐานสำหรับเกณฑ์เท่ากับ 0.025 และสำหรับน้ำหนักเท่ากับ 0.05 หลังกลายพันธุ์ระบบตรวจขอบเขตของเกณฑ์ ปัดน้ำหนักของกลุ่มที่ไม่ใช้งาน และปรับผลรวมน้ำหนักอีกครั้ง กระบวนการนี้ทำซ้ำตามจำนวนรุ่นที่กำหนด

การทดลองบนข้อมูลเต็มใช้ประชากร 64 ชุด จำนวน 60 รุ่น เก็บประชากรชั้นนำ 8 ชุด และทำซ้ำด้วยค่า seed 42, 43 และ 44 ทั้งนโยบายคะแนนอย่างเดียว นโยบายใช้ชื่อช่วยตัดสิน และนโยบายแบบถ่วงน้ำหนักใช้ขนาดประชากรและจำนวนรุ่นเท่ากันในรอบนี้ หลังจบการค้นหา ผู้วิจัยเลือกผลของแต่ละนโยบายข้าม seed โดยเรียงตามต้นทุน FP, FN, REVIEW และ seed ตามลำดับ พร้อมเก็บประวัติการค้นหาไว้ตรวจสอบความเปลี่ยนแปลงของคำตอบ

การใช้หลาย seed ช่วยตรวจสอบผลจากการสุ่มเริ่มต้น แต่ไม่ได้รับประกันว่าพบคำตอบที่ดีที่สุดของพื้นที่ค้นหาทั้งหมด นอกจากนี้ ค่าตั้งต้นของการทดลองย่อยอาจต่างจากรอบข้อมูล

เต็ม จึงต้องอ้างอิงการตั้งค่าจากไฟล์ของรอบที่นำมารายงานเสมอ

3.7 การออกแบบการประเมินนโยบายที่พัฒนาเพิ่มเติม

3.7.1 การแบ่งบทบาทของข้อมูลและการตรึงนโยบาย

ผู้วิจัยแยกบทบาทของการฝึกแบบจำลอง การเลือกนโยบาย และการทดสอบออกจากกัน โดย ใช้คะแนนและการแบ่งกลุ่มที่บันทึกไว้ในชุดข้อมูลของแต่ละการทดลอง การค้นหาพารามิเตอร์ของ GA ใช้เฉพาะคู่ validation ส่วน test ใช้ประเมินนโยบายหลังเลือกเสร็จแล้ว การเปรียบเทียบแต่ละนโยบายจึงใช้คู่ข้อมูล คะแนนโมเดล และนิยามต้นทุนเดียวกัน

สำหรับรอบข้อมูลเต็ม มีคู่ทั้งหมด 2,086,245 คู่ แบ่งเป็นคู่ที่ใช้คะแนนโมเดล 2,073,842 คู่ และคู่ในชั้น Exact-First 12,403 คู่ โดย GA ใช้คู่ validation ที่ผ่านการให้คะแนนโมเดลจำนวน 1,010,926 คู่ในการค้นหา หลังเลือกนโยบาย ผู้วิจัยบันทึกค่าเกณฑ์ น้ำหนัก seed รายชื่อกลุ่มข้อมูลที่เปิดใช้งาน และรหัสตรวจสอบไฟล์ต้นทางไว้ก่อนเรียกขั้นตอนประเมิน test

การตรึงนโยบายก่อนทดสอบช่วยป้องกันการนำผล test ในรอบนั้นกลับไปปรับพารามิเตอร์ อย่างไรก็ตาม การมีไฟล์ตรึงนโยบายไม่ได้ยืนยันด้วยตัวเองว่าคะแนนต้นทางทุกชุดถูกสร้างโดยปราศจากข้อมูลรั่วไหล หรือว่าชุดทดสอบไม่เคยถูกใช้ในงานก่อนหน้า การกล่าวถึงการแยกข้อมูลระดับบุคคลหรือการทดสอบกับชุดใหม่จึงต้องอาศัยหลักฐานของกระบวนการต้นทางเพิ่มเติมด้วย

3.7.2 ฐานเปรียบเทียบและขอบเขตการเปลี่ยนแปลง

การประเมินใช้สี่แนวทาง ได้แก่ ผลการตัดสินใจจากระบบเดิม นโยบายคะแนนโมเดลอย่างเดียวที่ค้นหาเกณฑ์สองระดับด้วย GA นโยบายที่ใช้ชื่อช่วยตัดสินด้วยพารามิเตอร์สี่ค่า และนโยบายแบบถ่วงน้ำหนักสิบค่า การมีฐานคะแนนอย่างเดียวช่วยแยกผลของการปรับเกณฑ์ออกจากผลของการเพิ่มหลักฐานหลายด้าน ส่วนนโยบายใช้ชื่อช่วยตัดสินทำให้เห็นผลของการเปลี่ยนรูปแบบกฎจากการตัดสินในช่วง REVIEW มาเป็นคะแนนรวมขั้นเดียว

คู่ที่ผ่านชั้น Exact-First ยังคงคำตัดสิน MATCH ตามระบบเดิมทุกแนวทาง จึงไม่ใช่ส่วนที่ GA ปรับปรุง ความผิดพลาดของชั้นดังกล่าวยังต้องนับเมื่อรายงานผลรวม ขณะเดียวกัน ผลบนคู่ที่ใช้คะแนนโมเดลเพียงอย่างเดียวต้องแยกจากผลที่รวม Exact-First แล้ว เพื่อไม่ให้ความแม่นยำของกฎเดิมถูกตีความเป็นผลของ GA ทั้งหมด

3.7.3 ตัวชี้วัดและการอ่านผลลัพธ์สามทาง

ผู้วิจัยรายงานต้นทุน จำนวน FP จำนวน FN จำนวน REVIEW, precision, recall และ F1 ร่วมกัน โดย precision ของการรวมอัตโนมัติคำนวณจากคู่บวกที่เป็น MATCH หารด้วยคู่ทั้งหมดที่เป็น MATCH ส่วน recall คำนวณจากคู่บวกที่เป็น MATCH หารด้วยคู่บวกทั้งหมดในขอบเขตที่กำลังประเมิน

$$\text{Precision} = \frac{TP}{TP + FP}, \qquad \text{Recall} = \frac{TP}{N_+}, \qquad F1 = \frac{2\,\text{Precision}\,\text{Recall}}{\text{Precision} + \text{Recall}}$$

กำหนดให้ TP เป็นคู่บวกที่ตัดสินเป็น MATCH และ N_+ เป็นคู่บวกทั้งหมดในชุดประเมิน คู่บวกที่อยู่ใน REVIEW ยังไม่ถือว่ารวมสำเร็จ จึงยังอยู่ในตัวหารของ recall ด้วย ดังนั้น ค่า FN ที่แสดงในฟังก์ชันต้นทุนไม่สามารถนำไปแทนตัวหารของ recall เป็น $TP + FN$ ได้ทันที เพราะจะขาดคู่บวกที่รอตรวจสอบ หากตัวหารเป็นศูนย์ต้องระบุว่าไม่มีตัวอย่างรองรับการตีความ แทนการมองค่าที่โปรแกรมเติมให้เป็นหลักฐานของประสิทธิภาพ

การรายงานแยกผลบน validation ผลบน test และผลการนำไปใช้กับคู่ทั้งหมด โดยผลรวมทุกคู่ใช้แสดงปริมาณงานที่นโยบายก่อให้เกิดขึ้นในข้อมูลชุดนั้น และไม่ใช้แทนผลทดสอบบนข้อมูลที่กันไว้ กลุ่มที่บันทึกเป็น drop ต้องแสดงแยกตามสถานะของข้อมูลต้นทาง และไม่เรียกว่าเป็นชุดทดสอบเพิ่มเติม

นอกจากนี้ การประเมินบนคู่ผู้สมัครยังไม่ครอบคลุมคู่จริงที่หลุดไปตั้งแต่ขั้นสร้างคู่ ผู้วิจัยจึงอ่านผลนโยบายร่วมกับความครอบคลุมของ candidate generation ที่อธิบายไว้ในหัวข้อ 3.5 การปรับ GA ไม่สามารถกู้คืนคู่ที่ไม่เคยถูกส่งเข้ามาให้ตัดสินได้ หากไม่ได้ปรับขั้นสร้างคู่ด้วย

3.7.4 การตรวจสอบน้ำหนักและข้อมูลที่ขาดหาย

ผู้วิจัยรายงานน้ำหนักที่ตรึงไว้พร้อมสัดส่วนความพร้อมใช้งานของหลักฐาน เพื่อช่วยอธิบายว่าระบบอาศัยข้อมูลใดในการตัดสินใจ น้ำหนักรวมของนโยบายยังต้องแยกจากน้ำหนักที่มีผลจริงต่อแต่ละคู่ เพราะสูตรคำนวณจะปรับสัดส่วนใหม่เมื่อบางด้านไม่มีข้อมูล ตัวอย่างเช่น น้ำหนักภาพในนโยบายอาจมีค่าน้อย แต่ในคู่ที่ไม่มีหลักฐานชนิดอื่น สัดส่วนที่มีผลจริงอาจแตกต่างจากน้ำหนักรวมมาก

การวิเคราะห์จึงพิจารณาทั้งน้ำหนัก ความครอบคลุม ความเปลี่ยนแปลงระหว่าง seed และข้อผิดพลาดของคู่ที่มีหรือไม่มีหลักฐานแต่ละด้าน การอ้างว่ากลุ่มใดสำคัญที่สุดต่อแบบจำลองยังต้องใช้การวิเคราะห์แบบจำลองโดยตรงเพิ่มเติม ไม่สามารถสรุปจากน้ำหนักนโยบายเพียงอย่างเดียวได้

3.8 ขั้นตอนการดำเนินงานส่วนที่พัฒนาเพิ่มเติม

เพื่อให้เห็นความเชื่อมโยงกับงานเดิม ผู้วิจัยจัดลำดับงานเพิ่มเติมตั้งแต่ตรวจสอบข้อมูลต้นทางจนถึงจัดเตรียมผลสำหรับระบบ CRM เป็น 9 ขั้นตอนดังนี้

ขั้นตอนที่ 1 ทบทวนผลและข้อจำกัดของระบบเดิม

รวบรวมคะแนนรายคู่ คำตัดสินเดิม และผลประเมินของกระบวนการ Exact-First ร่วมกับเกณฑ์สองระดับ ตรวจสอบจำนวนคู่ที่รวมผิด คู่ที่ปฏิเสธผิด และคู่ที่รอตรวจสอบ เพื่อกำหนดว่าการพัฒนาครั้งนี้จะปรับวิธีตัดสินใจในส่วนใด ผลที่ต้องได้คือฐานเปรียบเทียบที่มีขอบเขตและนิยามตัวชี้วัดตรงกัน

ขั้นตอนที่ 2 จัดเตรียมคู่ข้อมูลและตรวจความถูกต้อง

แยกคู่ Exact-First ออกจากคู่ที่ใช้คะแนนโมเดล ตรวจรหัสคู่ซ้ำ จำนวนแถว และรหัสตรวจสอบไฟล์ต้นทาง จากนั้นจัดคู่ validation และ test ตามข้อมูลการแบ่งกลุ่มที่บันทึกไว้ ขั้นตอนนี้ช่วยให้เปรียบเทียบทุกนโยบายกับประชากรเดียวกัน และติดตามได้ว่าผลที่รายงานมาจากข้อมูลรุ่นใด

ขั้นตอนที่ 3 สร้างหลักฐานสำหรับการตัดสินใจ

เชื่อมข้อมูลคู่กับคุณลักษณะชื่อ ประวัติย่อ ลิงก์ ตำแหน่งที่อยู่ สัญญาณทางสังคม ภาพ และรูปแบบการเขียนตามที่มีจริง จัดทิศทางคะแนนให้สอดคล้องกัน และสร้างตัวบ่งชี้ความพร้อมใช้งานแยกจากค่าคะแนน สำหรับข้อมูลจำนวนมากให้ประมวลผลเป็นส่วนย่อย และตรวจรหัสคู่ทุกส่วนก่อนรวมผล

ขั้นตอนที่ 4 ตรวจความครอบคลุมและกำหนดกลุ่มที่ใช้งาน

นับจำนวนและสัดส่วนคู่ที่ใช้หลักฐานแต่ละด้านได้ ตรวจกรณีข้อมูลหายหรือไม่มีช่องข้อมูล และกำหนดรายชื่อกลุ่มที่เปิดให้ GA ค้นหาน้ำหนักจาก validation สำหรับรอบข้อมูลเต็ม ปิด location และ social ตามสภาพข้อมูลจริง พร้อมบันทึกเหตุผล เพื่อไม่ตีความการไม่มีข้อมูลเป็นผลเชิงลบของหลักฐานด้านนั้น

ขั้นตอนที่ 5 กำหนดนโยบายเปรียบเทียบและต้นทุน

เตรียมนโยบายคะแนนอย่างเดียว นโยบายใช้ชื่อช่วยตัดสิน และนโยบายแบบถ่วงน้ำหนัก กำหนดต้นทุนเป็น $2FP + FN + 0.1R$ เหมือนกันทุกแนวทาง และระบุให้ชัดว่าคู่บวกใน

REVIEW คิดเป็นงานตรวจสอบ การกำหนดวิธีนับก่อนเริ่มค้นหาช่วยลดความคลาดเคลื่อนในการเปรียบเทียบผล

ขั้นตอนที่ 6 ค้นหาพารามิเตอร์บน validation

ใช้ GA ค้นหาค่าเกณฑ์และน้ำหนักตามโครงสร้างของแต่ละนโยบาย ทำซ้ำด้วย seed ที่กำหนด และบันทึกต้นทุนกับพารามิเตอร์ระหว่างการค้นหา เปรียบเทียบผลจากการตั้งค่าของรอบเดียวกัน แล้วเลือกชุดที่ดีที่สุดตามลำดับเกณฑ์ที่กำหนดไว้ โดยยังไม่นำผล test มาใช้เลือก

ขั้นตอนที่ 7 บันทึกและตรึงนโยบายก่อนทดสอบ

จัดเก็บเกณฑ์ น้ำหนัก seed การตั้งค่า GA กลุ่มข้อมูลที่เปิดใช้งาน และรหัสตรวจสอบไฟล์ต้นทางลงในไฟล์นโยบายที่ตรึงไว้ ขั้นตอนนี้ทำให้ย้อนตรวจได้ว่าชุดพารามิเตอร์ที่ใช้ประเมิน test เป็นชุดเดียวกับที่เลือกจาก validation และสามารถนำกลับมาใช้ตัดสินข้อมูลได้ซ้ำ

ขั้นตอนที่ 8 ประเมิน test และนำไปตัดสินคู่ทั้งหมด

นำพารามิเตอร์ที่ตรึงไว้ไปประเมิน test โดยไม่ปรับค่าเพิ่มเติม จากนั้นคำนวณคำตัดสินสำหรับคู่ทั้งหมดโดยคง Exact-First ตามเดิม และส่งออกผลแยกตามนโยบาย รายงานผล validation, test, drop และภาพรวมแยกกัน เพื่อให้เห็นทั้งคุณภาพในขอบเขตทดสอบและปริมาณงานที่เกิดเมื่อใช้กับข้อมูลทั้งหมด

ขั้นตอนที่ 9 วิเคราะห์ข้อผิดพลาดและเตรียมผลส่งต่อ CRM

ตรวจคู่ที่ตัดสินต่างจากระบบเดิม โดยเฉพาะคู่ที่เปลี่ยนจาก REVIEW เป็น MATCH หรือ NO_MATCH เพื่ออธิบายว่าภาระตรวจสอบที่ลดลงสัมพันธ์กับความผิดพลาดอย่างไร จัดเก็บรหัสคู่ คะแนน คำตัดสิน และรุ่นนโยบายสำหรับส่งต่อกระบวนการรวมโปรไฟล์หรือคิวตรวจสอบ ผลส่งออกนี้เป็นหลักฐานของการประมวลผลในโครงงาน ยังไม่ใช่หลักฐานว่าเจ้าหน้าที่ได้ตรวจครบทุกคู่ หรือระบบ CRM ใช้งานจริงและเกิดผลประหยัดตามสมมติฐานแล้ว

ช่วงดำเนินงาน	ผลงานที่จัดเก็บเพื่อตรวจสอบย้อนกลับ
เตรียมข้อมูล	ตารางหลักฐานรายคู่ ตัวบ่งชี้ความพร้อมใช้งาน และข้อมูลตรวจสอบแหล่งที่มา
ค้นหานโยบาย	ผล validation ของแต่ละ seed และประวัติการค้นหา GA
ตรึงนโยบาย	เกณฑ์ น้ำหนัก การตั้งค่า และไฟล์นโยบายก่อนประเมิน test
ประเมินและส่งออก	ตาราง ตัวชี้วัด แยกกลุ่มข้อมูล และคะแนนกับคำตัดสินรายคู่ของแต่ละนโยบาย

ตารางที่ 3.20 ผลงานจากขั้นตอนการพัฒนานโยบายเพิ่มเติม

การดำเนินงานส่วนนี้ทำให้กระบวนการเดิมมีขั้นตอนเลือกนโยบายที่ตรวจสอบย้อนกลับได้ ตั้งแต่หลักฐานที่ใช้ ค่าพารามิเตอร์ที่เลือก ไปจนถึงผลกระทบต่อการรวมข้อมูลและคิวตรวจสอบ โดยยังรักษาความเชื่อมโยงกับการเตรียมข้อมูล การสร้างคู่ และการให้คะแนนที่ได้พัฒนาไว้ก่อนหน้า