การพัฒนาแบบจำลองสำหรับการเชื่อมโยงข้อมูลจากแหล่งต่าง ๆ ของลูกค้าเข้าด้วยกันเพื่อสร้างเป็นคุณลักษณะของลูกค้าคนเดียว และกำหนดคะแนนแก่ลูกค้าเป้าหมายเพื่อใช้สำหรับระบบบริหารลูกค้าสัมพันธ์แบบอัจฉริยะ

DEVELOPMENT OF IDENTITY RESOLUTION AND LEAD SCORING MODELS FOR AGENTIC CRM PLATFORM

โดย

วิมลสิริ ปานมา

ถาวรีย์ ขันสาคร

VIMOLSIRI PANMA

THAWAREE KHANSAKORN

ปริญญานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรวิทยาศาสตรบัณฑิต

สาขาวิชาวิทยาการข้อมูลและการวิเคราะห์เชิงธุรกิจ

คณะเทคโนโลยีสารสนเทศ

สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

ภาคเรียนที่ 2 ปีการศึกษา 2568

การพัฒนาแบบจำลองสำหรับการเชื่อมโยงข้อมูลจากแหล่งต่าง ๆ ของลูกค้าเข้าด้วยกันเพื่อสร้างเป็นคุณลักษณะของลูกค้าคนเดียว และกำหนดคะแนนแก่ลูกค้าเป้าหมายเพื่อใช้สำหรับระบบบริหารลูกค้าสัมพันธ์แบบอัจฉริยะ

DEVELOPMENT OF IDENTITY RESOLUTION AND LEAD SCORING MODELS FOR AGENTIC CRM PLATFORM

โดย

วิมลสิริ ปานมา

ถาวรีย์ ขันสาคร

อาจารย์ที่ปรึกษา

ดร.ปาณิตา ธูสรานนท์

อ.เฉลิมพล ศิริกายน

ปริญญานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรวิทยาศาสตรบัณฑิต

สาขาวิชาวิทยาการข้อมูลและการวิเคราะห์เชิงธุรกิจ

คณะเทคโนโลยีสารสนเทศ

สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

ภาคเรียนที่ 2 ปีการศึกษา 2568

DEVELOPMENT OF IDENTITY RESOLUTION AND LEAD SCORING MODELS FOR AGENTIC CRM PLATFORM

VIMOLSIRI PANMA

THAWAREE KHANSAKORN

A PROJECT SUBMITTED IN PARTIAL FULFILLMENT

OF THE REQUIREMENT FOR THE DEGREE OF

BACHELOR OF SCIENCE PROGRAM IN DATA SCIENCE AND BUSINESS ANALYTICS

SCHOOL OF INFORMATION TECHNOLOGY

KING MONGKUT'S INSTITUTE OF TECHNOLOGY LADKRABANG

2/2025

COPYRIGHT 2025

SCHOOL OF INFORMATION TECHNOLOGY

KING MONGKUT'S INSTITUTE OF TECHNOLOGY LADKRABANG

ใบรับรองปริญญานิพนธ์ ประจำปีการศึกษา 2568

คณะเทคโนโลยีสารสนเทศ

สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

เรื่อง การพัฒนาแบบจำลองสำหรับการเชื่อมโยงข้อมูลจากแหล่งต่าง ๆ ของลูกค้าเข้าด้วยกันเพื่อสร้างเป็นคุณลักษณะของลูกค้าคนเดียว และกำหนดคะแนนแก่ลูกค้าเป้าหมายเพื่อใช้สำหรับระบบบริหารลูกค้าสัมพันธ์แบบอัจฉริยะ

DEVELOPMENT OF IDENTITY RESOLUTION AND LEAD SCORING MODELS FOR AGENTIC CRM PLATFORM

ผู้จัดทำ

1. นางสาววิมลสิริ ปานมา รหัสนักศึกษา 66070187
2. นางสาวถาวรีย์ ขันสาคร รหัสนักศึกษา 66070260

.....อาจารย์ที่ปรึกษา

(.....)

.....อาจารย์ที่ปรึกษาร่วม

(.....)

ใบรับรองโครงงาน (PROJECT)

เรื่อง

การพัฒนาแบบจำลองสำหรับการเชื่อมโยงข้อมูลจากแหล่งต่าง ๆ ของลูกค้าเข้าด้วยกันเพื่อสร้างเป็นคุณลักษณะของลูกค้าคนเดียว และกำหนดคะแนนแก่ลูกค้าเป้าหมายเพื่อใช้สำหรับระบบบริหารลูกค้าสัมพันธ์แบบอัจฉริยะ

DEVELOPMENT OF IDENTITY RESOLUTION AND LEAD SCORING MODELS FOR AGENTIC CRM PLATFORM

นางสาววิมลสิริ ปานมา รหัสนักศึกษา 66070187

นางสาวถาวรีย์ ขันสาคร รหัสนักศึกษา 66070260

ขอรับรองว่ารายงานฉบับนี้ ข้าพเจ้าไม่ได้คัดลอกมาจากที่ใด

รายงานฉบับนี้ได้รับการตรวจสอบและอนุมัติให้เป็นส่วนหนึ่งของ

การศึกษาวิชาโครงงาน หลักสูตรวิทยาศาสตรบัณฑิต (สาขาวิชาวิทยาการข้อมูลและการวิเคราะห์เชิงธุรกิจ)

ภาคเรียนที่ 2 ปีการศึกษา 2568

.....

(นางสาววิมลสิริ ปานมา)

.....

(นางสาวถาวรีย์ ขันสาคร)

หัวข้อโครงงาน	การพัฒนาแบบจำลองสำหรับการเชื่อมโยงข้อมูลจากแหล่งต่าง ๆ ของลูกค้าเข้าด้วยกันเพื่อสร้างเป็นคุณลักษณะของลูกค้าคนเดียว และกำหนดคะแนนแก่ลูกค้าเป้าหมายเพื่อใช้สำหรับระบบบริหารลูกค้าสัมพันธ์แบบอัจฉริยะ
นักศึกษา	นางสาววิมลสิริ ปานมา นางสาวถาวรีย์ ขันสาคร
ปริญญา	วิทยาศาสตรบัณฑิต
สาขาวิชา	วิทยาการข้อมูลและการวิเคราะห์เชิงธุรกิจ
ปีการศึกษา	2568
อาจารย์ที่ปรึกษา	ดร.ปาณิตา ธูสรานนท์ , อ.เฉลิมพล ศิริกายน

บทคัดย่อ

ในปัจจุบันองค์กรมักประสบปัญหาข้อมูลลูกค้ากระจัดกระจายอยู่ตามแพลตฟอร์มต่าง ๆ ทำให้ไม่สามารถมองเห็นภาพรวมของลูกค้าได้ชัดเจน ส่งผลให้การวิเคราะห์ Customer Journey ขาดความต่อเนื่องและทีมงานต้องเสียเวลาในการรวบรวมข้อมูลด้วยตนเอง โครงการนี้จึงมุ่งเน้นพัฒนาระบบส่วนหนึ่งของระบบ Agentic CRM ที่ทำหน้าที่เป็นเสมือนศูนย์กลางอัจฉริยะ โดยการรวม Lead จากทุกแหล่งข้อมูลให้เป็นโปรไฟล์ลูกค้าเดียวกันโดยอัตโนมัติ และใช้ AI/ML ตรวจจับความสัมพันธ์ของข้อมูล ผ่านกระบวนการ Identity Resolution เพื่อให้ได้ภาพรวมลูกค้าที่ชัดเจน ระบบนี้จะช่วยให้ทีมขายและการตลาดสามารถเข้าถึงข้อมูลเชิงลึกได้ทันที ซึ่งรวมถึงการวิเคราะห์ Customer Journey และแนะนำ Script เพื่อเพิ่มขีดความสามารถในการแข่งขันและปิดการขายได้อย่างมีประสิทธิภาพ

Project	DEVELOPMENT OF IDENTITY RESOLUTION AND LEAD SCORING MODELS FOR AGENTIC CRM PLATFORM	
Student	Miss Vimolsiri Panma	Student ID 66070187
	Miss Thawaree Khansakorn	Student ID 66070260
Degree	Bachelor of Science	
Program	Data Science and Business Analytics	
Academic Year	2025	
Advisor	Dr. Panita Thusaranon, Mr. Chaloemphon Sirikayon	

ABSTRACT

Nowadays, organizations often face the problem of customer data being scattered across platforms, making it impossible to clearly see the customer's overview. As a result, the Customer Journey analysis lacks continuity and the team has to waste time collecting data manually. This project focuses on developing a system part of the system. Agentic CRM acts as a virtual hub of intelligence by automatically integrating leads from all data sources into the same customer profile and using AI/ML to detect the relationship of the data through the Identity Resolution process to provide a clear customer overview. This system will allow sales and marketing teams to access. Immediate insights, including Customer Journey analysis and Script introduction to increase competitiveness and effectively close sales.

กิตติกรรมประกาศ

การทำโครงงานเรื่อง การพัฒนาแบบจำลองสำหรับการเชื่อมโยงข้อมูลจากแหล่งต่าง ๆ ของลูกค้าเข้าด้วยกันเพื่อสร้างเป็นคุณลักษณะของลูกค้าคนเดียว และกำหนดคะแนนแก่ลูกค้าเป้าหมายเพื่อใช้สำหรับระบบบริหารลูกค้าสัมพันธ์แบบอัจฉริยะ และรายงานวิจัยฉบับนี้สามารถสำเร็จลุล่วงด้วยดี เนื่องจากได้รับความอนุเคราะห์และสนับสนุนเป็นอย่างดียิ่งจาก ดร.ปาณิตา ธูสรานนท์ และ อ.เฉลิมพล ศิริกายน ที่ให้ความกรุณาอย่างสูงในการให้คำแนะนำ คำปรึกษา และให้ความรู้ในการทำวิจัย การตรวจทาน แก้ไขข้อบกพร่องต่าง ๆ จนการทำโครงงาน และการเขียนรายงานวิจัยจนสำเร็จลุล่วงด้วยดี

ขอขอบคุณเพื่อนร่วมงานที่อำนวยความสะดวก และช่วยเหลือในด้านต่าง ๆ ทั้งการศึกษา หาข้อมูล การลงมือทำโครงงาน และการเขียนรายงานวิจัยฉบับนี้จนสำเร็จลุล่วงด้วยดี

สุดท้ายนี้คณะผู้จัดทำหวังว่าวิจัยฉบับนี้จะสามารถเป็นประโยชน์สำหรับหน่วยงานที่เกี่ยวข้องและผู้ที่สนใจศึกษาต่อไป

ชื่อ วิมลสิริ นามสกุล ปานมา

ชื่อ ถาวรีย์ นามสกุล ขันสาคร

สารบัญ

หน้า

บทคัดย่อ I

ABSTRACT II

กิตติกรรมประกาศ III

สารบัญ IV

สารบัญตาราง VI

สารบัญรูป VIII

บทที่ 1 1

1.1 ที่มาและความสำคัญ 1

1.2 วัตถุประสงค์ 1

1.3 วิธีการดำเนินงาน 2

1.4 ขอบเขตของงาน 3

1.5 ประโยชน์ที่คาดว่าจะได้รับ 3

1.6 แผนการดำเนินงาน 4

บทที่ 2 เอกสารและงานที่เกี่ยวข้อง 5

2.1 แนวคิดที่เกี่ยวข้อง 5

2.2 ทฤษฎีที่เกี่ยวข้อง 7

2.3 สถาปัตยกรรมระบบที่เกี่ยวข้อง 10

2.4 งานวิจัยที่เกี่ยวข้อง 11

บทที่ 3 วิธีการดำเนินวิจัย 15

3.1 การทำความเข้าใจธุรกิจ (Business Understanding) 16

3.2 การทำความเข้าใจข้อมูล (Data Understanding) 19

3.3 การเตรียมข้อมูล (Data Preparation) 24

สารบัญ(ต่อ)

หน้าที่

3.4 การสร้างแบบจำลอง (Modeling) 39

3.5 การประเมินผล (Evaluation) 49

บทที่ 4 ผลการทดลอง 55

4.1 การเตรียมข้อมูล 55

4.2 วิธีวัดประสิทธิภาพ 58

4.3 Candidate-Scoring Model ที่ใช้ก่อน Decision Thresholding 61

4.4 Exact-First ร่วมกับ Calibrated Candidate Scoring สำหรับ Decision Thresholding 70

4.5 ผลลัพธ์ปลายทางของ MATCH, REVIEW และ NO_MATCH สำหรับ CRM 71

4.6 ความสำคัญของคุณลักษณะทั้ง 41 ตัวที่สนับสนุนการตัดสินใจ 76

4.7 สรุปผลของ Project 1 ในขอบเขต Decision Thresholding 78

บทที่ 5 วิเคราะห์และสรุปผล 79

5.1 สรุปผลการดำเนินงาน 79

5.2 ปัญหาและอุปสรรคในการดำเนินงาน 84

5.3 ข้อจำกัดของงานวิจัย 85

5.4 ข้อเสนอแนะสำหรับการทำวิจัยในอนาคต 86

บรรณานุกรม 88

สารบัญตาราง

ตารางที่ **หน้า**

ตารางที่ 1.1 แผนการดำเนินงาน 4
ตารางที่ 2.1 เปรียบเทียบ Similarity Measures ที่ใช้ในงาน Identity Resolution 8
ตารางที่ 2.2 สรุปงานวิจัยที่เกี่ยวข้องกับโครงงาน 13
ตารางที่ 3.1 จำนวนข้อมูลแยกตามแพลตฟอร์มในชุดข้อมูลมาตรฐานหลัก 20
ตารางที่ 3.2 ฟิลด์อ้างอิงหลักและบทบาทในการใช้งานจริงของระบบ 20
ตารางที่ 3.3 ตัวอย่างการแปลงข้อมูลหลักในขั้นทำความสะอาดและปรับมาตรฐาน 25
ตารางที่ 3.4 ตัวอย่างการสร้างฟิลด์สนับสนุนจากข้อมูลบริบท 27
ตารางที่ 3.5 โครงสร้างชุดคู่ข้อมูลสำหรับการฝึกแบบจำลอง 29
ตารางที่ 3.6 ขนาดของชุดข้อมูลที่ได้หลังแบ่ง train, validation และ test 31
ตารางที่ 3.7 ขนาดของ merged feature matrices ใน stage 9 38
ตารางที่ 3.8 สายการทดลองหลักในขั้น Modeling 40
ตารางที่ 3.9 ชุดการทดลองใน multimodal suite 41
ตารางที่ 3.10 สรุปเกณฑ์ที่ใช้คัดเลือกแบบจำลองในขั้น Modeling 41
ตารางที่ 3.11 ระดับการทดลองในสาย Multimodal Suite 45
ตารางที่ 3.12 สรุปค่าตั้งต้นไฮเปอร์พารามิเตอร์ของแบบจำลองหลักในขั้นตอน Modeling 46
ตารางที่ 3.13 สรุปผลเชิงตัวเลขและการคัดเลือกแบบจำลองในแต่ละสายการทดลอง 48
ตารางที่ 3.14 สรุประดับการประเมินผลและตัวชี้วัดหลักที่ใช้ในงานวิจัย 51
ตารางที่ 3.15 กรอบการประเมินขั้น Retrieval และ Candidate Generation 52
ตารางที่ 3.16 กรอบการประเมินแบบจำลองในสายการทดลองหลัก 53
ตารางที่ 3.17 กรอบการประเมินผลระดับ Calibration และ Production Workflow 54
ตารางที่ 4.1 จำนวน valid profiles แยกตามแพลตฟอร์มที่ใช้จริง 56
ตารางที่ 4.2 ผลของขั้นเตรียม candidate set ก่อนเข้าสู่ candidate scoring 57
ตารางที่ 4.3 โครงสร้างของ supervised split สำหรับ main run 57
ตารางที่ 4.4 ผล validation leaderboard ภายใน main run 63
ตารางที่ 4.5 ผลเปรียบเทียบ candidate-scoring configurations ที่ใช้เลือก main run 64
ตารางที่ 4.6 Confusion matrix เปรียบเทียบ candidate-scoring configurations บน test split 65
ตารางที่ 4.7 ผลของ main run บน test split ก่อนเข้าสู่ production thresholding 66
ตารางที่ 4.8 Retrieval funnel ของ Project 1 ก่อนเข้าสู่การตัดสินใจปลายทาง 71
ตารางที่ 4.9 Operating point ที่ใช้จริงในขั้น decision thresholding 72

สารบัญตาราง

ตารางที่ **หน้า**

ตารางที่ 4.10 คุณภาพของแต่ละ tier ที่เกี่ยวข้องกับการตัดสินใจปลายทาง 73
ตารางที่ 4.11 สรุป pattern ของข้อผิดพลาดจากตัวอย่าง `fp_top.csv` และ `fn_top.csv` ... 75
ตารางที่ 4.12 คุณลักษณะที่สำคัญสูงสุดของ main run 77
ตารางที่ 5.1 สรุปเปรียบเทียบประสิทธิภาพจากทุกสายการทดลอง 81
ตารางที่ 5.2 สรุปผลระดับ Production 82

สารบัญรูป

รูปที่ **หน้า**

รูปที่ 2.1 สถาปัตยกรรมระบบ LINKSOCIAL สำหรับการเชื่อมโยงโปรไฟล์ข้ามแพลตฟอร์ม 10
รูปที่ 2.2 สถาปัตยกรรม Human-in-the-Loop Data Integration 11
รูปที่ 2.3 ขั้นตอนการทำงานของระบบ Identity Resolution และ Lead Scoring 14
รูปที่ 3.1 แสดงกรอบวิธีวิจัยที่ใช้เป็นโครงหลักของการพัฒนาระบบเชื่อมโยงอัตลักษณ์ลูกค้าและการให้คะแนนลูกค้าเป้าหมายในงานวิจัยนี้ 15
รูปที่ 3.2 ซึ่งแสดงภาพรวมของระบบในเชิงธุรกิจและเชิงเทคนิคพร้อมกัน โดยให้เห็นเส้นทางข้อมูลจากโปรไฟล์ต้นทาง การคัด candidate pairs การให้คะแนน การตัดสินใจ การรวมเอนทิตีและการสร้างคะแนนลูกค้า เพื่อให้ผู้อ่านเห็นตั้งแต่ต้นว่างานนี้ไม่ได้จบที่การทำนายคู่ข้อมูล แต่ไปถึงการใช้งานจริงในระบบปลายทาง 17
รูปที่ 3.3 จำนวนข้อมูลที่ไม่เป็นค่าว่างของฟิลด์สำคัญในชุดข้อมูล LinkSocial 22
รูปที่ 3.4 แสดงการไหลของข้อมูลจากแหล่งข้อมูลดิบไปสู่ชุดข้อมูลมาตรฐาน 23
รูปที่ 3.5 เพื่อแสดงความสัมพันธ์เชิงคีย์ของข้อมูลในลักษณะ Entity-Relationship Diagram .. 23
รูปที่ 3.6 Pair building pipeline การสร้างชุดคู่ข้อมูลสำหรับการฝึกแบบจำลอง 30
รูปที่ 3.7 ลำดับการลดทอนคอลัมน์และคัดเลือกคุณลักษณะ 49
รูปที่ 3.8 ลำดับขั้น Model Development Pipeline 49
รูปที่ 3.9 ความสัมพันธ์ของสายการทดลองและจุดบรรจบ 55
รูปที่ 3.8 Evaluation Framework: กรอบการประเมินผลของระบบในหลายระดับ 55
รูปที่ 4.1 สรุปผลการเตรียมข้อมูล 58
รูปที่ 4.2 ตัวอย่างโปรไฟล์จาก 3 แพลตฟอร์มหลังผ่าน Standardization 58
รูปที่ 4.3 โครงสร้างของ main-run model pipeline สำหรับ Project 1 62
รูปที่ 4.4 การเปรียบเทียบ model families บน final 41-feature split 63
รูปที่ 4.5 การเปรียบเทียบ metric ของ candidate-scoring configurations 64
รูปที่ 4.6 Confusion matrices ของ candidate-scoring configurations ทั้ง3แบบบน test split . 65
รูปที่ 4.7 Confusion matrix ของ main run บน test split ที่ threshold = 0.35 66
รูปที่ 4.8 การกระจายของ calibrated scores บน test split แยกตาม Actual MATCH และ Actual NO_MATCH พร้อมเส้นอ้างอิงที่ threshold = 0.35 และเส้น production thresholds ที่ 0.95 และ 0.98 67
รูปที่ 4.9 พฤติกรรมของ Precision Recall และ F1 ของ main run เมื่อเปลี่ยน threshold บน test split แสดงความแตกต่างระหว่าง threshold เชิงจำแนกที่ 0.35 กับ production review threshold ที่ 0.95 68

สารบัญรูป

รูปที่ **หน้าที่**

รูปที่ 4.10 Reliability ของ calibrated probabilities หลังผ่าน Isotonic Regression เปรียบเทียบ validation set และ test set โดยใช้ขนาด marker แทนจำนวนคู่ในแต่ละ probability bin และเส้นตั้งแสดง production thresholds ที่ 0.95 และ 0.98 69
รูปที่ 4.11 คุณภาพการจัดอันดับของ candidate scoring บน full candidate pairs โดยแสดง precision@100 precision@500 precision@1000 และ precision@5000 ร่วมกับค่า Candidate AP และ ROC-AUC 70
รูปที่ 4.12 Retrieval funnel ของ Project 1 แสดงการลด search space จาก all cross-platform pairs ไปสู่ exact-first pairs model candidates final MATCH only และ REVIEW queue 71
รูปที่ 4.13 โครงสร้างของ Project 1 ในขั้น decision thresholding เริ่มจาก exact-first และ blocking ก่อนส่ง candidate pairs เข้าสู่ calibrated candidate scoring แล้วแยกผลลัพธ์เป็น MATCH REVIEW และ NO_MATCH 71
รูปที่ 4.14 ผลของ thresholding ต่อปริมาณงานและคุณภาพการตัดสินใจ แสดงจำนวนคู่ในแต่ละ tier precision ของกลุ่ม auto-merge และ recall contribution 73
รูปที่ 4.15 Production decision matrix ที่ operating point สุดท้าย แสดงความสัมพันธ์ระหว่าง Actual MATCH และ Actual NO_MATCH กับผลการตัดสินใจใน tier MATCH REVIEW และ NO_MATCH 74
รูปที่ 4.16 การวิเคราะห์ข้อผิดพลาดจากตัวอย่าง false positives และ false negatives แสดงการกระจุกตัวตามคู่แพลตฟอร์มและลักษณะของสัญญาณชื่อ ภาพ และ caption ที่เกี่ยวข้องกับความผิดพลาด 75
รูปที่ 4.17 ความสำคัญของคุณลักษณะทั้ง 41 ตัวใน main run แสดงให้เห็นว่า feature กลุ่มชื่อและ username เป็นหลักฐานหลักของระบบ ขณะที่ feature จำนวนหนึ่งมีผลต่อการตัดสินใจต่ำมากหรือเป็นศูนย์ในรอบนี้ 77
รูปที่ 4.18 การรวม feature importance ตามตระกูลหลัก แสดงสัดส่วนของหลักฐานจากชื่อ bio style image-cross-signal และหลักฐานประเภทอื่นที่แบบจำลองใช้จริงใน main run 78
รูปที่ 4.19 Coverage ของข้อมูลภาพใน main run แยกระดับ profile และ test pair แสดงให้เห็นว่าการทดลองในรอบนี้ยังเป็น partial multimodal setting มากกว่า full image-to-image matching 78
รูปที่ 4.20 สรุปเส้นทางการพัฒนาระบบจาก Leakage diagnosis ไปสู่ Final multimodal 79

บทที่ 1

บทนำ

1.1 ที่มาและความสำคัญ

จุดเริ่มต้นของโครงงานนี้เกิดขึ้นจากการศึกษางานวิจัยด้าน cross-platform user identification ซึ่งพบว่าปัญหาหนึ่งที่พบได้บ่อยในข้อมูลโซเชียลมีเดียคือบุคคลคนเดียวกันอาจปรากฏอยู่บนหลายแพลตฟอร์มพร้อมกัน ไม่ว่าจะเป็น Twitter, Instagram หรือ Google+ โดยใช้ชื่อผู้ใช้และรูปโปรไฟล์ที่แตกต่างกัน แม้เนื้อหาที่โพสต์จะบ่งชี้ว่าเป็นบุคคลเดียวกัน แต่การพิสูจน์โดยไม่ต้องตรวจสอบทีละรายการด้วยมือนั้นยังคงเป็นโจทย์ที่ท้าทาย

โครงงานนี้ใช้ Dataset-LinkSocial ที่รวบรวมและเผยแพร่โดย Sharma และ Dyreson [7] ซึ่งประกอบด้วยโปรไฟล์จาก Twitter, Instagram และ Google+ Archive รวม 36,807 โปรไฟล์ ข้อมูลใน dataset นี้มีลักษณะไม่สมบูรณ์โดยธรรมชาติ โดยเฉพาะข้อมูลจาก Google+ ที่ปิดตัวลงในปี 2019 ทำให้ Post ที่ยังเข้าถึงได้ ข้อมูลการมีปฏิสัมพันธ์ และ Metadata บางส่วนมีความไม่ครบถ้วน ซึ่งจริง ๆ แล้วเป็นสถานการณ์ที่สะท้อนความเป็นจริงของงานด้านนี้ ไม่ใช่เพียงข้อจำกัดของ dataset เพียงอย่างเดียว

ในมุมขององค์กร ปัญหาเดียวกันนี้เกิดขึ้นในรูปแบบของ Data Silo เมื่อข้อมูลลูกค้าถูกเก็บแยกกันในระบบหลายระบบ ไม่ว่าจะเป็น Website, แอปพลิเคชัน, Email หรือโซเชียลมีเดีย โดยแต่ละระบบมีรูปแบบข้อมูลและ Identifier ที่แตกต่างกัน ทำให้ไม่สามารถรู้ได้ว่าลูกค้าที่ซื้อสินค้าบน Website กับผู้ใช้ที่แสดงความเห็นใน Instagram เป็นคนเดียวกันหรือไม่ ปัญหานี้ส่งผลโดยตรงต่อคุณภาพของการวิเคราะห์พฤติกรรมลูกค้าและประสิทธิภาพของแคมเปญการตลาด

โครงงานนี้จึงมีเป้าหมายในการสร้าง Proof-of-Concept ของระบบ Identity Resolution โดยนำ Dataset-LinkSocial มาใช้เป็นกรณีศึกษา กระบวนการสกัด Feature ครอบคลุมทั้งมิติข้อความ รูปภาพ และรูปแบบพฤติกรรม แล้วนำไปฝึกแบบจำลอง Ensemble ที่ตัดสินใจว่าโปรไฟล์สองชุดใดเป็นบุคคลเดียวกัน ผล Unified Profile ที่ได้จากกระบวนการนี้ถูกนำไปใช้เป็นข้อมูลตั้งต้นสำหรับแบบจำลอง Lead Scoring เพื่อทดสอบว่าการรวมข้อมูลจากหลายแพลตฟอร์มจะให้การประเมินโอกาส Conversion ที่แม่นยำกว่าการใช้ข้อมูลจากแหล่งเดียวหรือไม่

1.2 วัตถุประสงค์

1. เพื่อพัฒนาระบบที่สามารถรวบรวมรายชื่อลูกค้า จากทุกแหล่งข้อมูลให้อยู่ในรูปแบบโปรไฟล์เดียว เพื่อขจัดปัญหาข้อมูลซ้ำซ้อน

2. เพื่อประยุกต์ใช้เทคโนโลยี AI และ Machine Learning ในการตรวจจับความสัมพันธ์ของข้อมูล และวิเคราะห์เส้นทางของผู้บริโภค
3. เพื่อเป็นส่วนหนึ่งของการสร้างระบบ Agentic CRM ที่ช่วยสนับสนุนการทำงานของทีมขายและการตลาดให้มีความรวดเร็ว แม่นยำ และมีข้อมูลครบถ้วนสำหรับการตัดสินใจ
4. เพื่อให้ระบบ AI สามารถให้คำแนะนำในการติดตามผลและกำหนดกิจกรรม/Script ที่ควรทำ เป็นตัวช่วยให้ทีมขาย-การตลาดทำงานได้รวดเร็ว แม่นยำ และมีข้อมูลครบถ้วน

1.3 วิธีการดำเนินงาน

1. รวบรวมและจัดเตรียมข้อมูล โดยใช้ชุดข้อมูลจาก Dataset-LinkSocial [7] ซึ่งเป็นข้อมูลสาธารณะที่เผยแพร่ผ่าน GitHub เพื่อนำมาใช้เป็นข้อมูลตั้งต้นในการพัฒนาและทดสอบระบบ ก่อนเข้าสู่กระบวนการตรวจสอบคุณภาพและความสมบูรณ์ของข้อมูล
2. ทำความสะอาดและจัดระเบียบข้อมูลให้อยู่ในรูปแบบเป็นอันหนึ่งอันเดียวกัน ที่พร้อมใช้งานสำหรับ AI โดยการรับและจัดเตรียมข้อมูลจำลอง ก่อนจะนำเข้าและการตรวจสอบเบื้องต้น
3. ทำ Data Standardization และ Normalization และจัดเก็บข้อมูลที่ผ่านกระบวนการแล้ว
4. ทำการประยุกต์ใช้ AI/ML เพื่อวิเคราะห์ข้อมูลที่สะอาดแล้วเพื่อสร้างโปรไฟล์ลูกค้าที่สมบูรณ์และเป็น Agentic
    4.1. ทำการสร้าง Feature Set จากข้อมูลทั้งหมดที่มี เช่น Name , Username , Bio และ URL ของ Social Media
    4.2. ทำการพัฒนาแบบจำลองสำหรับจับคู่ข้อมูลลูกค้าที่อาจเป็นบุคคลเดียวกัน โดยที่ระบบจะคำนวณคะแนนความคล้ายกันและแปลงเป็นเปอร์เซ็นต์ความมั่นใจออกมา
    4.3. หากคะแนนความมั่นใจเกิน Threshold ที่กำหนดระบบจะแสดงรายการ Candidate Profiles ที่น่าจะเป็นคนเดียวกันบนหน้าจอ UI พร้อมแสดงข้อมูลเปรียบเทียบแบบ Side-by-side และค่า % ความมั่นใจ และผู้ตัดสินใจเลือก Merge Profile หรือไม่ใช่คนเดียวกัน จากนั้นจะบันทึกผลการตัดสินใจของผู้ใช้ เพื่อนำไปใช้ปรับปรุงแบบจำลอง และบันทึก Audit Log ทุกครั้งที่มีการ Merge
5. นำแบบจำลองที่ได้มาวิเคราะห์พฤติกรรมของลูกค้าที่ถูกรวมโปรไฟล์เข้าด้วยกัน และทำการจัดประเภทลูกค้าว่ากำลังอยู่ช่วงใดของ Funnel
6. คำนวณคะแนนสำหรับลูกค้าแต่ละราย เพื่อหาลูกค้าที่เป็นกลุ่มเป้าหมายโดยอ้างอิงข้อมูลจากหลายแหล่ง เช่น พฤติกรรม Engagement ประวัติการสื่อสาร แหล่งที่มา และความพร้อมซื้อ

7. ประยุกต์ใช้แบบจำลองที่พัฒนาขึ้นมากับข้อมูลสถานะของลูกค้า และการให้คะแนนแก่ลูกค้าเป้าหมายเพื่อแนะนำการดำเนินการที่เหมาะสมที่สุดแก่ทีมขาย

1.4 ขอบเขตของงาน

1. โครงงานใช้ชุดข้อมูลจาก Dataset-LinkSocial [7] ซึ่งเป็นข้อมูลสาธารณะ โดยข้อมูลได้รับการทำความสะอาด (Data Cleaning) และจัดให้อยู่ในรูปแบบมาตรฐาน (Data Preprocessing) ก่อนนำไปใช้กับแบบจำลอง
2. ระบบครอบคลุมการพัฒนาแบบจำลองรวมตัวตนลูกค้า (Identity Resolution) เพื่อระบุว่าโปรไฟล์ใดเป็นบุคคลเดียวกัน และสร้างโปรไฟล์ลูกค้าที่สมบูรณ์และเป็น Agentic
3. ระบบวิเคราะห์พฤติกรรมลูกค้าและจัดประเภทเส้นทางลูกค้า (Customer Journey) ตามขั้นของ Funnel โดยอาศัยข้อมูลจาก Interaction และ Engagement
4. ระบบพัฒนาแบบจำลองให้คะแนนศักยภาพลูกค้า (Lead Scoring) เพื่อประเมินระดับความพร้อมซื้อและจัดลำดับความสำคัญของลูกค้าในระบบต้นแบบ
5. ระบบสามารถแสดง Candidate Profiles ที่มีความเป็นไปได้ว่าเป็นบุคคลเดียวกัน พร้อมเปอร์เซ็นต์ความมั่นใจ และเปิดโอกาสให้ผู้ใช้ตัดสินใจรวมโปรไฟล์หรือแยกเป็นคนละบุคคล โดยมีการบันทึกข้อมูลลงใน Audit Log
6. ระบบแสดงผลการวิเคราะห์ Journey Stage คะแนน Lead Score และคำแนะนำเบื้องต้นสำหรับการติดตามลูกค้า (Recommended Action) เพื่อสาธิตความสามารถของแบบจำลองและระบบ AI
7. ระบบพัฒนาในรูปแบบเว็บต้นแบบ (Web-based Prototype) เพื่อแสดงผลการทำงานของแบบจำลองและส่วนติดต่อผู้ใช้ โดยไม่เชื่อมต่อกับระบบบริหารจัดการความสัมพันธ์ลูกค้า (CRM) จริง

1.5 ประโยชน์ที่คาดว่าจะได้รับ

1. องค์กรมีฐานข้อมูลลูกค้าที่เป็นมาตรฐานเดียวลดความซ้ำซ้อนและความผิดพลาดของข้อมูล
2. ทีมขายและการตลาดสามารถเข้าใจพฤติกรรมลูกค้าผ่าน Customer Journey ที่วิเคราะห์โดย AI นำไปสู่กลยุทธ์ที่แม่นยำขึ้น
3. ลดระยะเวลาในการเตรียมข้อมูล ทำให้ทีมงานโฟกัสกับงานเชิงกลยุทธ์และการดูแลลูกค้าได้เต็มที่

1.6 แผนการดำเนินงาน

ตารางที่ 1.1

การดำเนินงาน	ธันวาคม 2567				มกราคม 2568				กุมภาพันธ์ 2568				มีนาคม 2568			
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
1.การวางแผน																
1.1 กำหนดวัตถุประสงค์และขอบเขต	◄····►															
	◄═══►															
1.2 กำหนดแผนการทำงาน		◄····►														
		◄═══►														
2.การศึกษาและรวบรวมข้อมูล																
2.1 ศึกษาพื้นฐาน Identity Resolution		◄·····►														
		◄═══►														
2.2 ศึกษาเทคนิค String Similarity และ Blocking			◄·····►													
			◄═══►													
2.3 ศึกษา Deep Learning สำหรับ Classification				◄·····►												
				◄═══►												
3.การเตรียมข้อมูล																
3.1 สร้าง Synthetic Dataset (3 แพลตฟอร์ม)					◄·····►											
					◄═══►											
3.2 Blocking และ Entity-Aware Labeling						◄·····►										
						◄═══►										
4.การดำเนินงาน																
4.1 ออกแบบและพัฒนาโมเดล IdentityMLP							◄·····►									
							◄═══►									
4.2 พัฒนา Decision Thresholding และ									◄·····►							
									◄═══►							
5.การทดสอบและประเมินผล																
5.1 ทดสอบโมเดลบน Test Set										◄·····►						
										◄═══►						
5.2 เปรียบเทียบผล Thresholding รูปแบบต่างๆ											◄·····►					
											◄═══►					
5.3 ปรับปรุงโมเดลและ Pipeline												◄·····►				
												◄═══►				
6.สรุปผลและรายงานผล																
6.1 จัดทำรายงานผล													◄·····►			
													◄═══►			
6.2 นำเสนอโครงงาน															◄····►	
															◄═══►	

◄·····► = แผนที่วางไว้ ◄═══► = ผลการดำเนินงานจริง

บทที่ 2

เอกสารและงานวิจัยที่เกี่ยวข้อง

2.1 แนวคิดที่เกี่ยวข้อง

2.1.1 Identity Resolution และ User Identity Linkage

ในโลกของการจัดการข้อมูลลูกค้าผ่านแพลตฟอร์มดิจิทัลหลายช่องทาง ปัญหาพื้นฐานที่องค์กรต้องเผชิญคือการระบุว่าบัญชีหรือระเบียนข้อมูลจากแหล่งต่าง ๆ นั้นเป็นของบุคคลเดียวกันหรือไม่ กระบวนการนี้เรียกว่า Identity Resolution หรือ User Identity Linkage ซึ่งเป็นรากฐานสำคัญของการสร้าง Single Customer View อันเป็นเป้าหมายหลักของระบบบริหารจัดการความสัมพันธ์ลูกค้า (CRM) สมัยใหม่ งานวิจัยในสาขานี้เริ่มเข้มข้นขึ้นตั้งแต่ราวปี 2010 และยังคงพัฒนาต่อเนื่องตามการขยายตัวของแพลตฟอร์มโซเชียลมีเดีย

Halimi และ Ayday [3] ได้ทบทวนเทคนิคและแนวทางสำหรับ User Identity Linkage บนเครือข่ายสังคมออนไลน์อย่างครอบคลุม พบว่าแนวทางหลักแบ่งได้เป็นสองกลุ่ม คือ Profile-based Approach ที่อาศัยข้อมูลโปรไฟล์ เช่น ชื่อ รูปภาพ และข้อมูลประชากร กับ Behavioral-based Approach ที่ใช้รูปแบบการใช้งานและพฤติกรรมออนไลน์เป็นสัญญาณในการระบุตัวตน น่าสังเกตว่างานวิจัยส่วนใหญ่ในกลุ่มนี้ถูกทดสอบบนแพลตฟอร์มที่ยังให้บริการอยู่และมีข้อมูลครบถ้วน

กรณีของโครงงานนี้มีความแตกต่างที่สำคัญตรงนี้ เนื่องจาก Google+ ปิดตัวไปแล้วตั้งแต่ปี 2019 Behavioral Data จากแพลตฟอร์มนั้นจึงไม่สามารถเก็บแบบ Real-time ได้อีกต่อไป แบบจำลองที่ออกแบบสำหรับสถานการณ์นี้จึงต้องพึ่งพา Profile-based Features เป็นหลัก และต้องออกแบบ Threshold Policy ให้ยอมรับความไม่แน่นอนได้สูงกว่าแบบจำลองในสภาพแวดล้อมที่ข้อมูลครบถ้วน ซึ่งนำไปสู่แนวคิด POSSIBLE_MATCH ที่ใช้ในการออกแบบระบบนี้โดยตรง

2.1.2 Behavioral Modeling สำหรับการเชื่อมโยงบัญชีผู้ใช้ข้ามแพลตฟอร์ม

Zafarani และ Liu [2] ได้เสนอแนวทาง Behavioral Modeling ซึ่งสร้างแบบจำลองพฤติกรรมของผู้ใช้จากข้อมูลในแต่ละแพลตฟอร์ม เช่น ความถี่ในการโพสต์ คำศัพท์ที่ใช้บ่อย และช่วงเวลาที่ Active ของแต่ละวัน จากนั้นหาความคล้ายคลึงกันระหว่างแบบจำลองเพื่อตัดสินว่าเป็นบุคคลเดียวกันหรือไม่ ข้อได้เปรียบของแนวทางนี้คือสามารถทำงานได้แม้ข้อมูลโปรไฟล์ไม่ครบถ้วน เพราะพฤติกรรมของผู้ใช้มักมีความสม่ำเสมอข้ามแพลตฟอร์ม

Sharma และ Dyreson [1] ได้นำแนวคิดนี้ไปพัฒนาระบบ LINKSOCIAL ซึ่งผสมผสานทั้ง Profile-based และ Behavioral-based Features เพื่อเพิ่มความแม่นยำในการเชื่อมโยงโปรไฟล์ข้ามแพลตฟอร์ม ผลการทดลองแสดงให้เห็นว่าการรวม Feature จากทั้งสองแหล่งให้ประสิทธิภาพสูงกว่าการใช้แนวทางใดแนวทางหนึ่ง แม้ว่างานวิจัยนี้จะยังทดสอบบนแพลตฟอร์มที่ข้อมูล Active อยู่ แต่หลักการของการรวม Feature ประเภทต่าง ๆ นั้นใช้ได้กับบริบทของ Archive Data ด้วยเช่นกัน

ในกรณีของ Google+ Archive ข้อจำกัดสำคัญคือ Behavioral Data เช่น Engagement Patterns และ Posting Frequency ไม่ครบถ้วนตามที่ควรจะเป็น ดังนั้นโครงงานนี้จึงปรับกลยุทธ์มาเน้น Text Similarity และ Profile Metadata เป็นหลัก พร้อมทั้งนำ Temporal Features ที่ยังเหลืออยู่ใน Archive มาเสริม ซึ่งสอดคล้องกับข้อเสนอแนะของ Zafarani และ Liu ที่ระบุว่าการปรับน้ำหนัก Feature ตามความน่าเชื่อถือของข้อมูลแต่ละแหล่งเป็นสิ่งจำเป็น

2.1.3 Human-in-the-Loop สำหรับ Entity Matching

การจับคู่ระเบียนข้อมูล (Entity Matching) โดยระบบอัตโนมัติย่อมมีข้อจำกัดในกรณีที่ข้อมูลมีความกำกวม (Ambiguous) สูง Doan และคณะ [4] ได้รายงานความท้าทายและบทเรียนสำคัญจากการนำระบบ Human-in-the-Loop Entity Matching ไปใช้งานจริง ได้แก่ การออกแบบ Workflow ที่ลดภาระของผู้ตรวจสอบ การจัดการกับ Noisy Labels และการรักษาความสม่ำเสมอในการตัดสินใจ สิ่งที่น่าสนใจคือบทเรียนเหล่านี้เกิดขึ้นจากระบบที่ใช้งานจริงในระดับ Production ไม่ใช่สภาพแวดล้อมทดลอง

Li และคณะ [5] ได้นำเสนอสถาปัตยกรรม Human-in-the-Loop Data Integration ที่ออกแบบมาเพื่อสมดุลระหว่างคุณภาพและต้นทุน โดยระบบจะใช้ Machine Learning ในการตัดสินใจโดยอัตโนมัติสำหรับกรณีที่มีความมั่นใจสูง และส่งต่อเฉพาะกรณีที่ไม่แน่ใจให้มนุษย์พิจารณา แนวทางนี้ช่วยลดปริมาณงานที่มนุษย์ต้องตรวจสอบได้อย่างมีนัยสำคัญในขณะที่ยังคงรักษาความแม่นยำสูง

แนวคิดนี้เชื่อมโยงโดยตรงกับการออกแบบระบบในโครงงาน ในขั้นตอน Merge Logic ได้กำหนดให้แบบจำลองแบ่ง Match ออกเป็นสามระดับ ได้แก่ MATCH สำหรับกรณีที่ Confidence สูงซึ่งแบบจำลองตัดสินใจได้เอง POSSIBLE_MATCH สำหรับกรณีกำกวมที่ต้องรอการยืนยัน และ NO_MATCH สำหรับกรณีที่ชัดเจนว่าไม่ใช่บุคคลเดียวกัน แนวทางนี้เป็นการนำหลักการ Human-in-the-Loop มาปรับใช้ให้เหมาะสมกับบริบทของ Archive Data ที่มีข้อมูลไม่สมบูรณ์

2.1.4 Lead Scoring และ Predictive CRM

Lead Scoring เป็นกระบวนการกำหนดคะแนนให้กับลูกค้าเป้าหมาย (Lead) เพื่อประเมินโอกาสในการแปลงเป็นลูกค้าจริง (Conversion) Schafer, Hassan และ Muller [6] ได้ทำการทดสอบเทคนิค Machine Learning หลายแบบสำหรับ Predictive Lead Scoring ใน

บริบท B2B Sales ได้แก่ Random Forest, Gradient Boosting Machines (GBM), Logistic Regression และ Neural Networks บนชุดข้อมูลลูกค้า 50,000 ราย

ผลการทดลองของ Schafer และคณะ [6] พบว่า GBM ให้ค่า AUC-ROC สูงสุดที่ 0.87 และที่สำคัญกว่านั้นคือการพิสูจน์ว่า Feature ที่รวมมาจากหลายแหล่งข้อมูล (Multi-source Identity Data) ให้ประสิทธิภาพสูงกว่า Feature จากแหล่งเดียวอย่างมีนัยสำคัญทางสถิติ ซึ่งตรงกับสมมุติฐานหลักที่โครงงานนี้ต้องการทดสอบ

โครงงานนี้จึงมองส่วน Lead Scoring เป็นการทดสอบสมมุติฐานที่ว่า Unified Profile ซึ่งรวมข้อมูลจาก 3 แพลตฟอร์มจะให้ผลการพยากรณ์ที่ดีกว่าการใช้ข้อมูลจากแพลตฟอร์มเดียว ถ้าผลลัพธ์ออกมาสนับสนุนสมมุติฐานนี้ ก็จะเป็นหลักฐานเชิงประจักษ์ว่าขั้นตอน Identity Resolution ก่อนหน้าสร้างมูลค่าที่วัดได้จริง ไม่ใช่แค่การลดความซ้ำซ้อนของข้อมูลเท่านั้น

2.2 ทฤษฎีที่เกี่ยวข้อง

2.2.1 Similarity Measures สำหรับ Record Matching

การคำนวณความคล้ายคลึงระหว่างระเบียนข้อมูลเป็นหัวใจสำคัญของ Identity Resolution Similarity Measures ที่ใช้กันทั่วไปสามารถแบ่งออกเป็นสองกลุ่มหลัก ได้แก่ String-based Similarity เช่น Edit Distance (Levenshtein) ที่นับจำนวนการแก้ไขขั้นต่ำ และ Jaro-Winkler ที่เหมาะสำหรับชื่อบุคคล กับ Token-based Similarity เช่น Jaccard ที่วัด Overlap ของชุด Token และ TF-IDF Cosine ที่คำนึงถึงความสำคัญของคำในบริบท

สูตรคำนวณหลักของแต่ละ Measure มีดังนี้ โดยสมการที่ 2.1 แสดง Edit Distance ที่ใช้คำนวณจำนวนการแก้ไขขั้นต่ำระหว่างสองสตริง โดยที่ δ = 0 หาก s_I = t_j มิฉะนั้น δ = 1:

$$d_{i,j} = \min\left(d_{i-1,j} + 1,\ d_{i,j-1} + 1,\ d_{i-1,j-1} + \delta\right) \tag{2.1}$$

โดยที่

- $d_{i,j}$ หมายถึง จำนวนการแก้ไขขั้นต่ำที่สุดในการแปลงข้อความ
- δ (เดลตา) หมายถึง ค่าเงื่อนไข โดยมีค่าเป็น 0 หากอักขระตัวที่ ของสตริงแรก (s_i) ตรงกับอักขระตัวที่ j ของสตริงที่สอง (t_j) แต่มิฉะนั้น δ จะมีค่าเป็น 1
- $d_{i-1,j} + 1$ หมายถึง ปฏิบัติการลบอักขระ (Deletion)
- $d_{i,j-1} + 1$ หมายถึง ปฏิบัติการแทรกอักขระ (Insertion)
- $d_{i-1,j-1} + \delta$ หมายถึง ปฏิบัติการแทนที่อักขระ (Substitution)

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} \tag{2.2}$$

โดยที่

- $J(A, B)$ หมายถึง ค่าความคล้ายคลึงแบบ Jaccard
- A, B หมายถึง ชุดของโทเค็น (Token) จากข้อความที่ต้องการเปรียบเทียบ
- $|A \cap B|$ หมายถึง ขนาดของอินเตอร์เซกชัน (Intersection) หรือจำนวนโทเค็นที่มีเหมือนกันระหว่างชุดข้อมูลทั้งสอง
- $|A \cup B|$ หมายถึง ขนาดของยูเนียน (Union) หรือจำนวนโทเค็นทั้งหมดเมื่อนำชุดข้อมูลทั้งสองมารวมกัน

$$\cos(A, B) = \frac{A \cdot B}{\|A\| \cdot \|B\|} \tag{2.3}$$

โดยที่

- $\cos(A, B)$ หมายถึง ค่าความคล้ายคลึงโคไซน์ (การวัดมุมระหว่างเวกเตอร์)
- A, B หมายถึง เวกเตอร์ของข้อความ เช่น ค่า TF-IDF
- $A \cdot B$ หมายถึง ผลคูณเชิงสเกลาร์ (Dot Product) ของเวกเตอร์ A และ B
- $\| A \|, \| B \|$ หมายถึง ขนาด (Magnitude) ของเวกเตอร์ A และ B

Halimi และ Ayday [3] ได้ทบทวนการนำ Similarity Measures ต่าง ๆ ไปใช้ในงาน User Identity Linkage พบว่าไม่มี Measure ใดที่ดีที่สุดในทุกสถานการณ์ แต่การรวม Measures หลายแบบ (Ensemble Approach) มักให้ประสิทธิภาพสูงกว่าการใช้ Measure เดียว โดยเฉพาะเมื่อข้อมูลมาจากแพลตฟอร์มที่มีรูปแบบข้อมูลแตกต่างกัน

ตารางที่ 2.1 เปรียบเทียบ Similarity Measures ที่ใช้ในงาน Identity Resolution

Measure	คำอธิบาย	ข้อดี	ข้อจำกัด
Edit Distance	นับจำนวน Insert/Delete/Replace ขั้นต่ำ	ใช้ได้กับข้อความทุกรูปแบบ	ใช้ทรัพยากรสูงสำหรับข้อความยาว O(mn)
Jaro-Winkler	วัดความคล้ายสตริงสั้น ให้น้ำหนักพิเศษกับอักขระต้น	เหมาะสำหรับชื่อบุคคลและรหัสสั้น	ไม่เหมาะกับข้อความยาวหรือหลายคำ
Jaccard	วัด Token Intersection / Union	คำนวณเร็ว ทนต่อการสลับลำดับคำ	ไม่คำนึงถึงความถี่และความสำคัญของคำ
TF-IDF Cosine	มุมระหว่างเวกเตอร์ TF-IDF ของข้อความ	คำนึงถึงความสำคัญของคำในบริบท Corpus	ต้องการ Corpus ขนาดใหญ่เพื่อ IDF ที่แม่นยำ

2.2.2 Machine Learning สำหรับ Classification ใน Lead Scoring

แบบจำลอง Machine Learning ที่นำมาใช้ใน Lead Scoring ส่วนใหญ่เป็นแบบจำลองประเภท Supervised Classification ที่ฝึกด้วยประวัติการแปลงของลูกค้าในอดีต Schafer และคณะ [6] ได้เปรียบเทียบแบบจำลองหลายประเภทและพบว่า Gradient Boosting Machines (GBM) ให้ประสิทธิภาพสูงสุดด้วยค่า AUC-ROC 0.87 โดยมีข้อได้เปรียบสำคัญคือสามารถจัดการ Missing Values และ Imbalanced Class ได้ดีกว่า Logistic Regression ซึ่งพบบ่อยในชุดข้อมูลลูกค้าจริง

สูตรการอัปเดตของ GBM แสดงดังสมการที่ 2.4

$$F_m(x) = F_{m-1}(x) + \eta \cdot h_m(x) \tag{2.4}$$

โดยที่

- $F_m(x)$ หมายถึง แบบจำลองสะสมในรอบที่ m
- $F_{m-1}(x)$หมายถึง แบบจำลองสะสมของรอบก่อนหน้า ($m-1$)
- η (อีตา) หมายถึง อัตราการเรียนรู้ (Learning Rate)
- $h_m(x)$ หมายถึง แบบจำลองการเรียนรู้แบบอ่อน (Weak Learner) เช่น Decision Tree ที่ถูกฝึกด้วยค่าความคลาดเคลื่อน (Residual) ของรอบก่อนหน้า
- $\mathbf{x}$ หมายถึง ข้อมูลนำเข้า (Input Features) ของแบบจำลอง

Feature Importance Analysis ในงานวิจัยของ Schafer และคณะ [6] ยังแสดงให้เห็นว่า Features ที่มาจากการรวมข้อมูลหลายแหล่ง (Merged Identity Features) มี Predictive Power สูงกว่า Features จากแหล่งเดียว ซึ่งเป็นหลักฐานสำคัญที่สนับสนุนการออกแบบระบบ Identity Resolutionก่อนการสร้าง Lead Scoring Model ในโครงงานนี้

2.2.3 Active Learning และ Semi-supervised Learning

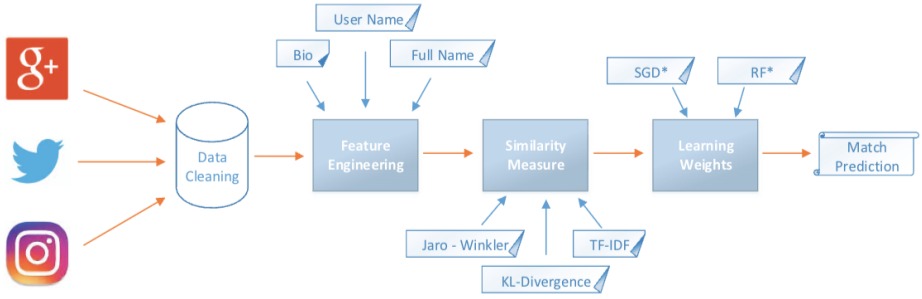
Active Learning เป็นเทคนิคที่ให้ระบบสามารถเลือกตัวอย่างที่ต้องการ Label จากมนุษย์ได้อย่างมีประสิทธิภาพ Li และคณะ [5] ได้นำ Active Learning มาใช้ใน Human-in-the-Loop Data Integration โดยระบบเลือกถามเฉพาะกรณีที่แบบจำลองมีความไม่แน่ใจสูงสุด (Uncertainty Sampling) กลยุทธ์นี้ช่วยลดจำนวนคำถามที่ต้องถามผู้ตรวจสอบได้อย่างมีนัยสำคัญในขณะที่ยังคงรักษาประสิทธิภาพของแบบจำลองในระดับสูง อย่างไรก็ตาม ในโครงงานนี้ยังไม่ได้นำ Active Learning มาใช้จริง เนื่องจากข้อมูล Label ที่มีอยู่เพียงพอสำหรับการฝึกแบบ Supervised ทั่วไป และขอบเขตของโครงงานไม่ครอบคลุมถึงการพัฒนา Annotation Pipeline แบบ Online ทั้งนี้ แนวทางดังกล่าวถือเป็นแนวทางที่มีศักยภาพสำหรับการพัฒนาต่อในอนาคต โดยเฉพาะในกรณีที่ต้องการปรับแบบจำลองให้เข้ากับข้อมูลใหม่ที่เพิ่มขึ้นเรื่อย ๆ

2.3 สถาปัตยกรรมระบบที่เกี่ยวข้อง

2.3.1 LINKSOCIAL: ระบบเชื่อมโยงโปรไฟล์ข้ามแพลตฟอร์ม

LINKSOCIAL [1] เป็นระบบที่พัฒนาโดย Sharma และ Dyreson สำหรับเชื่อมโยงโปรไฟล์ผู้ใช้งานข้ามแพลตฟอร์มสื่อสังคมออนไลน์หลายชนิด สถาปัตยกรรมของระบบประกอบด้วยสามส่วนหลัก ได้แก่ Feature Extraction ที่ดึงข้อมูลโปรไฟล์และพฤติกรรมจากแต่ละแพลตฟอร์ม, Similarity Computation ที่คำนวณความคล้ายคลึงระหว่างโปรไฟล์คู่ต่าง ๆ และ Classification ที่ตัดสินใจว่าโปรไฟล์คู่ใดเป็นบุคคลเดียวกัน

ระบบ LINKSOCIAL [1] ได้รับการทดสอบบนชุดข้อมูลที่มีคู่บัญชีที่ยืนยันแล้วกว่า 7,000 คู่ ข้ามสามแพลตฟอร์ม ผลการทดลองแสดงค่า Precision สูงถึง 0.92 และ Recall ที่ 0.87 สถาปัตยกรรมนี้ให้แนวทางที่ชัดเจนสำหรับการออกแบบโมดูล Identity Resolution ของโครงงานนี้ โดยเฉพาะในด้านการจัดการ Feature จากหลายแพลตฟอร์มพร้อมกัน

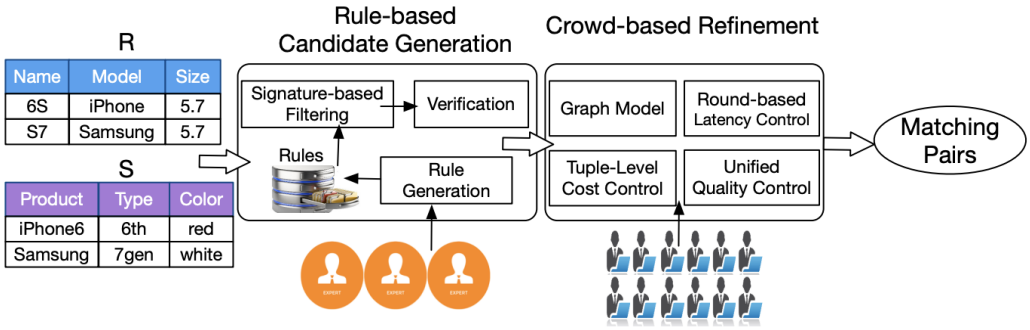


รูปที่ 2.1 สถาปัตยกรรมระบบ LINKSOCIAL สำหรับการเชื่อมโยงโปรไฟล์ข้ามแพลตฟอลม์ [1]

2.3.2 Human-in-the-Loop Data Integration Architecture

Li และคณะ [5] ได้เสนอสถาปัตยกรรม Human-in-the-Loop Data Integration ที่ประกอบด้วยส่วน ได้แก่ (1) Machine Processor สำหรับกรณีที่ระบบมีความมั่นใจสูงและดำเนินการอัตโนมัติ (2) Human Processor ที่รับงานที่มีความไม่แน่ใจสูงและต้องการการตัดสินใจจากมนุษย์ (3) Task Manager ที่จัดสรรงานระหว่างสองส่วนแรกตามค่า Confidence Score และ (4) Data Integration System ที่รวบรวมผลลัพธ์เป็นฐานข้อมูลที่สมบูรณ์

Doan และคณะ [4] ได้เพิ่มเติมข้อค้นพบสำคัญเกี่ยวกับการออกแบบ Interface ที่มีประสิทธิภาพสำหรับผู้ตรวจสอบโดยเน้นว่าควรแสดงข้อมูลที่เกี่ยวข้องที่สุดในรูปแบบที่เข้าใจง่าย พร้อมทั้งมีระบบ Audit Log ที่บันทึกการตัดสินใจทุกครั้งเพื่อความโปร่งใสและตรวจสอบได้ สถาปัตยกรรมนี้เป็นแบบอย่างในการออกแบบ Human Review Module ของโครงงานนี้



รูปที่ 2.2 สถาปัตยกรรม Human-in-the- Loop Data Integration [5]

2.4 งานวิจัยที่เกี่ยวข้อง

2.4.1 LINKSOCIAL: Linking User Profiles Across Multiple Social Media Platforms [1]

งานวิจัยของ Sharma และ Dyreson [1] ซึ่งนำเสนอในการประชุม IEEE International Conference on Big Knowledge (ICBK) ปี 2018 ถือเป็นงานวิจัยหลักที่เกี่ยวข้องโดยตรงกับโครงงานนี้ ระบบ LINKSOCIAL ได้พัฒนาวิธีการดึง Feature จากโปรไฟล์ที่หลากหลาย ทั้งชื่อผู้ใช้ รูปโปรไฟล์ คำอธิบายตัวเอง ตำแหน่งที่ตั้ง และประวัติกิจกรรม จากนั้นใช้ Classifier ตัดสินว่าโปรไฟล์สองชุดเป็นบุคคลเดียวกันหรือไม่

จุดเด่นของงานวิจัยนี้ที่นำมาประยุกต์ใช้ในโครงงานได้แก่ กระบวนการ Feature Engineering แบบ Multi-source และการออกแบบ Pipeline ที่รองรับข้อมูลจากหลายแพลตฟอร์มพร้อมกัน โครงงานนี้ขยายแนวคิดจาก Social Media Profile Linking ไปสู่ Customer Data Linking ในบริบทของ CRM Platform ที่มีระบบ Transaction, Behavioral และ Demographic Data

2.4.2 Connecting Users Across Social Media Sites: A Behavioral-Modeling Approach [2]

งานวิจัยของ Zafarani และ Liu [2] ที่นำเสนอใน ACM SIGKDD ปี 2013 เป็นงานบุกเบิกที่แสดงให้เห็นว่าพฤติกรรมออนไลน์ของผู้ใช้มีความสม่ำเสมอข้ามแพลตฟอร์ม ซึ่งเปิดทางสู่การระบุตัวตนได้แม้ว่าชื่อผู้ใช้และข้อมูลโปรไฟล์จะแตกต่างกัน งานนี้สร้าง Behavioral Profile จากข้อมูลเชิงสถิติของการใช้งาน แล้วนำมาเปรียบเทียบโดยใช้ Machine Learning

ข้อมูลเชิงลึกจากงานวิจัยนี้มีผลโดยตรงต่อการออกแบบ Feature Engineering ของโครงงาน โดยเฉพาะในส่วนของ Behavioral Signal เช่น เวลาในการซื้อ

ความถี่ในการเข้าเว็บไซต์ และรูปแบบการเลือกสินค้า ซึ่งสามารถใช้เป็น Soft Signal สำหรับยืนยันการ Matching เมื่อ Hard Identifier เช่น Email หรือหมายเลขโทรศัพท์ไม่สามารถใช้ได้

2.4.3 User Identity Linkage on Social Networks: A Review [3]

งานวิจัยของ Halimi และ Ayday [3] ที่ตีพิมพ์ใน IEEE Access ปี 2024 เป็นการทบทวนวรรณกรรมที่ครอบคลุมที่สุดในสาขา User Identity Linkage ในช่วงไม่กี่ปีที่ผ่านมา งานนี้จำแนกเทคนิคออกเป็น 4 กลุ่ม ได้แก่ Profile-based, Behavioral-based, Network-based และ Hybrid Approach พร้อมทั้งวิเคราะห์จุดแข็งและจุดอ่อนของแต่ละแนวทาง

ผลการทบทวนของ Halimi และ Ayday [3] ระบุว่า Hybrid Approach ที่รวม Feature จากหลายมิติให้ประสิทธิภาพสูงที่สุดโดยเฉลี่ย แต่มีความซับซ้อนในการ Implement สูงกว่า ข้อค้นพบนี้สนับสนุนการตัดสินใจออกแบบของโครงงานนี้ที่เลือกใช้ Ensemble Approach ที่รวม Multiple Similarity Measures และ Behavioral Signals

2.4.4 Human-in-the-Loop Challenges for Entity Matching [4] และ Data Integration [5]

กลุ่มงานวิจัย Human-in-the-Loop ของ Doan และคณะ [4] และ Li และคณะ [5] ได้วางรากฐานสำคัญสำหรับการนำมนุษย์เข้ามาอยู่ในกระบวนการ Data Integration อย่างมีประสิทธิภาพ Doan และคณะ [4] เน้นที่ด้าน User Experience และ Workflow Design ในขณะที่ Li และคณะ [5] เน้นที่สถาปัตยกรรมระบบและการผสานรวมระหว่าง Machine Learning กับการตัดสินใจของมนุษย์

ทั้งสองงานวิจัยมีผลโดยตรงต่อการออกแบบโมดูล Human Review Interface และ Audit Log ของโครงงานนี้ โดยเฉพาะในแง่ของการออกแบบ Review Queue ที่เรียงลำดับตาม Confidence Score การแสดงข้อมูล Context ที่เพียงพอสำหรับการตัดสินใจ และการบันทึก Decision Log เพื่อใช้ในการ Retrain แบบจำลองในอนาคต

2.4.5 Predictive Lead Scoring Using Machine Learning Techniques [6]

งานวิจัยของ Schafer, Hassan และ Muller [6] ที่ตีพิมพ์ใน Arabian Journal of Science and Engineering ปี 2022 เป็นงานวิจัยที่มีความเกี่ยวข้องโดยตรงกับโมดูล Lead Scoring ของโครงงานนี้ งานนี้ทดสอบแบบจำลอง Machine Learning บนชุดข้อมูล B2B Sales จริง ครอบคลุมทั้ง Feature Engineering, Model Selection, Evaluation Metrics และ Business Impact Assessment

ข้อค้นพบสำคัญที่โครงงานนี้นำมาประยุกต์ใช้คือ การพิสูจน์ว่าการรวม Features จากหลายแหล่งข้อมูล (Identity Data Fusion) เพิ่มประสิทธิภาพของ Lead Scoring Model

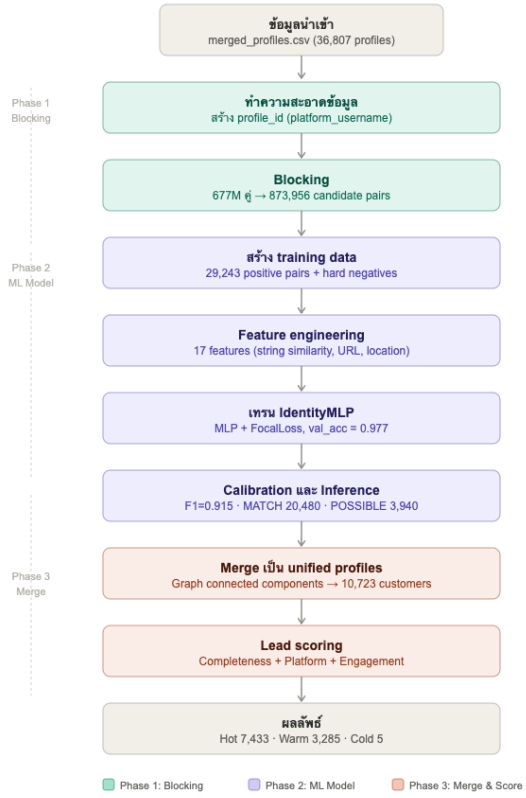
อย่างมีนัยสำคัญ นอกจากนี้ยังได้นำ GBM มาเป็น Baseline Model เริ่มต้น และใช้ AUC-ROC เป็น Primary Evaluation Metric ตามที่งานวิจัยนี้แนะนำ

ตารางที่ 2.2 สรุปงานวิจัยที่เกี่ยวข้องกับโครงงาน

อ้างอิง	(ปี)	หัวข้อ	เทคนิคหลัก	ความเกี่ยวข้องกับโครงงาน
[1]	Sharma & Dyreson (2018)	LINKSOCIAL	Profile & Behavioral Features, Classifier	สถาปัตยกรรม Multi-source Identity Resolution
[2]	Zafarani & Liu (2013)	Behavioral-Modeling User Linking	Behavioral Profile, ML Classification	Feature Engineering สำหรับ Behavioral Matching
[3]	Halimi & Ayday (2024)	User Identity Linkage Review	Hybrid Approach, Multi-dimensional Features	Framework การเลือก Similarity Measures
[4]	Doan et al. (2017)	Human-in-the-Loop Entity Matching	Crowdsourcing, Workflow Design	ออกแบบ Review Interface & Audit Log
[5]	Li et al. (2017)	Human-in-the-Loop Data Integration	Active Learning, Task Manager	สถาปัตยกรรม Hybrid Machine-Human Processing
[6]	Schafer et al. (2022)	Predictive Lead Scoring	GBM, AUC-ROC, Multi-source Features	Lead Scoring Model & Feature Importance

จากการทบทวนงานวิจัยข้างต้น จะเห็นได้ว่างานส่วนใหญ่ถูกพัฒนาและทดสอบบนข้อมูลจากแพลตฟอร์มที่ยังให้บริการอยู่ ซึ่งสามารถดึง Behavioral Signal แบบ Real-time ได้ครบถ้วน สิ่งที่ยังขาดอยู่ในวรรณกรรมคือแนวทางที่รองรับกรณีที่หนึ่งในแพลตฟอร์มปิดตัวไปแล้วและมีเพียง Archive ที่ไม่สมบูรณ์เหลืออยู่ โครงงานนี้จึงพยายามเติมเต็มช่องว่างดังกล่าวโดยออกแบบ Feature Engineering และ Threshold Policy ที่ทำงานได้กับ Profile ที่ขาดข้อมูลบางส่วน

และนำเสนอระบบ POSSIBLE_MATCH เป็นกลไกจัดการความไม่แน่นอนที่เกิดขึ้นจากข้อจำกัดเชิงโครงสร้างของข้อมูล



รูปที่ 2.3 ขั้นตอนการทำงานของระบบ Identity Resolution และ Lead Scoring ที่พัฒนาในโครงงานนี้

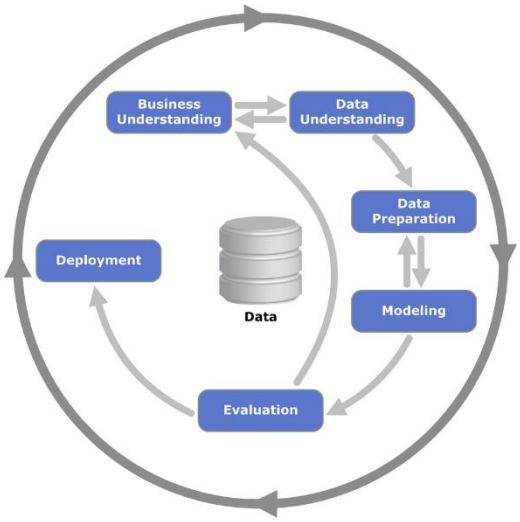
บทที่ 3

วิธีการดำเนินวิจัย

งานวิจัยนี้เลือกใช้กรอบ CRISP-DM (Cross-Industry Standard Process for Data Mining) เป็นหลักในการพัฒนาระบบเชื่อมโยงอัตลักษณ์และการจัดลำดับลูกค้าเป้าหมายสำหรับระบบบริหารจัดการความสัมพันธ์ลูกค้า (CRM) เนื่องจากครอบคลุมครบวงจรตั้งแต่การทำความเข้าใจธุรกิจไปจนถึงการนำไปใช้งานจริง ซึ่งตอบโจทย์ระบบที่มีความซับซ้อนทั้งส่วน Retrieval, Classification และ Entity Consolidation

การประยุกต์ใช้เป็นลักษณะ Iterative (วนซ้ำ) ไม่ได้เป็นลำดับเส้นตรง ช่วยให้สามารถย้อนกลับไปปรับปรุงขั้นตอนก่อนหน้าได้ทันที โดยในบทนี้จะอธิบายรายละเอียดผ่าน 5 ขั้นตอนหลัก ได้แก่

1. การทำความเข้าใจธุรกิจ (Business Understanding)
2. การทำความเข้าใจข้อมูล (Data Understanding)
3. การเตรียมข้อมูล (Data Preparation)
4. การสร้างแบบจำลอง (Modeling)
5. การประเมินผล (Evaluation)



รูปที่ 3.1 แสดงกรอบวิธีวิจัยที่ใช้เป็นโครงหลักของการพัฒนาระบบเชื่อมโยงอัตลักษณ์ลูกค้าและการให้คะแนนลูกค้าเป้าหมายในงานวิจัยนี้

3.1 การทำความเข้าใจธุรกิจ (Business Understanding)

3.1.1 ปัญหาทางธุรกิจ

ปัญหาตั้งต้นของงานวิจัยนี้เกิดจากข้อจำกัดที่พบได้จริงในระบบบริหารจัดการความสัมพันธ์ลูกค้า (CRM) คือ ข้อมูลของลูกค้าคนเดียวกันไม่ได้ถูกรวบรวมไว้ภายใต้ระเบียน (Record) เดียว แต่กระจายอยู่หลายแหล่งและหลายแพลตฟอร์ม เช่น ทวิตเตอร์ (Twitter) อินสตาแกรม (Instagram) และกูเกิลพลัส (Google+) โดยแต่ละแหล่งใช้โครงสร้างข้อมูลต่างกัน มีความสมบูรณ์ของข้อมูลไม่เท่ากัน และผู้ใช้เองก็อาจใช้ชื่อ รูปแบบการเขียน หรือช่องทางการแสดงตัวตนต่างกันในแต่ละบัญชี ส่งผลให้บุคคลเดียวกันอาจถูกเก็บเป็นหลายระเบียนที่ไม่เชื่อมโยงกันอย่างถูกต้อง เมื่อระบบไม่สามารถรวมระเบียนเหล่านี้ให้เป็นเอนทิตี (Entity) เดียวได้ ระบบ CRM จะเห็นลูกค้าเพียงบางส่วน ทำให้การวิเคราะห์พฤติกรรม การจัดกลุ่มลูกค้า การนำเสนอแบบเฉพาะบุคคล (Personalization) การจัดลำดับความสำคัญของลูกค้าเป้าหมาย และการวางแผนการสื่อสารทางการตลาดคลาดเคลื่อนได้

ในทางปฏิบัติ สิ่งที่ธุรกิจต้องการไม่ใช่เพียงการบอกว่าคู่โปรไฟล์ (Profile) ใดคล้ายกัน แต่ต้องการระบบที่สามารถระบุได้ว่าระเบียนใดเป็นบุคคลเดียวกัน แล้วรวมข้อมูลเหล่านั้นให้กลายเป็นข้อมูลลูกค้าแบบเบ็ดเสร็จ (Unified Customer Profile) ที่พร้อมใช้ในงานปลายทาง เช่น การคัดเลือกลูกค้าเป้าหมาย การวางแผนการติดตามลูกค้า และการประเมินคุณค่าทางธุรกิจของลูกค้าแต่ละราย

3.1.2 การแปลงเป็นปัญหาเชิงข้อมูล

เมื่อแปลงโจทย์ทางธุรกิจให้อยู่ในรูปปัญหาเชิงข้อมูล ได้มีการกำหนดให้แกนหลักของระบบเป็นงาน Identity Resolution โดยนิยามว่า ระบบต้องตัดสินว่าโปรไฟล์สองรายการเป็นบุคคลเดียวกันหรือไม่ จากนั้นผลลัพธ์ที่ยืนยันแล้วจะถูกนำไปรวมเป็นเอนทิตีลูกค้าเดียวเพื่อใช้ในขั้น Lead scoring ต่อไป อย่างไรก็ตาม งานนี้ไม่ใช่ปัญหา Classification เพียงอย่างเดียว เพราะก่อนที่ระบบจะตัดสินว่าคู่ใด match ระบบต้องหา Candidate pairs ที่ควรพิจารณาให้พบก่อน

ข้อจำกัดสำคัญคือจำนวนคู่เปรียบเทียบทั้งหมดมีขนาดใหญ่มาก หากใช้โปรไฟล์ทั้งหมด 36,804 รายการ ซึ่งหากนับทุกคู่แบบไม่เรียงลำดับจะได้ 677,248,806 คู่ และหากพิจารณา

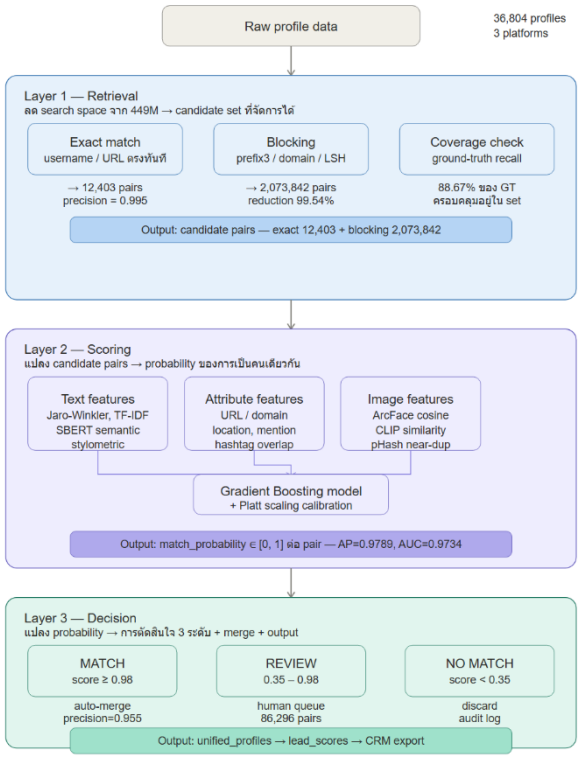
เฉพาะคู่ข้ามแพลตฟอร์มตามนิยามของการทดลองหลัก จะยังมีมากถึง 449,149,239 คู่ ดังนั้น การนำทุกคู่เข้าสู่แบบจำลองโดยตรงจึงไม่เหมาะสมทั้งในแง่เวลาและทรัพยากร

จากข้อจำกัดดังกล่าว จึงออกแบบกระบวนการแก้ปัญหาออกเป็น 3 ลำดับชั้น ที่ทำงานสอดประสานกันอย่างเป็นระบบ ได้แก่

1) **ชั้นการดึงข้อมูลและคัดกรอง (Retrieval Layer)** ทำหน้าที่กรอง Candidate Pairs ออกจากพื้นที่ค้นหาขนาดใหญ่ เพื่อลดปริมาณข้อมูลขยะ โดยในสายการประมวลผลหลักได้เลือกใช้กลยุทธ์ Exact-first และ Blocking เป็นกลไกสำคัญ

2) **ชั้นการให้คะแนน (Scoring Layer)** ทำหน้าที่ประเมินคู่ Candidate ที่ผ่านการคัดกรองจากชั้นแรก โดยจะคำนวณค่าความน่าจะเป็นในการเป็นบุคคลเดียวกัน ผ่านการคำนวณคุณลักษณะความคล้ายคลึง และการใช้ Multimodal Evidence

3) **ชั้นการตัดสินใจ (Decision Layer)** ทำหน้าที่ประเมินผลลัพธ์จากคะแนนที่ได้ เพื่อฟันธงว่าคู่โปรไฟล์ดังกล่าวควรจับคู่หรือไม่ และส่งต่อผลลัพธ์ไปยังกระบวนการควบรวมข้อมูลปลายทางต่อไป



รูปที่ 3.2 ซึ่งแสดงภาพรวมของระบบในเชิงธุรกิจและเชิงเทคนิคพร้อมกัน โดยให้

เห็นเส้นทางข้อมูลจากโปรไฟล์ต้นทาง การคัด candidate pairs การให้คะแนน การตัดสินใจ การรวมเอนทิตี และการสร้างคะแนนลูกค้า เพื่อให้ผู้อ่านเห็นตั้งแต่ต้นว่างานนี้ไม่ได้จบที่การทำนายคู่ข้อมูล แต่ไปถึงการใช้งานจริงในระบบปลายทาง

3.1.3 ขอบเขตเชิงธุรกิจกับขอบเขตการทดลอง

แม้เป้าหมายเชิงธุรกิจของระบบจะครอบคลุมการระบุว่าโปรไฟล์ใดเป็นบุคคลเดียวกันโดยไม่จำกัดแพลตฟอร์ม แต่การทดลองหลักของโครงการนี้มุ่งเน้นกรณี Cross-platform identity linkage เป็นหลัก เนื่องจากข้อจำกัดของชุดข้อมูลกำกับที่มีอยู่จริง ในเชิงนิยามของปัญหา โปรไฟล์ทั้ง 36,804 รายการสามารถสร้างคู่แบบไม่เรียงลำดับได้ทั้งหมด 677,248,806 คู่ โดยแบ่งเป็นคู่ข้ามแพลตฟอร์ม 449,149,239 คู่ และคู่ในแพลตฟอร์มเดียวกัน 228,099,567 คู่ อย่างไรก็ตาม เมื่อใช้ user_folder เป็นตัวแทนเอนทิตีต้นทางเพื่อสร้าง Ground truth จะพบว่าคู่เชิงบวกแบบ Cross-platform มี 29,243 คู่ ขณะที่คู่เชิงบวกแบบ Same-platform มีเพียง 4 คู่เท่านั้น

ข้อจำกัดนี้ทำให้กรณี Same-platform ยังไม่มีจำนวนตัวอย่างเชิงบวกมากพอสำหรับการฝึกและประเมินผลอย่างมั่นคงในระดับที่ใช้สรุปเชิงวิชาการได้ ด้วยเหตุนี้ เพื่อให้การสร้าง positive pairs และการประเมินผลหลักยึดกับส่วนของข้อมูลที่มีหลักฐานรองรับเพียงพอที่สุด ผลการทดลองหลักของงาน เช่น จำนวน Ground truth Cross-platform 29,243 คู่ Exact Matches 12,403 คู่ Candidate pairs 2,073,842 คู่ และ retrieval coverage 88.67% จึงควรถูกตีความว่าเป็นผลลัพธ์สำหรับกรณี Cross-platform เป็นสำคัญ ไม่ใช่ผลยืนยันประสิทธิภาพของ All-platform identity resolution

ระบบมีขอบเขตเชิงธุรกิจที่กว้างกว่า Implementation เชิงทดลองในรายงานฉบับนี้ โดยขอบเขตธุรกิจมุ่งสู่การรวม Identity ในทุกกรณี ขณะที่ขอบเขตการทดลองหลักถูกจำกัดให้เหมาะกับข้อเท็จจริงของข้อมูลที่มีอยู่

3.1.4 เป้าหมายของระบบ

จากการวิเคราะห์ข้างต้น เป้าหมายของระบบในงานนี้จึงไม่ได้จำกัดอยู่ที่การเพิ่มค่าความแม่นยำของแบบจำลองอย่างเดียว แต่ครอบคลุมเป้าหมายเชิงระบบ 4 ประการพร้อมกัน

1) ระบบต้องค้นหาคู่ที่น่าจะเป็นบุคคลเดียวกันได้ครอบคลุมเพียงพอ กล่าวคือ retrieval ต้องไม่ทำให้คู่จริงหลุดจาก pipeline มากเกินไป

2) ระบบต้องลดจำนวนคู่เปรียบเทียบลงจนสามารถคำนวณได้จริงในระดับ production โดยไม่ต้องสร้าง feature และ score ทุกคู่ในจักรวาลข้อมูล
3) ระบบต้องให้คะแนนที่สามารถนำไปกำหนด Threshold สำหรับการใช้งานจริงได้ เพื่อให้สามารถแบ่งผลลัพธ์เป็น MATCH, REVIEW และ NO_MATCH อย่างเป็นระบบ
4) ผลลัพธ์สุดท้ายต้องสามารถแปลงเป็น Unified customer profiles และ Lead tiers ที่พร้อมใช้งานในระบบบริหารจัดการความสัมพันธ์ลูกค้า (CRM) ได้โดยตรง

ดังนั้น ขั้น Business Understanding เป็นขั้นที่ทำให้ตัดสินใจว่า Pipeline จำเป็นต้องประกอบด้วย Retrieval, Scoring, Decision tiers, Review workflow, Entity merge และ Lead scoring อยู่ในระบบเดียวกัน ไม่ใช่การพัฒนา classifier แยกเดี่ยวเพียงตัวเดียวแล้วจบกระบวนการ

3.2 การทำความเข้าใจข้อมูล (Data Understanding)

ข้อมูลที่ใช้ในงานนี้อ้างอิงจากชุดข้อมูล LinkSocial ซึ่งเป็นชุดข้อมูลมาตรฐานสำหรับงานเชื่อมโยงอัตลักษณ์ผู้ใช้ข้ามแพลตฟอร์ม ข้อมูลต้นทางถูกจัดเก็บในรูปแบบไฟล์ JSON ของโปรไฟล์สาธารณะจากหลายแพลตฟอร์มสังคมออนไลน์ และในงานวิจัยนี้เลือกใช้ 3 แพลตฟอร์มหลัก ได้แก่ Twitter, Google+ และ Instagram ในขั้นตอนการเตรียมข้อมูล เริ่มจากไล่อ่านโฟลเดอร์ 1.profile.data 2.profile.datและ 3.profile.data แล้วรวมโปรไฟล์ทั้งหมดเป็นตารางเดียว โดยดึง user_folder, source_folderและ platform มาจากโครงสร้าง Directory และชื่อไฟล์ต้นทาง การรวมข้อมูลในขั้นนี้ทำให้ข้อมูลกึ่งโครงสร้างหลายแหล่งถูกเปลี่ยนเป็นรูปแบบตารางที่พร้อมตรวจสอบและประมวลผลต่อได้เพื่อให้สะดวกต่อการทำความสะอาด และนำไปใช้ในขั้นตอนถัดไป หลังจากนั้นจึงเพิ่มข้อมูลกำกับที่จำเป็น เพื่อให้สามารถติดตามที่มาของข้อมูลและเชื่อมโยงข้อมูลระหว่างขั้นตอนต่าง ๆ ของการประมวลผลได้อย่างถูกต้อง

เมื่อผ่านการเตรียมข้อมูลเบื้องต้นแล้ว ข้อมูลจะถูกทำความสะอาดและปรับให้อยู่ในรูปแบบมาตรฐานสำหรับใช้ในสถาปัตยกรรมการประมวลผลหลักของงานวิจัย โดยชุดข้อมูลสุดท้ายที่ใช้ประกอบด้วยข้อมูลทั้งหมด ดังแสดงในตารางที่ 3.1

ตารางที่ 3.1 จำนวนข้อมูลแยกตามแพลตฟอร์มในชุดข้อมูลมาตรฐานหลัก

Platform	**Number of Profiles**
Twitter	13,960
Google+	11,890
Instagram	10,957
รวม	**36,807**

เมื่อพิจารณาโครงสร้างของข้อมูลที่รวมได้แล้ว จะพบว่าตารางกลางมีคอลัมน์สำคัญทั้งหมด 11 คอลัมน์ ได้แก่ userName, fullName, bio, location, externalUrl, pictureURL, user_folder, outputProfileName, platform, source_folder และ bigrams อย่างไรก็ตาม ไม่ใช่ทุกคอลัมน์จะถูกนำเข้าสู่แบบจำลองโดยตรง บางคอลัมน์ทำหน้าที่เป็นข้อมูลดิบสำหรับสร้างคุณลักษณะ บางคอลัมน์ทำหน้าที่เป็นคีย์อ้างอิงของระบบ และบางคอลัมน์เป็นข้อมูลทางผ่านที่ใช้เฉพาะในช่วง reprocessing เท่านั้น

ตารางที่ 3.2 ฟิลด์อ้างอิงหลักและบทบาทในการใช้งานจริงของระบบ

กลุ่มข้อมูล	**คอลัมน์อ้างอิง**	**คำอธิบายโดยย่อ**	**บทบาทหลักในระบบ**
Core Identity Attributes	userName	ชื่อบัญชีผู้ใช้หรือ handle	ใช้ใน exact matching, prefix blocking และ string similarity
	fullName	ชื่อที่แสดงบนโปรไฟล์	ใช้เปรียบเทียบชื่อแสดงผลและเสริมการจับคู่
	externalUrl	ลิงก์ภายนอกที่ผู้ใช้ระบุ	ใช้ใน URL/domain normalization, exact-first และ domain overlap matching

ตารางที่ 3.2 (ต่อ) ฟิลด์อ้างอิงหลักและบทบาทในการใช้งานจริงของระบบ

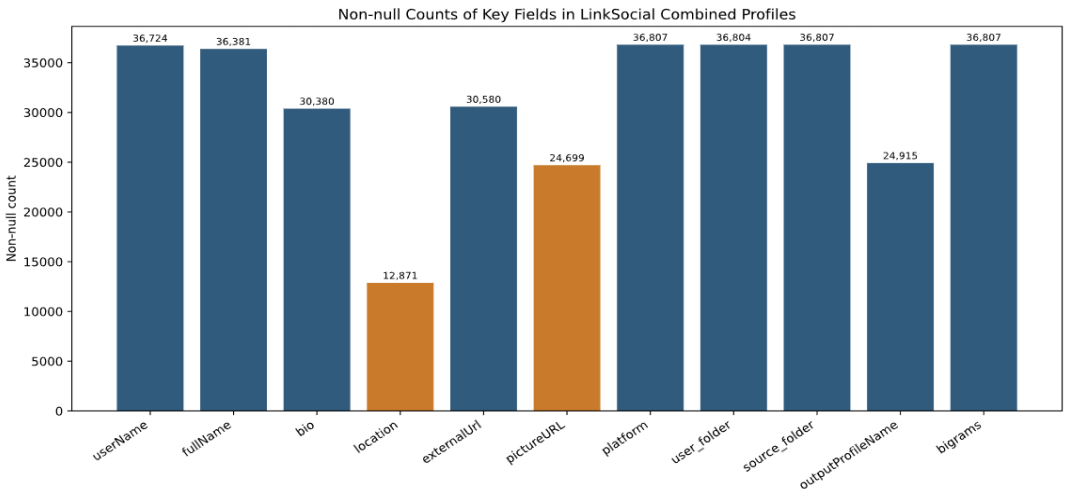
กลุ่มข้อมูล	คอลัมน์อ้างอิง	คำอธิบายโดยย่อ	บทบาทหลักในระบบ
Contextual & Multimodal Signals	bio	คำอธิบายตัวตนหรือข้อความโปรไฟล์	ใช้สร้าง semantic และ text features
	location	สถานที่ที่ผู้ใช้ระบุ	ใช้ใน location normalization และ location similarity
	pictureURL	URL ของรูปโปรไฟล์ต้นทาง	ใช้เป็นจุดตั้งต้นของสายภาพและ multimodal features
Linkage Keys & ERD Identifiers	profile_id	รหัสอ้างอิงโปรไฟล์หลัง normalize	ใช้เป็นคีย์อ้างอิงมาตรฐานของโปรไฟล์ใน pipeline
	profile_row_id	รหัสลำดับแถวของโปรไฟล์	ใช้เชื่อม feature matrix, scoring outputs และ CRM artifacts
	platform	ชื่อแพลตฟอร์มของโปรไฟล์	ใช้กำหนดขอบเขต cross-platform pairing และสร้าง platform_pair_code
Validation & Audit Trail	user_folder	ตัวระบุเอนทิตีจากแหล่งต้นทาง	ใช้สร้าง ground truth และ positive pairs
	source_folder	ตัวระบุแหล่งที่มาของข้อมูล	ใช้ตรวจสอบ provenance และ audit trail
Processing Artifacts	outputProfileName	ตัวระบุชั่วคราวในขั้น preprocessing	ใช้เป็นฐานสำหรับการสร้าง profile_id

ตารางที่ 3.2 (ต่อ) ฟิลด์อ้างอิงหลักและบทบาทในการใช้งานจริงของระบบ

กลุ่มข้อมูล	คอลัมน์อ้างอิง	คำอธิบายโดยย่อ	บทบาทหลักในระบบ
Processing Artifacts	bigrams	ข้อมูลตัวอักษรคู่ที่สร้างในสาย preprocessing รุ่นต้น	ไม่ได้อยู่ใน selected features ของแบบจำลองหลัก

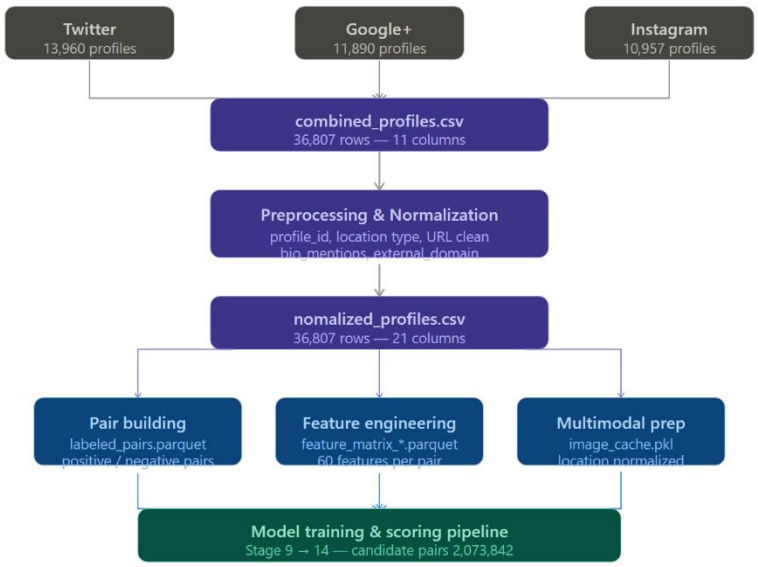
จากตารางที่ 3.2 จะเห็นได้ว่าฟิลด์สำคัญของระบบไม่ได้มีบทบาทเหมือนกันทั้งหมด ฟิลด์กลุ่ม Core Identity Attributes เช่น userName, fullName และ externalUrl เป็นแกนหลักของการพิสูจน์อัตลักษณ์ ขณะที่ bio, location และ pictureURL ทำหน้าที่เป็นข้อมูลบริบทและข้อมูลเสริมที่ช่วยเพิ่มความแม่นยำในกรณีที่สัญญาณหลักไม่เพียงพอ ส่วน profile_id, profile_row_id, user_folder และ source_folder เป็นฟิลด์เชิงโครงสร้างที่ทำให้ระบบสามารถเชื่อมโยงข้อมูล ประเมินผล และตรวจสอบย้อนกลับได้อย่างเป็นระบบ

เมื่อพิจารณาความพร้อมใช้งานของข้อมูล พบว่าฟิลด์อย่าง userName, fullName และ externalUrl มีข้อมูลค่อนข้างสมบูรณ์ จึงเหมาะสำหรับใช้เป็นคุณลักษณะหลัก ในขณะที่ location และ pictureURL มีข้อมูลขาดหายมากกว่า จึงเหมาะสำหรับใช้เป็นข้อมูลสนับสนุนมากกว่าการใช้คุณลักษณะหลักเพียงลำพัง เพื่อให้เห็นภาพรวมของความสมบูรณ์ของข้อมูลได้ชัดเจนยิ่งขึ้น จึงแสดงจำนวนข้อมูลที่ไม่เป็นค่าว่างของแต่ละฟิลด์ในรูปแบบกราฟแท่ง ดังรูปที่ 3.3

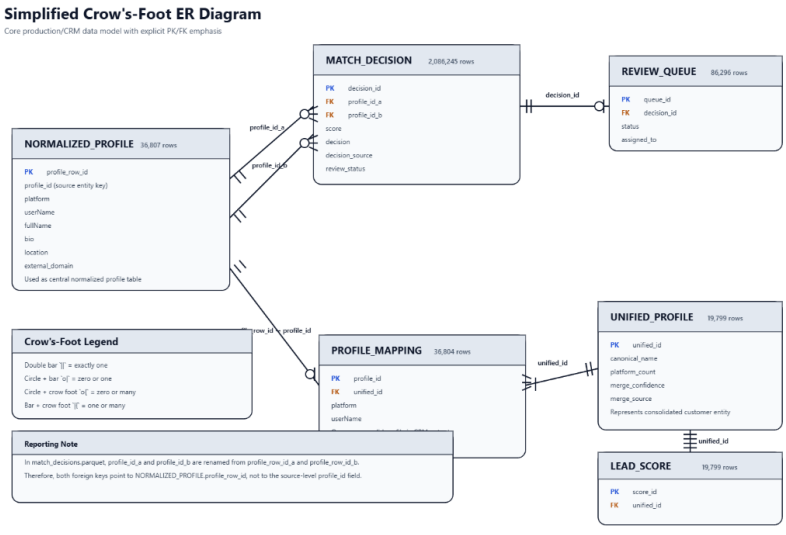


รูปที่ 3.3 จำนวนข้อมูลที่ไม่เป็นค่าว่างของฟิลด์สำคัญในชุดข้อมูล LinkSocial

ในแง่ของการจัดการข้อมูล ขั้นตอนนี้ไม่ได้มีเพียงการรวมข้อมูลหรือตรวจสอบจำนวนคอลัมน์เท่านั้น แต่เป็นการเตรียมข้อมูลให้พร้อมสำหรับ Pipeline ในระยะถัดไป ข้อมูลดิบจากหลายแพลตฟอร์มซึ่งอยู่ในรูปแบบกึ่งโครงสร้างจะถูกแปลงให้อยู่ในรูปแบบมาตรฐาน เพื่อให้พร้อมนำไปใช้งานต่อในขั้นตอน Pair Building, Feature Engineering และ Model Training



รูปที่ 3.4 แสดงการไหลของข้อมูลจากแหล่งข้อมูลดิบไปสู่ชุดข้อมูลมาตรฐาน



รูปที่ 3.5 เพื่อแสดงความสัมพันธ์เชิงคีย์ของข้อมูลในลักษณะ Entity-Relationship Diagram

3.3 การเตรียมข้อมูล (Data Preparation)

ขั้นตอนการเตรียมข้อมูลนับเป็นหนึ่งในกระบวนการที่มีความสำคัญอย่างยิ่ง เนื่องจากเป็นขั้นตอนที่เปลี่ยนผ่านข้อมูลดิบที่มีความหลากหลายและไม่สม่ำเสมอสูง ให้กลายเป็นชุดข้อมูลมาตรฐานที่พร้อมใช้งานสำหรับกระบวนการสร้างชุดคู่ข้อมูล (Pair Building) การทำวิศวกรรมคุณลักษณะ (Feature Engineering) และการฝึกสอนตัวแบบ (Model Training) ทั้งนี้ การเตรียมข้อมูลในโครงงานนี้ไม่ได้จำกัดอยู่เพียงการจัดการค่าว่างหรือการแปลงข้อความขั้นพื้นฐานเท่านั้น แต่ยังครอบคลุมถึงกระบวนการเชิงลึกอย่างครบวงจร ตั้งแต่การทำความสะอาดข้อมูลเชิงข้อความ การสร้างคีย์อ้างอิงกลาง การปรับมาตรฐาน (Normalize) คุณลักษณะสำคัญ เช่น ข้อมูลสถานที่ การจัดเตรียมฐานข้อมูลภาพ ไปจนถึงการสร้างชุดคู่ข้อมูลสำหรับการฝึกสอน และการสร้างเมทริกซ์คุณลักษณะ (Feature Matrix) แบบแบ่งส่วน (Chunked) เพื่อรองรับการแบ่งชุดข้อมูลฝึกสอน (Train), ชุดข้อมูลตรวจสอบ (Validation) และชุดข้อมูลทดสอบ (Test) อย่างมีประสิทธิภาพ

3.3.1 การทำความสะอาดข้อมูลและสร้างรหัสอ้างอิง (Data Cleaning & Canonical key)

กระบวนการนี้มุ่งเน้นไปที่การเตรียมความพร้อมของข้อมูลดิบให้มีความถูกต้องและเป็นมาตรฐานเดียวกัน โดยมีขั้นตอนหลักดังต่อไปนี้

1) การจัดการค่าที่ขาดหาย (Missing Value Handling)

- **กลุ่มข้อมูลระบุตัวตนหลัก** ได้แก่ userName, fullName, bio, location, externalUrl และ pictureURL จะถูกแทนที่ค่าที่ขาดหายด้วยค่าว่าง เพื่อรักษาสะพานการเชื่อมต่อข้อมูล ให้ระบบสามารถประมวลผลในขั้นต่อไปได้อย่างสม่ำเสมอโดยไม่เกิดข้อผิดพลาด
- **กลุ่มข้อมูลเพื่อการเชื่อมโยง** ในกรณีที่ outputProfileName ไม่มีค่า ระบบจะดึงข้อมูลจาก user_folder มาเติมทดแทน เพื่อให้มั่นใจว่าทุกโปรไฟล์มีตัวอ้างอิงตั้งต้นที่สามารถใช้งานได้ทันที

2) การปรับมาตรฐานข้อความ (Text Normalization)

ข้อมูลในแต่ละฟิลด์จะถูกทำความสะอาดด้วยชุดกฎที่สอดคล้องกับธรรมชาติของข้อมูลนั้น ๆ เพื่อเพิ่มความแม่นยำในการเปรียบเทียบ ดังนี้

- **userName** ตัดสัญลักษณ์ @ นำหน้า แปลงเป็นตัวพิมพ์เล็กทั้งหมด ลบอีโมจิและสัญลักษณ์ที่ไม่จำเป็น รวมถึงยุบรวมตัวคั่นที่พิมพ์ซ้ำซ้อน (เช่น ... หรือ ___) ให้เหลือเพียงตัวเดียว
- **fullName** แปลงเป็นตัวพิมพ์เล็ก ตัดคำนำหน้าชื่อที่ระบบไม่ต้องการ ลบอักขระพิเศษ และจัดระเบียบช่องว่างให้เป็นมาตรฐาน เพื่อช่วยให้ชื่อที่สะกดต่างรูปแบบกันแต่มีความหมายเดียวกันสามารถนำมาเปรียบเทียบได้ง่ายขึ้น
- **bio** เนื่องจากเป็นฟิลด์ที่มีข้อมูลหลากหลายรูปแบบซ่อนอยู่ กระบวนการจึงครอบคลุมทั้งการลบข้อมูลรบกวนและการสกัดข้อมูลเฉพาะ โดยจะดึง URL การกล่าวถึง (@mention) และแฮชแท็ก (#---) แยกออกมา เพื่อนำไปสร้างเป็นคุณลักษณะเชิงบริบทในขั้นตอนถัดไป

3) การสร้างคีย์อ้างอิงกลาง (Canonical Key Generation) เพื่อให้ระบบสามารถตรวจสอบย้อนกลับ ได้ตั้งแต่ต้นน้ำจนถึงปลายน้ำ ได้ออกแบบระบบคีย์อ้างอิงแบบ 2 ระดับ ได้แก่

- **profile_id (Entity Key)** รหัสหลักที่ได้จากการปรับมาตรฐานข้อมูล ทำหน้าที่เป็นศูนย์กลางในการรวบรวมและเชื่อมโยงโปรไฟล์ทั้งหมดของบุคคลเดียวกันเข้าด้วยกัน
- **profile_row_id (Row Key)** รหัสกำกับข้อมูลรายบรรทัดที่ใช้จัดการระบบหลังบ้าน เพื่อให้การส่งต่อข้อมูลไปยังขั้นตอน Pair Building, Scoring และระบบบริหารจัดการความสัมพันธ์ลูกค้า (CRM) ดำเนินไปอย่างราบรื่น

ตารางที่ 3.3 ตัวอย่างการแปลงข้อมูลหลักในขั้นทำความสะอาดและปรับมาตรฐาน

ข้อมูลตั้งต้น	**ตัวอย่างก่อนประมวลผล**	**ฟิลด์ที่สร้างใหม่**	**ค่าผลลัพธ์ที่ได้**
userName	@A_A.ron 🔥	userName_clean	a_a.ron
fullName	Mr. Aaron Bird ✨	fullName_clean	aaron bird
bio	Now designer @Uber...	bio_clean	now designer...
		bio_mentions	uber

ตารางที่ 3.3 (ต่อ) ตัวอย่างการแปลงข้อมูลหลักในขั้นทำความสะอาดและปรับมาตรฐาน

ข้อมูลตั้งต้น	ตัวอย่างก่อนประมวลผล	ฟิลด์ที่สร้างใหม่	ค่าผลลัพธ์ที่ได้
location	San Francisco, CA	location	san francisco, ca
externalUrl	HTTPS//www.LinkedIn.com/in/Aaron/?utm=1	externalUrl_clean	linkedin.com/in/aaron
		external_domain	linkedin.com
outputProfileName	aaronbird	profile_id	aaronbird

3.3.2 การสกัดคุณลักษณะเชิงบริบทและสัญญาณสนับสนุน (Contextual Feature Extraction and Supportive Signals)

หลังจากผ่านกระบวนการทำความสะอาดข้อมูลเบื้องต้น ขั้นตอนต่อไปคือการสร้าง ฟิลด์คุณลักษณะสนับสนุนจากข้อมูลบริบท เพื่อแปลงข้อมูลให้เป็นสัญญาณที่มีความละเอียดและโครงสร้างชัดเจนยิ่งขึ้น โดยมีการจัดการข้อมูลเฉพาะในแต่ละฟิลด์ดังนี้

- **bio** นอกจากการทำความสะอาดข้อความแล้ว ระบบยังสกัดข้อมูลเชิงโครงสร้าง เช่น รายการ/จำนวน URL และการกล่าวถึง (@mention) เพื่อใช้ประเมินทั้งความหมายและพฤติกรรมการพิมพ์ของผู้ใช้
- **location** ระบบจะจำแนกประเภทสถานที่ ได้แก่ ข้อความ พิกัดตัวเลข หรือข้อมูลขยะ และสร้างฟิลด์กำกับ เช่น location_type, latitude, longitude เพื่อให้สามารถเลือกระหว่างการเทียบข้อความ หรือการเทียบพิกัดภูมิศาสตร์ได้อย่างเหมาะสม
- **externalUrl** จัดรูปแบบลิงก์โดยตัดส่วนเกิน (Protocol, www., Query String) ออกแล้วสกัดเฉพาะโดเมนหลักแยกออกมา เพื่อให้ลิงก์เป็นสัญญาณจับคู่ได้แม่นยำขึ้น
- **pictureURL** ทำหน้าที่เป็นตัวอ้างอิงไปยังฐานข้อมูลภาพที่ประมวลผลไว้ล่วงหน้า เพื่อดึงคุณลักษณะต่าง ๆ เช่น Metadata, Image Hash และคำบรรยายภาพ มาใช้งานได้ทันที

ตารางที่ 3.4 ตัวอย่างการสร้างฟิลด์สนับสนุนจากข้อมูลบริบท

ฟิลด์ตั้งต้น	ตัวอย่างก่อนประมวลผล	ฟิลด์สนับสนุนที่สร้างขึ้น	ตัวอย่างผลลัพธ์ที่ได้
bio	Now designer @Uber...	bio_mentions	uber
	Co-Founder... http//bizible.com	bio_urls	http//bizible.com
		bio_url_count	1
location	San Francisco, CA	location_type	text_location
		location_valid	1
	40.7128, -74.0060	latitude	40.7128
		longitude	-74.0060
		location_type	coordinates
externalUrl	https//www.twitch.tv/WeaponII?ref=profile	externalUrl_clean	twitch.tv/weaponii
		external_domain	twitch.tv
		url_count	1
pictureURL	https://.../profile.jpg	ข้อมูลภาพที่เตรียมไว้ล่วงหน้า	Metadata, Quality features, Hash similarity, Captions

จากตัวอย่างในตารางจะเห็นได้ว่าฟิลด์สนับสนุนไม่ได้เป็นเพียงการเปลี่ยนชื่อคอลัมน์ แต่เป็นการแยกข้อมูลที่ซ่อนอยู่ในฟิลด์ดิบออกมาให้อยู่ในรูปที่ระบบสามารถนำไปใช้งานได้โดยตรง เช่น bio หนึ่งบรรทัดสามารถแตกออกเป็นข้อความที่สะอาด รายการ mention และรายการ URL ขณะที่ location หนึ่งค่าก็สามารถถูกตีความต่อได้ว่าเป็นข้อความสถานที่ทั่วไปหรือเป็นพิกัดเชิงภูมิศาสตร์จริง การเตรียมฟิลด์ลักษณะนี้ทำให้ขั้น feature engineering ในภายหลังมีสัญญาณหลายมิติมากกว่าการพึ่งข้อความดิบเพียงอย่างเดียว

3.3.3 การสร้างชุดข้อมูลคู่เปรียบเทียบเพื่อการเรียนรู้ (Training Pair Formulation)

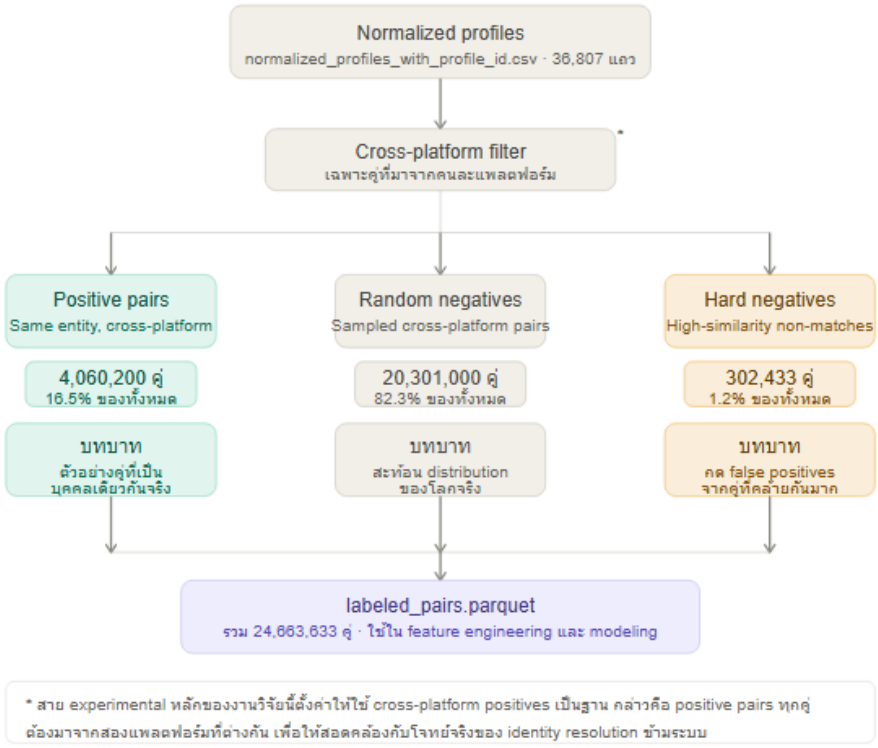
เมื่อกระบวนการเตรียมข้อมูลระดับโปรไฟล์เสร็จสมบูรณ์ ขั้นตอนถัดมาคือการปรับเปลี่ยนโครงสร้างปัญหา จากการวิเคราะห์ระดับโปรไฟล์เดี่ยว (Profile-level) ไปสู่การวิเคราะห์ระดับคู่เปรียบเทียบ (Pair-level) เพื่อให้แบบจำลองสามารถเรียนรู้และแยกแยะความสัมพันธ์ได้ว่าโปรไฟล์คู่ใดคือบุคคลเดียวกัน และคู่ใดไม่ใช่

- ประเภทของคู่ข้อมูล ได้ทำการสังเคราะห์คู่ข้อมูลออกเป็น 3 ประเภทหลัก ได้แก่
    1) **Positive Pairs** โปรไฟล์บุคคลเดียวกันจริง โดยจะใช้เฉพาะข้อมูลข้ามแพลตฟอร์ม เพื่อให้สอดคล้องกับขอบเขตของงานวิจัย
    2) **Random Negative Pairs** สุ่มจับคู่โปรไฟล์ที่เป็นคนละคนกันอย่างชัดเจน
    3) **Hard Negative Pairs** โปรไฟล์ที่เป็นคนละคนกัน แต่มีข้อมูลหรือชื่อคล้ายคลึงกันมาก หากแบบจำลองฝึกสอนด้วยคู่ลบที่แยกแยะได้ง่ายเพียงอย่างเดียว จะเกิดแนวโน้มการเรียนรู้แบบผิวเผิน และนำไปสู่ความผิดพลาดประเภทผลบวกลวง (False Positive) ได้ง่ายเมื่อเผชิญกับกรณีที่ชื่อหรือข้อมูลกำกวม การนำคู่ลบแบบยากเข้ามาเป็นส่วนหนึ่งของชุดฝึกสอน จึงเป็นการบังคับให้แบบจำลองเรียนรู้ที่จะแยกแยะกรณีเหล่านี้ออกได้อย่างแม่นยำ
- กระบวนการสกัดและสัดส่วนของชุดคู่ข้อมูล
    1) การกำหนดฐานจากคู่ Positive Pairs ด้วยการรวบรวมโปรไฟล์ที่มี user_folder เดียวกันเป็นตัวแทนของ Entityเดียวกัน จากนั้นนำมาจับคู่แบบสองตัวเลือก โดยคัดกรองเฉพาะกรณีที่อยู่คนละแพลตฟอร์ม ทำให้ได้คู่บวกตั้งต้นจำนวน 4,060,200 คู่ ซึ่งตัวเลขนี้ถูกนำไปใช้เป็นฐานในการคำนวณคู่ลบในลำดับถัดไป
    1) สร้างคู่ Random Negatives ทั่วไป เพื่อสร้างคลาสลบให้มีขนาดใหญ่พอที่จะสะท้อนความเป็นจริง ได้ตั้งเป้าหมายอัตราส่วนไว้ที่ 5 เท่าของคู่ Positive Pairs (4,060,200 × 5) ซึ่งเท่ากับ 20,301,000 คู่ คู่ข้อมูลเหล่านี้เกิดจากการสุ่มจับคู่โปรไฟล์ที่อยู่ต่าง Entity กัน และมีการตรวจสอบเพื่อตัดคู่ที่ซ้ำกับคู่ Positive Pairs ออกเสมอ ซึ่งผลลัพธ์ในขั้นตอนนี้สามารถสร้างข้อมูลได้ครบถ้วนตามเป้าหมายที่ตั้งไว้
    2) สกัดคู่ Hard Negatives โดยมีการตั้งเป้าหมายอัตราส่วนไว้ที่ 2 เท่าของคู่บวก (8,120,400 คู่) โดยมีเงื่อนไขคือ ต้องเป็นโปรไฟล์ต่างเอนทิตีที่มีค่า userName คล้ายคลึงกันและผ่านเกณฑ์ประเมินที่ระดับ 0.65 ขึ้นไป รวมทั้งต้องไม่ซ้ำซ้อนกับชุดข้อมูลที่สร้างไปแล้ว อย่างไรก็ตาม เมื่อดำเนินการกับชุดข้อมูลจริง พบว่ามีคู่ที่ผ่านเกณฑ์อันเข้มงวดนี้เพียง 302,433 คู่ นัยสำคัญของตัวเลขที่ลดลงนี้ สะท้อนให้เห็นว่า

ชุดข้อมูลในงานวิจัยนี้เป็นผลลัพธ์ที่ได้จากการคัดกรองตามความคล้ายคลึงที่เกิดขึ้นจริง

ตารางที่ 3.5 โครงสร้างชุดคู่ข้อมูลสำหรับการฝึกแบบจำลอง

Pair Type	**จำนวนคู่**	**บทบาทในการฝึก**
Positive pairs	4,060,200	ตัวอย่างคู่ที่เป็นบุคคลเดียวกันจริง
Random negatives	20,301,000	ตัวอย่างคู่ลบทั่วไปเพื่อให้สะท้อน Distribution ของโลกจริง
Hard negatives	302,433	ตัวอย่างคู่ลบที่คล้ายกันมาก เพื่อกด False Positives
รวมทั้งหมด	**24,663,633**	**ชุด Labeled Pairs ที่ใช้ในขั้น Feature Engineering และ Modeling**



รูปที่ 3.6 Pair building pipeline การสร้างชุดคู่ข้อมูลสำหรับการฝึกแบบจำลอง

3.3.4 การสร้าง split artifacts และ feature matrix แบบ chunked

หลังจากได้ชุดคู่ข้อมูล (Labeled Pairs) ขั้นตอนถัดมาคือการแปลงคู่ข้อมูลเหล่านี้ให้เป็นข้อมูลเชิงตัวเลขและเวกเตอร์ เพื่อเตรียมความพร้อมสำหรับการฝึกสอนแบบจำลอง กระบวนการในขั้นตอนนี้ประกอบด้วยการแบ่งชุดข้อมูลและการสกัดคุณลักษณะ ซึ่งมีรายละเอียดดังต่อไปนี้

1. **การแบ่งชุดข้อมูลระดับเอนทิตี (Entity-Level Data Splitting)**
   - **วัตถุประสงค์** เพื่อป้องกันปัญหาข้อมูลรั่วไหล (Data Leakage) ที่ทำให้ผลประเมินสูงเกินจริง โดยเลี่ยงการสุ่มรายโปรไฟล์หรือรายคู่ แล้วเปลี่ยนมาแบ่งตามกลุ่มบุคคลแทน
   - **เกณฑ์การแบ่งสัดส่วน** ระบบใช้ user_folder เป็นตัวแทนของ Entity และทำการสุ่มแบ่งเอนทิตีทั้งหมดออกเป็น 3 ส่วน ในสัดส่วนประมาณ **70 : 15 : 15** โดยกำหนดให้เป็นชุดฝึกสอน (Training Set) 70% ส่วนอีก 30% ที่เหลือถูกแบ่งครึ่งเป็นชุดตรวจสอบ (Validation Set) และชุดทดสอบ (Test Set) ภายใต้เงื่อนไขบังคับคือ **โปรไฟล์ทั้งหมดของบุคคลเดียวกันต้องอยู่ในชุดข้อมูลเดียวกัน**

- **การจัดการคู่ข้อมูลข้ามชุด** เพื่อป้องกัน Data Leakage อย่างเด็ดขาด ระบบจะตัดคู่ข้อมูลที่มีโปรไฟล์อยู่ต่างชุดกันทิ้งทั้งหมด (เช่น ฝั่งหนึ่งอยู่ Train อีกฝั่งอยู่ Test) โดยเก็บไว้เฉพาะคู่ที่ทั้งสองฝั่งอยู่ในชุดเดียวกันเท่านั้น

2. **สถิติและขนาดของชุดข้อมูล (Dataset Statistics)**

จากหลักการแบ่งและคัดกรองข้างต้น ทำให้ได้ชุดข้อมูลผลลัพธ์ที่พร้อมใช้งาน จำนวน 36,807 โปรไฟล์ และ 15,107,705 คู่ข้อมูล รายละเอียดดังตารางที่ 3.6

ตารางที่ 3.6 ขนาดของชุดข้อมูลที่ได้หลังแบ่ง train, validation และ test

ชุดข้อมูล (Split)	**จำนวนโปรไฟล์ (Profiles)**	**จำนวนคู่ข้อมูล (Pairs)**
Training Set	15,848	10,133,486
Validation Set	17,595	4,511,311
Test Set	3,364	462,908
รวมทั้งหมด	**36,807**	**15,107,705**

หมายเหตุ : จำนวนคู่ข้อมูลหลังการแบ่งชุดข้อมูล (15,107,705 คู่) มีจำนวนลดลงจากชุด Labeled Pairs ตั้งต้น (24,663,633 คู่) ส่วนต่างจำนวน 9,555,928 คู่ที่หายไป เกิดจากการบังคับใช้เงื่อนไขตัดคู่ข้อมูลที่เชื่อมข้ามระหว่างชุดออกเพื่อป้องกันข้อมูลรั่วไหล

3. **กลยุทธ์การประมวลผลข้อมูลขนาดใหญ่ (Chunked Processing)**

เนื่องจากปริมาณคู่ข้อมูลมีขนาดใหญ่ถึง 15 ล้านคู่ การประมวลผลทั้งหมดในหน่วยความจำหลัก (RAM) ในคราวเดียวจึงไม่สามารถทำได้ ระบบจึงประยุกต์ใช้เทคนิคการประมวลผลแบบแบ่งส่วนย่อย (Chunked Processing) โดยอ่านข้อมูลและสร้างคุณลักษณะทีละ 100,000 คู่ (Batch Size) แล้วจึงนำผลลัพธ์มารวมกันเป็นตารางข้อมูลขนาดใหญ่ในขั้นตอนสุดท้าย วิธีการนี้ช่วยให้ระบบสามารถจัดการข้อมูลระดับ Big Data ได้อย่างมีประสิทธิภาพ โดยไม่ก่อให้เกิดปัญหาหน่วยความจำเกินพิกัด

4. **การสกัดคุณลักษณะ (Feature Engineering)**

ในแต่ละรอบการประมวลผลส่วนย่อย (Chunk) ระบบจะดำเนินการสร้างคุณลักษณะ (Features) โดยนำข้อมูลจากโปรไฟล์ทั้งสองฝั่งมาคำนวณร่วมกัน เพื่อแปลงให้เป็นเวกเตอร์ตัวเลข 1 แถวต่อ 1 คู่ข้อมูล ซึ่งประกอบด้วยมิติต่าง ๆ ดังนี้

1. **ความคล้ายคลึงของข้อความ (Textual Similarity)** การเปรียบเทียบ userName และ fullName
2. **การวิเคราะห์ประวัติส่วนตัว (Bio Analysis)** การวัดความคล้ายคลึงของ bio ทั้งในเชิงคำศัพท์ผ่านเทคนิค TF-IDF และในเชิงความหมายผ่าน Word Embedding
3. **ข้อมูลบริบทและสัญญาณอื่น ๆ (Contextual Signals)** สัญญาณความเชื่อมโยงจาก URL, Domain, สถานที่ตั้ง (location), รวมถึงข้อมูลบริบทจากการใช้ Mentions และ Hashtags
4. **ข้อมูลพหุรูปแบบ (Multimodal Features)** การนำสัญญาณจากข้อมูลภาพมาวิเคราะห์ร่วมด้วย
5. **ข้อควรระวังเชิงระเบียบวิธีวิจัย (Methodological Rigor)** ในการสร้างตัวแทนเชิงข้อความ เช่น การสร้างพจนานุกรมคำศัพท์สำหรับ TF-IDF ระบบจะดำเนินการฝึกสอน (Fit) บนข้อมูล bio ในชุดข้อมูลฝึกสอน (Training Set) เท่านั้น จากนั้นจึงนำพจนานุกรมดังกล่าวไปแปลงข้อมูล (Transform) ในชุดข้อมูลตรวจสอบ (Validation Set) และชุดข้อมูลทดสอบ (Test Set) วิธีนี้ช่วยป้องกันไม่ให้ข้อมูลจากชุดประเมินไหลย้อนกลับมาส่งผลต่อชุดข้อมูลฝึกสอน

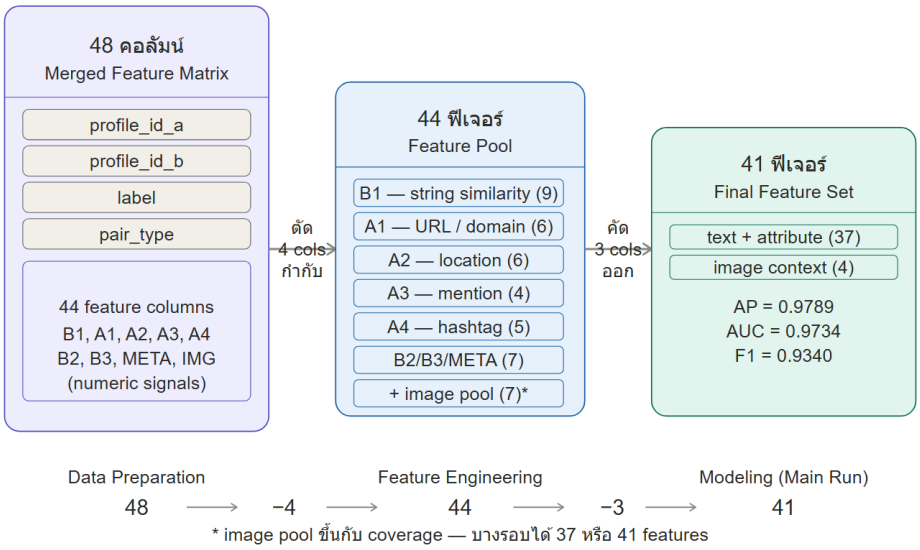
5. **การผสานข้อมูลและวิวัฒนาการของชุดคุณลักษณะ (Feature Merging & Evolution)**

หลังการคำนวณแบบ Chunk เสร็จสิ้น ระบบจะรวมผลลัพธ์เป็น **Merged Feature Matrix** เพื่อส่งต่อจากขั้น Data Preparation ไปยังขั้น Modeling ซึ่งความหมายของ จำนวนคอลัมน์ตามลำดับ Pipeline เป็น 3 ระดับ มีดังนี้

- **48 คอลัมน์ (Merged Feature Matrix)** ตารางข้อมูลหลังกระบวนการ Merge ซึ่งยังคงรวมคอลัมน์ระบุตัวคู่และคอลัมน์กำกับไว้ด้วย ได้แก่ profile_id_a, profile_id_b, label, และ pair_type
- **44 คุณลักษณะ (Feature Pool)** ชุดคุณลักษณะเชิงตัวเลขที่เหลืออยู่หลังจากตัดคอลัมน์กำกับออก เป็นกลุ่มคุณลักษณะตั้งต้นที่พร้อมป้อนเข้าสู่แบบจำลอง

- **41 คุณลักษณะ (Final Feature Set)** ชุดคุณลักษณะที่ถูกคัดเลือกไปใช้งานจริงในรอบการทดลองหลักของสายการวิเคราะห์แบบ Multimodal

แต่สะท้อนให้เห็นลำดับของกระบวนการ กล่าวคือ ขั้น Data Preparation ทำหน้าที่สร้างตารางให้พร้อมใช้ จากนั้นตัดคอลัมน์ที่ไม่จำเป็นออก และในขั้น Modeling จึงทำการคัดเลือกเฉพาะคุณลักษณะที่สะท้อนสัญญาณได้ดีที่สุดไปใช้งานจริง



รูปที่ 3.7 ลำดับการลดทอนคอลัมน์และคัดเลือกคุณลักษณะก่อนเข้าสู่กระบวนการฝึกสอนตัวแบบ

6. รูปแบบการคำนวณและการแปลงรูปทางคณิตศาสตร์ (Mathematical Formulations)

ในเชิงวิธีการคำนวณ ระบบไม่ได้ป้อนข้อมูลดิบของโปรไฟล์เข้าสู่แบบจำลองโดยตรง แต่ใช้การเปรียบเทียบข้อมูลจากโปรไฟล์ทั้งสองฝั่งทีละมิติ แล้วแปลงผลลัพธ์ให้เป็นค่าตัวเลขหนึ่งค่าในแต่ละคุณลักษณะ หากกำหนดให้โปรไฟล์สองฝั่งคือ A และ B เวกเตอร์คุณลักษณะของคู่ข้อมูลจะอยู่ในรูปแบบ

$$x_{A,B} = [f_1(A,B), f_2(A,B), \ldots, f_k(A,B)]$$

โดย $f_i(A, B)$ คือฟังก์ชันที่ใช้วัดความคล้ายคลึง ความแตกต่าง อัตราส่วน หรือสถานะของโปรไฟล์คู่นั้น ในทางปฏิบัติ คุณลักษณะที่ใช้ในงานนี้สามารถอธิบายด้วยรูปแบบการคำนวณหลัก 7 รูปแบบ ดังนี้

1. **การเทียบสถานะแบบตรงกัน (Exact Match)** ใช้เมื่อต้องการตรวจสอบความตรงกันโดยสมบูรณ์ เช่น domain_exact_match

$$f(A, B) = \begin{cases} 1, & \text{ถ้าค่าตรงกันและไม่ว่าง} \\ 0, & \text{ในกรณีอื่น ๆ} \end{cases}$$

2. **การวัดความคล้ายคลึงของข้อความ (String Similarity)** ใช้กับชื่อและตำแหน่งที่ตั้ง เพื่อรองรับกรณีที่พิมพ์ไม่ตรงกันแบบตัวต่อตัว โดยมีสมการที่ใช้ ได้แก่

- Jaro-Winkler : $f(A, B) = JW(a, b)$
- Normalized Levenshtein : $f(A, B) = 1 - \frac{Lev(a,b)}{max(|a|,|b|,1)}$
- Token-sort Ratio : $f(A, B) = \frac{TokenSort(a,b)}{100}$

3. การวัดความทับซ้อนของชุดข้อมูล (Set Overlap) ใช้กับข้อมูลที่มีลักษณะเป็นกลุ่มคำ เช่น โดเมน, URL, Mentions และ Hashtags โดยประยุกต์ใช้ Jaccard Similarity

4. $f(A, B) = \frac{|S_A \cap S_B|}{|S_A \cup S_B|}$

5. การวัดความคล้ายคลึงเชิงความหมาย (Semantic Similarity) ใช้เปรียบเทียบเนื้อหาในระดับความหมาย สำหรับข้อความ Bio และ Caption ภาพ ผ่านการหาค่า Cosine Similarity ของเวกเตอร์ (เช่น TF-IDF หรือ SBERT)

6. ~~$f(A, B) = \cos(v_A, v_B)$~~ $f(A, B) = \cos(v_A, v_B)$

7. การวัดความแตกต่างและอัตราส่วน (Difference & Ratio) ใช้กับคุณลักษณะเชิงสถิติ เช่น ความยาวข้อความ, ความสว่างภาพ, และขนาดไฟล์

   - **ความแตกต่าง (*Absolute Difference) :*** $\mathrm{f(A,B)} = |\mathrm{x_A} - \mathrm{x_A}|$
   - **อัตราส่วน (*Min-Max Ratio) :*** $\mathrm{f(A,B)} = \frac{\min(\mathrm{x_A},\mathrm{x_B})}{\max(\mathrm{x_A},\mathrm{x_B},\in)}$

8. การวัดความใกล้เคียงเชิงภูมิศาสตร์ (Geographic Proximity) เมื่อข้อมูลตำแหน่งถูกแปลงเป็นพิกัด ระยะทาง (d) จะถูกคำนวณผ่านสูตร Haversine และแปลงเป็นค่าความคล้ายคลึง

$$\mathrm{f(A,B)} = \mathrm{e}^{-\frac{\mathrm{d}}{100}}$$

9. การเชื่อมสัญญาณข้ามสื่อ (Cross-modal Token Matching) เป็นการนำข้อมูลข้อความอธิบายภาพจากฝั่งหนึ่ง ไปตรวจสอบความสอดคล้องกับข้อความพื้นฐานของโปรไฟล์อีกฝั่งหนึ่งโดยตรง เพื่อเพิ่มมิติการวิเคราะห์ข้ามรูปแบบ ซึ่งวิธีการนี้ช่วยให้ระบบสามารถใช้สัญญาณจากภาพ เพื่อยืนยันความสอดคล้องกับชื่อหรือข้อความของโปรไฟล์อีกฝั่งหนึ่งได้ ในงานวิจัยนี้ คุณลักษณะกลุ่มดังกล่าวถูกประเมินด้วย การเปรียบเทียบแบบสองทิศทาง (Bidirectional Comparison) คือ ระบบจะเปรียบเทียบคำบรรยายภาพของฝั่ง A กับข้อความของฝั่ง B และในขณะเดียวกันก็เปรียบเทียบคำบรรยายภาพของฝั่ง B กับข้อความของฝั่ง A จากนั้นจึงเลือกค่าผลประเมินที่สูงกว่ามาเป็นค่าคุณลักษณะสุดท้าย

10.

   - สำหรับคุณลักษณะ Feature image_caption_fullname_token_cross สามารถเขียนสมการได้ดังนี้

$$f_{\text{cap-fullname}}(A, B) = \max\left(\frac{\text{TokenSort}(c_A, n_B)}{100}, \frac{\text{TokenSort}(c_B, n_A)}{100}\right)$$

11. โดยที่ $\boldsymbol{c_A}$ และ $\boldsymbol{c_B}$ คือคำบรรยายภาพจากฝั่ง A และ B ตามลำดับ ส่วน $\boldsymbol{n_A}$ และ $\boldsymbol{n_B}$ คือ fullName ที่ผ่านการ Normalize แล้วของแต่ละฝั่ง

- สำหรับคุณลักษณะ image_caption_username_token_cross จะใช้โครงสร้างสมการเดียวกัน แต่เปลี่ยนชุดข้อมูลอ้างอิงเป็น userName

$$f_{\text{cap-username}}(A, B) = \max\left(\frac{\text{TokenSort}(c_A, u_B)}{100}, \frac{\text{TokenSort}(c_B, u_A)}{100}\right)$$

โดยที่ u_Aและ u_B คือข้อมูล userName ที่ผ่านการปรับมาตรฐานแล้ว ค่าผลลัพธ์ที่ได้จะอยู่ในช่วง 0 ถึง 1 ซึ่งค่าที่ยิ่งสูง จะยิ่งสะท้อนให้เห็นว่าคำบรรยายภาพของโปรไฟล์ฝั่งหนึ่ง มีถ้อยคำที่ใกล้เคียงกับชื่อหรือชื่อบัญชีของอีกฝั่งหนึ่งอย่างมีนัยสำคัญ

7. โครงสร้างข้อมูลรายคู่ (Pairwise Feature Matrix Row)

Feature Matrix มีขนาด 1 แถวต่อ 1 คู่ข้อมูล หมายความว่า ข้อมูลใน 1 แถว จะประกอบไปด้วยองค์ประกอบ 3 ส่วนหลัก

12. คอลัมน์ระบุตัวคู่ (Identifier Columns) เช่น profile_id_a และ profile_id_b

13. คอลัมน์กำกับ (Label Columns) เช่น label และ pair_type

14. ชุดคุณลักษณะเชิงเปรียบเทียบ คือชุดตัวแปรที่ผ่านการคำนวณจากทั้งสองฝั่ง

15. ระบบในงานวิจัยนี้ไม่ได้ป้อนข้อมูลดิบของโปรไฟล์แต่ละฝั่งเข้าสู่แบบจำลองโดยตรง แต่เป็นการป้อน ผลลัพธ์จากการเปรียบเทียบความสัมพันธ์ระหว่างสองโปรไฟล์ในรูปแบบเวกเตอร์ตัวเลขแทน ดังรายละเอียดที่แจกแจงในตารางที่ 3.7

16.

ตารางที่ 3.7 แจกแจงคุณลักษณะ 41 ตัวที่ถูกใช้จริงในแบบจำลองหลัก

กลุ่มคุณลักษณะ	**จำนวน**	**วิธีการคำนวณโดยย่อ**	**รายชื่อคุณลักษณะ (Features)**
Identity string	6	วัดความคล้ายของ userName และ fullName ด้วย String Similarity หลายรูปแบบ	username_jaro, username_lev, username_token_sort, fullname_jaro, fullname_lev, fullname_token_sort
Bio text semantics	2	วัดความคล้ายของ bio ทั้งเชิงคำและเชิงความหมาย	bio_tfidf_cosine, bio_sbert_cosine
URL / domain	4	วัดการซ้อนทับของ URL และโดเมน พร้อมนับจำนวนโดเมน	domain_jaccard, url_jaccard, domain_count_a, domain_count_b
Location	2	วัดความคล้ายของตำแหน่งที่ตั้งหลังการปรับมาตรฐาน	location_jaro, location_token_sort
Mention / hashtag	4	วัดการซ้อนทับของ Mentions และ Hashtags ใน bio	mention_jaccard, hashtag_jaccard, hashtag_count_a, hashtag_count_b
Stylometric	4	วัดความต่างของรูปแบบการเขียน เช่น การใช้ตัวพิมพ์ใหญ่ ความยาวคำและวรรคตอน	style_caps_diff, style_avgword_diff, style_biolen_ratio, style_punct_diff

ตารางที่ 3.7 (ต่อ) แจกแจงคุณลักษณะ 41 ตัวที่ถูกใช้จริงในแบบจำลองหลัก

กลุ่มคุณลักษณะ	จำนวน	วิธีการคำนวณโดยย่อ	รายชื่อคุณลักษณะ (Features)
Platform / metadata	1	เข้ารหัสชนิดของคู่แพลตฟอร์มที่กำลังเปรียบเทียบ	platform_pair_code
Image availability	3	ตรวจสอบว่าคู่โปรไฟล์มีข้อมูลภาพส่วนตัว (Local Image) พร้อมใช้หรือไม่	image_any_local, image_both_local, image_one_local_only
Image statistics	11	วัดความคล้ายของภาพจาก Hash และความแตกต่างของคุณภาพภาพเชิงสถิติ	image_phash_sim, image_dhash_sim, image_brightness_diff, image_contrast_diff, image_entropy_diff, image_rgb_l1, image_filesize_ratio, image_face_count_diff, image_face_area_diff, image_blur_diff, image_metadata_any
Image-caption context	4	ใช้ข้อความอธิบายภาพ (Caption) เชื่อมกับข้อความพื้นฐานของอีกฝั่งหนึ่งข้ามสื่อ	image_caption_any, image_caption_bio_sbert_cross, image_caption_fullname_token_cross, image_caption_username_token_cross

ตารางที่ 3.8 ขนาดของ Feature Matrices ที่พร้อมใช้ในการฝึกสอนและประเมินผล

ชุดข้อมูล	จำนวนแถว	จำนวนคอลัมน์	บทบาทในการทดลอง
ชุดฝึกสอน (Training Set)	10,133,486	48	ใช้ฝึกสอนให้แบบจำลองเรียนรู้รูปแบบ
ชุดตรวจสอบ (Validation Set)	4,511,311	48	ใช้ประเมินเพื่อเลือกแบบจำลองที่ดีที่สุดและกำหนด Threshold
ชุดทดสอบ (Test Set)	462,908	48	ใช้ประเมินประสิทธิภาพการทำงานในขั้นสุดท้าย (Final Evaluation)

3.4 การสร้างแบบจำลอง (Modeling)

หลังจากได้ feature matrices แล้ว ขั้น Modeling ของโครงการนี้ไม่ได้เลือกแบบจำลองเพียงตัวเดียวตั้งแต่ต้น แต่ใช้การทดลองเปรียบเทียบหลายสายเพื่อให้ตอบคำถามวิจัย 3 ข้อได้แก่

- แบบจำลองกลุ่มใดจัดการข้อมูลแบบตารางของงานนี้ได้ดีที่สุด?
- การเพิ่มข้อมูลภาพและบริบทข้ามสื่อช่วยแยกแยะโปรไฟล์ที่กำกวมได้จริงหรือไม่?
- เมื่อเทียบกับแบบจำลอง Deep Learning แล้ว แบบจำลองที่ตีความง่ายกว่าและดูแลง่ายกว่าสามารถให้ผลลัพธ์ที่เพียงพอหรือดีกว่าหรือไม่?

3.4.1 โครงสร้างสายการทดลองหลัก (Experimental Tracks)

การสร้างแบบจำลองในงานวิจัยนี้ถูกแบ่งออกเป็น 3 สายการทดลองที่แยกขาดจากกัน เพื่อให้แต่ละคำถามวิจัยมีกรอบการพิสูจน์ที่ชัดเจน โดยเน้นการควบคุมตัวแปรไม่ให้ปะปนกัน หลักการนี้ช่วยให้สามารถเปรียบเทียบผลลัพธ์ระหว่างสายได้ และมีเหตุผลรองรับในการคัดเลือกแบบจำลองสุดท้าย ดังสรุปในตารางที่ 3.9

ตารางที่ 3.9 สรุปสายการทดลองหลักในขั้นตอน Modeling

สายการทดลอง	แนวทางที่ใช้	สิ่งที่ต้องการพิสูจน์	บทบาทในงานวิจัย
Classical Leakage-safe	ฝึกแบบจำลองหลายตระกูลบนข้อมูลชุดเดียวกัน ภายใต้การควบคุม Data Leakage	แบบจำลองกลุ่มใดเหมาะกับข้อมูลเชิงตารางของงานนี้มากที่สุด	ใช้เป็นฐานเปรียบเทียบของระบบ
Multimodal Suite	ทยอยเพิ่มข้อมูลจากภาพเข้าไปทีละระดับบนแกนทดลองเดียวกัน	ข้อมูลภาพช่วยเพิ่มประสิทธิภาพการแยกแยะคู่กำกวมได้จริงหรือไม่	ใช้กำหนด ชุดคุณลักษณะสำหรับ Final Run
Neural Reference	ฝึกโครงข่ายประสาทเทียม (Neural Network) บนชุดข้อมูลเดียวกัน	แบบจำลองเชิงลึกให้ประโยชน์คุ้มค่ากับความซับซ้อนที่เพิ่มขึ้นหรือไม่	ใช้ยืนยันความเหมาะสมของคำตอบสุดท้าย

ตารางที่ 3.10 สรุปเกณฑ์ที่ใช้คัดเลือกแบบจำลองในขั้น Modeling

สายการทดลอง	ตัวชี้วัดที่ใช้คัดเลือก	วิธีตัดสิน
Classical leakage-safe	validation AP, validation ROC-AUC, validation F1	เลือก model family ที่ดีที่สุดบน validation set แล้วค่อยหา threshold
Multimodal suite	composite score, validation AP, validation F1, validation ROC-AUC	เปรียบเทียบแต่ละชุด feature ภายใต้เงื่อนไขเดียวกัน แล้วเลือก best run
Neural reference	validation AP, early stopping result, validation F1 หลัง calibration	ใช้เป็น reference ไม่ได้บังคับให้ต้องชนะทุกตัวชี้วัด

3.4.2 สายการทดลอง Classical Leakage-Safe (การหาฐานเปรียบเทียบจากข้อมูลตาราง)

แม้ปัญหางานวิจัยนี้จะเป็นการจำแนกประเภท Binary Classification เพื่อระบุว่าโปรไฟล์สองรายการเป็นบุคคลเดียวกันหรือไม่ แต่ข้อมูลนำเข้าได้ถูกแปลงให้อยู่ในรูปของเมทริกซ์คุณลักษณะเชิงตาราง ที่ผ่านการคำนวณความคล้ายคลึงและความแตกต่างมาแล้ว ลักษณะข้อมูลเช่นนี้จึงเหมาะสมกับ แบบจำลองกลุ่มคลาสสิก (Classical Models) เนื่องจากสามารถเรียนรู้เส้นแบ่งการตัดสินใจได้ดี มีความเสถียร ตีความผลลัพธ์ได้ง่ายและรองรับการปรับเทียบได้อย่างเป็นระบบ

เพื่อพิสูจน์ว่าโครงสร้างข้อมูลที่เตรียมไว้เหมาะกับแบบจำลองกลุ่มใดมากที่สุด กระบวนการในสายการทดลองนี้จึงถูกกำหนดกรอบการทำงานไว้ 4 ประเด็นหลัก ดังนี้

1) **การควบคุมการรั่วไหลของข้อมูล**

- **การแบ่งชุดข้อมูล** ยึดหลักการแบ่งข้อมูลระดับเอนทิตี (Entity-level Split) เพื่อรับประกันว่าจะไม่มีโปรไฟล์ของบุคคลเดียวกันหลุดรอดไปอยู่ต่างชุดข้อมูล (Train, Validation, Test)
- **การปรับสเกลข้อมูล (Feature Scaling)** ระบบจะคำนวณค่าสถิติจากชุด Training Set เพียงชุดเดียวเท่านั้น แล้วจึงนำค่าพารามิเตอร์ดังกล่าวไปแปลงข้อมูลในชุด Validation และ Test วิธีนี้ช่วยให้ทุกแบบจำลองถูกฝึกสอนบนฐานข้อมูลเดียวกันภายใต้เงื่อนไขเดียวกัน

2) **การคัดเลือกและเปรียบเทียบตระกูลแบบจำลอง**

กำหนดขอบเขตการเปรียบเทียบไว้ที่แบบจำลอง 3 รูปแบบหลัก ซึ่งเป็นตัวแทนของแนวคิดการเรียนรู้ที่แตกต่างกันอย่างชัดเจน

- **แบบจำลองเชิงเส้น (Linear Models)** ใช้เป็นเส้นฐานอ้างอิงที่เรียบง่ายที่สุด (Simple Baseline) เพื่อทดสอบว่าปัญหาเบื้องต้นนี้จำเป็นต้องใช้กลไกที่ซับซ้อนหรือไม่
- **แบบจำลองต้นไม้แบบ Boosting (Boosting Trees)** ใช้ทดสอบประสิทธิภาพในการจับความสัมพันธ์แบบ Non-linear และ Feature Interactions ซึ่งเป็นจุดเด่นของชุดข้อมูลประเภทความคล้ายคลึง

- **แบบจำลองต้นไม้แบบ Bagging (Bagging Trees)** ใช้ทดสอบแนวทางที่เน้นความเสถียรสูง (Robustness) และทนทานต่อ Noise ผ่านการเฉลี่ยคำตอบจากหลายแบบจำลอง

3) การกำหนดหน้าที่ของชุดข้อมูล

เพื่อให้กระบวนการประเมินผลมีความน่าเชื่อถือเชิงวิชาการ ชุดข้อมูลทั้งสามจึงถูกกำหนดหน้าที่แยกขาดจากกัน

- **Training Set** ใช้สำหรับเรียนรู้พารามิเตอร์ของแบบจำลอง
- **Validation Set** ใช้ประเมินผลด้วยเมตริกที่รองรับปัญหาข้อมูลไม่สมดุล (Class Imbalance) เพื่อจัดอันดับและคัดเลือกแบบจำลองที่ดีที่สุด นอกจากนี้ยังใช้สำหรับทำ Probability Calibration และค้นหา Threshold ที่เหมาะสมที่สุดสำหรับการใช้งานจริง
- **Test Set** ใช้ประเมินประสิทธิภาพขั้นสุดท้ายด้วย Threshold ที่ได้จาก Validation Set โดยข้อมูลชุดนี้จะไม่มีส่วนในการตัดสินใจเลือกระหว่างทางอย่างเด็ดขาด

4. **บทสรุปและบทบาทของสายการทดลอง**

เป้าหมายสูงสุดของสายการทดลอง Classical Leakage-Safe ไม่ได้หยุดอยู่แค่การหาว่าแบบจำลองใดได้คะแนนสูงสุด แต่ทำหน้าที่เป็น ฐานอ้างอิงหลัก (Primary Baseline) ของทั้งโครงการ เพื่อยืนยันให้ชัดเจนว่า การจำกัดการทดลองไว้แค่ 3 ตระกูลแบบจำลองหลัก ช่วยลดความซ้ำซ้อนจากการฝึกสอนแบบจำลองฟที่การทำงานคล้ายกัน ทำให้ได้ข้อสรุปที่ตรงประเด็นและคุมต้นทุนการคำนวณได้ อีกทั้งเป็นการหาคำตอบให้ชัดเจนก่อนว่า ถ้ายึดแค่คุณลักษณะข้อความและแอตทริบิวต์ โครงสร้างข้อมูลตารางที่เตรียมมานั้น ทำงานได้ดีกับแบบจำลองตระกูลไหนที่สุด ซึ่งแบบจำลองที่ชนะจากขั้นนี้ จะถูกยกไปเป็นแกนหลักในสาย Multimodal ทันที เพื่อใช้วัดว่า คุณลักษณะภาพช่วยเพิ่มความแม่นยำแค่ไหนในขั้นตอนต่อไป โดยไม่ต้องเริ่มทดลองใหม่

3.4.3 สายการทดลอง Multimodal Suite (การประเมินคุณลักษณะภาพ)

หลังจากได้ฐานเปรียบเทียบจากสายแรกแล้ว ระบบได้นำแบบจำลองที่ดีที่สุดมาทดลองเพิ่มคุณลักษณะจากภาพอย่างเป็นลำดับขั้น เพื่อตรวจสอบว่าข้อมูลภาพช่วยยกระดับความแม่นยำได้จริงหรือไม่ โดยยังคงเงื่อนไขการแบ่งชุดข้อมูลไว้ดังเดิม เพื่อให้ผลต่างที่เกิดขึ้นสะท้อนถึง

ประสิทธิภาพที่เปลี่ยนไปโดยเกิดจากภาพอย่างแท้จริง โดยมีโครงสร้างการทำงานแบ่งออกเป็น 4 ส่วนสำคัญ ดังนี้

1) **การเตรียมข้อมูลส่วนกลาง** ระบบจะโหลดข้อมูลที่ต้องใช้ร่วมกันในทุกชุดการทดลอง เช่น SBERT Embeddings และ Image Descriptors มาเก็บไว้ในหน่วยความจำ (Cache) วิธีนี้ช่วยลดความคลาดเคลื่อนจากการคำนวณซ้ำ และลดระยะเวลาในการประมวลผลได้อย่างมาก
2) **การระบุระดับของคุณลักษณะ** ระบบจะเพิ่มคุณลักษณะตามระดับการทดลอง 3 รูปแบบ ได้แก่
   - text_attr_hybrid เส้นฐานที่ใช้เฉพาะข้อความและแอตทริบิวต์
   - image_stats เพิ่มคุณลักษณะภาพระดับสถิติ เช่น Perceptual Hash, ความสว่าง, ขนาดไฟล์
   - image_context เพิ่มคุณลักษณะบริบทข้ามสื่อ เช่น การนำข้อความอธิบายภาพไปเทียบกับ SBERT Embeddings ของประวัติส่วนตัวฝั่งตรงข้าม
3) **การฝึกสอนและประเมินผล** ทุกชุดการทดลองจะถูกฝึกสอนภายใต้ค่ากำหนดเดียวกัน เพื่อให้เปรียบเทียบกันได้อย่างยุติธรรม ผลลัพธ์จะถูกจัดอันดับด้วยค่าคะแนนรวม ซึ่งคำนวณจากสมการ

$$\text{Composite Score} = 0.45 * \text{Average Precision} + 0.35 * \text{F1} - \text{Score} + 0.20 * \text{ROC} - \text{AUC}$$

โดยมีหลักการและเหตุผลของการถ่วงน้ำหนักคือการป้องกันความเอนเอียงจากการตัดสินแบบจำลองด้วยตัวชี้วัดเพียงค่าเดียว งานวิจัยนี้จึงกระจายน้ำหนักการประเมินดังนี้

- Average Precision (AP) [น้ำหนัก 45%] ให้น้ำหนักสูงสุด เนื่องจากชุดข้อมูลมีปัญหา Class Imbalance สูง ตัวชี้วัดนี้จึงสะท้อนคุณภาพการจัดอันดับคู่ข้อมูลที่มีแนวโน้มเป็นบุคคลเดียวกันได้ดีที่สุด
- F1-score [น้ำหนัก 35%] ใช้สะท้อนความสมดุลระหว่างความแม่นยำ (Precision) และความครอบคลุม (Recall) ณ จุดตัด (Threshold) ที่เลือก ซึ่งการันตีว่าโมเดลพร้อมนำไปใช้งานจริง

- ROC-AUC [น้ำหนัก 20%] ให้น้ำหนักน้อยที่สุด เพราะแม้จะใช้วัดความสามารถในการแยกแยะคลาสในภาพรวมได้ แต่ในชุดข้อมูลที่ Imbalance สูง ค่านี้มักจะมีแนวโน้มสูงเกินจริงและไม่สะท้อนคุณภาพการจัดอันดับที่แท้จริง

4) **สรุปผลการทดลอง** จากรายงานผล พบว่าชุดการทดลองแบบ image_context รวม 41 คุณลักษณะ ให้ผลลัพธ์ดีที่สุด โดยมีความสมดุลระหว่างประสิทธิภาพและความสามารถในการตีความ ซึ่งช่วยยืนยันความสัมพันธ์ได้ชัดเจนกว่า

ตารางที่ 3.11 ระดับการทดลองในสาย Multimodal Suite

ชุดการทดลอง	จำนวนคุณลักษณะ	คุณลักษณะที่เพิ่มจากเส้นฐาน	จุดประสงค์การประเมิน
text_attr_hybrid	23	ใช้ข้อความและแอตทริบิวต์เป็นหลัก	ใช้เป็นเส้นฐาน (Baseline) สำหรับเปรียบเทียบ
image_stats	37	เพิ่ม Metadata และ Hash ภาพ	ทดสอบประโยชน์ของภาพในระดับสถิติ
image_context	41	เพิ่มการเชื่อมโยงภาพกับข้อความโดยตรง	ทดสอบประโยชน์ของการวิเคราะห์บริบทข้ามสื่อ (Cross-modal) ช่วยแยกคู่กำกวมได้ไหม

3.4.4 การฝึกโครงข่ายประสาทเทียมเพื่อเป็นเส้นฐานอ้างอิง (Neural Reference Model)

แม้งานวิจัยนี้จะเลือกใช้แบบจำลองตระกูล Tree Ensemble เป็นหลัก แต่ได้มีการพัฒนาสายโครงข่ายประสาทเทียมไว้เป็นแบบจำลองอ้างอิง เพื่อพิสูจน์ว่าความซับซ้อนที่เพิ่มขึ้นให้ประโยชน์คุ้มค่าหรือไม่ กระบวนการพัฒนาในสายนี้ประกอบด้วย

- **การจัดการข้อมูล** ใช้ข้อมูลชุด Train, Validation และ Test เดียวกับสายอื่น แต่มีการทำสุ่มลดจำนวนข้อมูลกลุ่มลบ (Undersampling Negatives) ในชุด Train เพื่อป้องกันไม่ให้ข้อมูลกลุ่มลบครอบงำการฝึกสอน (Class Imbalance) จากนั้นจึงทำการปรับสเกลข้อมูล

- **สถาปัตยกรรม** ใช้แบบจำลอง IdentityMLP ขนาด Hidden Layers [256, 128, 64] โดยแต่ละชั้นประกอบด้วย Linear, BatchNorm1d, ReLU และ Dropout
- **การฝึกสอน** ใช้ฟังก์ชันการสูญเสียแบบ Focal Loss เพื่อรับมือกับความไม่สมดุลของข้อมูล ใช้ตัวปรับพารามิเตอร์แบบ Adam และใช้เทคนิค Early Stopping เพื่อหยุดการฝึกอัตโนมัติเมื่อค่าความแม่นยำ (Validation AP) เริ่มคงที่
- **การปรับตั้งค่า** หลังจากการฝึกสอนเสร็จสิ้น ระบบจะทำการปรับเทียบความน่าจะเป็นและค้นหาค่าจุด Threshold ที่ให้ค่า F1 สูงที่สุดเช่นเดียวกับโมเดลกลุ่มอื่น

เพื่อความชัดเจนในการอ้างอิง ค่าตั้งต้น (Hyperparameters) ที่สำคัญของแบบจำลองทุกกลุ่มในขั้นตอน Modeling ได้ถูกสรุปไว้ในตารางที่ 3.10

ตารางที่ 3.12 สรุปค่าตั้งต้นไฮเปอร์พารามิเตอร์ของแบบจำลองหลักในขั้นตอน Modeling

กลุ่มแบบจำลอง	ไฮเปอร์พารามิเตอร์
Linear baseline	max_iter = 2000, class_weight = balanced
Tree-based boosting	n_estimators = 300, learning_rate = 0.05, max_depth = 6
Tree-based bagging	n_estimators = 400, max_depth = 18, min_samples_leaf = 2, class_weight = balanced_subsample
Neural reference	hidden_layers = [256, 128, 64], dropout = 0.3, focal_alpha = 0.25, focal_gamma = 2.0, lr = 1e-3, epochs = 30, patience = 5, train_neg_ratio = 3.0
Multimodal suite	random_neg_ratio = 0.75, hard_neg_ratio = 2.0, seed = 42

3.4.5 การปรับเทียบ (Calibration) และการกำหนดจุดตัด (Threshold)

ไม่ว่าจะเป็นแบบจำลองจากสายการทดลองใด ทุกแบบจำลองจะต้องผ่านกระบวนการจัดการผลลัพธ์ 2 ขั้นตอนเสมอ โดยดำเนินการบน Validation Set เท่านั้น ได้แก่

1) **Probability Calibration** นำคะแนนความน่าจะเป็นที่ได้จากแบบจำลองไปผ่านอัลกอริทึม Isotonic Regression บนชุด Validation เพื่อปรับการกระจายตัวของคะแนนให้สะท้อนความน่าจะเป็นที่แท้จริง
2) **Threshold Selection** ค้นหาจุดตัดที่สร้างสมดุลระหว่างการจับคู่ผิด (False Positive) และการพลาดคู่จริง (False Negative) ให้สอดคล้องกับวัตถุประสงค์การใช้งาน

ผลลัพธ์จากแบบจำลองในงานวิจัยนี้จะต้องถูกส่งต่อไปยังระบบตัดสินใจของ CRM หากไม่มีการปรับเทียบคะแนน การตั้งค่าจุดตัดเพื่อใช้งานจริงจะขาดความเสถียร นอกจากนี้ การบังคับใช้ให้ทั้งสองขั้นตอนดำเนินการบนชุด Validation เท่านั้น เป็นหลักการสำคัญที่ช่วยรักษาความน่าเชื่อถือทางวิชาการและป้องกันการอธิบายผลเกินจริง (Overfitting)

3.4.6 หลักเกณฑ์และผลการคัดเลือกแบบจำลองสุดท้าย (Final Model Selection)

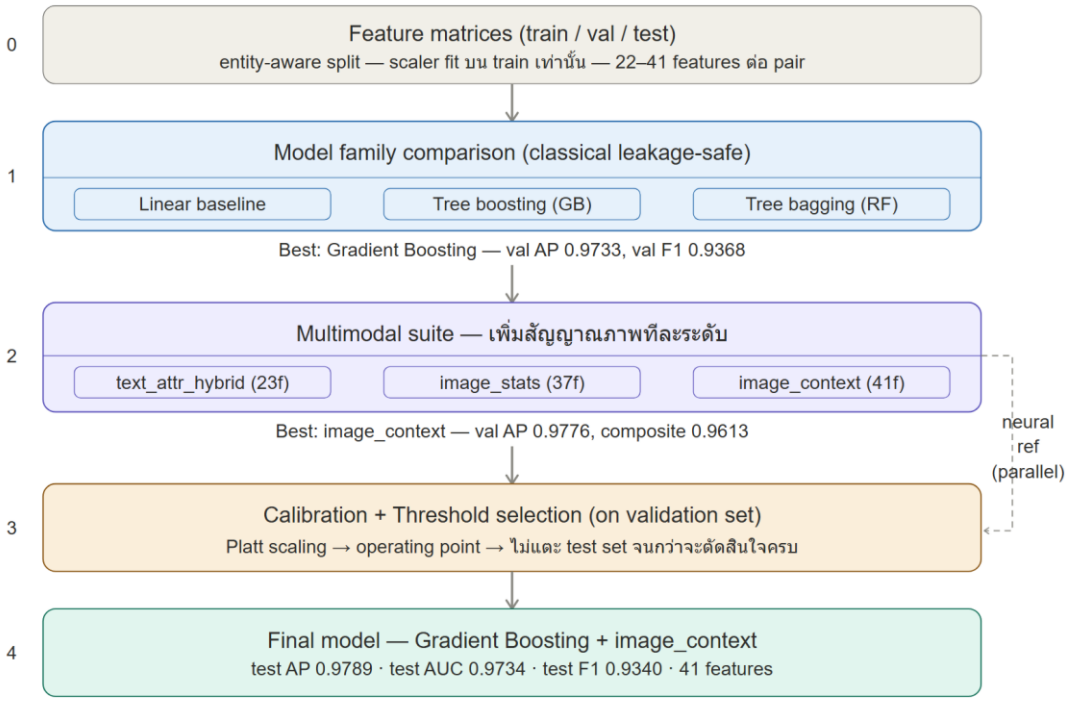
การคัดเลือกแบบจำลองเพื่อใช้งานจริง พิจารณาจาก 4 มิติหลัก ได้แก่

- ประสิทธิภาพบนชุดข้อมูลที่ควบคุม Leakage
- ความเหมาะสมกับลักษณะของตารางคุณลักษณะ
- ความสามารถในการอธิบายข้อผิดพลาด
- ความพร้อมในการเชื่อมต่อกับระบบ CRM

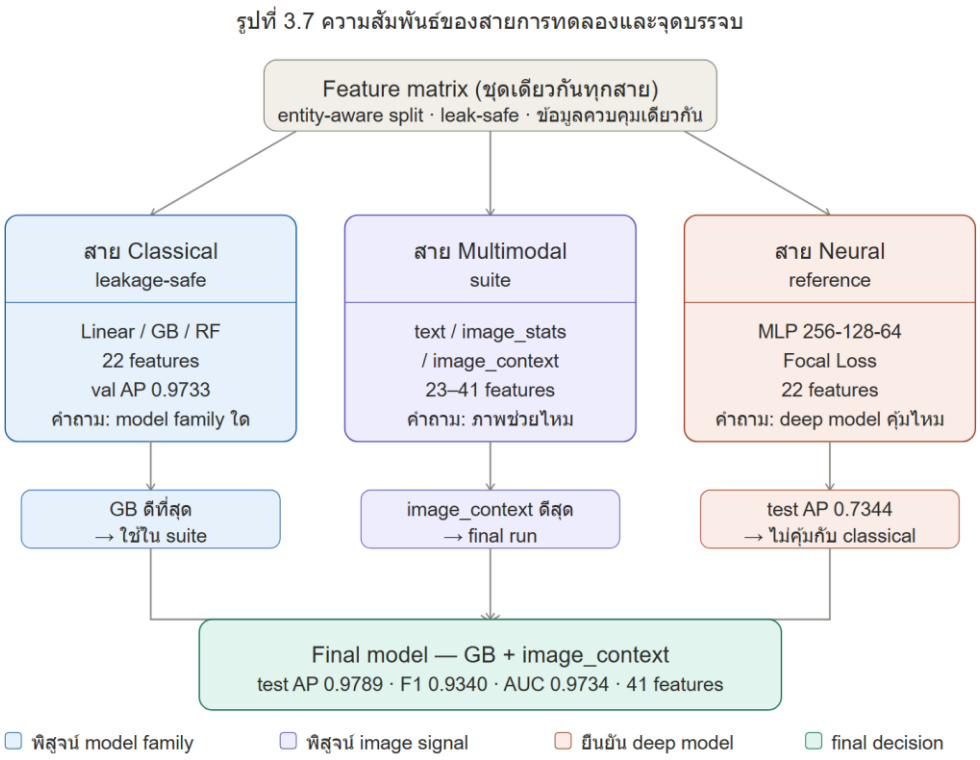
แบบจำลองที่ถูกเลือกเป็น Final Model คือ **Gradient Boosting** จากชุดการทดลอง image_context สาเหตุหลักมาจากข้อมูลคุณลักษณะส่วนใหญ่เป็นค่าความคล้ายคลึงและข้อมูลเชิงสถิติ ซึ่งแบบจำลองกลุ่ม Tree Ensemble สามารถจับความสัมพันธ์แบบไม่เป็นเชิงเส้นได้ดีเยี่ยม โดยไม่จำเป็นต้องพึ่งพาโครงข่ายประสาทเทียมที่ใช้ทรัพยากรสูงกว่า ดังสรุปผลการประเมินในตารางที่ 3.11

ตารางที่ 3.13 สรุปผลเชิงตัวเลขและการคัดเลือกแบบจำลองในแต่ละสายการทดลอง

สายการทดลอง	**แบบจำลองที่ดีที่สุด**	**จำนวนคุณลักษณะ**	**ตัวชี้วัดสำคัญ**	**ผลการทดสอบ**
1. Classical Leakage-safe	Gradient Boosting	22	Avg_Precision = 0.9733 F1 = 0.9368	Avg_Precision = 0.9703 F1 = 0.9337
2.Multimodal Suite (Final Model)	image_context	41	Composite_Score = 0.9613 Avg_Precision = 0.9776 F1 = 0.9339	Avg_Precision = 0.9789 F1 = 0.9340
3. Neural Reference	IdentityMLP	22	Avg_Precision ≈ 1.0000	Avg_Prec



รูปที่ 3.7 ลำดับขั้น Model Development Pipeline



รูปที่ 3.8 ความสัมพันธ์ของสายการทดลองและจุดบรรจบ

3.5 การประเมินผล (Evaluation)

การประเมินผลในงานวิจัยนี้ ไม่ได้วัดเฉพาะความแม่นยำของแบบจำลองเพียงอย่างเดียว แต่ถูกออกแบบให้ประเมินประสิทธิภาพการทำงานของระบบตลอดทั้งสาย (End-to-End Pipeline) เนื่องจากผลลัพธ์ของงาน Identity Resolution ในระบบ CRM ต้องอาศัยการทำงานร่วมกันหลายขั้นตอน

3.5.1 กรอบการประเมินผลและตัวชี้วัดที่ใช้

- ระดับการประเมินออกเป็น 4 ระดับ ในการพัฒนาระบบแต่ละช่วง ดังนี้

    1. **การประเมินขั้นคัดกรองข้อมูล (Retrieval Evaluation)** ตรวจสอบว่าระบบลดขนาดพื้นที่ค้นหาได้จริงหรือไม่ และทำคู่ข้อมูลจริงหลุดหายไปหรือไม่
    2. **การประเมินแบบจำลอง (Model Evaluation)** ตรวจสอบความสามารถในการแยกแยะคู่ที่เป็นบุคคลเดียวกัน (MATCH) ออกจากคู่ที่ไม่ใช่ (NO_MATCH)
    3. **การประเมินการปรับเทียบ (Calibration Evaluation)** ตรวจสอบว่าคะแนนความน่าจะเป็น (Probability Score) ที่ได้ มีความน่าเชื่อถือพอที่จะใช้ตั้งจุดตัด (Threshold) หรือไม่
    4. **การประเมินระดับใช้งานจริง (Production Evaluation)** ตรวจสอบว่าเมื่อนำระบบไปใช้จริง ภาระงานและผลลัพธ์ปลายทางมีความเหมาะสมกับการทำงานใน CRM หรือไม่

- **ตัวชี้วัดที่ใช้ (Evaluation Metrics)** เนื่องจากชุดข้อมูลมีปัญหาความไม่สมดุลของคลาส (Class Imbalance) สูงมาก การใช้ความแม่นยำ (Accuracy) เพียงอย่างเดียวจะไม่สะท้อนคุณภาพที่แท้จริง งานวิจัยนี้จึงเลือกใช้ตัวชี้วัดดังนี้

    - **Precision และ Recall** ใช้ดูความสมดุล (Trade-off) ระหว่างการจับคู่ผิดกับการพลาดคู่จริง
    - **F1-score** ค่าเฉลี่ยฮาร์มอนิกของ Precision และ Recall
    - **Average Precision (AP)** เหมาะกับการประเมินคุณภาพการจัดอันดับในชุดข้อมูลที่ไม่สมดุล

- **ROC-AUC** ประเมินความสามารถการแยกแยะคลาสในภาพรวม โดยไม่อิงจุดตัดใดจุดตัดหนึ่ง
- **Expected Calibration Error (ECE)** ตรวจสอบว่าคะแนนที่โมเดลให้ สื่อถึงระดับความมั่นใจได้แม่นยำแค่ไหน
- **Confusion Matrix และ Classification Report** ใช้สำหรับดูรายละเอียดเชิงลึกว่าโมเดลทำนายคลาสใดผิดพลาดในสัดส่วนเท่าใด

ตารางที่ 3.14 สรุประดับการประเมินผลและตัวชี้วัดหลักที่ใช้ในงานวิจัย

ระดับการประเมิน	**คำถามวิจัยที่ต้องการตอบ**	**ตัวชี้วัดหลัก (Key Metrics)**
1. Retrieval	ระบบลด Search Space ได้ดีแค่ไหน? คู่จริงหลุดไปหรือไม่?	Exact matches, Candidate pairs, Search-space reduction, Ground-truth coverage
2. Model	แบบจำลองแยก MATCH กับ NO_MATCH ได้ดีเพียงใด?	Precision, Recall, F1-score, ROC-AUC, Average Precision, Confusion Matrix
3. Calibration	คะแนนที่ปรับเทียบแล้ว สื่อถึงความมั่นใจได้ดีขึ้นหรือไม่?	ECE ก่อนและหลัง Calibration, Threshold stability
4. Production	จุดตัดที่เลือก ส่งผลดีต่อภาระงานและการใช้งานจริงหรือไม่?	MATCH, REVIEW, NO_MATCH, Review queue size, Unified profiles

3.5.2 การประเมินขั้น Retrieval และ Candidate Generation

จุดประสงค์ของขั้นตอนนี้คือ การตรวจสอบว่าวิธีการ Exact-first และการจัดกลุ่ม Blocking สามารถลดปริมาณคู่ข้อมูลมหาศาล ให้เหลือเฉพาะกลุ่มตัวเลือก (Candidate Set) ที่ระบบประมวลผลไหว โดยประกอบด้วยการประเมิน 3 มิติหลัก

1. **คุณภาพของ Exact-first**
2. **ประสิทธิภาพของการทำ Blocking**

3. **ความครอบคลุมคู่จริง (Ground-truth Coverage)**

ตารางที่ 3.15 กรอบการประเมินขั้น Retrieval และ Candidate Generation

มิติที่ประเมิน	ตัวชี้วัดหลัก	จุดประสงค์
Exact-first quality	จำนวน Exact matches, Precision	ตรวจสอบว่ากฎที่เข้มงวด ให้คู่ที่เชื่อถือได้มากเพียงใด
Blocking efficiency	Candidate pairs, Search-space reduction	ตรวจสอบว่าระบบลดภาระการคำนวณได้มากเพียงใด
Coverage of true pairs	Ground-truth coverage	ตรวจสอบว่าคู่จริงไม่หลุดหายไป และถูกส่งต่อให้แบบจำลอง

3.5.3 การประเมินแบบจำลองเชิงการจำแนก (Classification Model Evaluation)

จุดประสงค์ของขั้นตอนนี้คือ ตรวจสอบว่า เมื่อกลุ่ม Candidate Set ผ่านขั้นตอนการคัดกรองมาแล้ว แบบจำลองจะสามารถจำแนกคู่ที่เป็นบุคคลเดียวกัน (MATCH) ออกจากคู่ที่ไม่ใช่บุคคลเดียวกัน (NO_MATCH) ได้ดีเพียงใด ในการประเมินผลได้มีการออกแบบการประเมินออกเป็น สายการทดลองแบบคู่ขนาน ตอบคำถามเชิงโครงสร้างของระบบ 3 ประการ ได้แก่

1. **เชิงตระกูลแบบจำลอง (Model Family)** แบบจำลองที่มีกลไกต่างกัน ชนิดใดสามารถจัดการกับโครงสร้างข้อมูลแบบตารางของงานนี้ได้ดีกว่ากัน
2. **เชิงชนิดของคุณลักษณะ (Feature Modality)** การลงทุนดึงข้อมูลภาพและบริบทข้ามสื่อมาใช้งาน เพิ่มความแม่นยำได้คุ้มค่ากับทรัพยากรการประมวลผลที่ต้องเสียไปหรือไม่
3. **เชิงความซับซ้อน** แบบจำลองเชิงลึก (Neural Network) ให้ผลลัพธ์ที่ก้าวกระโดดจากแบบจำลองการเรียนรู้ของเครื่อง (Machine Learning) พื้นฐาน มากพอที่จะคุ้มค่ากับต้นทุนการดูแลรักษาระบบในระยะยาวหรือไม่

เพื่อให้การประเมินมีความน่าเชื่อถือตามหลักวิชาการ ชุดข้อมูลจะถูกแบ่งหน้าที่อย่างเด็ดขาด โดยใช้ชุดฝึกสอน (Train Set) เพื่อให้โมเดลเรียนรู้ ใช้ชุดตรวจสอบ (Validation Set)

เพื่อคัดเลือกโมเดลและกำหนดจุดตัด (Operating Point) และใช้ชุดทดสอบ (Test Set) สำหรับการประเมินผลขั้นสุดท้ายเพียงครั้งเดียวเท่านั้น ห้ามนำผลจากชุดทดสอบมาใช้ช่วยตัดสินใจเลือกระหว่างทางโดยเด็ดขาด

ตารางที่ 3.16 กรอบการประเมินแบบจำลองในสายการทดลองหลัก

สายการทดลอง	**จุดประสงค์ของการประเมิน**	**ตัวชี้วัดหลัก**
Classical leakage-safe	ใช้เปรียบเทียบ model family บนข้อมูลเชิงตารางภายใต้เงื่อนไขที่ควบคุม leakage	Precision, Recall, F1-score, ROC-AUC, Average Precision
Multimodal suite	ใช้ตรวจผลของการเพิ่มข้อมูลภาพและบริบทข้ามสื่อ	Precision, Recall, F1-score, ROC-AUC, Average Precision
Neural reference	ใช้เป็นตัวอ้างอิงเพื่อเปรียบเทียบกับแนวทางที่ซับซ้อนกว่า	Precision, Recall, F1-score, ROC-AUC, Average Precision

3.5.4 การประเมิน Calibration และผลในระดับ Production Workflow

ขั้นตอนนี้ทำหน้าที่เป็นเชื่อมระหว่างตัวเลขประสิทธิภาพของแบบจำลอง กับการนำผลลัพธ์ไปประยุกต์ใช้งานจริงในระบบธุรกิจ โดยไม่ได้มองแค่ว่าโมเดลทำนายถูกหรือผิด แต่ประเมินว่าคะแนนจากโมเดลสามารถนำไปควบคุมผลลัพธ์เชิงปฏิบัติการได้หรือไม่ แบ่งการพิจารณาออกเป็น 3 ระดับ ดังนี้

1) **การประเมินการปรับเทียบ (Calibration Evaluation)**

ตรวจสอบว่าคะแนนความน่าจะเป็นดิบสะท้อนความมั่นใจที่แท้จริงของแบบจำลองหรือไม่ โดยวัดความคลาดเคลื่อนจากค่า Expected Calibration Error (ECE) ทั้งก่อนและหลังปรับเทียบ รวมถึงดูความเสถียรของการกำหนดจุดตัด บน

Validation Set ขั้นตอนนี้สำคัญมาก เพราะหากคะแนนขาดความน่าเชื่อถือ จะทำให้ชั้นการตัดสินใจ (Decision Layer) ทำงานผิดพลาด

2) **การประเมินชั้นการตัดสินใจ (Decision Layer Evaluation)**

ตรวจสอบว่าเมื่อนำคะแนนที่ปรับเทียบแล้วมากำหนดจุดตัดระบบสามารถแบ่งผลลัพธ์ออกเป็น 3 กลุ่มปฏิบัติการได้อย่างสมเหตุสมผลหรือไม่ ได้แก่

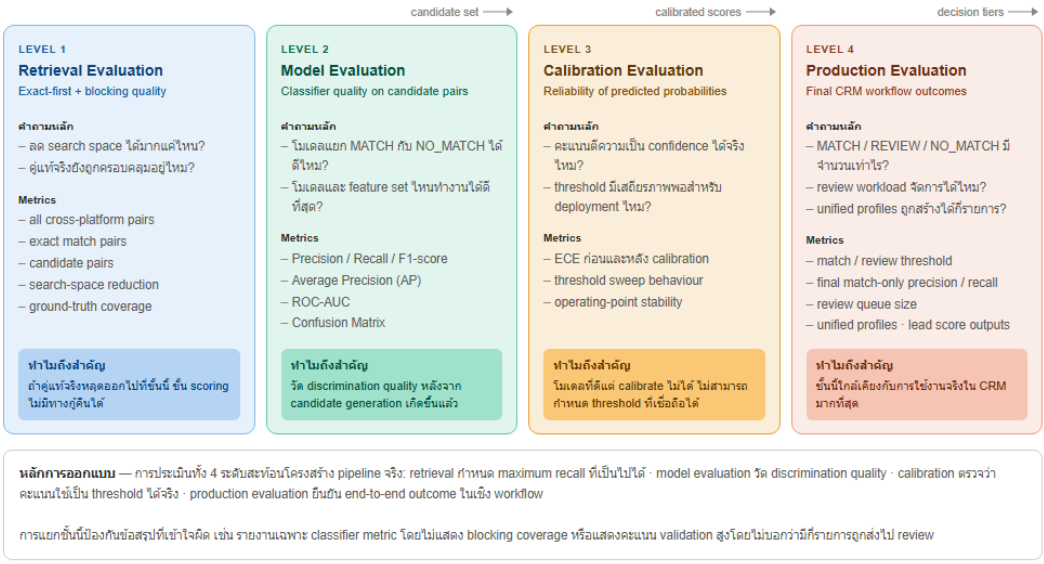
- **MATCH** ข้อมูลตรงกัน (รวมโปรไฟล์อัตโนมัติ)
- **REVIEW** ข้อมูลมีความกำกวม (ส่งให้มนุษย์ตรวจสอบ)
- **NO_MATCH** ข้อมูลไม่ตรงกัน (ปฏิเสธการรวมโปรไฟล์)

3) **การประเมินระดับการใช้งานจริง (Production Workflow Evaluation):**

ประเมินผลกระทบที่มีต่อระบบ CRM และผู้ใช้งาน โดยพิจารณาจากภาระงานปลายทาง (Downstream Workload) เช่น ขนาดคิวที่ต้องตรวจสอบและปริมาณโปรไฟล์ที่ถูกรวมสำเร็จ เพื่อยืนยันว่าจุดตัดที่เลือกสอดคล้องกับข้อจำกัดด้านทรัพยากรบุคคลและนำไปใช้งานได้จริง

ตารางที่ 3.17 กรอบการประเมินผลระดับ Calibration และ Production Workflow

ระดับการประเมิน	**คำถามวิจัยที่ต้องการตอบ**	**ตัวชี้วัดหลัก (Key Metrics)**
1. Calibration	คะแนนที่ปรับเทียบแล้ว สื่อถึงระดับความมั่นใจได้ดีและเสถียรขึ้นหรือไม่?	ECE ก่อนและหลัง Calibration, Threshold stability
2. Decision Layer	จุดตัดที่กำหนด สามารถแบ่งกลุ่ม MATCH, REVIEW และ NO_MATCH ได้เหมาะสมหรือไม่?	Match threshold, Review threshold, Tier precision, Final precision/recall
3. Production Workflow	ระบบทั้งเส้นทาง (End-to-End) สามารถนำผลไปใช้งานในระบบ CRM ได้จริงหรือไม่?	Review queue size, Unified profiles, Lead scores, Downstream workload



รูปที่ 3.9 Evaluation Framework: กรอบการประเมินผลของระบบในหลายระดับ

3.6 การพัฒนานโยบายการตัดสินใจด้วยขั้นตอนวิธีเชิงพันธุกรรม

งานในส่วนนี้เป็นการพัฒนาต่อจากกระบวนการเชื่อมโยงอัตลักษณ์ที่อธิบายไว้ในหัวข้อ 3.1–3.5 โดยยังใช้การเตรียมข้อมูล การสร้างคู่ผู้สมัคร และคะแนนจากแบบจำลองเป็นพื้นฐานเดิม สิ่งที่เพิ่มเติมคือวิธีนำคะแนนและหลักฐานของแต่ละคู่มาใช้ตัดสินใจว่า ควรรวมข้อมูลอัตโนมัติ ส่งให้เจ้าหน้าที่ตรวจสอบ หรือไม่รวมข้อมูล ผู้วิจัยจึงเพิ่มขั้นตอนการค้นหานโยบายการตัดสินใจด้วยขั้นตอนวิธีเชิงพันธุกรรม (Genetic Algorithm: GA) เพื่อให้การเลือกเกณฑ์มีหลักฐานจากชุดข้อมูลตรวจสอบรองรับ และสะท้อนภาระงานที่เกิดขึ้นในระบบ CRM ได้ชัดเจนขึ้น

การพัฒนาส่วนนี้อยู่ภายใต้กรอบ CRISP-DM เดิม โดยขยายรายละเอียดในขั้นการสร้างแบบจำลองและการประเมินผล รวมถึงเตรียมผลการตัดสินใจสำหรับกระบวนการปลายทาง ขอบเขตของงานที่เพิ่มจึงครอบคลุมการออกแบบนโยบาย การค้นหาพารามิเตอร์ การทดสอบ และการส่งออกผลรายคู่ ส่วนผลเชิงตัวเลขจากการเปรียบเทียบนโยบายควรนำเสนอในบทผลการทดลองแยกจากวิธีดำเนินงานนี้

3.6.1 เหตุผลและขอบเขตของการพัฒนาเพิ่มเติม

ในระบบเดิม แบบจำลองให้คะแนนว่าคู่โปรไฟล์มีแนวโน้มเป็นบุคคลเดียวกันมากน้อยเพียงใด จากนั้นจึงใช้เกณฑ์สองระดับแบ่งคำตัดสินเป็น MATCH, REVIEW และ NO_MATCH วิธีนี้ทำให้ระบบมีทางเลือกสำหรับคู่ที่ยังไม่แน่ชัด อย่างไรก็ตาม การกำหนดเกณฑ์ด้วยค่าคงที่อาจยังไม่สอดคล้องกับสัดส่วนข้อมูล ความผิดพลาด และจำนวนคู่ที่เจ้าหน้าที่ต้องตรวจสอบในแต่ละชุดข้อมูล

ตัวอย่างเช่น การลดเกณฑ์ MATCH อาจทำให้ระบบเชื่อมโยงคู่ที่ถูกต้องได้มากขึ้น แต่ก็อาจรวมคนละคนเข้าด้วยกันมากขึ้นด้วย ในทางกลับกัน การเพิ่มเกณฑ์อาจลดการรวมผิดแต่ทำให้คู่จำนวนมากค้างอยู่ใน REVIEW การเลือกนโยบายจึงต้องพิจารณาทั้งความถูกต้องของการรวมข้อมูลและภาระงานที่ตามมา ผู้วิจัยใช้ GA ค้นหาชุดพารามิเตอร์ที่ทำให้ต้นทุนการตัดสินใจบนชุด validation ต่ำลง แล้วจึงตรวจสอบผลด้วยตัวชี้วัดด้านความแม่นยำและปริมาณงานร่วมกัน

ในการเปรียบเทียบนโยบาย ผู้วิจัยตรึงคะแนนจากแบบจำลองไว้ เพื่อให้ความแตกต่างของผลลัพธ์อธิบายได้จากการเปลี่ยนชั้นการตัดสินใจ ส่วนการปรับคุณลักษณะหรือฝึกแบบจำลองในสายการทดลองอื่นถือเป็นงานอีกส่วนหนึ่ง น้ำหนักที่ GA ค้นหาในขั้นตอนนี้จึงเป็นน้ำหนักของนโยบายการตัดสินใจ ไม่ใช่น้ำหนักภายในแบบจำลอง Gradient Boosting และไม่ใช่ค่าความสำคัญของคุณลักษณะจากแบบจำลองโดยตรง

3.6.2 ลำดับการพัฒนาจากกฎเดิมสู่นโยบายแบบถ่วงน้ำหนัก

ผู้วิจัยพัฒนานโยบายเป็นลำดับ โดยเริ่มจากกฎที่ใช้คะแนนจากแบบจำลองและเกณฑ์สองระดับเป็นฐานเปรียบเทียบ จากนั้นเพิ่มการใช้ความคล้ายของชื่อช่วยตัดสินคู่ที่อยู่ในช่วง REVIEW และจึงขยายไปสู่นโยบายที่รวมหลักฐานหลายด้านเป็นคะแนนเดียว ตารางที่ 3.18 สรุปความแตกต่างของแนวทางที่ใช้ในการศึกษา

แนวทาง	สิ่งที่ใช้ตัดสินใจ	บทบาทในการทดลอง
เกณฑ์ สอง ระดับ จาก คะแนนโมเดล	คะแนน โมเดลและเกณฑ์ MATCH กับ REVIEW	ใช้ ตรวจ ว่าการ ปรับ เกณฑ์ เพียง อย่างเดียวเพียงพอหรือไม่
GA ที่ใช้ชื่อช่วยตัดสิน	คะแนนโมเดล เกณฑ์สองระดับ และ เกณฑ์ความคล้ายของชื่ออีกสองค่า	เป็น แนวทาง ต่อย อด ระยะ แรก และ ฐานเปรียบเทียบของนโยบายใหม่
GA แบบ ถ่วง น้ำ หนัก ขั้นเดียว	คะแนน โมเดลร่วม กับ หลัก ฐาน ที่ มี ข้อมูล ของ แต่ละ คู่ และ เกณฑ์ สอง ระดับ	ค้นหา น้ำ หนัก และ เกณฑ์ ร่วม กัน แล้วตัดสินจากคะแนนรวมครั้งเดียว

ตารางที่ 3.18 ลำดับการพัฒนานโยบายการตัดสินใจ

นโยบายที่ใช้ชื่อช่วยตัดสินมีโครโมโซม 4 ค่า ได้แก่ เกณฑ์ MATCH เกณฑ์ REVIEW เกณฑ์ความ คล้าย ของ ชื่อ สำหรับ เลื่อน คู่ ขึ้น เป็น MATCH และเกณฑ์สำหรับ ลด คู่ ลง เป็น NO_MATCH โดยเกณฑ์ของชื่อทำงานเฉพาะคู่ที่คะแนนโมเดลอยู่ในช่วง REVIEW เท่านั้น ข้อจำกัดของแนวทางนี้คือ ชื่อถูกกำหนด ให้เป็นหลักฐานหลักตั้งแต่ก่อนเริ่มค้นหา GA จึงเลือกค่าจุดตัดของชื่อได้ แต่ยังไม่ได้เปรียบเทียบว่าหลักฐานชนิดอื่นเหมาะสมกว่าหรือไม่

เพื่อศึกษาข้อจำกัดดังกล่าว ผู้วิจัยเพิ่มการทดลองใช้หลักฐานแต่ละกลุ่มเป็นตัวช่วยตัดสินและต่อยอดเป็นนโยบายแบบถ่วงน้ำหนักขั้นเดียว (One-Stage Weighted Policy) ซึ่งรวมคะแนนโมเดลและหลักฐานที่มีอยู่ก่อนเปรียบเทียบกับเกณฑ์ MATCH และ REVIEW แนวทางนี้ไม่มีเกณฑ์เลื่อนขึ้นและลดลงของชื่อซ้อนอยู่ในช่วง REVIEW อีกชั้นหนึ่ง แต่ยังเปิดให้ GA เลือกน้ำหนักของชื่อได้ตามผลบน validation

3.6.3 การเตรียมข้อมูลสำหรับชั้นการตัดสินใจ

ข้อมูลสำหรับนโยบายต้องอ้างอิงคู่เดียวกับที่ระบบให้คะแนนไว้จริง ผู้วิจัยจึงจัดเตรียมตารางคุณลักษณะสำหรับการตัดสินใจ โดยเก็บรหัสโปรไฟล์ทั้งสองฝั่ง คะแนนโมเดล กลุ่มข้อมูลที่ใช้ประเมิน ค่าความจริงสำหรับคำนวณผล และหลักฐานแต่ละด้านไว้ด้วยกัน พร้อมตัวบ่งชี้ว่าหลักฐานด้านนั้นใช้งานได้หรือไม่ การมีรหัสคู่ช่วยตรวจสอบว่าคะแนนและคุณลักษณะไม่ได้ถูกนำไปจับกับคู่ผิดระหว่างการประมวลผลแบบแบ่งส่วน

โครงสร้างนโยบายกำหนดช่องข้อมูลไว้ 8 ช่อง ได้แก่ คะแนนโมเดล ชื่อ ประวัติย่อ ลิงก์ตำแหน่งที่อยู่ สัญญาณทางสังคม ภาพ และรูปแบบการเขียน ดังตารางที่ 3.19 ค่าหลักฐาน

ถูกจัดให้อยู่ในช่วง 0 ถึง 1 และมีทิศทางเดียวกัน คือค่าสูงแสดงความสอดคล้องมากกว่า ส่วนคุณลักษณะที่เดิมเป็นค่าความแตกต่างต้องแปลงทิศทางก่อนนำมาใช้

กลุ่มข้อมูล	ความหมายในขั้นการตัดสินใจ
คะแนนโมเดล	คะแนนความเป็นบุคคลเดียวกันจากแบบจำลองที่ตรึงไว้
ชื่อ	ความคล้ายของชื่อผู้ใช้หรือชื่อที่แสดงในโปรไฟล์
ประวัติย่อ	ความคล้ายของข้อความหรือความหมายในประวัติย่อ
ลิงก์	ความสอดคล้องของ URL หรือโดเมนที่อ้างอิง
ตำแหน่งที่อยู่	ความคล้ายของข้อมูลสถานที่เมื่อมีข้อมูลที่ใช้งานได้
สัญญาณทางสังคม	ความสอดคล้องของการกล่าวถึงบัญชีหรือแฮชแท็กในคุณลักษณะที่เตรียมไว้
ภาพ	หลักฐานจากภาพหรือข้อความประกอบภาพตามที่มีในตารางคุณลักษณะ
รูปแบบการเขียน	ความสอดคล้องของลักษณะการเขียน เช่น ความยาวและการใช้เครื่องหมาย

ตารางที่ 3.19 กลุ่มข้อมูลที่โครงสร้างนโยบายรองรับ

การรองรับ 8 ช่องไม่ได้หมายความว่าทุกรอบทดลองใช้ข้อมูลได้ครบทั้ง 8 ด้าน ในรอบข้อมูลเต็มวันที่ 14 กันยายน 2569 ตารางคุณลักษณะไม่มีช่อง social และไม่มีรายการ location ที่พร้อมใช้งาน จึงปิดการใช้งานสองด้านนี้และกำหนดน้ำหนักเป็นศูนย์ตั้งแต่เริ่มค้นหา ส่วนกลุ่มที่มีข้อมูลให้ใช้เปิดให้ GA ค้นหาน้ำหนักได้ตามการตั้งค่าของรอบนั้น การเปิดใช้งานในรอบนี้พิจารณาว่ามีหลักฐานด้านนั้นปรากฏใน validation หรือไม่ โดยไม่ได้กำหนดเกณฑ์ขั้นต่ำด้านสัดส่วนความครอบคลุมและจำนวนคู่บวกเพิ่มเติม

ผู้วิจัยตรวจสอบสัดส่วนคู่ที่มีหลักฐานพร้อมใช้งานควบคู่กับน้ำหนักที่ได้ เพื่อแยกกรณี “ไม่มีข้อมูลให้ใช้” ออกจากกรณี “มีข้อมูล แต่ GA เลือกน้ำหนักเป็นศูนย์” นอกจากนี้ หลักฐานกลุ่มภาพอาจรวมสัญญาณจากคำบรรยายภาพด้วย สัดส่วนความพร้อมของกลุ่มภาพจึงไม่ควรตีความเป็นสัดส่วนคู่ที่มีภาพจริงครบทั้งสองฝั่งโดยอัตโนมัติ

3.6.4 การคำนวณคะแนนเมื่อข้อมูลแต่ละคู่มีไม่ครบ

โปรไฟล์แต่ละคู่มีข้อมูลไม่เท่ากัน หากแทนข้อมูลที่ขาดด้วยศูนย์แล้วเฉลี่ยทุกด้านเท่ากัน คู่ที่ไม่มีประวัติย่อหรือภาพอาจได้คะแนนต่ำลงเพียงเพราะไม่มีข้อมูล ผู้วิจัยจึงแยกค่าหลักฐานออกจากตัวบ่งชี้ความพร้อมใช้งาน และปรับสัดส่วนน้ำหนักตามข้อมูลที่มีจริงในแต่ละคู่

กำหนดให้ s_{ik} เป็นค่าหลักฐานช่องที่ k ของคู่ที่ i, m_{ik} เป็นตัวบ่งชี้ความพร้อมใช้งาน โดยมีค่า 1 เมื่อใช้ได้และ 0 เมื่อใช้ไม่ได้ และ w_k เป็นน้ำหนักที่ GA ค้นหา คะแนนรวมของแต่ละคู่คำนวณได้ดังนี้

$$S_i = \frac{\sum_{k=1}^{8} w_k m_{ik} s_{ik}}{\sum_{k=1}^{8} w_k m_{ik}}, \qquad w_k \geq 0, \quad \sum_{k=1}^{8} w_k = 1$$

สูตรนี้ ใช้เมื่อผลรวมน้ำหนักของช่องที่พร้อมใช้งานมากกว่าศูนย์ ตัวอย่างเช่น หากนโยบายให้น้ำหนักคะแนนโมเดล 0.2 ชื่อ 0.5 และประวัติย่อ 0.3 แต่คู่หนึ่งไม่มีประวัติย่อ ระบบจะหารด้วย 0.7 ซึ่งเป็นน้ำหนักรวมของสองด้านที่ยังใช้ได้ แทนการหารด้วย 1 จึงไม่ลดคะแนนเพราะการขาดประวัติย่อเพียงอย่างเดียว หากไม่มีหลักฐานที่มีน้ำหนักให้ใช้เลย ระบบกำหนดคู่นั้นเป็น REVIEW

จากนั้นระบบเปรียบเทียบคะแนนรวมกับเกณฑ์สองระดับเพียงครั้งเดียว ดังนี้

$$D_i = \begin{cases} \text{MATCH}, & S_i \geq t_{\text{match}}, \\ \text{NO_MATCH}, & S_i < t_{\text{review}}, \\ \text{REVIEW}, & t_{\text{review}} \leq S_i < t_{\text{match}}. \end{cases}$$

MATCH หมายถึงคู่ที่ผ่านเกณฑ์สำหรับการเชื่อมโยงอัตโนมัติ REVIEW หมายถึงคู่ที่ยังต้องตรวจสอบเพิ่มเติม และ NO_MATCH หมายถึงคู่ที่ไม่ผ่านเกณฑ์การเชื่อมโยงในรอบนั้น คะแนน S_i เป็นคะแนนรวมของนโยบาย จึงไม่ควรเรียกว่าเป็นความน่าจะเป็นที่ผ่านการปรับเทียบแล้ว เว้นแต่มีการประเมินการปรับเทียบของคะแนนรวมนี้เพิ่มเติม

3.6.5 การกำหนดโครโมโซมและเงื่อนไขการค้นหา

โครโมโซมของนโยบายแบบถ่วงน้ำหนักประกอบด้วย 10 ค่า คือเกณฑ์สองระดับและน้ำหนักอีก 8 ค่า เรียงตามลำดับดังนี้

$$\boldsymbol{g} = [t_m, t_r, w_p, w_n, w_b, w_u, w_l, w_s, w_i, w_y]$$

โดย t_m และ t_r แทนเกณฑ์ MATCH และ REVIEW ส่วนน้ำหนัก w_p ถึง w_y แทนคะแนนโมเดล ชื่อ ประวัติย่อ ลิงก์ ตำแหน่งที่อยู่ สัญญาณทางสังคม ภาพ และรูปแบบการเขียนตามลำดับ

การค้นหาในโค้ดกำหนดให้ $0.50 \leq t_m \leq 0.999$ และ $0.05 \leq t_r \leq t_m$ น้ำหนักทุกค่าต้องไม่ติดลบ และปรับผลรวมให้เท่ากับ 1 หลังสร้างหรือเปลี่ยนแปลงโครโมโซม กลุ่มข้อมูลที่ไม่ได้เปิดใช้งานมีน้ำหนักเป็นศูนย์ตลอดการค้นหา เงื่อนไขเหล่านี้ช่วยให้โครโมโซมทุกชุดนำไปตัดสินใจได้จริงและคงลำดับของเกณฑ์สองระดับไว้เสมอ

3.6.6 การกำหนดต้นทุนสำหรับประเมินนโยบาย

ผู้วิจัยประเมินนโยบายด้วยต้นทุนสามประเภท ได้แก่ การรวมโปรไฟล์ของคนละคนเข้าด้วยกัน การไม่รวมคู่ที่เป็นคนเดียวกัน และการส่งคู่ให้เจ้าหน้าที่ตรวจสอบ โดยใช้สมมติฐานค่าแรง 100 บาทต่อชั่วโมง เวลาตรวจสอบคู่ละ 1 นาที เวลาแก้ไขการรวมผิด 20 นาที และเวลาจัดการคู่ที่ตกหล่น 10 นาที สมมติฐานเหล่านี้เป็นค่าที่กำหนดสำหรับการทดลอง ยังไม่ใช่ต้นทุนที่วัดจากการใช้งาน CRM จริง

เมื่อคิดเฉพาะค่าแรง จะได้ต้นทุนประมาณ 33.33 บาทต่อการรวมผิดหนึ่งคู่ 16.67 บาทต่อคู่ที่ตกหล่นหนึ่งคู่ และ 1.67 บาทต่อการตรวจสอบหนึ่งคู่ เมื่อนำต้นทุนคู่ที่ตกหล่นมาเป็นหน่วยอ้างอิง จะได้อัตราส่วน 2 ต่อ 1 ต่อ 0.1 และกำหนดฟังก์ชันต้นทุนดังนี้

$$C(\boldsymbol{g}) = 2\,FP + FN + 0.1\,R$$

ในสมการนี้ FP คือจำนวนคู่คนละคนที่ถูกตัดสินเป็น MATCH, FN คือจำนวนคู่คนเดียวกันที่ถูกตัดสินเป็น NO_MATCH และ R คือจำนวนคู่ทั้งหมดที่ถูกส่งเป็น REVIEW การนับ FN ในต้นทุนจึงหมายถึงการปฏิเสธคู่ที่ควรเชื่อมโยงโดยตรง ส่วนคู่บวกที่อยู่ใน REVIEW ถูกคิดเป็นต้นทุนการตรวจสอบ และไม่ได้ถูกคิดซ้ำเป็น FN ในสมการเดียวกัน

GA ค้นหานโยบายที่ทำให้ต้นทุนดังกล่าวต่ำที่สุดบน validation การลดต้นทุนอาจมาพร้อมกับการเปลี่ยนแปลงของ precision, recall และจำนวน REVIEW จึงต้องรายงานตัวชี้วัดเหล่านี้ร่วมกัน ไม่สามารถสรุปจากต้นทุนเพียงค่าเดียวว่านโยบายดีกว่าในทุกด้าน และไม่ควรแปลงผลต้นทุนเป็นเงินที่องค์กรประหยัดได้จริงโดยไม่มีข้อมูลการปฏิบัติงานรองรับ

3.6.7 ขั้นตอนการค้นหานโยบายด้วย GA

การค้นหาเริ่มจากสร้างประชากรของชุดพารามิเตอร์หลายชุด แต่ละชุดแทนนโยบายที่เป็นไปได้หนึ่งนโยบาย ผู้วิจัยสุ่มค่าเกณฑ์และน้ำหนักเริ่มต้น แล้วปรับให้อยู่ภายใต้เงื่อนไขที่กำหนด จากนั้นนำทุกนโยบายไปตัดสินคู่ใน validation และคำนวณต้นทุนของแต่ละชุด

ในแต่ละรุ่น ระบบเรียงประชากรตามต้นทุนจากน้อยไปมาก สำหรับตัวค้นหานโยบายแบบถ่วงน้ำหนัก หากต้นทุนเท่ากันจะพิจารณา precision ที่สูงกว่า จำนวน FP ที่น้อยกว่า recall ที่สูงกว่า และจำนวน REVIEW ที่น้อยกว่าตามลำดับ แล้วเก็บนโยบายอันดับต้นไว้เป็นกลุ่มชั้นนำเพื่อใช้สร้างรุ่นถัดไป

การสร้างลูกใช้การเลือกยีนแต่ละตำแหน่งจากพ่อหรือแม่ด้วยโอกาสเท่ากัน จากนั้นกลายพันธุ์แต่ละยีนด้วยความน่าจะเป็น 0.30 โดยเพิ่มค่ารบกวนจากการแจกแจงปกติ ส่วนเบี่ยงเบนมาตรฐานสำหรับเกณฑ์เท่ากับ 0.025 และสำหรับน้ำหนักเท่ากับ 0.05 หลังกลายพันธุ์ระบบตรวจขอบเขตของเกณฑ์ ปัดน้ำหนักของกลุ่มที่ไม่ใช้งาน และปรับผลรวมน้ำหนักอีกครั้ง กระบวนการนี้ทำซ้ำตามจำนวนรุ่นที่กำหนด

การทดลองบนข้อมูลเต็มใช้ประชากร 64 ชุด จำนวน 60 รุ่น เก็บประชากรชั้นนำ 8 ชุด และทำซ้ำด้วยค่า seed 42, 43 และ 44 ทั้งนโยบายคะแนนอย่างเดียว นโยบายใช้ชื่อช่วยตัดสิน และนโยบายแบบถ่วงน้ำหนักใช้ขนาดประชากรและจำนวนรุ่นเท่ากันในรอบนี้ หลังจบการค้นหา ผู้วิจัยเลือกผลของแต่ละนโยบายข้าม seed โดยเรียงตามต้นทุน FP, FN, REVIEW และ seed ตามลำดับ พร้อมเก็บประวัติการค้นหาไว้ตรวจสอบความเปลี่ยนแปลงของคำตอบ

การใช้หลาย seed ช่วยตรวจสอบผลจากการสุ่มเริ่มต้น แต่ไม่ได้รับประกันว่าพบคำตอบที่ดีที่สุดของพื้นที่ค้นหาทั้งหมด นอกจากนี้ ค่าตั้งต้นของการทดลองย่อยอาจต่างจากรอบข้อมูล

เต็ม จึงต้องอ้างอิงการตั้งค่าจากไฟล์ของรอบที่นำมารายงานเสมอ

3.7 การออกแบบการประเมินนโยบายที่พัฒนาเพิ่มเติม

3.7.1 การแบ่งบทบาทของข้อมูลและการตรึงนโยบาย

ผู้วิจัยแยกบทบาทของการฝึกแบบจำลอง การเลือกนโยบาย และการทดสอบออกจากกัน โดย ใช้คะแนนและการแบ่งกลุ่มที่บันทึกไว้ในชุดข้อมูลของแต่ละการทดลอง การค้นหาพารามิเตอร์ของ GA ใช้เฉพาะคู่ validation ส่วน test ใช้ประเมินนโยบายหลังเลือกเสร็จแล้ว การเปรียบเทียบแต่ละนโยบายจึงใช้คู่ข้อมูล คะแนนโมเดล และนิยามต้นทุนเดียวกัน

สำหรับรอบข้อมูลเต็ม มีคู่ทั้งหมด 2,086,245 คู่ แบ่งเป็นคู่ที่ใช้คะแนนโมเดล 2,073,842 คู่ และคู่ในชั้น Exact-First 12,403 คู่ โดย GA ใช้คู่ validation ที่ผ่านการให้คะแนนโมเดลจำนวน 1,010,926 คู่ในการค้นหา หลังเลือกนโยบาย ผู้วิจัยบันทึกค่าเกณฑ์ น้ำหนัก seed รายชื่อกลุ่มข้อมูลที่เปิดใช้งาน และรหัสตรวจสอบไฟล์ต้นทางไว้ก่อนเรียกขั้นตอนประเมิน test

การตรึงนโยบายก่อนทดสอบช่วยป้องกันการนำผล test ในรอบนั้นกลับไปปรับพารามิเตอร์ อย่างไรก็ตาม การมีไฟล์ตรึงนโยบายไม่ได้ยืนยันด้วยตัวเองว่าคะแนนต้นทางทุกชุดถูกสร้างโดยปราศจากข้อมูลรั่วไหล หรือว่าชุดทดสอบไม่เคยถูกใช้ในงานก่อนหน้า การกล่าวถึงการแยกข้อมูลระดับบุคคลหรือการทดสอบกับชุดใหม่จึงต้องอาศัยหลักฐานของกระบวนการต้นทางเพิ่มเติมด้วย

3.7.2 ฐานเปรียบเทียบและขอบเขตการเปลี่ยนแปลง

การประเมินใช้สี่แนวทาง ได้แก่ ผลการตัดสินใจจากระบบเดิม นโยบายคะแนนโมเดลอย่างเดียวที่ค้นหาเกณฑ์สองระดับด้วย GA นโยบายที่ใช้ชื่อช่วยตัดสินด้วยพารามิเตอร์สี่ค่า และนโยบายแบบถ่วงน้ำหนักสิบค่า การมีฐานคะแนนอย่างเดียวช่วยแยกผลของการปรับเกณฑ์ออกจากผลของการเพิ่มหลักฐานหลายด้าน ส่วนนโยบายใช้ชื่อช่วยตัดสินทำให้เห็นผลของการเปลี่ยนรูปแบบกฎจากการตัดสินในช่วง REVIEW มาเป็นคะแนนรวมขั้นเดียว

คู่ที่ผ่านชั้น Exact-First ยังคงคำตัดสิน MATCH ตามระบบเดิมทุกแนวทาง จึงไม่ใช่ส่วนที่ GA ปรับปรุง ความผิดพลาดของชั้นดังกล่าวยังต้องนับเมื่อรายงานผลรวม ขณะเดียวกัน ผลบนคู่ที่ใช้คะแนนโมเดลเพียงอย่างเดียวต้องแยกจากผลที่รวม Exact-First แล้ว เพื่อไม่ให้ความแม่นยำของกฎเดิมถูกตีความเป็นผลของ GA ทั้งหมด

3.7.3 ตัวชี้วัดและการอ่านผลลัพธ์สามทาง

ผู้วิจัยรายงานต้นทุน จำนวน FP จำนวน FN จำนวน REVIEW, precision, recall และ F1 ร่วมกัน โดย precision ของการรวมอัตโนมัติคำนวณจากคู่บวกที่เป็น MATCH หารด้วยคู่ทั้งหมดที่เป็น MATCH ส่วน recall คำนวณจากคู่บวกที่เป็น MATCH หารด้วยคู่บวกทั้งหมดในขอบเขตที่กำลังประเมิน

$$\text{Precision} = \frac{TP}{TP + FP}, \qquad \text{Recall} = \frac{TP}{N_+}, \qquad F1 = \frac{2\,\text{Precision}\,\text{Recall}}{\text{Precision} + \text{Recall}}$$

กำหนดให้ TP เป็นคู่บวกที่ตัดสินเป็น MATCH และ N_+ เป็นคู่บวกทั้งหมดในชุดประเมิน คู่บวกที่อยู่ใน REVIEW ยังไม่ถือว่ารวมสำเร็จ จึงยังอยู่ในตัวหารของ recall ด้วย ดังนั้น ค่า FN ที่แสดงในฟังก์ชันต้นทุนไม่สามารถนำไปแทนตัวหารของ recall เป็น $TP + FN$ ได้ทันที เพราะจะขาดคู่บวกที่รอตรวจสอบ หากตัวหารเป็นศูนย์ต้องระบุว่าไม่มีตัวอย่างรองรับการตีความ แทนการมองค่าที่โปรแกรมเติมให้เป็นหลักฐานของประสิทธิภาพ

การรายงานแยกผลบน validation ผลบน test และผลการนำไปใช้กับคู่ทั้งหมด โดยผลรวมทุกคู่ใช้แสดงปริมาณงานที่นโยบายก่อให้เกิดขึ้นในข้อมูลชุดนั้น และไม่ใช้แทนผลทดสอบบนข้อมูลที่กันไว้ กลุ่มที่บันทึกเป็น drop ต้องแสดงแยกตามสถานะของข้อมูลต้นทาง และไม่เรียกว่าเป็นชุดทดสอบเพิ่มเติม

นอกจากนี้ การประเมินบนคู่ผู้สมัครยังไม่ครอบคลุมคู่จริงที่หลุดไปตั้งแต่ขั้นสร้างคู่ ผู้วิจัยจึงอ่านผลนโยบายร่วมกับความครอบคลุมของ candidate generation ที่อธิบายไว้ในหัวข้อ 3.5 การปรับ GA ไม่สามารถกู้คืนคู่ที่ไม่เคยถูกส่งเข้ามาให้ตัดสินได้ หากไม่ได้ปรับขั้นสร้างคู่ด้วย

3.7.4 การตรวจสอบน้ำหนักและข้อมูลที่ขาดหาย

ผู้วิจัยรายงานน้ำหนักที่ตรึงไว้พร้อมสัดส่วนความพร้อมใช้งานของหลักฐาน เพื่อช่วยอธิบายว่าระบบอาศัยข้อมูลใดในการตัดสินใจ น้ำหนักรวมของนโยบายยังต้องแยกจากน้ำหนักที่มีผลจริงต่อแต่ละคู่ เพราะสูตรคำนวณจะปรับสัดส่วนใหม่เมื่อบางด้านไม่มีข้อมูล ตัวอย่างเช่น น้ำหนักภาพในนโยบายอาจมีค่าน้อย แต่ในคู่ที่ไม่มีหลักฐานชนิดอื่น สัดส่วนที่มีผลจริงอาจแตกต่างจากน้ำหนักรวมมาก

การวิเคราะห์จึงพิจารณาทั้งน้ำหนัก ความครอบคลุม ความเปลี่ยนแปลงระหว่าง seed และข้อผิดพลาดของคู่ที่มีหรือไม่มีหลักฐานแต่ละด้าน การอ้างว่ากลุ่มใดสำคัญที่สุดต่อแบบจำลองยังต้องใช้การวิเคราะห์แบบจำลองโดยตรงเพิ่มเติม ไม่สามารถสรุปจากน้ำหนักนโยบายเพียงอย่างเดียวได้

3.8 ขั้นตอนการดำเนินงานส่วนที่พัฒนาเพิ่มเติม

เพื่อให้เห็นความเชื่อมโยงกับงานเดิม ผู้วิจัยจัดลำดับงานเพิ่มเติมตั้งแต่ตรวจสอบข้อมูลต้นทางจนถึงจัดเตรียมผลสำหรับระบบ CRM เป็น 9 ขั้นตอนดังนี้

ขั้นตอนที่ 1 ทบทวนผลและข้อจำกัดของระบบเดิม

รวบรวมคะแนนรายคู่ คำตัดสินเดิม และผลประเมินของกระบวนการ Exact-First ร่วมกับเกณฑ์สองระดับ ตรวจสอบจำนวนคู่ที่รวมผิด คู่ที่ปฏิเสธผิด และคู่ที่รอตรวจสอบ เพื่อกำหนดว่าการพัฒนาครั้งนี้จะปรับวิธีตัดสินใจในส่วนใด ผลที่ต้องได้คือฐานเปรียบเทียบที่มีขอบเขตและนิยามตัวชี้วัดตรงกัน

ขั้นตอนที่ 2 จัดเตรียมคู่ข้อมูลและตรวจความถูกต้อง

แยกคู่ Exact-First ออกจากคู่ที่ใช้คะแนนโมเดล ตรวจรหัสคู่ซ้ำ จำนวนแถว และรหัสตรวจสอบไฟล์ต้นทาง จากนั้นจัดคู่ validation และ test ตามข้อมูลการแบ่งกลุ่มที่บันทึกไว้ ขั้นตอนนี้ช่วยให้เปรียบเทียบทุกนโยบายกับประชากรเดียวกัน และติดตามได้ว่าผลที่รายงานมาจากข้อมูลรุ่นใด

ขั้นตอนที่ 3 สร้างหลักฐานสำหรับการตัดสินใจ

เชื่อมข้อมูลคู่กับคุณลักษณะชื่อ ประวัติย่อ ลิงก์ ตำแหน่งที่อยู่ สัญญาณทางสังคม ภาพ และรูปแบบการเขียนตามที่มีจริง จัดทิศทางคะแนนให้สอดคล้องกัน และสร้างตัวบ่งชี้ความพร้อมใช้งานแยกจากค่าคะแนน สำหรับข้อมูลจำนวนมากให้ประมวลผลเป็นส่วนย่อย และตรวจรหัสคู่ทุกส่วนก่อนรวมผล

ขั้นตอนที่ 4 ตรวจความครอบคลุมและกำหนดกลุ่มที่ใช้งาน

นับจำนวนและสัดส่วนคู่ที่ใช้หลักฐานแต่ละด้านได้ ตรวจกรณีข้อมูลหายหรือไม่มีช่องข้อมูล และกำหนดรายชื่อกลุ่มที่เปิดให้ GA ค้นหาน้ำหนักจาก validation สำหรับรอบข้อมูลเต็ม ปิด location และ social ตามสภาพข้อมูลจริง พร้อมบันทึกเหตุผล เพื่อไม่ตีความการไม่มีข้อมูลเป็นผลเชิงลบของหลักฐานด้านนั้น

ขั้นตอนที่ 5 กำหนดนโยบายเปรียบเทียบและต้นทุน

เตรียมนโยบายคะแนนอย่างเดียว นโยบายใช้ชื่อช่วยตัดสิน และนโยบายแบบถ่วงน้ำหนัก กำหนดต้นทุนเป็น $2FP + FN + 0.1R$ เหมือนกันทุกแนวทาง และระบุให้ชัดว่าคู่บวกใน

REVIEW คิดเป็นงานตรวจสอบ การกำหนดวิธีนับก่อนเริ่มค้นหาช่วยลดความคลาดเคลื่อนในการเปรียบเทียบผล

ขั้นตอนที่ 6 ค้นหาพารามิเตอร์บน validation

ใช้ GA ค้นหาค่าเกณฑ์และน้ำหนักตามโครงสร้างของแต่ละนโยบาย ทำซ้ำด้วย seed ที่กำหนด และบันทึกต้นทุนกับพารามิเตอร์ระหว่างการค้นหา เปรียบเทียบผลจากการตั้งค่าของรอบเดียวกัน แล้วเลือกชุดที่ดีที่สุดตามลำดับเกณฑ์ที่กำหนดไว้ โดยยังไม่นำผล test มาใช้เลือก

ขั้นตอนที่ 7 บันทึกและตรึงนโยบายก่อนทดสอบ

จัดเก็บเกณฑ์ น้ำหนัก seed การตั้งค่า GA กลุ่มข้อมูลที่เปิดใช้งาน และรหัสตรวจสอบไฟล์ต้นทางลงในไฟล์นโยบายที่ตรึงไว้ ขั้นตอนนี้ทำให้ย้อนตรวจได้ว่าชุดพารามิเตอร์ที่ใช้ประเมิน test เป็นชุดเดียวกับที่เลือกจาก validation และสามารถนำกลับมาใช้ตัดสินข้อมูลได้ซ้ำ

ขั้นตอนที่ 8 ประเมิน test และนำไปตัดสินคู่ทั้งหมด

นำพารามิเตอร์ที่ตรึงไว้ไปประเมิน test โดยไม่ปรับค่าเพิ่มเติม จากนั้นคำนวณคำตัดสินสำหรับคู่ทั้งหมดโดยคง Exact-First ตามเดิม และส่งออกผลแยกตามนโยบาย รายงานผล validation, test, drop และภาพรวมแยกกัน เพื่อให้เห็นทั้งคุณภาพในขอบเขตทดสอบและปริมาณงานที่เกิดเมื่อใช้กับข้อมูลทั้งหมด

ขั้นตอนที่ 9 วิเคราะห์ข้อผิดพลาดและเตรียมผลส่งต่อ CRM

ตรวจคู่ที่ตัดสินต่างจากระบบเดิม โดยเฉพาะคู่ที่เปลี่ยนจาก REVIEW เป็น MATCH หรือ NO_MATCH เพื่ออธิบายว่าภาระตรวจสอบที่ลดลงสัมพันธ์กับความผิดพลาดอย่างไร จัดเก็บรหัสคู่ คะแนน คำตัดสิน และรุ่นนโยบายสำหรับส่งต่อกระบวนการรวมโปรไฟล์หรือคิวตรวจสอบ ผลส่งออกนี้เป็นหลักฐานของการประมวลผลในโครงงาน ยังไม่ใช่หลักฐานว่าเจ้าหน้าที่ได้ตรวจครบทุกคู่ หรือระบบ CRM ใช้งานจริงและเกิดผลประหยัดตามสมมติฐานแล้ว

ช่วงดำเนินงาน	ผลงานที่จัดเก็บเพื่อตรวจสอบย้อนกลับ
เตรียมข้อมูล	ตารางหลักฐานรายคู่ ตัวบ่งชี้ความพร้อมใช้งาน และข้อมูลตรวจสอบแหล่งที่มา
ค้นหานโยบาย	ผล validation ของแต่ละ seed และประวัติการค้นหา GA
ตรึงนโยบาย	เกณฑ์ น้ำหนัก การตั้งค่า และไฟล์นโยบายก่อนประเมิน test
ประเมินและส่งออก	ตาราง ตัวชี้วัด แยกกลุ่มข้อมูล และคะแนนกับคำตัดสินรายคู่ของแต่ละนโยบาย

ตารางที่ 3.20 ผลงานจากขั้นตอนการพัฒนานโยบายเพิ่มเติม

การดำเนินงานส่วนนี้ทำให้กระบวนการเดิมมีขั้นตอนเลือกนโยบายที่ตรวจสอบย้อนกลับได้ ตั้งแต่หลักฐานที่ใช้ ค่าพารามิเตอร์ที่เลือก ไปจนถึงผลกระทบต่อการรวมข้อมูลและคิวตรวจสอบ โดยยังรักษาความเชื่อมโยงกับการเตรียมข้อมูล การสร้างคู่ และการให้คะแนนที่ได้พัฒนาไว้ก่อนหน้า

บทที่ 4

ผลการทดลอง

4.1 การเตรียมข้อมูล

ชุดข้อมูลที่ใช้ในการพัฒนาและทดสอบระบบครั้งนี้เป็นชุดข้อมูลจำลอง (Synthetic Dataset) ที่สร้างขึ้นโดยอ้างอิงจากเทมเพลตโครงสร้างข้อมูลที่บริษัทจัดให้ ครอบคลุมโปรไฟล์ผู้ใช้จาก 3 แพลตฟอร์ม ได้แก่ Twitter, Instagram และ Google+ Archive รวมทั้งสิ้น 36,807 โปรไฟล์ โดยแต่ละโปรไฟล์ประกอบด้วยข้อมูลชื่อผู้ใช้ (Username), ชื่อจริง (Full Name), ประวัติย่อ (Bio), ลิงก์อ้างอิง (URL) และตำแหน่งที่อยู่ (Location) ซึ่งมีระดับความสมบูรณ์ของข้อมูล ที่แตกต่างกันไปตามแต่ละแพลตฟอร์ม

แพลตฟอร์ม	จำนวนโปรไฟล์	สัดส่วน (%)
Twitter	15,234	41.4%
Instagram	12,871	35.0%
Google+	8,702	23.6%
รวม	36,807	100%

ก่อนที่โปรไฟล์ทั้งหมดจะเข้าสู่กระบวนการ Classification จำเป็นต้องผ่านขั้นตอน Blocking ก่อน เพื่อลดพื้นที่การค้นหาจากจำนวน Candidate Pairs ทั้งหมด C(36,807, 2) ≈ 677 ล้านคู่ ให้เหลือเฉพาะคู่ที่มีโอกาสเป็นบุคคลเดียวกัน โดยใช้ Blocking Strategy แบบผสมผสานระหว่าง Username Prefix Blocking และ Full Name Jaro-Winkler Similarity ซึ่งสามารถลด Candidate Space ลงเหลือ 873,956 คู่ คิดเป็น Reduction Ratio 99.9% ในขณะที่ยังคงรักษา Blocking Recall ไว้ในระดับสูง จากนั้นได้ทำการติด Label ด้วยกระบวนการ Human-in-the-Loop ได้ชุดข้อมูลที่มี Label ทั้งสิ้น 162,442 pairs ก่อนแบ่งออกเป็น Train/Val/Test ตามแนวทาง Entity-Aware Split เพื่อป้องกัน Data Leakage ดังแสดงในตารางที่ 4.2

ตารางที่ 4.2 Entity-Aware Train/Val/Test Split (70/15/15)

Split	จำนวน Entities	จำนวน Pairs	Positive	Negative
Train	8,472	114,007	16,258	97,749
Val	1,815	24,113	3,510	20,603
Test	1,816	24,322	3,438	20,884

~~รวม~~	~~12,103~~	~~162,442~~	~~23,206~~	~~139,236~~

รายการ	ค่าที่ได้
All cross-platform pairs	449,149,239
Exact-first auto-accepted pairs	12,403
Candidate pairs for model	2,073,842
Search-space reduction	99.54%
Ground-truth coverage	88.67%

ข้อมูล Google+ มีลักษณะพิเศษที่กว่าอีกสองแพลตฟอร์ม เนื่องจาก Google+ ปิดตัวลงในปี 2019 ข้อมูลที่เหลืออยู่จึงอยู่ในรูปแบบ Archive ที่ไม่สมบูรณ์ ทั้งในแง่ Metadata และข้อมูล Engagement บางส่วนที่หายไปพร้อมกับการปิดระบบ สถานการณ์นี้เป็นตัวแทนของปัญหาข้อมูลไม่ครบในสภาพแวดล้อมจริง ไม่ใช่เพียงข้อจำกัด ของงานวิจัยนี้เพียงอย่างเดียว จำนวนโปรไฟล์แยกตามแพลตฟอร์มแสดงไว้ในตารางที่ 4.1

ตารางที่ 4.1 จำนวน valid profiles แยกตามแพลตฟอร์มที่ใช้จริง

แพลตฟอร์ม	จำนวนโปรไฟล์	สัดส่วน (%)
Twitter	13,959	37.9
Instagram	10,956	29.8
Google+	11,889	32.3
รวม	36,804	100.0

ก่อนที่โปรไฟล์ทั้งหมดจะเข้าสู่ขั้น candidate scoring ระบบต้องผ่านกระบวนการลดพื้นที่ค้นหาก่อน เพราะหากเปรียบเทียบทุกคู่แบบ Cross-platform โดยตรงจะมีจำนวนคู่สูงถึง 449,149,239 คู่ การลด Search space จึงเป็นเงื่อนไขจำเป็นของ ไม่ใช่เพียงขั้นตอนเสริม โดย Pipeline ใช้ Exact-First ร่วมกับ Blocking เพื่อดึงคู่ที่หลักฐานชัดมากออกมาจับคู่กันอัตโนมัติทันที และทำการส่งคู่ที่ยังมีความกำกวมเข้าสู่ขั้น Candidate scoring

ตารางที่ 4.2 ผลของขั้นเตรียม candidate set ก่อนเข้าสู่ candidate scoring

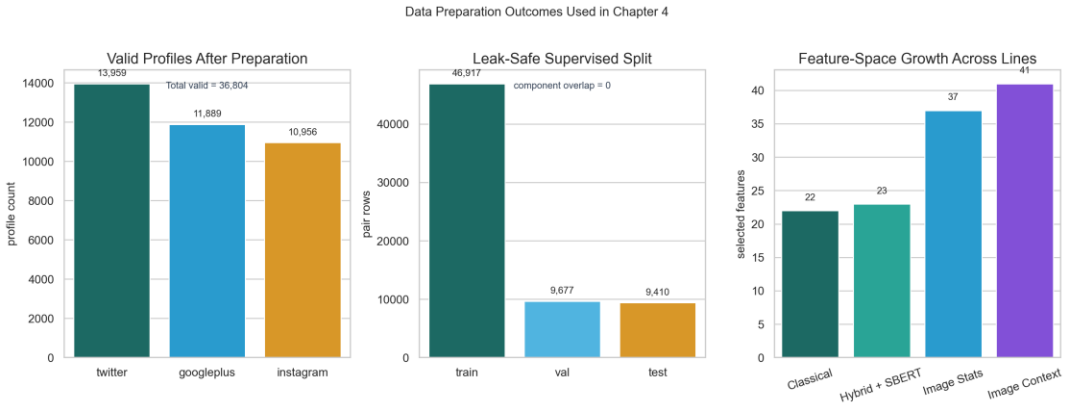
สำหรับชุดข้อมูลที่ใช้พัฒนาแบบจำลองการให้คะแนน (Candidate-scoring Model) ระบบได้ใช้เทคนิคการแบ่งข้อมูลแบบป้องกันการรั่วไหล (Leak-safe Split) โดยมีเงื่อนไขว่าต้องไม่

มีการทับซ้อนของข้อมูลระหว่างชุด Train, Validation และ Test รวมถึงต้องไม่มีคู่โปรไฟล์ที่จับคู่กับตัวเองหลงเหลืออยู่ การแบ่งข้อมูลด้วยวิธีนี้ช่วยป้องกันปัญหาผลการประเมินสูงเกินจริง ซึ่งเป็นปัญหาที่พบได้บ่อยในงานระบุตัวตน เมื่อข้อมูลของบุคคลเดียวกันรั่วไหลไปปรากฏอยู่ในหลายชุดข้อมูลพร้อมกัน

ตารางที่ 4.3 โครงสร้างของ supervised split สำหรับ main run

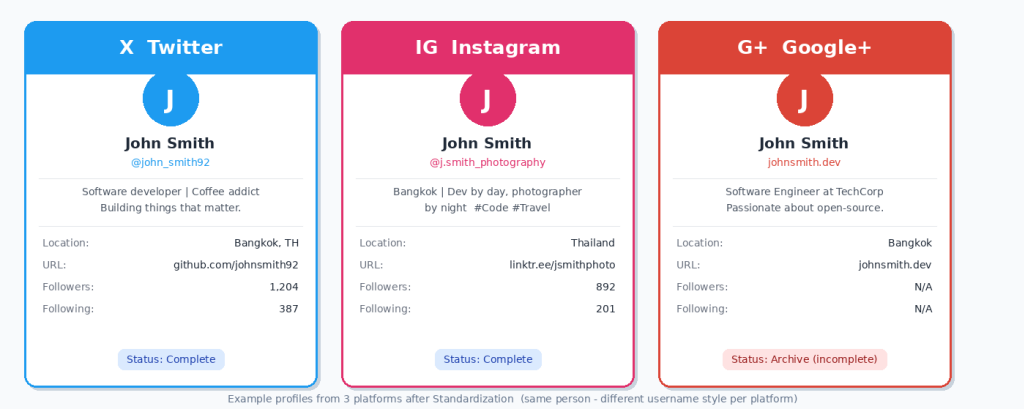
Split	Profiles	Positive Pairs	Random Negatives	Hard Negatives	Rows รวม
Train	22,478	20,470	15,346	5,987	41,803
Validation	7,925	4,386	3,289	905	8,580
Test	6,401	4,387	3,290	636	8,313

แสดงให้เห็นว่าการใคก Positive pairs เพียงอย่างเดียว แต่ใช้ทั้ง Random negatives` และ `hard negatives` เพื่อทำให้ model เห็นกรณีที่แยกได้ง่ายและกรณีที่สับสนคล้ายกันมากในเวลาเดียวกัน การออกแบบนี้ส่งผลโดยตรงต่อคุณภาพของ calibrated candidate scoring ในขั้นถัดไป



รูปที่ 4.1 สรุปผลการเตรียมข้อมูล ได้แก่ จำนวนโปรไฟล์ที่ใช้งานได้แยกตามแพลตฟอร์ม (รวม 36,604 โปรไฟล์), การแบ่ง Train/Val/Test แบบ Leak-Safe และการเติบโตของ Feature Space ในแต่ละชุด Feature ที่ออกแบบไว้

การแบ่งข้อมูลในลักษณะ Entity-Aware คือการแยก Entities ออกก่อน แล้วให้ Pairs ที่เกี่ยวข้องติดตามไปยัง Split เดียวกัน ซึ่งแตกต่างจาก Random Split ตรงที่ Entity เดียวกันจะไม่กระจายอยู่ทั้งใน Train และ Test พร้อมกัน การออกแบบนี้ช่วยป้องกันปัญหา Optimistic Bias ที่มักเกิดขึ้นในงาน Entity Matching เมื่อใช้การแบ่งแบบสุ่มทั่วไป



รูปที่ 4.2 ตัวอย่างโปรไฟล์จาก 3 แพลตฟอร์มหลังผ่าน Standardization

4.2 วิธีวัดประสิทธิภาพ

แนวทางการวัดผลในงานวิจัยครั้งนี้แบ่งออกเป็น 3 ระดับตามลำดับของ pipeline จริง ได้แก่ ระดับการลดพื้นที่ค้นหา, ระดับ candidate scoring และระดับ decision thresholding สำหรับการใช้งานจริงใน CRM การแยกตัวชี้วัด ออกตามหน้าที่ของแต่ละขั้นมีความสำคัญ เพราะค่า metric ที่ดีในระดับหนึ่ง ไม่ได้แปลว่าระบบพร้อมใช้งานจริงโดยอัตโนมัติเสมอไป

4.2.1 ตัวชี้วัดสำหรับ Search Space Reduction และ Candidate Retrieval

ในขั้นก่อนเข้าสู่ candidate scoring ผู้วิจัยใช้ตัวชี้วัดหลัก 2 ค่า

- Reduction Ratio สะท้อนว่าระบบลดจำนวนคู่ที่ต้องตรวจต่อได้มากเพียงใด ยิ่งสูงยิ่งดี เพราะหมายถึง pipeline ประหยัดภาระการคำนวณในขั้น scoring ได้มากขึ้น

$$\text{Reduction Ratio} = 1 - \left(\frac{\text{Pairs}_{\text{after}}}{\text{Pairs}_{\text{before}}}\right)$$

- **Ground-truth Coverage** สะท้อนถึงสัดส่วนการคงอยู่ของคู่ข้อมูลจริงที่ต้องนำไปประมวลผลต่อในขั้นถัดไป หากค่าความครอบคลุม มีระดับที่ต่ำจนเกินไป ตัวแบบจะสูญเสียโอกาสในการกู้คืนคู่ข้อมูลจริงที่ถูกคัดทิ้งไปในขั้นตอนก่อนหน้า ซึ่งวัดสัดส่วนของ True Positive Pairs ที่สามารถผ่าน Blocking เข้ามาได้เทียบกับ True Positive Pairs ทั้งหมด ค่านี้ยิ่งสูงยิ่งดี เนื่องจากหาก Blocking ตัด Positive Pairs ออกไป

$$\text{Ground} - \text{truth Coverage} = \frac{\text{TP passed}}{\text{TP total}}$$

4.2.2 ตัวชี้วัดสำหรับ Candidate Scoring

ในระดับ candidate scoring ใช้ตัวชี้วัดมาตรฐานของงานจัดอันดับและจำแนก ได้แก่

- Precision วัดว่าจากทั้งหมดที่แบบจำลองทำนายว่า MATCH มีกี่เปอร์เซ็นต์ที่เป็น True Positive จริง

$$\text{Precision} = \frac{\text{TP}}{(\text{TP} + \text{FP})}$$

- Recall ซึ่งวัดว่าจาก Positive Pairs ทั้งหมด แบบจำลองสามารถจับได้กี่เปอร์เซ็นต์

$$\text{Recall} = \frac{\text{TP}}{(\text{TP} + \text{FN})}$$

- F1-score ค่าเฉลี่ยฮาร์โมนิกของ Precision และ Recall เหมาะสำหรับข้อมูลที่มี Class Imbalance เพราะให้น้ำหนักทั้งสองค่าเท่ากัน

$$\text{F1} - \text{Score} = 2 \times \frac{(\text{Precision} \times \text{Recall})}{(\text{Precision} + \text{Recall})}$$

- Average Precision (AP) เป็นตัวชี้วัดที่ใช้ประเมินคุณภาพการจัดอันดับของแบบจำลองบนข้อมูลที่มีความไม่สมดุลของคลาส โดยคำนวณจากพื้นที่ใต้เส้นโค้ง Precision-Recall ซึ่งสะท้อนว่าแบบจำลองสามารถจัดคู่ข้อมูลที่เป็นบวกจริงให้อยู่ในลำดับต้นได้ดีเพียงใด ทั้งนี้สามารถเขียนได้ในรูป

$$\text{AP} = \sum_{\text{n}} (\text{R}_\text{n} - \text{R}_{\text{n}-1})\text{P}_\text{n}$$

โดยที่

P_n คือค่า Precision ที่จุดลำดับที่ n
R_n คือค่า Recall ที่จุดลำดับที่ n

- ROC-AUC ใช้วัดความสามารถของแบบจำลองในการแยกคู่ MATCH ออกจาก NO_MATCH โดยไม่ยึดกับ threshold ใด threshold หนึ่ง เส้น ROC สร้างจากความสัมพันธ์ระหว่าง True Positive Rate (TPR) และ False Positive Rate (FPR) และค่า AUC คือพื้นที่ใต้เส้นโค้งดังกล่าว เข้าใกล้ 1.0 หมายถึงแบบจำลองมีความสามารถในการแยกแยะสูงมาก

$$\mathrm{AUC} = \int_0^1 \mathrm{TPR}(\mathrm{FPR})\mathrm{d}(\mathrm{FPR})$$

นอกจากตัวชี้วัดหลักดังกล่าว ยังมีการใช้ Confusion Matrix เพื่อวิเคราะห์ลักษณะความผิดพลาดของแบบจำลอง และใช้ precision@k เพื่อประเมินคุณภาพของการจัดอันดับคู่ข้อมูลที่มีคะแนนสูงสุดบน full candidate pairs ซึ่งมีความสำคัญต่อการนำผลลัพธ์ไปใช้จัดลำดับงานตรวจสอบในขั้น review

4.2.3 ตัวชี้วัดสำหรับ Probability Calibration และ Decision Thresholding

เมื่อนำคะแนนจากแบบจำลองไปใช้งานจริงในระดับ Production เป้าหมายของการประเมินจะเปลี่ยนจากการวัดความแม่นยำเชิงสถิติทั่วไป ไปสู่ ตัวชี้วัดเชิงการตัดสินใจ (Decision-centric Metrics) เพื่อตอบโจทย์กระบวนการทำงานของระบบ CRM โดยให้ความสำคัญกับตัวชี้วัดหลัก 3 ส่วน ดังนี้

Expected Calibration Error (ECE) ใช้ตรวจสอบว่าคะแนนความน่าจะเป็นที่ผ่านการปรับเทียบ (Calibration) แล้ว มีความสอดคล้องกับสัดส่วนความเป็นจริงมากน้อยเพียงใด ค่า ECE ที่ต่ำจะเป็นเครื่องยืนยันว่า การตั้งค่าจุดตัด (Threshold) ในระดับสูง ~~(เช่น 0.95 หรือ 0.98) มีความน่าเชื่อถือ และสามารถนำไปใช้อ้างอิงเป็นเกณฑ์ในการปฏิบัติงานได้จริง~~

$$\mathrm{ECE} = \mathrm{m} = 1\sum \mathrm{m}^{\mathrm{n}} \mid \mathrm{B_m} \mid \mathrm{acc}(\mathrm{B_m}) - \mathrm{conf}(\mathrm{B_m})$$

โดยที่

$\mathrm{B_m}$ คือกลุ่มข้อมูลใน bin ที่ m

$\mid \mathrm{B_m} \mid$ คือจำนวนตัวอย่างใน bin นั้น

n คือจำนวนตัวอย่างทั้งหมด

$\mathrm{acc}(\mathrm{B_m})$ คือ accuracy จริงของ bin ที่ m

$\mathrm{conf}(\mathrm{B_m})$ คือค่า confidence เฉลี่ยของ bin ที่ m

- Final Match-only Precision และ Final Match-only Recall เป็นตัวชี้วัดที่ใช้ตอบโจทย์ปลายทางโดยตรงว่า จุดปฏิบัติการ (Operating Point) หรือค่าจุดตัดที่ระบบเลือกใช้นั้น มีความแม่นยำและปลอดภัยเพียงพอสำหรับการทำ "การรวมโปรไฟล์อัตโนมัติ (Auto-merge)" ในระบบ CRM หรือไม่ โดยไม่ก่อให้เกิดความผิดพลาดที่ยอมรับไม่ได้

$$\text{Final Match-only Recall} = \frac{\text{TP}_{\text{match}}}{\text{TP}_{\text{all}}}$$

$$\text{Final Match} - \text{only Precision} = \text{TP}_{\text{match}} + \text{FP}_{\text{match}} \;\; \text{TP}_{\text{match}}$$

โดยที่

- TP_{match} คือจำนวนคู่จริงที่ระบบจัดอยู่ในกลุ่ม MATCH
- FP_{match} คือจำนวนคู่ผิดที่ระบบจัดอยู่ในกลุ่ม MATCH
- TP_{all} คือจำนวนคู่จริงทั้งหมดในข้อมูลอ้างอิง

- Operational Outcomes และ Review Queue Size พิจารณาจากสัดส่วนของผลลัพธ์ที่ถูกแบ่งออกเป็น 3 กลุ่มปฏิบัติการ (MATCH, REVIEW, NO_MATCH) รวมถึง ขนาดของคิวที่พนักงานต้องตรวจสอบด้วยตาเปล่า (Review Queue Size) เพื่อประเมินว่าระบบสามารถช่วยลดภาระงานของมนุษย์ได้จริง และไม่สร้างคอขวด (Bottleneck) ในกระบวนการทำงาน

$$\text{Review Queue Size} = \text{N}(\text{T}_{\text{review}} \leq \text{score} < \text{T}_{\text{match}})$$

$$\text{Match Count} = \text{N}(\text{score} > \text{T}_{\text{match}}) + \text{N (exact match)}$$

$$\text{NO_MATCH Count} = \text{N}(\text{score} < \text{T}_{\text{review}})$$

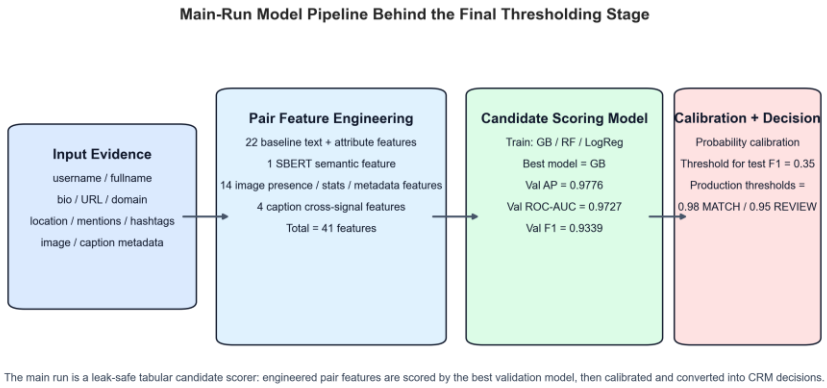
โดยที่

- T_{match} คือ threshold สำหรับ MATCH
- T_{review} คือ threshold ต่ำสุดของช่วง REVIEW

4.3 Candidate-Scoring Model ที่ใช้ก่อน Decision Thresholding

main run ที่ถูกใช้เป็นฐานของ Project 1 คือ image_context_r075_h20_s42 จากชุดทดลอง multimodal suite ซึ่งสืบทอด pair construction, leakage-safe split และ calibration logic มาจาก rebuilt hybrid pipeline เดิม ดังนั้นผลในบทนี้จึงไม่ใช่ผลจาก pair source ที่รั่วหรือ split ที่มี entity overlap ระหว่าง train, validation และ test

แบบจำลองในงานนี้ไม่ได้รับ raw profiles เข้าไปโดยตรง แต่แปลงโปรไฟล์สองฝั่งให้เป็น pair-level feature vector ก่อนเสมอ โดยโครงสร้างของ feature space เติบโตเป็นลำดับจาก 22 baseline text+attribute features ไปเป็น 23 features เมื่อเพิ่ม SBERT, ขยายเป็น 37 features เมื่อเพิ่ม image statistics และสิ้นสุดที่ 41 features เมื่อเพิ่ม caption-to-text cross signals ใน run แบบ image_context วิธีออกแบบเช่นนี้ทำให้ระบบทำงานในฐานะ tabular candidate scorer ที่เรียนรู้จากหลักฐานเชิงความคล้ายของคู่โปรไฟล์หลายประเภทพร้อมกัน



รูปที่ 4.3 โครงสร้างของ main-run model pipeline สำหรับ Project 1 เริ่มจากการสร้าง pair features จากข้อมูลชื่อ ข้อความ attribute ภาพ และ caption จากนั้นให้ candidate-scoring model ประเมินคะแนน ก่อนผ่าน probability calibration และ decision thresholding

จากรูปที่ 4.2 จะเห็นว่าตัวแบบในงานนี้ไม่ใช่ end-to-end deep model ที่เรียนรู้จากข้อมูลดิบ ทั้งก้อน แต่เป็น pipeline เชิงวิศวกรรมข้อมูลที่แยกขั้นชัดเจน กล่าวคือผู้วิจัยสร้าง feature table ระดับคู่ก่อน แล้วจึงให้ model family ที่เหมาะกับข้อมูลเชิงตารางเรียนรู้รูปแบบการแยก MATCH / NO_MATCH วิธีนี้เหมาะกับขอบเขตของ Project 1 เพราะอธิบายได้ชัด ตรวจสอบได้ง่าย และรองรับการนำคะแนนไป calibrate และ threshold ต่อในเชิงปฏิบัติการ

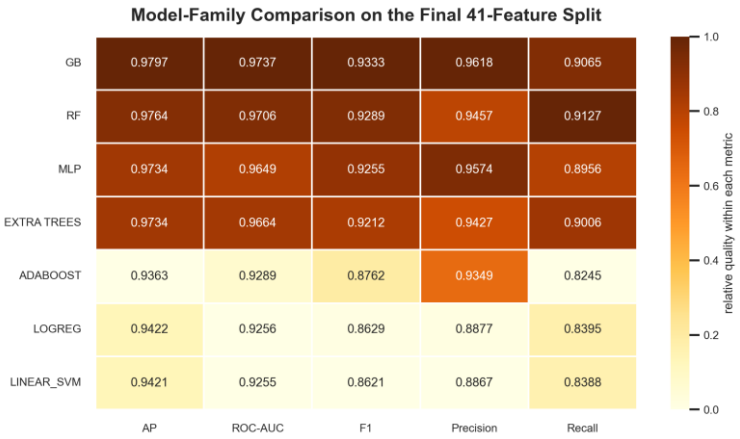
4.3.1 การเลือกโมเดลและการเปรียบเทียบ candidate-scoring configurations

ภายใน main run ระบบฝึกและเปรียบเทียบอย่างน้อย Gradient Boosting, Random Forest และ Logistic Regression แล้วเลือกโมเดลที่ให้ผลดีที่สุดบน validation set ซึ่ง experiment_report.json ระบุชัดว่า best_model = gb หรือ Gradient Boosting

ตารางที่ 4.4 ผล validation leaderboard ภายใน main run

Model	Val AP	Val ROC-AUC	ข้อสรุปใน run
Gradient Boosting	0.9795	0.9720	ดีที่สุด
Random Forest	0.9778	0.9696	รองลงมา
Logistic Regression	0.9431	0.9245	ต่ำกว่าสองตัวแรกชัดเจน

เพื่อไม่ให้การเลือก Gradient Boosting อิงเพียง leaderboard ภายใน run เดียว ผู้วิจัยยัง benchmark model families หลายชนิดบน final 41-feature split เดียวกันเพิ่มเติม ซึ่งรวมถึง MLP, Extra Trees, AdaBoost, Logistic Regression และ Linear SVM ด้วย ผลในชุด benchmark นี้ชี้ว่า Gradient Boosting ให้สมดุลของ AP, ROC-AUC, F1 และ Precision ดีที่สุดในภาพรวม แม้บางโมเดลจะมีค่าในบาง metric ใกล้เคียงกัน

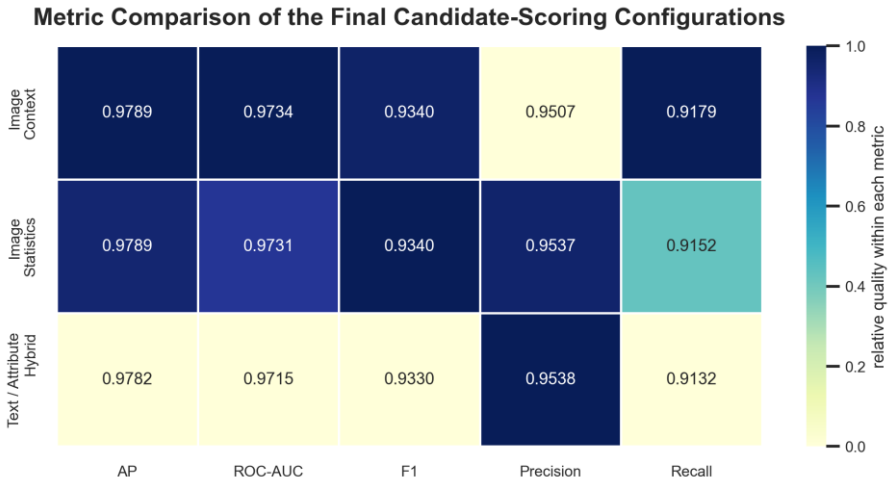


รูปที่ 4.4 การเปรียบเทียบ model families บน final 41-feature split โดยใช้สีแสดงคุณภาพสัมพัทธ์ภายในแต่ละ metric และใช้ตัวเลขในเซลล์แสดงค่าจริงของ AP ROC-AUC F1 Precision และ Recall

พร้อมกันนั้น ผู้วิจัยยังเปรียบเทียบ candidate-scoring configurations ที่ใช้ pair set และ split เดียวกัน เพื่อพิสูจน์ว่า image_context เหมาะสมกว่าการหยุดที่ text_attr_hybrid หรือ image_stats

ตารางที่ 4.5 ผลเปรียบเทียบ candidate-scoring configurations ที่ใช้เลือก main run

Configuration	Feature Count	AP	ROC-AUC	F1	Precision	Recall
Text/Attribute Hybrid	23	0.9782	0.9715	0.9330	0.9538	0.9132
Image Statistics	37	0.9789	0.9731	0.9340	0.9537	0.9152
Image Context	41	0.9789	0.9734	0.9340	0.9507	0.9179



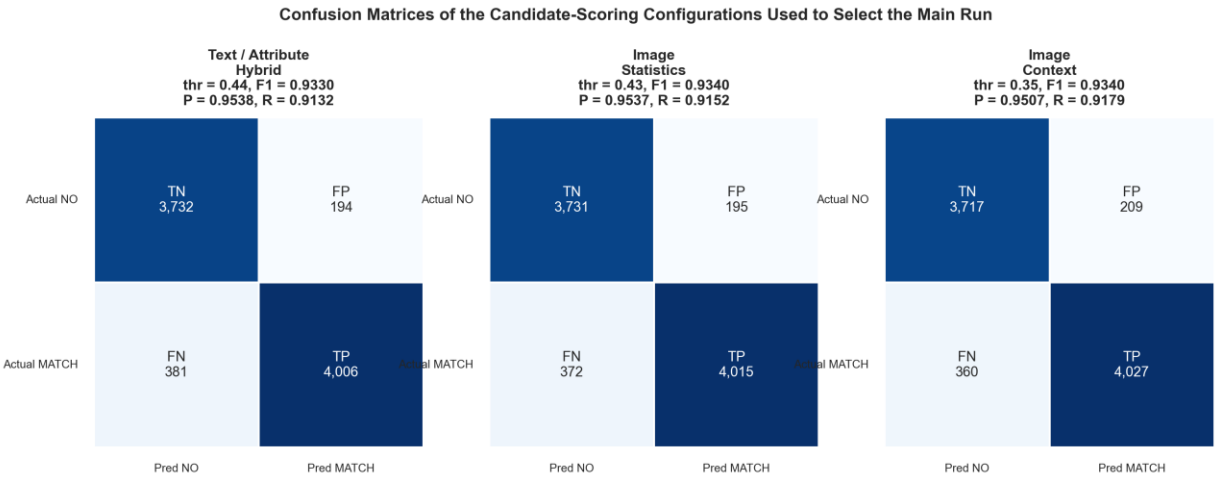
รูปที่ 4.5 การเปรียบเทียบ metric ของ candidate-scoring configurations โดยใช้สีแสดงคุณภาพสัมพัทธ์ภายในแต่ละ metric และใช้ตัวเลขในเซลล์แสดงค่าจริงของ AP ROC-AUC F1 Precision และ Recall

ผลในตารางที่ 4.5 และรูปที่ 4.4 แสดงว่า image_context เป็น configuration ที่เหมาะสมที่สุดสำหรับ Project 1 เพราะให้ AP, ROC-AUC และ Recall สูงที่สุดในภาพรวม แม้ Image Statistics จะมี F1 สูงกว่าในหลักทศนิยมลึกบางจุด แต่ความต่างนั้นน้อยมากเมื่อเทียบกับข้อได้เปรียบของ Image Context ในด้าน ranking quality และความครอบคลุมของคู่จริง

เพื่อให้การเปรียบเทียบครบในระดับโครงสร้างความผิดพลาด ผู้วิจัยจึงพิจารณา confusion matrix ของทั้งสาม configuration ควบคู่ไปด้วย เพราะค่า AP หรือ F1 เพียงอย่างเดียวอาจยังไม่อธิบายได้ชัดว่าความต่างของแต่ละ run เกิดจากการลด false positives หรือการลด false negatives เป็นหลัก

ตารางที่ 4.6 Confusion matrix เปรียบเทียบ candidate-scoring configurations บน test split

Configuration	Threshold	TN	FP	FN	TP
Text/Attribute Hybrid	0.44	3,732	194	381	4,006
Image Statistics	0.43	3,731	195	372	4,015
Image Context	0.35	3,717	209	360	4,027



รูปที่ 4.6 Confusion matrices ของ candidate-scoring configurations ทั้งสามแบบบน test split แสดง trade-off ระหว่าง false positives และ false negatives ที่ใช้ประกอบการเลือก main run

ผลในตารางที่ 4.6 และรูปที่ 4.5 ชี้ให้เห็นลักษณะ trade-off ที่สำคัญ 2 ประเด็น ประเด็นแรก Image Statistics ลด FN ลงจาก 381 เหลือ 372 เมื่อเทียบกับ Text/Attribute Hybrid โดยแทบไม่เพิ่ม FP เลย

ซึ่งยืนยันว่าการเพิ่มสัญญาณภาพระดับสถิติมีผลเชิงบวกจริงต่อการกู้คู่จริง ประเด็นที่สอง Image Context ลด FN ต่อเนื่องลงเหลือ 360 แต่ยอมให้ FP เพิ่มเป็น 209 ภายใต้ threshold ที่ต่ำกว่า (0.35) ผลเช่นนี้สอดคล้องกับค่า Recall ที่สูงที่สุดของ run นี้ และเป็นเหตุผลสำคัญที่ผู้วิจัยเลือก image_context เป็น main run แล้วนำไป calibrate และตั้ง threshold เชิง production ต่อ แทนที่จะเลือก configuration ที่เข้มงวดกว่าแต่กู้คู่จริงได้น้อยกว่า

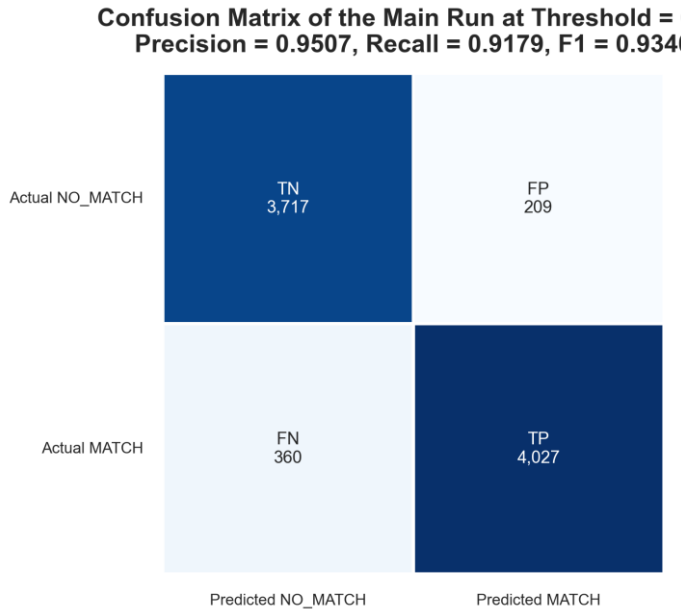
4.3.2 ผลเชิงจำแนกของ Main Run บน Test Split

เมื่อใช้ threshold เชิงจำแนก 0.35 บน test split main run ให้ Precision = 0.9507, Recall = 0.9179 และ F1 = 0.9340 พร้อม confusion matrix TN = 3,717, FP = 209, FN = 360 และ TP = 4,027

ตารางที่ 4.7 ผลของ main run บน test split ก่อนเข้าสู่ production thresholding

รายการ	ค่าที่ได้
Best model	Gradient Boosting
Feature count	41
Threshold สำหรับ test classification	0.35
Test AP	0.9789
Test ROC-AUC	0.9734
Test F1	0.9340

Test Precision	0.9507
Test Recall	0.9179
TN / FP / FN / TP	3,717 / 209 / 360 / 4,027

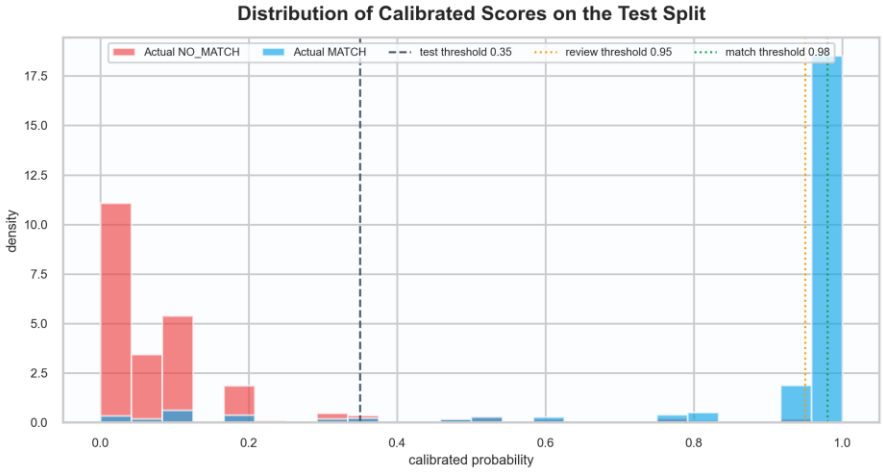


รูปที่ 4.7 Confusion matrix ของ main run บน test split ที่ threshold = 0.35 แสดงสมดุลระหว่าง true positives false positives true negatives และ false negatives ของแบบจำลองก่อนเข้าสู่ขั้น decision thresholding ระดับ production

ผลนี้ชี้ว่า main run สามารถรักษาสมดุลระหว่างความเข้มงวดและความครอบคลุมได้ดี กล่าวคือจำนวน false positives อยู่ในระดับต่ำเมื่อเทียบกับ true positives และจำนวน false negatives ก็ไม่ได้สูงเกินไปจนทำให้ recall ตกลงอย่างมีนัยสำคัญ หากมองในมุมของ pipeline ทั้งระบบ ผลในระดับนี้เหมาะกับการส่งต่อเข้าสู่ขั้น calibration และ thresholding มากกว่าการใช้ตัดสินใจ merge โดยตรง

4.3.3 การกระจายคะแนนและ Threshold Trade-off

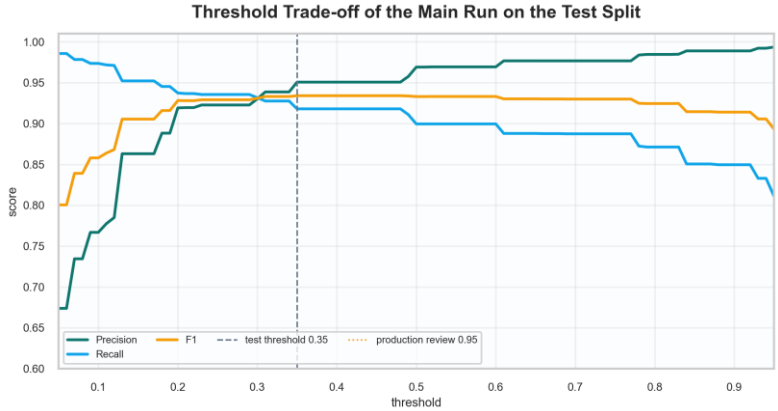
เมื่อพิจารณาการกระจายของ calibrated probabilities บน test split จะเห็นว่าคู่ NO_MATCH ส่วนใหญ่กระจุกตัวอยู่ใกล้ศูนย์ ขณะที่คู่ MATCH กระจุกตัวอยู่ใกล้หนึ่งอย่างชัดเจน โดยค่าเฉลี่ยของกลุ่ม NO_MATCH อยู่ที่ประมาณ 0.1095 และค่ามัธยฐานอยู่ที่ 0.0684 ส่วนกลุ่ม MATCH มีค่าเฉลี่ย 0.9012 และค่ามัธยฐานสูงถึง 0.9966 การแยกตัวของสอง distribution นี้เป็นสัญญาณว่าตัวแบบมีความสามารถในการจัดลำดับคู่ที่น่าใช่และไม่น่าใช่ออกจากกันได้ดี



รูปที่ 4.8 การกระจายของ calibrated scores บน test split แยกตาม Actual MATCH และ Actual NO_MATCH พร้อมเส้นอ้างอิงที่ threshold = 0.35 และเส้น production thresholds ที่ 0.95 และ 0.98

รูปที่ 4.7 ช่วยให้เห็นชัดว่า threshold สำหรับการประเมินเชิงจำแนก (0.35) และ threshold สำหรับการใช้งานจริง (0.95 / 0.98) อยู่คนละบริบทกัน โดย threshold 0.35 อยู่ในช่วงที่ optimize ความสมดุลของ F1 บน test split ขณะที่ threshold ปลายทางถูกเลื่อนไปยังปลายขวาของ distribution เพื่อคุม precision สำหรับการ merge จริงให้เข้มงวดขึ้นมาก

หากพิจารณาความสัมพันธ์ระหว่าง Precision, Recall และ F1 เมื่อขยับ threshold จะเห็น trade-off ชัดเจน กล่าวคือ threshold ต่ำช่วยให้ recall สูง แต่ precision ลดลงเร็ว ขณะที่ threshold สูงช่วยคุม precision ได้ดีขึ้นแลกกับ recall ที่ลดลง ซึ่งเป็นเหตุผลสำคัญที่ทำให้ production operating point ต้องแยก MATCH ออกจาก REVIEW แทนการใช้ threshold เดียวบังคับทั้งระบบ



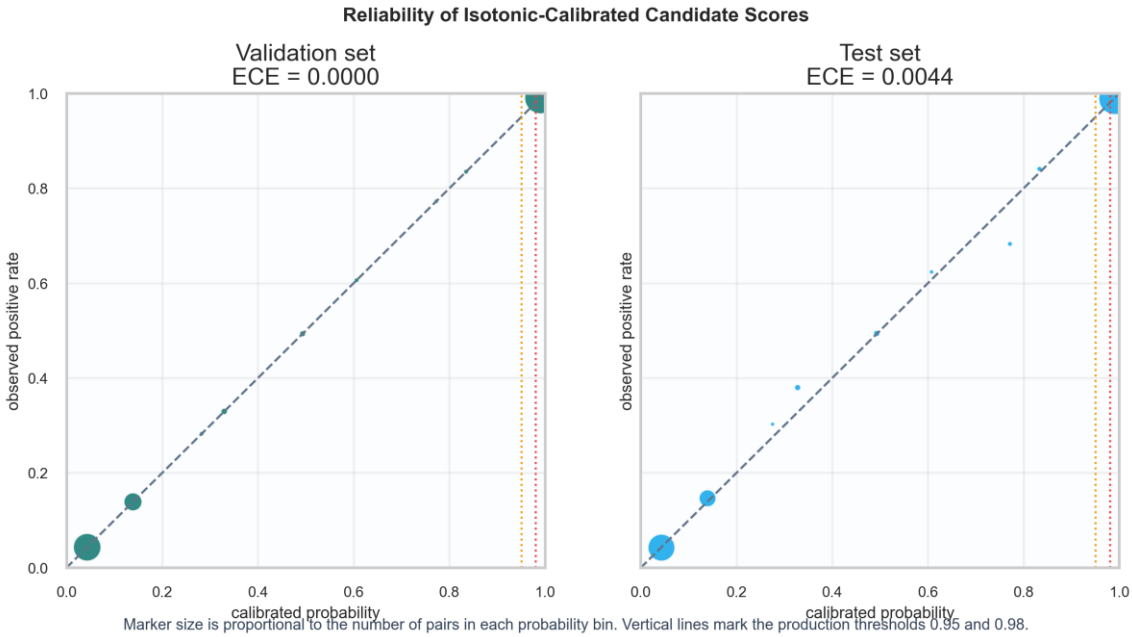
รูปที่ 4.9 พฤติกรรมของ Precision Recall และ F1 ของ main run เมื่อเปลี่ยน threshold บน test split แสดงความแตกต่างระหว่าง threshold เชิงจำแนกที่ 0.35 กับ production review threshold ที่ 0.95

ที่ threshold 0.35 ระบบได้ Precision = 0.9507, Recall = 0.9179 และ F1 = 0.9340 ซึ่งเหมาะสำหรับการประเมินเชิงแบบจำลอง แต่เมื่อยก threshold ไปถึง 0.95 ค่า precision บน test split จะสูงขึ้นเป็นประมาณ 0.9936 ขณะที่ recall ลดลงเหลือประมาณ 0.8110 และ F1 ลดลงมาอยู่ที่ประมาณ 0.8931 ผลนี้อธิบายได้ชัดเจนว่าทำไม production จึงต้องเพิ่มชั้น REVIEW เข้ามาช่วยรับคู่ที่ยังมีศักยภาพแต่ไม่ควรถูก auto-merge ทันที

4.3.4 การสอบเทียบความน่าจะเป็นด้วย Isotonic Regression

หลังจากเลือกโมเดลที่ดีที่สุดแล้ว pipeline ไม่ได้นำค่าความน่าจะเป็นดิบจาก predict_proba() ไปใช้ตัดสินใจใน production ทันที แต่ใช้ IsotonicRegression(out_of_bounds="clip") เป็นตัว calibrate คะแนนก่อนเสมอ โดยขั้นตอนจริงคือ fit isotonic calibrator บน validation raw scores กับ validation labels จากนั้นจึงนำ calibrator เดียวกันไปแปลงคะแนนของ train, validation และ test ให้กลายเป็น calibrated probabilities ก่อนเลือก operating point ระดับ production

ผลจาก score files ของ main run แสดงว่า isotonic calibration ทำงานได้ดีมาก โดย validation set ซึ่งเป็นชุดที่ใช้ fit calibrator มี ECE = 0.0000 และ test set มี ECE = 0.0044 เท่านั้น ค่าที่ต่ำมากนี้สะท้อนว่า calibrated probabilities บน test ยังคงเกาะใกล้ observed positive rate ในแต่ละช่วงคะแนนอยู่มาก

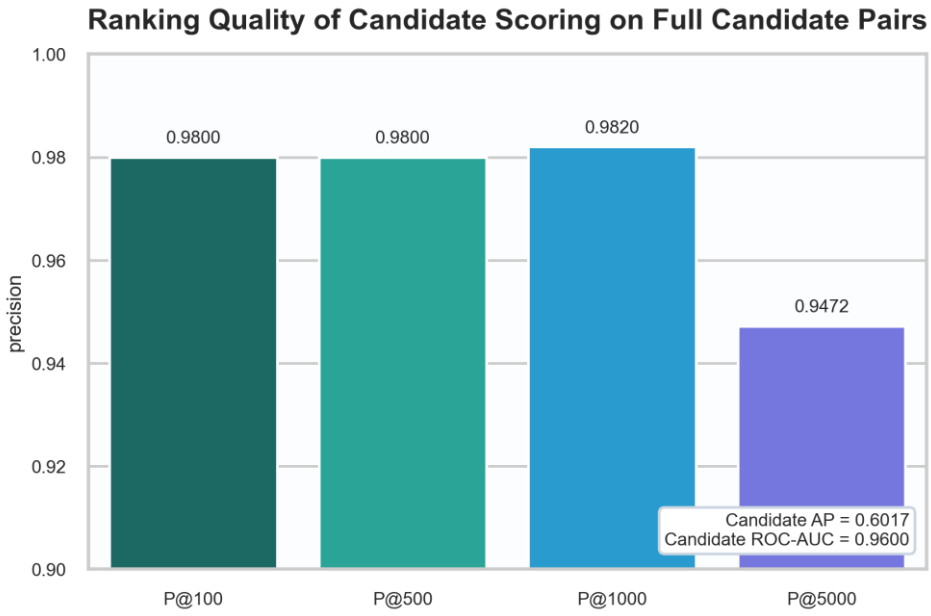


รูปที่ 4.10 Reliability ของ calibrated probabilities หลังผ่าน Isotonic Regression เปรียบเทียบ validation set และ test set โดยใช้ขนาด marker แทนจำนวนคู่ในแต่ละ probability bin และเส้นตั้งแสดง production thresholds ที่ 0.95 และ 0.98

รูปที่ 4.9 ให้ข้อสรุปสำคัญว่า calibrated score ของ main run มีความน่าเชื่อถือเพียงพอสำหรับการกำหนด operating point เชิง production กล่าวคือ validation reliability curve เกือบซ้อนทับเส้นทแยงตามธรรมชาติของ isotonic fit ขณะที่ test curve ยังเกาะใกล้แนวอุดมคติอยู่มาก แม้บาง bin ขนาดเล็กจะมีความผันผวนตามจำนวนตัวอย่างที่น้อย

4.3.5 คุณภาพการจัดอันดับบน Full Candidate Pairs

นอกเหนือจากผลบน test split ผู้วิจัยยังประเมินคุณภาพการจัดอันดับของ calibrated candidate scores บน candidate pairs จริงทั้งหมด 2,073,842 คู่ที่ผ่าน blocking เข้ามา ผลลัพธ์แสดงว่า candidate_avg_precision = 0.6017 และ candidate_roc_auc = 0.9600 พร้อมค่า precision@100 = 0.9800, precision@500 = 0.9800, precision@1000 = 0.9820 และ precision@5000 = 0.9472



รูปที่ 4.11 คุณภาพการจัดอันดับของ candidate scoring บน full candidate pairs โดยแสดง precision@100 precision@500 precision@1000 และ precision@5000 ร่วมกับค่า Candidate AP และ ROC-AUC

ค่าเหล่านี้มีความหมายเชิงระบบมาก เพราะชี้ว่าแม้ candidate pool จริงจะมี class imbalance สูงและมี candidate count ระดับล้านคู่ แต่คะแนนของแบบจำลองยังสามารถดันคู่จริงจำนวนมากขึ้นไปอยู่ในอันดับต้น ๆ ได้อย่างมีประสิทธิภาพ ซึ่งเป็นคุณสมบัติที่จำเป็นมากสำหรับ thresholding และ review workflow

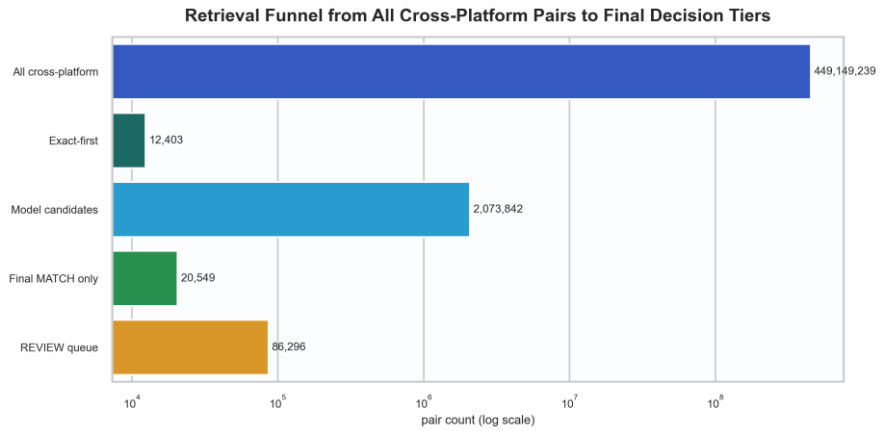
4.4 Exact-First ร่วมกับ Calibrated Candidate Scoring สำหรับ Decision Thresholding

เมื่อได้ candidate-scoring model ที่ผ่านการ calibration แล้ว ขั้นถัดไปคือการนำคะแนนดังกล่าวไปเชื่อมกับ exact-first เพื่อสร้างกฎตัดสินใจที่ใช้ได้จริงใน CRM จุดตั้งต้น ของปัญหานี้คือ valid profiles 36,804 โปรไฟล์ก่อให้เกิดคู่แบบ cross-platform ทั้งหมด 449,149,239 คู่ ซึ่งไม่สามารถเปรียบเทียบทุกคู่โดยตรงได้ในทางปฏิบัติ ดังนั้น pipeline จึงต้องลด search space ก่อน

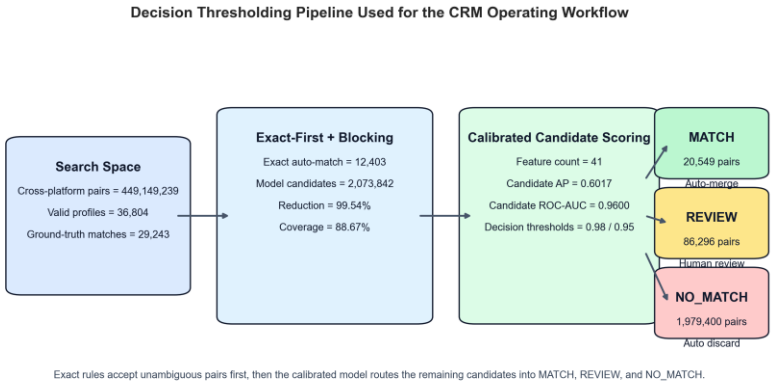
ผลรันจริงแสดงว่า exact-first และ blocking สามารถคัดคู่ exact ที่ merge ได้ทันที 12,403 คู่ และลดคู่ที่ต้องให้แบบจำลองประเมินต่อเหลือ 2,073,842 คู่ คิดเป็นการลดพื้นที่ค้นหาลง 99.54% พร้อมรักษา coverage ของ ground-truth matches ไว้ 88.67%

ตารางที่ 4.8 Retrieval funnel ของ Project 1 ก่อนเข้าสู่การตัดสินใจปลายทาง

ขั้นตอน	จำนวนคู่
All cross-platform pairs	449,149,239
Exact-first auto-accepted pairs	12,403
Candidate pairs for model	2,073,842
Final MATCH only	20,549
REVIEW queue	86,296



รูปที่ 4.12 Retrieval funnel ของ Project 1 แสดงการลด search space จาก all cross-platform pairs ไปสู่ exact-first pairs model candidates final MATCH only และ REVIEW queue



รูปที่ 4.13 โครงสร้างของ Project 1 ในขั้น decision thresholding เริ่มจาก exact-first และ blocking ก่อนส่ง candidate pairs เข้าสู่ calibrated candidate scoring แล้วแยกผลลัพธ์เป็น MATCH REVIEW และ NO_MATCH

ตารางที่ 4.8 และรูปที่ 4.11-4.12 ชี้ให้เห็นว่า `exact-first` ไม่ได้เป็นเพียง heuristic เสริม แต่เป็นองค์ประกอบหลักของ Project 1 เพราะช่วยดึงคู่ที่ชัดมากออกจากระบบตั้งแต่ต้น และเปิดทางให้โมเดลโฟกัสเฉพาะคู่ที่กำกวมกว่า ซึ่งเป็นส่วนที่ calibration และ thresholding จะสร้างคุณค่าจริง

4.5 ผลลัพธ์ปลายทางของ MATCH, REVIEW และ NO_MATCH สำหรับ CRM

ในระดับ production operating point ที่ถูกนำไปใช้จริง ระบบกำหนด match_threshold = 0.98 และ review_threshold = 0.95 เพื่อควบคุมความเสี่ยงของการ merge ผิดในบริบท CRM ซึ่ง false merge ถือเป็นความเสียหายที่รุนแรงกว่าการส่งคู่ไปให้มนุษย์ตรวจซ้ำ กติกาการตัดสินใจจริงจึงเป็นดังนี้

1. ถ้า username หรือ URL ตรงกันแบบ exact ให้ตัดสินเป็น MATCH ทันที
2. ถ้าไม่ใช่ exact pair แต่ calibrated score >= 0.98 ให้ตัดสินเป็น MATCH
3. ถ้าคะแนนอยู่ในช่วง 0.95 <= score < 0.98 ให้ส่งเข้า REVIEW
4. ถ้าคะแนนต่ำกว่า 0.95 ให้ตัดสินเป็น NO_MATCH

ตารางที่ 4.9 Operating point ที่ใช้จริงในขั้น decision thresholding

ชั้นการตัดสินใจ	เงื่อนไข	จำนวนคู่	บทบาทใน workflow
Exact-First	Username หรือ URL ตรงกันแบบ exact	12,403	ส่งเข้า `MATCH` ทันที

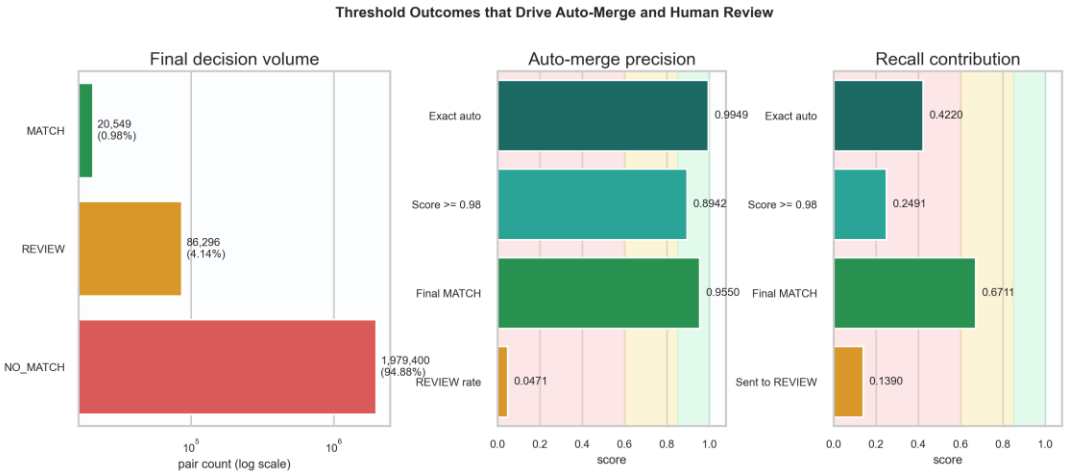
High-score Match	Calibrated score `>= 0.98`	8,146	ส่งเข้า `MATCH` แบบอัตโนมัติ
Review Band	`0.95 <= score < 0.98`	86,296	ส่งเข้า `REVIEW` ให้ผู้เชี่ยวชาญ
Low-score Reject	`score < 0.95`	1,979,400	ตัดเป็น `NO_MATCH`

เมื่อใช้ threshold ปลายทาง 0.98 / 0.95 กับคะแนนที่ผ่านการ calibration แล้ว ระบบได้ผลลัพธ์ปลายทางเป็น MATCH = 20,549 คู่, REVIEW = 86,296 คู่ และ NO_MATCH = 1,979,400 คู่ จาก final decisions ทั้งหมด 2,086,245 คู่ กล่าวอีกนัยหนึ่งคือ ระบบสามารถจัดการคู่ส่วนใหญ่ได้อัตโนมัติ และกันคู่ที่ยังไม่แน่ชัดออกมาให้มนุษย์ตรวจเพียงประมาณ 4.14% ของ final decisions เท่านั้น

คุณภาพของ MATCH ที่ระบบยอม merge อัตโนมัติเป็นจุดที่สำคัญที่สุดสำหรับ CRM หลังรวม exact matches กับ high-score matches เข้าด้วยกัน ระบบได้ final match-only precision = 0.9550 และ final match-only recall = 0.6711 ความหมายเชิงปฏิบัติของตัวเลขนี้คือ ในทุก 100 คู่ที่ระบบ auto-merge จะมี false merge ประมาณ 4-5 คู่ ขณะเดียวกันระบบกู้คู่จริงได้เองประมาณ 67.11% ของคู่จริงทั้งหมด ส่วนที่ยังไม่มั่นใจพอจะไม่ถูก merge ทันที แต่ถูกส่งไปยัง review queue แทน

ตารางที่ 4.10 คุณภาพของแต่ละ tier ที่เกี่ยวข้องกับการตัดสินใจปลายทาง

กลุ่มตัดสินใจ	**จำนวนคู่**	**คู่จริงในกลุ่ม**	**Precision**	**Recall ต่อคู่จริงทั้งหมด**	**ความหมายเชิงปฏิบัติ**
Exact auto	12,403	12,340	0.9949	0.4220	merge ได้ทันทีด้วยกฎ exact
Score `>= 0.98`	8,146	7,284	0.8942	0.2491	auto-merge จาก calibrated score
REVIEW	86,296	4,065	0.0471	0.1390	ส่งให้ผู้เชี่ยวชาญตรวจ
Final MATCH only	20,549	19,624	0.9550	0.6711	คุณภาพรวมของ auto-merge



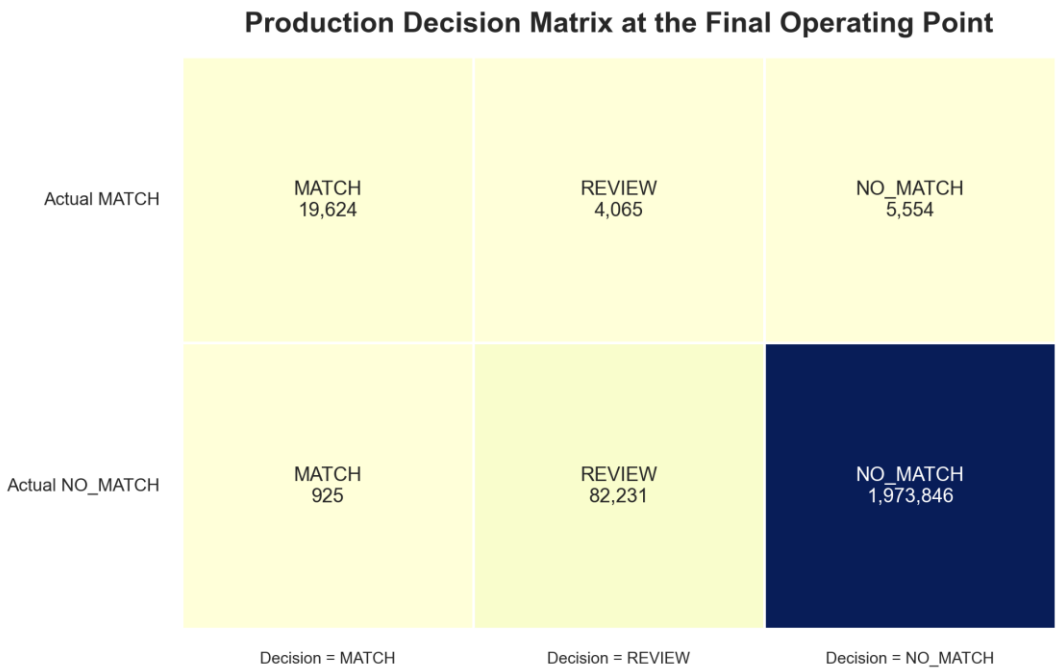
รูปที่ 4.14 ผลของ thresholding ต่อปริมาณงานและคุณภาพการตัดสินใจ แสดงจำนวนคู่ในแต่ละ tier precision ของกลุ่ม auto-merge และ recall contribution ของ exact auto score band สูง และกลุ่มที่ถูกส่งเข้า review

ผลในตารางที่ 4.10 และรูปที่ 4.13 สะท้อนบทบาทของแต่ละชั้นได้ชัดมาก โดย exact-first ช่วยกู้ recall ได้ 42.20% ตั้งแต่ก่อนใช้แบบจำลอง และทำด้วย precision เกือบสมบูรณ์ (0.9949) จากนั้นคะแนน calibrated ช่วงสูง (>= 0.98) ช่วยเพิ่ม recall อัตโนมัติอีก 24.91% ของคู่จริงทั้งหมด แม้ precision ของชั้นนี้จะต่ำกว่า exact rules แต่เมื่อนำมารวมกันใน Final MATCH only ระบบยังรักษา precision รวมไว้ได้ 0.9550

ในอีกด้านหนึ่ง REVIEW tier มี precision เพียง 0.0471 ซึ่งไม่ควรถูกตีความว่าเป็นจุดอ่อนของระบบ แต่ควรถูกตีความว่าเป็น buffer zone ที่ถูกออกแบบไว้โดยเจตนา กล่าวคือ ระบบกันคู่ที่ยังไม่ควร auto-merge ออกไปให้มนุษย์ตัดสินแทน เพื่อรักษาคุณภาพข้อมูลลูกค้าในระดับองค์กร

4.5.1 Production Decision Matrix ที่ Operating Point สุดท้าย

หากพิจารณาผลลัพธ์ปลายทางในรูปของ decision matrix จะเห็นโครงสร้างการกระจายของคู่จริงและคู่ไม่จริงในแต่ละ tier ชัดเจนยิ่งขึ้น กล่าวคือจากคู่จริงทั้งหมด 29,243 คู่ ระบบจัดให้ 19,624 คู่เข้าสู่ MATCH, 4,065 คู่เข้าสู่ REVIEW และยังเหลือคู่จริง 5,554 คู่ที่ถูกตัดเป็น NO_MATCH ขณะเดียวกันในฝั่งคู่ที่ไม่จริง ระบบยังคงกันไว้ใน NO_MATCH ได้ 1,973,846 คู่ และมีคู่ไม่จริงที่หลุดเข้า MATCH เพียง 925 คู่



รูปที่ 4.15 Production decision matrix ที่ operating point สุดท้าย แสดงความสัมพันธ์ระหว่าง Actual MATCH และ Actual NO_MATCH กับผลการตัดสินใจใน tier MATCH REVIEW และ NO_MATCH

รูปที่ 4.14 ช่วยให้ตีความ operating point ได้ชัดขึ้นในเชิงปฏิบัติ กล่าวคือ MATCH tier ถูกออกแบบให้กินคู่จริงเป็นหลัก ขณะที่ REVIEW tier ทำหน้าที่เป็นเขตกันชนสำหรับคู่ที่ยังมีศักยภาพแต่ไม่ควรถูก merge อัตโนมัติ และ NO_MATCH tier รับภาระในการคัดคู่ไม่จริงส่วนใหญ่ของระบบไว้ ผลในลักษณะนี้สอดคล้องกับเป้าหมายของ CRM ซึ่งให้ความสำคัญกับการลด false merge มากกว่าการพยายาม merge ให้ได้ครอบคลุมที่สุดตั้งแต่รอบแรก

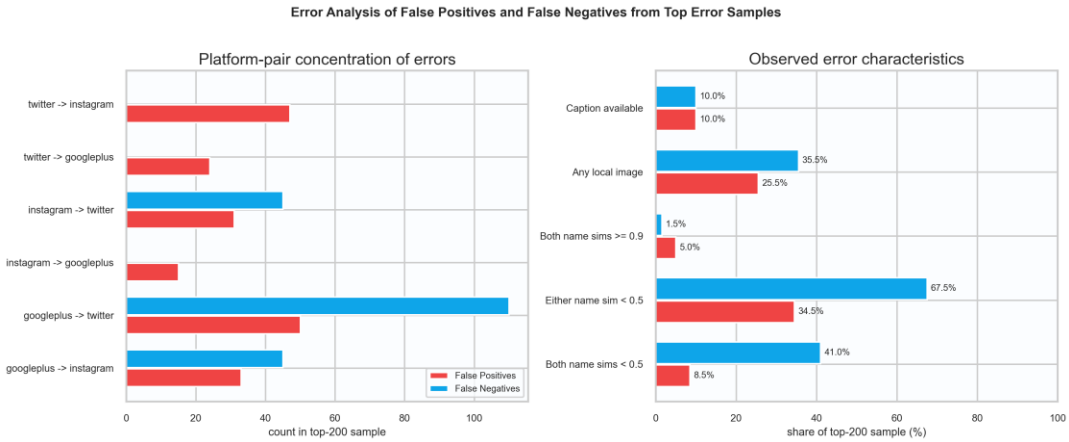
4.5.2 การวิเคราะห์ False Positives และ False Negatives จากตัวอย่างข้อผิดพลาด

เพื่อไม่ให้การอภิปรายผลหยุดอยู่เพียงที่ metric รวม ผู้วิจัยจึงวิเคราะห์ไฟล์ตัวอย่างข้อผิดพลาดจริง fp_top.csv และ fn_top.csv อย่างละ 200 คู่ ซึ่งเก็บคู่ที่แบบจำลองผิดพลาดเด่นที่สุดจาก test split ของ run หลัก ผลการสรุป pattern แสดงให้เห็นว่ากลุ่ม false negatives และ false positives มีธรรมชาติแตกต่างกันอย่างชัดเจน

ตารางที่ 4.11 สรุป pattern ของข้อผิดพลาดจากตัวอย่าง `fp_top.csv` และ `fn_top.csv`

ตัวชี้วัด	False Positives	False Negatives
ขนาดตัวอย่างที่วิเคราะห์	200	200
คู่แพลตฟอร์มที่พบบ่อยที่สุด	`googleplus -> twitter` 50 คู่ (25.0%)	`googleplus -> twitter` 110 คู่ (55.0%)

ทั้ง `username_jaro` และ `fullname_jaro` ต่ำกว่า 0.5	17 คู่ (8.5%)	82 คู่ (41.0%)
อย่างน้อยหนึ่งชื่อมี similarity ต่ำกว่า 0.5	69 คู่ (34.5%)	135 คู่ (67.5%)
ทั้ง `username_jaro` และ `fullname_jaro` ตั้งแต่ 0.9 ขึ้นไป	10 คู่ (5.0%)	3 คู่ (1.5%)
มีภาพอย่างน้อยหนึ่งฝั่ง	51 คู่ (25.5%)	71 คู่ (35.5%)
มี caption signal	20 คู่ (10.0%)	20 คู่ (10.0%)



รูปที่ 4.16 การวิเคราะห์ข้อผิดพลาดจากตัวอย่าง false positives และ false negatives แสดงการกระจุกตัวตามคู่แพลตฟอร์มและลักษณะของสัญญาณชื่อ ภาพ และ caption ที่เกี่ยวข้องกับความผิดพลาด

ผลในตารางที่ 4.11 และรูปที่ 4.15 ให้ข้อสังเกตสำคัญ 2 ประเด็น ประเด็นแรก false negatives กระจุกตัวอยู่ในคู่ googleplus -> twitter อย่างเด่นชัด และส่วนใหญ่มีสัญญาณจากชื่ออ่อนมาก กล่าวคือในตัวอย่าง 67.5% มีอย่างน้อยหนึ่งชื่อที่ similarity ต่ำกว่า 0.5 และ 41.0% มีทั้ง username และ fullname ต่ำกว่า 0.5 พร้อมกัน ซึ่งสะท้อนว่าข้อผิดพลาดประเภทนี้มักเกิดเมื่อผู้ใช้เปลี่ยนชื่อผู้ใช้หรือชื่อแสดงผลข้ามแพลตฟอร์มจนสัญญาณแบบ name-based แทบไม่เหลือ

ประเด็นที่สอง false positives จำนวนมากกลับเกิดในบริบทตรงข้าม คือเป็นคู่ลบที่ดูเหมือนคู่จริงมากเกินไป โดยเฉพาะกลุ่ม hard negatives ที่มีชื่อหรือชื่อผู้ใช้คล้ายกันมาก ตัวอย่างเช่นกรณี mitchellhall / mitchell hall และ pullbackes / pullbackes ซึ่งได้คะแนนสูงมากแม้เป็นคนละ user_folder จริง รูปแบบนี้อธิบายได้ว่าทำไมระบบจึงยังต้องมี REVIEW tier เพื่อกันคู่ที่ดูน่าใช่มาก แต่ยังไม่ปลอดภัยพอสำหรับการ merge อัตโนมัติในทุกกรณี

เมื่อพิจารณาร่วมกับผล feature importance
จะเห็นว่าข้อผิดพลาดทั้งสองแบบสอดคล้องกับธรรมชาติของแบบจำลอง
กล่าวคือระบบเก่งมากในกรณีที่มีสัญญาณจากชื่อชัด
แต่ยังมีข้อจำกัดเมื่อชื่ออ่อนเกินไปหรือเมื่อคู่ลบมีชื่อเหมือนกันผิดปกติ
ดังนั้นข้อเสนอเชิงเทคนิคสำหรับการพัฒนาต่อจึงไม่ใช่เพียงการปรับ threshold เท่านั้น
แต่ควรเพิ่ม coverage ของหลักฐานเสริมที่ช่วยแยกสองกรณีนี้ได้ เช่น image signal
ที่มีทั้งสองฝั่ง, caption-context ที่สมบูรณ์ขึ้น หรือ contextual features
อื่นที่ช่วยยืนยันตัวตนเมื่อสัญญาณจากชื่อไม่เพียงพอ

4.6 ความสำคัญของคุณลักษณะทั้ง 41 ตัวที่สนับสนุนการตัดสินใจ

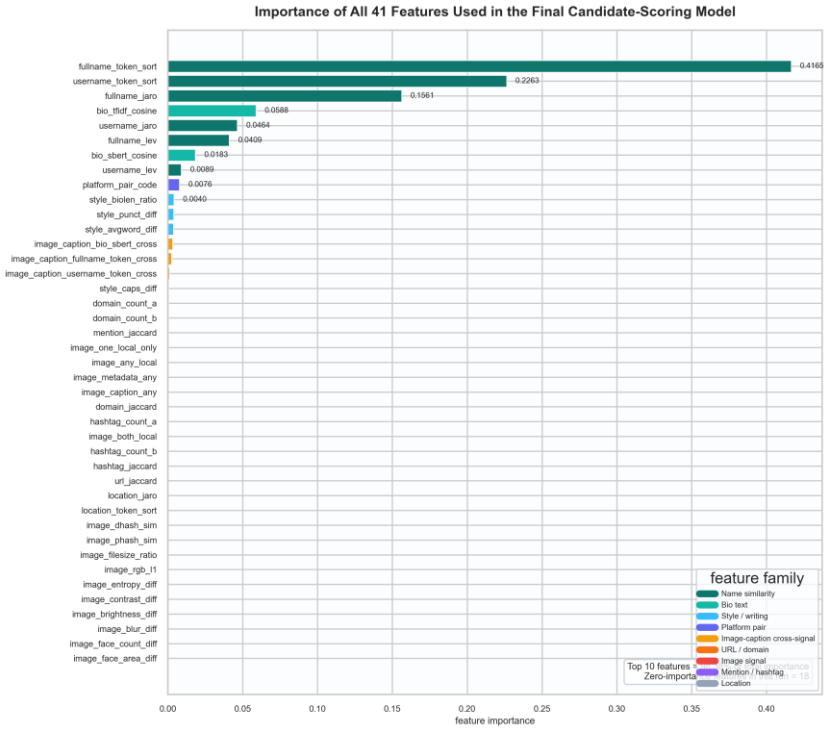
เพื่อทำความเข้าใจว่าระบบอาศัยหลักฐานประเภทใดในการตัดสินใจ ผู้วิจัยวิเคราะห์ feature importance ของ main run ซึ่งใช้ feature ทั้งหมด 41 ตัว ผลที่ได้ชี้ชัดว่าระบบยังพึ่งพาสัญญาณจากชื่อเป็นหลักอย่างมาก โดยเฉพาะกลุ่ม fullname_* และ username_* ขณะที่สัญญาณจาก bio, style และ image-cross-signal ทำหน้าที่เป็นหลักฐานเสริมมากกว่าจะเป็นแกนหลักของการตัดสินใจ

ตารางที่ 4.12 คุณลักษณะที่สำคัญสูงสุดของ main run

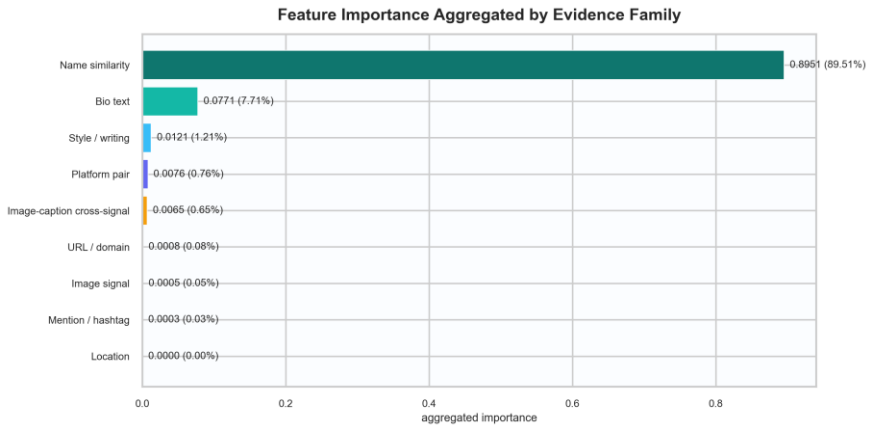
อันดับ	Feature	Importance
1	`fullname_token_sort`	0.4165
2	`username_token_sort`	0.2263
3	`fullname_jaro`	0.1561
4	`bio_tfidf_cosine`	0.0588
5	`username_jaro`	0.0464
6	`fullname_lev`	0.0409
7	`bio_sbert_cosine`	0.0183
8	`username_lev`	0.0089

9	`platform_pair_code`	0.0076
10	`style_biolen_ratio`	0.0040

หากรวมความสำคัญตามตระกูลของ feature จะพบว่า Name similarity ครองสัดส่วนรวมถึง 89.51% ของความสำคัญทั้งหมด ขณะที่ Bio text มี 7.71%, Style / writing มี 1.21%, Platform pair มี 0.76% และ Image-caption cross-signal มี 0.65% ที่สำคัญคือใน 41 features นี้มีถึง 18 ตัวที่ importance เป็นศูนย์ใน main run

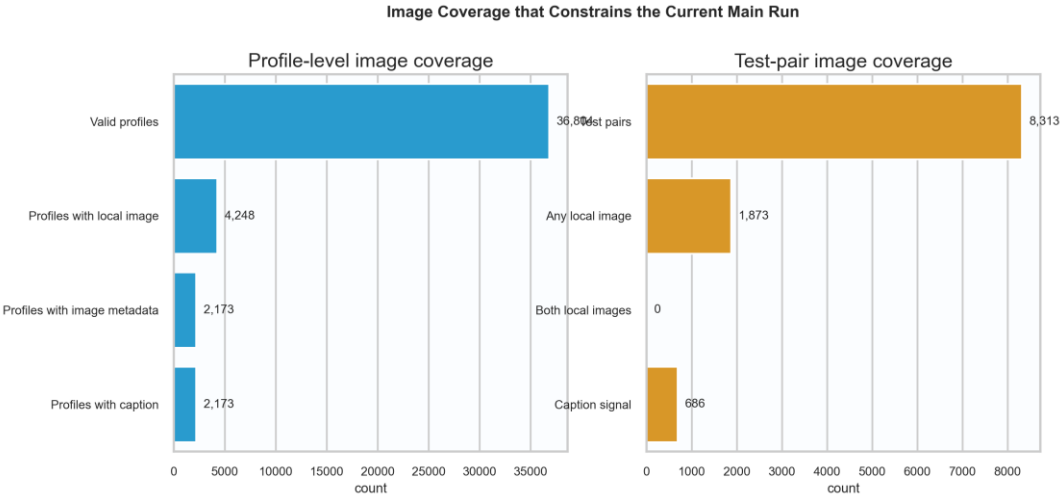


รูปที่ 4.17 ความสำคัญของคุณลักษณะทั้ง 41 ตัวใน main run แสดงให้เห็นว่า feature กลุ่มชื่อและ username เป็นหลักฐานหลักของระบบ ขณะที่ feature จำนวนหนึ่งมีผลต่อการตัดสินใจต่ำมากหรือเป็นศูนย์ในรอบนี้



รูปที่ 4.18 การรวม feature importance ตามตระกูลหลัก แสดงสัดส่วนของหลักฐานจากชื่อ bio style image-cross-signal และหลักฐานประเภทอื่นที่แบบจำลองใช้จริงใน main run

อย่างไรก็ตาม ผลในระดับ feature importance ต้องตีความร่วมกับข้อจำกัดของข้อมูลภาพด้วย โดย valid profiles ทั้งหมด 36,804 โปรไฟล์ มีเพียง 4,248 โปรไฟล์ที่มี local image, 2,173 โปรไฟล์ที่มี image metadata และ 2,173 โปรไฟล์ที่มี caption ใช้งานได้ อีกทั้งใน test pairs มีคู่ที่มีภาพอย่างน้อยหนึ่งฝั่ง 1,873 คู่ แต่ไม่มีคู่ที่มี local image พร้อมกันทั้งสองฝั่งเลย



รูปที่ 4.19 Coverage ของข้อมูลภาพใน main run แยกระดับ profile และ test pair แสดงให้เห็นว่าการทดลองในรอบนี้ยังเป็น partial multimodal setting มากกว่า full image-to-image matching

ผลในรูปที่ 4.16 อธิบายได้ว่าทำไม image-related features จำนวนมากยังมีน้ำหนักต่ำกว่ากลุ่มชื่อและข้อความอย่างชัดเจน กล่าวคือ image branch ช่วยเพิ่มคุณภาพของ main run จริง แต่ยังอยู่ในฐานะสัญญาณเสริมภายใต้ coverage ที่จำกัด

4.7 สรุปผลของ Project 1 ในขอบเขต Decision Thresholding

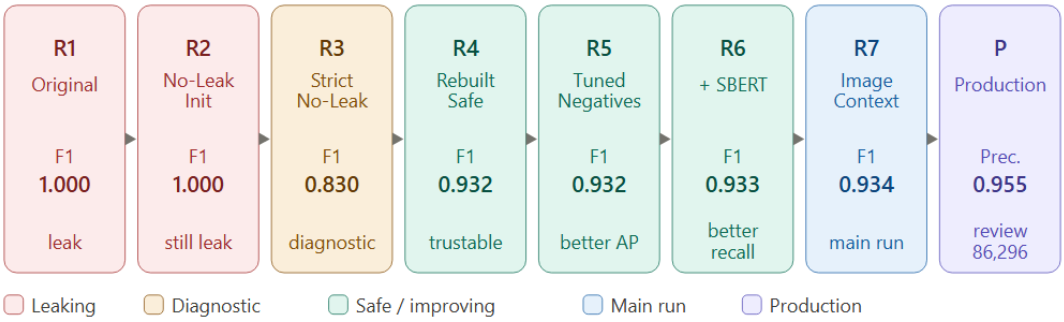
ผลการวิจัยในบทนี้ยืนยันว่าแกนหลักของ Project 1 คือ Decision thresholding ที่ทำงานต่อจาก Exact-first + calibrated candidate scoring โดยใช้ main run แบบ image_context เป็นตัวให้คะแนนคู่โปรไฟล์ แล้วแปลงคะแนนนั้นไปเป็นกฎการตัดสินใจใน workflow จริงของ CRM

หากสรุปในเชิง implementation ที่พร้อมนำไปใช้ต่อได้โดยตรง สามารถสรุปได้ดังนี้

1. ใช้ image_context เป็น candidate scorer หลัก เพราะให้สมดุลดีที่สุดในด้าน AP, ROC-AUC และ Recall บน feature space 41 ตัว

2. ใช้ IsotonicRegression เพื่อ calibrate ความน่าจะเป็นก่อนตั้ง threshold ปลายทาง เพื่อให้คะแนนมีความหมายเชิงปฏิบัติการมากขึ้น
3. ใช้กฎ exact-first เพื่อดึงคู่ที่ชัดมากออกมา merge อัตโนมัติก่อน แล้วค่อยใช้ calibrated score กับคู่ที่ยังมีความกำกวม
4. ใช้ thresholds 0.98 สำหรับ MATCH และ 0.95 สำหรับ REVIEW เพื่อควบคุมความเสี่ยงของ false merge ในบริบท CRM
5. ที่ operating point นี้ ระบบได้ final match-only precision = 0.9550 และ final match-only recall = 0.6711 พร้อม review queue = 86,296 คู่ ซึ่งสะท้อนสมดุลที่ยอมรับได้ระหว่างการ merge อัตโนมัติและการส่งคู่กำกวมให้มนุษย์ตรวจสอบต่อ

ดังนั้น ข้อสรุปสุดท้ายของ Project 1 ไม่ใช่เพียงว่าแบบจำลองให้ metric ดีบน test split แต่คือระบบสามารถแปลงคะแนนของแบบจำลองให้กลายเป็นกระบวนการตัดสินใจแบบ MATCH / REVIEW / NO_MATCH ที่ใช้งานได้จริงใน CRM โดยรักษาสมดุลระหว่างการ merge อัตโนมัติและการส่งคู่กำกวมให้มนุษย์ตรวจสอบต่ออย่างเป็นระบบ



รูปที่ 4.20 สรุปเส้นทางการพัฒนาระบบจาก Leakage diagnosis ไปสู่ Final multimodal

บทที่ 5

วิเคราะห์และสรุปผล

5.1 สรุปผลการดำเนินงาน

โครงงานนี้มีวัตถุประสงค์หลักในการพัฒนาระบบ Identity Resolution สำหรับข้อมูล Social Media Profiles จาก 3 แพลตฟอร์ม ได้แก่ Twitter, Instagram และ Google+ Archive รวม 36,807 profiles เพื่อสร้าง Unified Customer Profile ที่ลดความซ้ำซ้อนและเพิ่ม ความ

ครบถ้วนของข้อมูล สำหรับนำไปประยุกต์ใช้ใน Lead Scoring ของระบบ Agentic CRM ในอนาคต ผลการดำเนินงานทั้ง 2 ระยะที่ดำเนินการได้สำเร็จในงานวิจัยนี้สรุปได้ดังนี้

ในระยะที่ 1 การเตรียมข้อมูล ดำเนินการ Data Cleaning และ Standardization กับ Profiles ทั้งหมด 36,807 รายการ ครอบคลุมการแก้ไข Encoding, การ Normalize รูปแบบ Username และ Full Name ให้เป็นมาตรฐานเดียวกันข้ามแพลตฟอร์ม รวมถึงการสร้าง Candidate Pairs ด้วย Blocking Strategy ที่ผสม Username Prefix Blocking กับ Full Name Jaro-Winkler Similarity ได้ Candidate Pairs ทั้งสิ้น 873,956 คู่ และ Labeled Dataset จำนวน 162,442 pairs สำหรับใช้ฝึกโมเดล

ในระยะที่ 2 การพัฒนาโมเดล Identity Resolution ได้ออกแบบและฝึกโมเดล IdentityMLP ซึ่งเป็น Neural Network แบบ Multi-Layer Perceptron สำหรับ 3-Class Classification ใช้ FocalLoss แก้ปัญหา Class Imbalance และ Isotonic Calibration เพื่อให้ค่า Probability Output สะท้อนความน่าจะเป็นจริง ผลการทดสอบบน Test Set ได้ F1-Score = 0.93, Precision = 0.97, Recall = 0.90 และ AUC-ROC = 0.982 เมื่อนำโมเดลไปทำ Inference บน Candidate Pairs ทั้ง 873,956 คู่ ได้ผลลัพธ์เป็น MATCH 20,480 คู่ (2.34%), POSSIBLE_MATCH 3,940 คู่ (0.45%) และ NO_MATCH 849,536 คู่ (97.21%) ส่งผลให้ได้ Unified Profiles ทั้งสิ้น 10,723 profiles คิดเป็น Deduplication Ratio 70.9% โดยสรุประบบที่พัฒนาขึ้นสามารถบรรลุวัตถุประสงค์ด้าน Identity Resolution ได้สำเร็จ ทั้งในด้านความแม่นยำของโมเดล (F1 = 0.93) และความสามารถในการ Scale ไปยัง Candidate Pairs กว่า 8 แสนคู่ ส่วนขั้นตอน Lead Scoring ยังต้องพัฒนาต่อเมื่อ ข้อมูล Engagement และ Behavior พร้อมใช้งาน

งานวิจัยนี้ได้ศึกษาและพัฒนาระบบเชื่อมโยงตัวตนข้ามแพลตฟอร์ม (Cross-Platform Identity Resolution) สำหรับระบบบริหารจัดการความสัมพันธ์ลูกค้า (CRM) โดยใช้ข้อมูลโปรไฟล์ผู้ใช้จาก Twitter, Instagram และ Google+ จำนวนรวมทั้งสิ้น 36,804 โปรไฟล์

ระบบถูกออกแบบให้ทำงานเป็นลำดับขั้นตอน เริ่มตั้งแต่การลดขอบเขตการค้นหา (Search Space) ด้วยเทคนิคการจับคู่แบบตรงกันทุกประการ (Exact Matching) และการจัดกลุ่มข้อมูล (Blocking) จากนั้นจึงทำการให้คะแนนความคล้ายคลึงของคู่ข้อมูลด้วยแบบจำลองการเรียนรู้ของเครื่อง (Machine Learning) และตัดสินใจขั้นสุดท้ายสำหรับการนำไปใช้งานจริง (Production) ด้วยการใช้เกณฑ์ตัดสินใจแบบคู่ (Dual Threshold)

ในการวิจัยนี้ได้ทำการทดลองและเปรียบเทียบประสิทธิภาพของแบบจำลอง โดยแบ่งออกเป็น 3 กลุ่มการทดลองหลัก ได้แก่ 1) กลุ่มคลาสสิกแบบป้องกันข้อมูลรั่วไหล (Classical Leakage-Safe) ซึ่งใช้ชุดคุณลักษณะ (Features) จำนวน 22 ตัว 2) กลุ่มพหุรูปแบบ (Multimodal Suite) ที่มีการขยายชุดคุณลักษณะจาก 23 ตัวเป็น 41 ตัว และ 3) กลุ่มตัวแบบอ้างอิง (Neural-Network Reference) ที่ใช้แบบจำลอง IdentityMLP เป็นตัวเปรียบเทียบ ทั้งนี้

การประเมินผลการทดลองทั้งหมดอ้างอิงจากการแบ่งชุดข้อมูล (Data Split) ที่ออกแบบมาเพื่อป้องกันปัญหาข้อมูลตัวตนรั่วไหล (Identity Leakage) อย่างเคร่งครัด โดยควบคุมไม่ให้มีความซ้ำซ้อนขององค์ประกอบข้อมูลในแต่ละชุดการทดลอง (Zero Component Overlap)

ตารางที่ 5.1 สรุปเปรียบเทียบประสิทธิภาพจากทุกสายการทดลอง

สายการทดลอง	จำนวนคุณลักษณะ	Test AP	Test AUC	Test F1
Classical Leakage-Safe (GB)	22	0.9703	0.9772	0.9337
Multimodal Hybrid Text	23	0.9782	0.9715	0.9330
Multimodal Image Stats	37	0.9789	0.9731	0.9340
Multimodal Image Context (main run)	41	0.9789	0.9734	0.9340
Neural-Network MLP (41 features)	41	0.9734	0.9649	0.9255
Neural-Network MLP (strict 22 features)	22	0.7344	0.9960	0.8296

จากผลการศึกษาและการทดลองทั้งหมด สามารถสรุปประเด็นสำคัญของงานวิจัยได้ 4 ประเด็น ดังนี้

1. ปัญหาหลักของการพัฒนาระบบไม่ได้อยู่ที่การเลือกแบบจำลองแต่อยู่ที่วิธีการสร้างคู่ข้อมูลและการออกแบบการแบ่งชุดข้อมูล เห็นได้จากการประมวลผล ในรอบแรกที่ค่าตัวชี้วัด (Metrics) เช่น AP, AUC และ F1 มีค่าสูงถึง 1.0000 ซึ่งแท้จริงแล้วเกิดจากปัญหาข้อมูลตัวตนรั่วไหล (Identity Leakage) เมื่อทำการแก้ไขปัญหานี้แล้ว ค่าตัวชี้วัดจึงลดลงมาอยู่ในระดับที่สมเหตุสมผลและสะท้อนประสิทธิภาพที่แท้จริงของแบบจำลองได้

2. แบบจำลอง Gradient Boosting เป็นทางเลือกที่เหมาะสมที่สุดสำหรับงานวิจัยนี้ โดยในการทดลองกลุ่มคลาสสิกสามารถทำคะแนน Test AP ได้ 0.9703 และ F1 ได้ 0.9337 ซึ่งสูงที่สุดในกลุ่มแบบจำลอง 3 ชนิด และเมื่อเปรียบเทียบแบบจำลองทั้ง 7 ชนิดบนชุดคุณลักษณะ 41 ตัว Gradient Boosting ก็ยังคงทำคะแนน Test AP ได้สูงสุดที่ 0.9797 ซึ่งถือว่าสูงกว่าแบบจำลองโครงข่ายประสาทเทียม หรือ MLP ที่ทำได้ 0.9734 สาเหตุหลักเป็นเพราะ Gradient Boosting สามารถวิเคราะห์ความสัมพันธ์ที่ซับซ้อนระหว่างกลุ่มคุณลักษณะประเภทชื่อผู้ใช้ (Username) และชื่อจริง (Full Name) ได้อย่างมีประสิทธิภาพ นอกจากนี้ยังสามารถแสดงค่าความสำคัญของคุณลักษณะให้ตีความผลลัพธ์ได้ชัดเจนกว่าแบบจำลองโครงข่ายประสาทเทียม
3. การเพิ่มข้อมูลเข้าสู่ระบบทีละขั้นตอนช่วยเพิ่มความแม่นยำได้อย่างชัดเจน ตัวอย่างเช่น การนำแบบจำลอง SBERT มาช่วยวิเคราะห์ความคล้ายคลึงเชิงความหมาย (Semantic Similarity) ของประวัติย่อ (Bio) ทำให้ระบบสามารถจับคู่ข้อมูลที่ไม่ได้ใช้คำศัพท์ (Token) ตรงกันได้ ส่งผลให้ค่าความครอบคลุม (Recall) ดีขึ้น นอกจากนี้ การเพิ่มคุณลักษณะประเภทรูปภาพยังช่วยปรับปรุงค่า AP และ AUC อย่างต่อเนื่อง แม้จะเป็นการพัฒนาเพียงเล็กน้อยแต่ก็แสดงให้เห็นถึงแนวโน้มที่เสถียร เนื่องจากทุกการทดลองใช้ชุดคู่ข้อมูลและการแบ่งชุดข้อมูลแบบเดียวกัน
4. ระบบนี้มีความพร้อมในการนำไปใช้งานจริง โดยอาศัยการกำหนดเกณฑ์แบบ Exact-First ร่วมกับเกณฑ์ตัดสินใจแบบคู่ ซึ่งกำหนดเกณฑ์การจับคู่ (Match Threshold) ไว้ที่ 0.98 และเกณฑ์การตรวจสอบ (Review Threshold) ที่ 0.95 วิธีการนี้ช่วยลดขอบเขตการค้นหาจาก 449 ล้านคู่ เหลือเพียง 2 ล้านคู่ (ลดลงร้อยละ 99.54) แต่ยังคงครอบคลุมคู่ข้อมูลที่ถูกต้อง (True Matches) ได้ถึงร้อยละ 88.67 ผลลัพธ์สุดท้ายมีความแม่นยำในการจับคู่ (Match Precision) ที่ 0.9550 และสามารถรวบรวมข้อมูลเป็นโปรไฟล์ลูกค้า

แบบรวมศูนย์ (Unified Profiles) ได้จำนวน 19,799 รายชื่อ พร้อมสำหรับจัดแบ่งกลุ่มลูกค้าเพื่อนำไปใช้วางแผนกลยุทธ์ทางการตลาดได้ทันที

ตารางที่ 5.2 สรุปผลระดับ Production

รายการ	ค่า
Search space ทั้งหมด	449,149,239 คู่
Candidate pairs หลัง blocking	2,073,842 คู่
Search-space reduction	99.54%
Ground-truth coverage	88.67%
Match precision (exact + model)	0.9550
Unified profiles	19,799
Review queue	86,296 คู่

โดยสรุป แบบจำลองที่เหมาะสมที่สุดสำหรับงานวิจัยนี้คือ Gradient Boosting ซึ่งดำเนินการบนกระบวนการสร้างชุดคู่ข้อมูลและการแบ่งชุดข้อมูลที่ปราศจากปัญหาข้อมูลตัวตนรั่วไหล พร้อมทั้งผนวกข้อมูลเชิงความหมายของข้อความผ่าน SBERT และข้อมูลบริบทของรูปภาพเข้าไปเป็นลำดับขั้น โดยรอบการประมวลผลที่ให้ผลลัพธ์ดีที่สุดคือชุดการทดลอง image_context ซึ่งใช้ตัวแปรคุณลักษณะรวมทั้งสิ้น 41 ตัว และมีจุดตัดสำหรับการนำไปใช้งานจริงที่ระดับเกณฑ์การตัดสินใจ 0.98 และ 0.95

5.1.1 การตอบวัตถุประสงค์ของงานวิจัย

จากผลการทดลองและการวิเคราะห์ข้อมูลทั้งหมด สามารถสรุปผลการดำเนินงานตามวัตถุประสงค์ของงานวิจัยได้ดังนี้

วัตถุประสงค์ที่ 1 เพื่อศึกษาและพัฒนาระบบเชื่อมโยงตัวตนข้ามแพลตฟอร์มสำหรับระบบบริหารจัดการความสัมพันธ์ลูกค้า (CRM) โดยใช้แบบจำลองการเรียนรู้ของเครื่อง

ผลการวิจัยยืนยันว่าระบบที่พัฒนาขึ้นสามารถทำงานได้จริงอย่างมีประสิทธิภาพ โดยผลการประมวลผลหลักให้ค่า Test AP ถึง 0.9789 และ F1-Score ที่ 0.9340 ซึ่งอยู่ในระดับที่พร้อมใช้งานจริง นอกจากนี้ ระบบยังสามารถลดขอบเขตการค้นหา 449 ล้านคู่ ลงเหลือเพียง 2 ล้านคู่ ในขณะที่ยังคงความครอบคลุมคู่ข้อมูลที่ถูกต้องได้ถึงร้อยละ 88.67 แสดงให้เห็นว่าการออกแบบกระบวนการดึงข้อมูล ร่วมกับแบบจำลองการเรียนรู้ของเครื่อง สามารถรองรับการจัดการข้อมูลขนาดใหญ่ในเชิงปฏิบัติได้อย่างมีประสิทธิภาพ

วัตถุประสงค์ที่ 2 เพื่อเปรียบเทียบประสิทธิภาพของแบบจำลองหลายประเภท

ผลการเปรียบเทียบแสดงให้เห็นอย่างชัดเจนว่า แบบจำลอง Gradient Boosting ให้ผลลัพธ์โดยรวมดีที่สุด ทั้งในด้านค่า AP, F1-Score และความแม่นยำ (Precision) ซึ่งมีประสิทธิภาพเหนือกว่าแบบจำลอง MLP, Random Forest, Extra Trees, AdaBoost, Logistic Regression และ Linear SVM สาเหตุหลักเป็นเพราะแบบจำลองที่ใช้โครงสร้างต้นไม้เป็นฐาน (Tree-based Models) สามารถวิเคราะห์ปฏิสัมพันธ์ที่ซับซ้อนระหว่างคุณลักษณะต่าง ๆ ได้เป็นอย่างดี โดยเฉพาะกลุ่มคุณลักษณะประเภทชื่อผู้ใช้ ในขณะเดียวกัน แบบจำลองโครงข่ายประสาทเทียมแม้จะสามารถปรับตัวได้ดีขึ้นเมื่อปริภูมิคุณลักษณะ (Feature Space) ขยายตัว แต่ก็ยังคงมีประสิทธิภาพต่ำกว่า Gradient Boosting ในทุกมิติการวัดผลหลัก อีกทั้งยังมีข้อจำกัดในด้านการตีความผลลัพธ์

วัตถุประสงค์ที่ 3 เพื่อประเมินความเป็นไปได้ในการนำระบบไปใช้งานจริงในระดับการทำงานจริง (Production)

ระบบได้ผ่านการทดสอบด้วยเกณฑ์การตัดสินใจสำหรับการใช้งานจริง (Production Thresholds) ในรูปแบบ Exact-First ร่วมกับ Dual Threshold ซึ่งให้ค่าความแม่นยำในการจับคู่ (Match Precision) สูงถึง 0.9550 และมีข้อมูลที่ถูกส่งเข้าคิวรอการตรวจสอบด้วยเจ้าหน้าที่ (Review Queue) จำนวน 86,296 คู่ ท้ายที่สุด ระบบสามารถรวบรวมโปรไฟล์ข้ามแพลตฟอร์มให้กลายเป็นโปรไฟล์ลูกค้าแบบรวมศูนย์ (Unified Profiles) ได้จำนวน 19,799 รายการ พร้อมทั้งจัดกลุ่มเป้าหมายทางการตลาด (Lead Tiers) ออกเป็นกลุ่ม HOT 4,937 รายการ, WARM 9,039 รายการ และ COLD 5,823 รายการ ซึ่งพร้อมสำหรับการนำไปใช้บริหารลูกค้าสัมพันธ์และวางแผนการตลาดได้ทันที

5.2 ปัญหาและอุปสรรคในการดำเนินงาน

ระหว่างการวิจัยและพัฒนาระบบ ผู้วิจัยพบปัญหาและอุปสรรคสำคัญที่ต้องดำเนินการแก้ไข ดังนี้

5.2.1 ปัญหาความไม่สมดุลของข้อมูล (Class Imbalance) และการปรับเทียบแบบจำลอง (Model Calibration)

ในระยะแรกของการฝึกสอนแบบจำลอง พบว่าสัดส่วนของข้อมูลที่จับคู่กัน (Match) และไม่จับคู่ (No Match) มีความแตกต่างกันสูงถึง 1:6 ส่งผลให้แบบจำลองเกิดความลำเอียงและมักจะทำนายว่า ไม่จับคู่ ไว้ก่อนเพื่อลดค่าความผิดพลาด ผู้วิจัยจึงแก้ไขด้วยการนำฟังก์ชันการสูญเสียแบบโฟกัส (Focal Loss) มาใช้ ซึ่งช่วยบังคับให้แบบจำลองให้ความสำคัญกับกรณีที่ยากและซับซ้อนมากขึ้น นอกจากนี้ ยังพบปัญหาค่าความน่าจะเป็นที่ส่งออกมา ไม่สะท้อนความเป็นจริง จึง

ได้เพิ่มกระบวนการปรับเทียบแบบไอโซโทนิก (Isotonic Calibration) ในขั้นตอนหลังการฝึกสอน ซึ่งช่วยแก้ปัญหาและทำให้การตั้งค่าเกณฑ์ตัดสินใจ (Threshold) มีความแม่นยำขึ้นอย่างชัดเจน

5.2.2 อุปสรรคในการจัดการข้อมูลที่ซับซ้อน (Hard Cases)

แม้ระบบจะแสดงประสิทธิภาพที่น่าพึงพอใจ แต่ยังพบข้อจำกัดในกรณีที่ผู้ใช้งานตั้งชื่อแตกต่างกันอย่างสิ้นเชิงในแต่ละแพลตฟอร์ม เนื่องจากระบบในปัจจุบันยังคงพึ่งพาคุณลักษณะด้านความคล้ายคลึงของตัวอักษรเป็นหลัก ทำให้การจับคู่ในกรณีข้อมูลที่ซับซ้อน (Hard Cases) ทำได้ค่อนข้างยาก

5.3 ข้อจำกัดของงานวิจัย

งานวิจัยนี้มีข้อจำกัดที่ควรพิจารณาประกอบการตีความผลลัพธ์ ดังต่อไปนี้

1. ข้อมูลที่ใช้พัฒนามาจากเพียง 3 แพลตฟอร์ม ได้แก่ Twitter, Instagram และ Google+ ซึ่งปัจจุบันปิดให้บริการแล้ว และยังเป็นชุดข้อมูลจำลอง จึงอาจไม่สะท้อนความซับซ้อนของพฤติกรรมลูกค้าในสภาพแวดล้อมการทำงานจริงได้ครบถ้วน อีกทั้งยังไม่สามารถประเมินได้ว่าระบบจะทำงานได้ดีเพียงใดหากนำไปใช้กับแพลตฟอร์มยอดนิยมอื่น ๆ เช่น TikTok, LinkedIn หรือ Facebook
2. ระบบยังมีข้อจำกัดด้านการใช้ข้อมูลรูปภาพ เนื่องจากมีเพียงร้อยละ 11.5 ของโปรไฟล์ที่มีรูปภาพ และร้อยละ 5.9 ที่มีคำบรรยายภาพ (Caption) ยิ่งไปกว่านั้น ไม่มีคู่ข้อมูลทดสอบ (Test Pairs) ใดที่มีรูปภาพพร้อมกันทั้งสองฝั่ง ทำให้ไม่สามารถวัดศักยภาพของการจับคู่ภาพข้ามแพลตฟอร์มโดยตรง (Full Image-to-Image Matching) ได้ในการวิจัยครั้งนี้
3. งานวิจัยนี้ยังไม่ได้แบ่งข้อมูลเพื่อทดสอบตามลำดับเวลา ทำให้ไม่สามารถจำลองสถานการณ์ที่ผู้ใช้เปลี่ยนแปลงชื่อ ประวัติย่อ (Bio) หรือรูปโปรไฟล์ไปตามกาลเวลาได้ ซึ่งอาจส่งผลต่อความแม่นยำของการใช้งานระบบในระยะยาว
4. แบบจำลองโครงข่ายประสาทเทียม (MLP) มีลักษณะเป็นกล่องดำ ในขณะที่ Gradient Boosting แม้จะสามารถดูค่าความสำคัญของคุณลักษณะในภาพรวมได้ แต่ยังไม่สามารถอธิบายเหตุผลการตัดสินใจในระดับรายคู่ได้ ซึ่งเป็นอุปสรรคต่อการนำไปใช้งานในธุรกิจที่ต้องการความโปร่งใสสูง
5. จำนวนคู่ข้อมูลที่ถูกส่งเข้าคิวรอการตรวจสอบมีสูงถึง 86,296 คู่ ซึ่งยังคงเป็นภาระที่ต้องใช้ทรัพยากรบุคคลในการดำเนินการ และอาจไม่เหมาะสมสำหรับองค์กรที่มีขนาดเล็กหรือมีทรัพยากรจำกัด

5.4 ข้อเสนอแนะสำหรับการทำวิจัยในอนาคต

จากผลการวิจัยและข้อจำกัดที่กล่าวมา ผู้วิจัยมีข้อเสนอแนะสำหรับการต่อยอดในอนาคต ดังนี้

1. ควรนำระบบไปทดสอบกับข้อมูลจริงจากสภาพแวดล้อมการทำงานจริง รวมถึงขยายไปยังแพลตฟอร์มที่ใช้งานในปัจจุบัน เช่น TikTok, Facebook หรือ LinkedIn เพื่อทดสอบความสามารถในการนำไปใช้งานทั่วไป และควรเพิ่มชุดข้อมูลภาษาไทยเข้าไปในระบบ
2. เพิ่มคุณลักษณะด้านพฤติกรรม เช่น ช่วงเวลาการใช้งาน หรือหัวข้อเนื้อหา และนำเทคนิคการเรียนรู้เชิงลึก เช่น Contrastive Learning หรือ Siamese Network มาสร้างเวกเตอร์ตัวแทนรูปภาพ เพื่อยกระดับความแม่นยำในการจับคู่ภาพข้ามแพลตฟอร์มโดยตรง
3. การนำเทคนิคปัญญาประดิษฐ์ที่อธิบายได้ มาใช้ควรประยุกต์ใช้เทคนิค เช่น SHAP หรือ LIME เพื่อให้ระบบสามารถอธิบายเหตุผลการจับคู่ข้อมูลเป็นรายคู่ได้ ซึ่งจะช่วยเพิ่มความน่าเชื่อถือให้แก่ผู้ใช้งานในระบบ CRM
4. ควรเพิ่มการทดสอบการจำลองสถานการณ์ที่ข้อมูลผู้ใช้เปลี่ยนแปลงไปตามเวลา เพื่อประเมินอายุการใช้งาน ของแบบจำลองก่อนที่จะต้องทำการฝึกสอนใหม่
5. ควรเปิดใช้งานระบบให้เจ้าหน้าที่ตรวจสอบ (Human-in-the-loop) อย่างเต็มรูปแบบ และนำผลการตัดสินใจเหล่านั้นกลับมาเป็นข้อมูลฝึกสอน (Training Set) เพื่อปรับปรุงแบบจำลองอย่างต่อเนื่อง ซึ่งจะช่วยลดปริมาณงานใน Review Queue ลงในระยะยาว
6. การพัฒนาแบบจำลองลูกผสม (Hybrid Model) และระบบให้คะแนน (Lead Scoring) ควรศึกษาการใช้โครงข่ายประสาทเทียมเพื่อสกัดข้อมูลดิบ แล้วส่งต่อไปยัง Gradient Boosting ในฐานะ Meta-learner นอกจากนี้ ควรต่อยอดการออกแบบโมเดลการให้คะแนนลูกค้า (Lead Scoring Model) ที่พิจารณาเส้นทางลูกค้า (Customer Journey)

และรูปแบบการมีส่วนร่วมข้ามแพลตฟอร์ม เพื่อยกระดับสู่ระบบบริหารจัดการลูกค้าสัมพันธ์แบบอัตโนมัติ (Agentic CRM) ต่อไป

บรรณานุกรม

[1] V. Sharma and C. Dyreson, "LINKSOCIAL: Linking user profiles across multiple social media platforms," in Proc. IEEE Int. Conf. Big Knowledge (ICBK), Singapore, 2018, pp. 260–269, doi: 10.1109/ICBK.2018.00042.

[2] R. Zafarani and H. Liu, "Connecting users across social media sites: A behavioral-modeling approach," in Proc. 19th ACM SIGKDD, 2013, doi: 10.1145/2487575.2487648.

[3] S. Halimi and J. Ayday, "User identity linkage on social networks: A review of modern techniques and applications," IEEE Access, vol. 12, 2024.

[4] A. H. Doan et al., "Human-in-the-loop challenges for entity matching: A midterm report," in Proc. HILDA'17, 2017, doi: 10.1145/3077257.3077268.

[5] G. Li et al., "Human-in-the-loop data integration," Proc. VLDB Endow., 2017, doi: 10.14778/3137765.3137833.

[6] A. Schafer, M. K. Hassan, and J. Muller, "Predictive lead scoring using machine learning techniques," Arabian J. Sci. Eng., vol. 47, no. 9, 2022, doi: 10.1007/s13369-022-06560-8.

[7] V. Sharma and C. Dyreson. “Dataset-LinkSocial.” [Online]. เข้าถึงได้จาก: https://github.com/vishalshar/Dataset-LinkSocial. 2569

[8] W. Xu and B. C. M. Fung. "StyleLink: User Identity Linkage Across Social Media with Stylometric Representations." Proceedings of the International AAAI Conference on Web and Social Media (ICWSM), vol. 19, June 2025. pp. 2076-2088.

ภาคผนวก

ประวัติผู้เขียน



ชื่อ-นามสกุล	นางสาววิมลสิริ ปานมา
รหัสนักศึกษา	66070187
วัน เดือน ปีเกิด	11 สิงหาคม พ.ศ. 2547
ประวัติการศึกษา	วุฒิมัธยมศึกษาตอนปลายโรงเรียนสระบุรีวิทยาคม จังหวัดสระบุรี
ภูมิลำเนา	77 หมู่ 1 ตำบลท่าตูม อำเภอแก่งคอย จังหวัดสระบุรี
Email	66070187@kmitl.ac.th
สาขาที่จบ	วิทยาการข้อมูลและการวิเคราะห์เชิงธุรกิจ
รุ่นที่	7 ปีการศึกษาที่จบ 2570



ชื่อ-นามสกุล	นางสาวถาวรีย์ ขันสาคร
รหัสนักศึกษา	66070260
วัน เดือน ปีเกิด	2 กรกฎาคม พ.ศ. 2546
ประวัติการศึกษา	วุฒิมัธยมศึกษาตอนปลายโรงเรียนสายปัญญารังสิต
ภูมิลำเนา	59/9 หมู่ 3 ตำบลบึงบอน อำเภอหนองเสือ จังหวัดปทุมธานี 12170
Email	66070260@kmitl.ac.th
สาขาที่จบ	วิทยาการข้อมูลและการวิเคราะห์เชิงธุรกิจ
รุ่นที่	7 ปีการศึกษาที่จบ 2570