รายงานโครงการ Identity Resolution Pipeline

การจับคู่บัญชีผู้ใช้ข้ามแพลตฟอร์ม การรวมตัวตน และการตัดสินใจด้วย Machine Learning

สถานะเอกสาร: Final technical and research report

วันที่สรุป: 31 สิงหาคม 2026

ขอบเขตข้อมูล: Twitter, Google+, Instagram

หน่วยวิเคราะห์: คู่โปรไฟล์ข้ามแพลตฟอร์ม (cross-platform profile pair)

บทคัดย่อ

โครงการนี้พัฒนาระบบ Identity Resolution เพื่อพิจารณาว่าบัญชี social media จากหลายแพลตฟอร์มเป็นบุคคลเดียวกันหรือไม่ แล้วรวมบัญชีที่เชื่อมโยงกันเป็น unified customer profile สำหรับงาน Customer 360, CRM และ lead scoring ระบบเริ่มจากโปรไฟล์ดิบ 36,807 แถว ครอบคลุม Twitter 13,960 แถว Google+ 11,890 แถว และ Instagram 10,957 แถว หลังตรวจสอบ identifier แล้วมี 36,804 แถวที่เข้าสู่ production-style evaluation ได้ คิดเป็น 15,297 entity ตาม user_folder

หากเปรียบเทียบทุกบัญชีข้ามแพลตฟอร์มโดยตรงจะเกิดคู่ทั้งหมด 449,149,239 คู่ ระบบจึงใช้ exact matching และ blocking ลดพื้นที่ค้นหาเหลือ 2,086,245 คู่ หรือประหยัดการเปรียบเทียบ 99.54% โดยครอบคลุม ground-truth cross-platform 25,931 จาก 29,243 คู่ คิดเป็น retrieval recall 88.67% โมเดลหลักเป็น Gradient Boosting บน 41 features ร่วมกับ isotonic calibration ให้ผลบน supervised test 8,313 คู่ที่ Precision 0.9507, Recall 0.9179, F1 0.9340 และ Average Precision 0.9789 อย่างไรก็ตาม เมื่อวัดในระดับ full candidate workflow ซึ่งรวมข้อจำกัดจาก blocking และ decision policy แล้ว baseline มี Precision 0.9550, Recall 0.6710 และ F1 0.7882 แสดงให้เห็นว่า model quality เพียงอย่างเดียวไม่เพียงพอต่อคุณภาพระบบปลายทาง

งานทดลอง R0-R6 พบว่า R3 ซึ่งเพิ่ม BERT cosine แล้วปรับ decision rule ด้วย Genetic Algorithm (GA) ให้ผลดีที่สุดในชุดทดลองที่ Test F1 0.8373 และ full projection F1 0.8345 พร้อมลด review queue จาก 86,296 เหลือ 2,751 คู่ งาน ablation ด้านชื่อพบว่า char 3-gram ร่วมกับ handle features (N6) ให้ Validation F1 0.9553 เทียบ baseline N0 ที่ 0.9410 ส่วน feature-aware GA บน labeled population 58,696 คู่พบว่า bio guard ชนะ แต่เมื่อขยาย evidence cache ครบ 2,073,842 scored candidates historical-cost run เลือก style guard และเสีย recall มากเกินไป เมื่อ re-optimize ด้วย CRM-derived cost 2FP+FN+0.1REVIEW แบบ validation-only name guard ชนะที่ cost 3,498.60, Precision 0.9853 และ Recall 0.6240 ซึ่งยังไม่ผ่าน promotion gates จึงไม่เปิด test เดิมซ้ำ

ข้อสรุปหลักคือระบบมีความแม่นยำสูงในคู่ที่มี lexical evidence ชัด แต่ performance ปลายทางถูกจำกัดด้วยสามส่วน ได้แก่ blocking miss, weak/missing evidence และ decision thresholds การพัฒนาต่อควรแยกการปรับ representation, model scoring, retrieval และ decision policy ออกจากกัน ใช้ availability mask กับข้อมูลที่หาย และประเมินบน population ที่ตรงกับการใช้งานจริง

1. บทนำ

1.1 ที่มาและความสำคัญ

บุคคลหนึ่งอาจมีบัญชีอยู่บนหลายแพลตฟอร์ม แต่ข้อมูลแต่ละบัญชีไม่สมบูรณ์และไม่สอดคล้องกัน เช่น username ต่างกัน ชื่อเต็มใช้คนละภาษา bio ถูกย่อ URL หมดอายุ location ว่าง หรือรูปโปรไฟล์เปลี่ยนไป การใช้ exact match เพียงอย่างเดียวจึงจับคู่ได้เฉพาะกรณีง่าย ขณะที่การใช้ fuzzy matching แบบกว้างเกินไปสร้างความเสี่ยงจากการรวมคนละคนเข้าด้วยกัน

ความผิดพลาดสองประเภทมีต้นทุนไม่เท่ากัน:

- False positive (FP): รวมคนละคนเข้าด้วยกัน กระทบข้อมูล CRM ความเป็นส่วนตัว และการตัดสินใจทางธุรกิจ
- False negative (FN): ไม่รวมบัญชีของคนเดียวกัน ทำให้ customer view แตกเป็นหลาย entity

โครงการนี้จึงออกแบบเป็นระบบหลายชั้น: retrieval ด้วย blocking, pair scoring ด้วย machine learning, policy decision แบบ MATCH/REVIEW/NO_MATCH และ entity resolution ด้วย graph connectivity

1.2 วัตถุประสงค์

- สร้าง candidate pairs จากข้อมูลข้ามแพลตฟอร์มโดยลด search space อย่างมากแต่รักษา ground-truth coverage
- สร้าง features จากชื่อ ข้อความ URL location รูปภาพ และ metadata
- train และเปรียบเทียบโมเดลภายใต้ entity-aware split ที่ป้องกัน identity leakage
- calibrate probability และกำหนด decision policy ที่สมดุล Precision, Recall และ manual review cost
- วิเคราะห์ false positive, false negative, blocking miss และ hard cases อย่างเป็นระบบ
- ทดลอง representation และ decision strategy เพิ่มเติม ได้แก่ name-similarity ablation, BERT, Bloom filter, semantic blocking และ feature-aware GA
- ออกแบบทางเชื่อมจากผลจับคู่ไปสู่ unified profile และ CRM

1.3 คำถามวิจัย

- RQ1: blocking ลดจำนวนคู่ได้มากเพียงใด และแลกกับ ground-truth coverage เท่าใด
- RQ2: feature group และ model family ใดเหมาะกับ pair-level identity classification
- RQ3: เหตุใด pair-model F1 สูง แต่ end-to-end decision F1 ต่ำกว่า
- RQ4: GA ช่วยลด business cost และ review workload ได้หรือไม่
- RQ5: name_sim ควรเป็น guard แบบ hard-coded หรือมี feature อื่นที่เหมาะกว่า
- RQ6: missing evidence และ data quality จำกัด performance มากเพียงใด
- RQ7: แนวทางใดพร้อมใช้ แนวทางใดยังเป็นงานวิจัย และต้องทำอะไรต่อก่อน production promotion

1.4 ขอบเขต

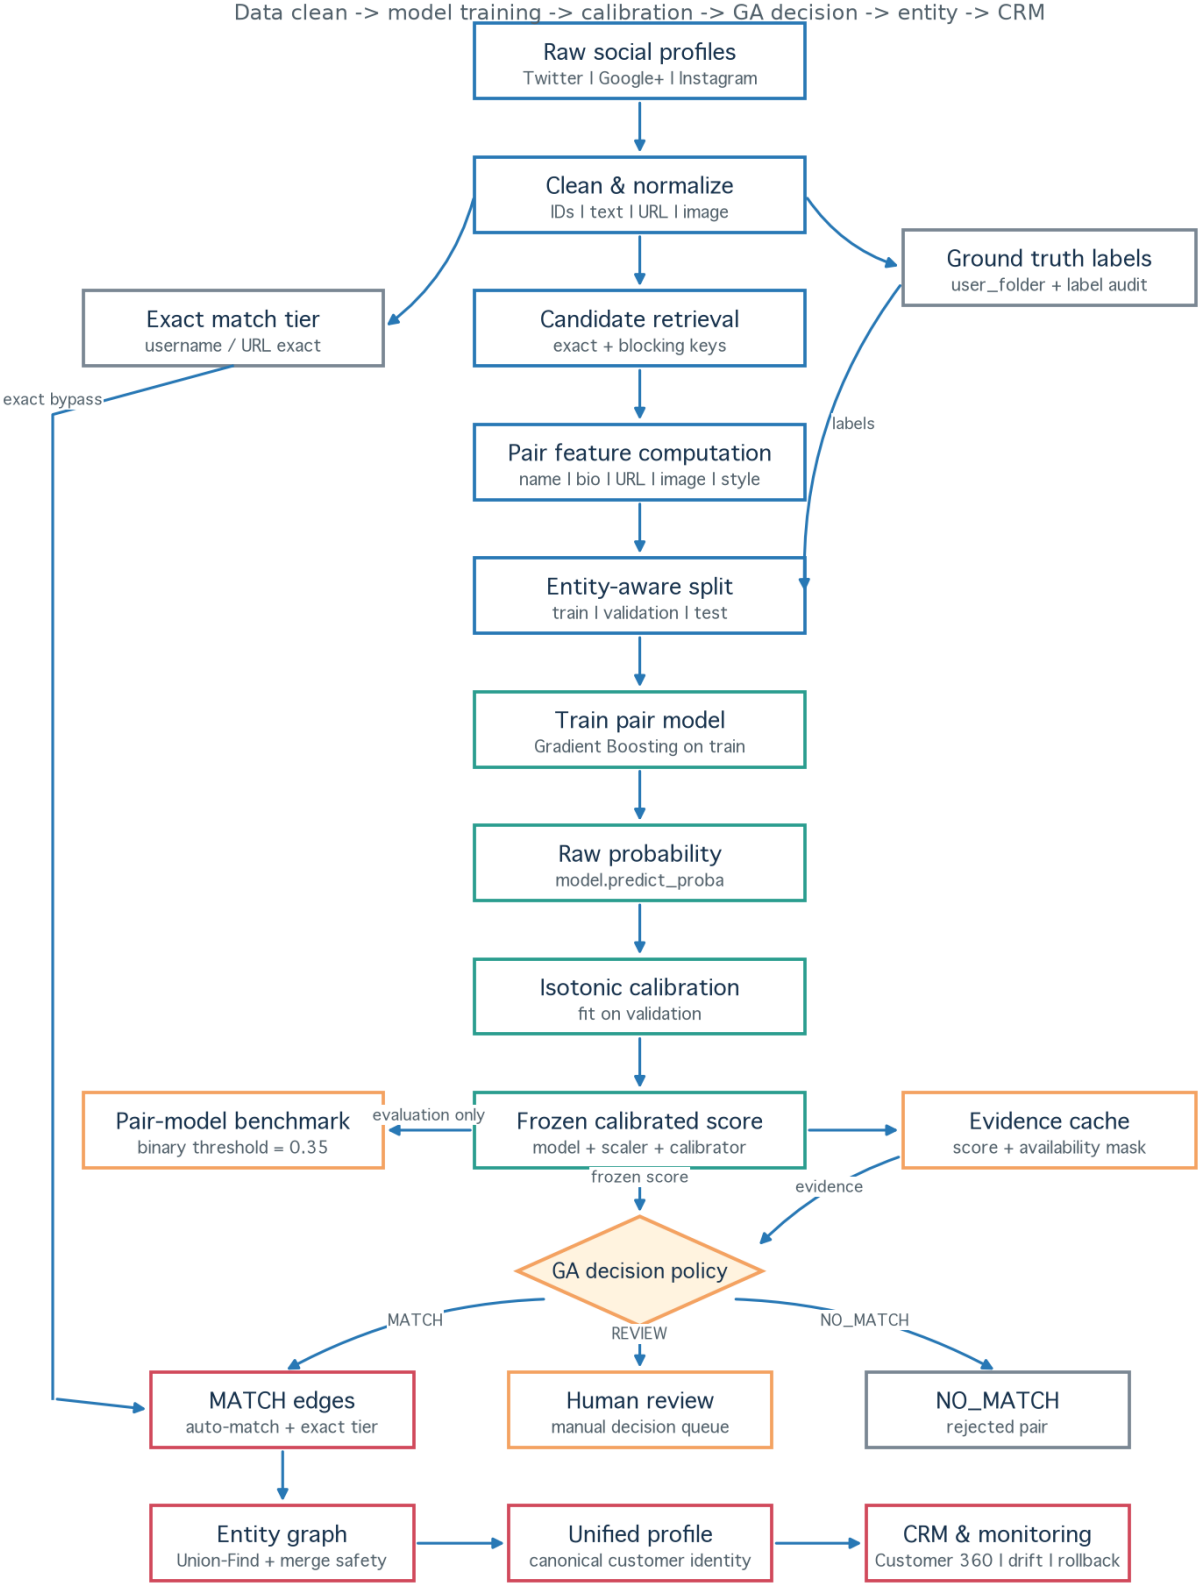
งานหลักวัดการจับคู่ ข้ามแพลตฟอร์ม เท่านั้น ข้อมูลมี ground truth จาก user_folder ไม่ได้อ้างว่าระบบถูก deploy ใน production จริง และไม่ได้สรุปว่าคู่ที่ไม่ถูกสร้างโดย blocking ได้รับการประเมินโดย model แล้ว

2. ภาพรวมสถาปัตยกรรม

2.0 End-to-end architecture ภาพเดียว

IDENTITY RESOLUTION: END-TO-END FLOW

Data clean -> model training -> calibration -> GA decision -> entity -> CRM



GA changes the decision rule, not the frozen model or calibrated probability

สถาปัตยกรรมรวมของ Identity Resolution Pipeline

รูปที่ 0 ภาพรวมงานทั้งหมดตั้งแต่รับข้อมูล social profiles, clean/normalize, สร้าง ground truth และ candidate pairs, คำนวณ features, train และ calibrate model, ส่ง frozen probability เข้า GA decision policy, รวม MATCH edges เป็น customer entity แล้วส่งออก CRM พร้อม monitoring

ให้อ่านภาพจากบนลงล่างตามเส้นกลาง: เตรียมข้อมูลและ candidate pairs ก่อนแบ่ง entity-aware split เพื่อ train และ calibrate model จากนั้น freeze calibrated score แล้วส่งเข้า GA decision policy แขนงด้านข้างแสดง ground-truth labels, exact matches, pair-model benchmark และ evidence cache ส่วนปลายทางแตกเป็น MATCH/REVIEW/NO_MATCH ก่อนนำ MATCH edges ไปสร้าง unified profile และ CRM จุดสำคัญคือ GA รับ calibrated probability จาก model ที่ freeze แล้ว ร่วมกับ evidence/availability masks ไม่ได้กลับไปเปลี่ยน model weights

2.1 Canonical lifecycle

```
flowchart LR
    A[Prepare<br/>clean and normalize] --> B[Pairs<br/>positive and negative pairs]
    B --> C[Features<br/>text URL location image]
    C --> D[Train<br/>model selection]
    D --> E[Evaluate<br/>validation and sealed test]
    E --> F[Predict<br/>full candidate scoring]
    F --> G[Resolve<br/>entities and CRM outputs]
```

โค้ด production-oriented อยู่ใต้ src/identity_resolution/ และเปิดผ่าน cli.py ตามลำดับ prepare -> pairs -> features -> train -> evaluate -> predict -> resolve ส่วน experiments/ เป็น research harness ซึ่งไม่ควรถูก import กลับเข้า production core

2.2 Architecture layers

```
flowchart TB
    CLI[CLI and orchestration] --> STAGE[Lifecycle stages]
    CLI --> WF[Full-candidate and CRM workflows]
    STAGE --> CORE[Pure domain core]
    WF --> CORE
    STAGE --> IMG[Imaging adapters]
    STAGE --> ART[(Model and data artifacts)]
    WF --> ART
    EXP[Research experiments] --> ART
    EXP -. must not control production .-> WF
```

Layer	หน้าที่	Source of truth
Core	pair identity, threshold policy, text normalization, entity graph	core/
Stages	data preparation, pair building, features, train, evaluate	stages/
Workflows	full candidate prediction และ CRM resolution	workflows/
Imaging	image normalization, embeddings, pair features	imaging/
Research	R0-R6, GA, ablation และ diagnostics	experiments/
Publication	benchmark tables และ report snapshots	pub_multi/

2.3 Data flow ตั้งแต่ profile ถึง customer entity

```
flowchart TB
    RAW[Raw social profiles] --> CLEAN[Normalized profiles]
    CLEAN --> GT[Ground truth by user_folder]
    CLEAN --> EXACT[Exact username or URL matches]
    CLEAN --> BLOCK[Blocking keys]
```

```
    BLOCK --> CAND[Candidate pairs]
    CAND --> FEAT[Pair feature computation]
    FEAT --> SCORE[Calibrated match probability]
    SCORE --> POLICY{Decision policy}
    EXACT --> MATCH[MATCH edges]
    POLICY -->|MATCH| MATCH
    POLICY -->|REVIEW| REVIEW[Human review queue]
    POLICY -->|NO_MATCH| REJECT[Rejected pair]
    MATCH --> GRAPH[Union-Find entity graph]
    GRAPH --> PROFILE[Unified customer profile]
    PROFILE --> LEAD[Lead score and CRM export]
```

2.4 Development และ deployment boundary

```
flowchart LR
    subgraph Development
        T[Train entities] --> M[Fit model]
        V[Validation entities] --> CAL[Calibration and threshold selection]
        M --> CAL
        CAL --> FREEZE[Frozen model and policy]
    end
    subgraph Evaluation
        TEST[Held-out test entities] --> ONCE[Evaluate once]
        FREEZE --> ONCE
    end
    subgraph Operations
        ALL[Full blocked candidates] --> APPLY[Apply frozen scorer and policy]
        FREEZE --> APPLY
        APPLY --> MON[Monitor drift, review, FP]
    end
```

หลักสำคัญคือห้ามใช้ test เลือก model, threshold, feature guard หรือน้ำหนัก GA historical run เปิด test หลัง freeze เพียงครั้งเดียว ส่วน CRM-cost rerun รุ่นล่าสุดเลือก policy จาก validation และยังไม่เปิด test เดิมซ้ำ

3. ข้อมูลและคุณภาพข้อมูล

3.1 ชุดข้อมูลหลัก

ไฟล์หลักคือ normalized_profiles_with_profile_id.csv

รายการ	จำนวน
แถว input	36,807
แถวที่มี profile_row_id และ profile_id ใช้งานได้	36,804
แถวที่ถูกตัดเพราะ identifier ไม่สมบูรณ์	3
Entity (user_folder)	15,297
Twitter (input / eligible)	13,960 / 13,959
Google+ (input / eligible)	11,890 / 11,889
Instagram (input / eligible)	10,957 / 10,956

ความแตกต่างระหว่างตัวเลข 36,807 กับ 36,804 ในเอกสารเดิมจึงไม่ใช่ความขัดแย้ง: ค่าแรกคือจำนวนแถว input ส่วนค่าหลังคือจำนวนที่ผ่าน eligibility filter ของ production workflow

3.2 Ground truth

กำหนดคู่เป็น positive เมื่อ user_folder เดียวกันและเป็นคนละ profile:

$$y_{ij} = \begin{cases} 1, & \text{เมื่อ } folder_i = folder_j \\ 0, & \text{เมื่อ } folder_i \ne folder_j \end{cases}$$

Scope	Positive pairs
ทุกคู่ภายใน entity	29,247
Cross-platform ตาม research scope	29,243
Same-platform ที่ไม่รวมใน primary evaluation	4

ตัวเลข 29,247 ที่พบใน experiment harness และ 29,243 ใน production blocking report จึงต่างกันจาก scope 4 คู่ ไม่ใช่การคำนวณผิด

3.3 ความสมบูรณ์ของ field

Field	Non-empty	Coverage
username	36,723	99.77%
full name	35,952	97.68%
bio	30,167	81.96%
external URL/domain	30,580	83.08%
location	12,794	34.76%

coverage ระดับ profile ไม่เท่ากับ coverage ระดับ pair เพราะ pair feature ต้องการข้อมูลจากทั้งสองฝั่ง ตัวอย่างเช่น feature-aware validation มี location evidence ที่ใช้ได้ 0% แม้ profile-level location จะไม่เป็นศูนย์ สาเหตุคือคู่ที่เลือกอาจไม่มี location ครบสองฝั่งหรือ preprocessing ไม่สร้าง usable match signal

3.4 ข้อมูลภาพ

รอบดาวน์โหลดล่าสุดใน download_report.json พยายาม 998 URL แต่ดาวน์โหลดใหม่สำเร็จ 0 รายการ ขณะเริ่ม run มีไฟล์เก่าใน cache 4,248 ไฟล์ ปัญหาหลักคือ archival URLs คืน HTTP 404 และ proxy บางเส้นทางคืน HTTP 429 ดังนั้นรายงานไม่อ้างว่าระบบ image ingestion ปัจจุบันมี coverage สูง

ผล model comparison สอดคล้องกับข้อจำกัดนี้:

Model configuration	Features	Test F1	Test AP
text attributes	23	0.9330	0.9782
image statistics	37	0.9340	0.9789
image context	41	0.9340	0.9789

image context เพิ่ม F1 จาก text-only ประมาณ 0.001 จุด จึงควรสรุปว่า “ทดลองและพบประโยชน์เล็กน้อยในข้อมูลนี้” ไม่ใช่ “ภาพเป็นสัญญาณหลัก”

3.5 ความเสี่ยงด้านข้อมูล

- Google+ เป็นข้อมูล archive จึงอาจมี temporal mismatch กับแพลตฟอร์มอื่น
- ค่า URL และรูปภาพอาจหมดอายุ แม้ field เดิมไม่ว่าง
- ground truth จาก folder มีความน่าเชื่อถือเชิงโครงสร้าง แต่ยังอาจมี label noise
- exact username ไม่ได้หมายถึงบุคคลเดียวกันเสมอ พบ false positive ใน exact tier 63 คู่
- hard cases บางคู่ไม่มี lexical หรือ contextual evidence เพียงพอ จึงเป็น data ceiling มากกว่าปัญหา model

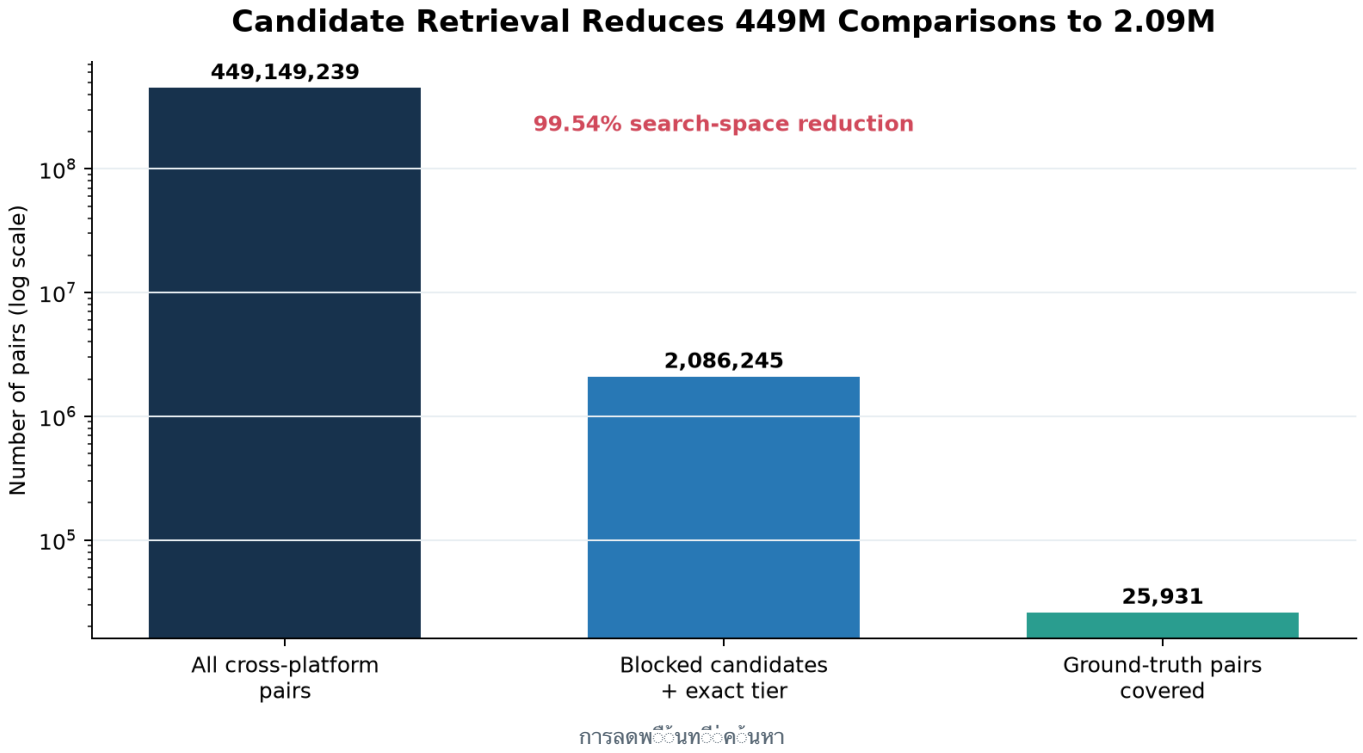
4. Candidate Generation และ Blocking

4.1 เหตุผลที่ต้อง blocking

จำนวนคู่ข้ามแพลตฟอร์มทั้งหมดคำนวณจากผลคูณระหว่างจำนวนบัญชีของแต่ละแพลตฟอร์ม:

$$N_{all}=N_{TW}N_{GP}+N_{TW}N_{IG}+N_{GP}N_{IG}=449{,}149{,}239$$

การคำนวณ feature ราคาแพงบนทุกคู่ไม่เหมาะกับเครื่อง RAM 16 GiB จึงใช้ blocking key เช่น username prefix, fullname prefix และ external domain เพื่อสร้าง candidate set



รูปที่ 1 การลด search space จาก 449.15 ล้านคู่เหลือ 2.086 ล้านคู่

4.2 ผล retrieval

รายการ	จำนวน/ค่า
All cross-platform pairs	449,149,239
Exact tier	12,403
Model-scored candidates	2,073,842
รวม candidate workflow	2,086,245
Search-space reduction	99.5355%
Cross-platform GT covered	25,931 / 29,243
Retrieval recall	88.6742%
Cross-platform blocking miss	3,312

research harness รุ่น R0-R6 รายงาน blocking miss 3,316 จาก positive 29,247 เพราะรวม same-platform 4 คู่ไว้ใน denominator เมื่อตีความผลจึงต้องระบุ scope เสมอ

4.3 Recall ceiling

หาก candidate generation ไม่สร้างคู่ใดขึ้นมา model และ GA จะไม่มีโอกาสแก้คู่นั้น เพดาน recall ของ R0-R5 ตาม research scope จึงเป็น:

$$Recall_{ceiling}=\frac{29{,}247-3{,}316}{29{,}247}=0.8866$$

การปรับ threshold หรือเปลี่ยน classifier แก้ได้เฉพาะ scored false negatives แต่ไม่แก้ blocking misses

5. Feature Engineering

5.1 Feature groups

Group	ตัวอย่าง features	แนวคิด
Name	Jaro-Winkler, normalized Levenshtein, token sort, char n-gram, handle	วัดรูปแบบชื่อที่สะกดหรือจัดลำดับต่างกัน
Bio	TF-IDF cosine, SBERT cosine	lexical และ semantic similarity ของคำอธิบาย
URL	domain/url Jaccard, counts	shared web identity และ external links
Location	Jaro, token sort	ความคล้ายของตำแหน่งที่ตั้ง
Style	capitalization, punctuation, word length, bio length ratio	writing-style consistency
Social context	mention/hashtag overlap	shared social vocabulary
Image	pHash, dHash, image statistics, caption cross-features	visual/context similarity
Platform metadata	platform pair code	ให้ model เรียนรู้ distribution shift ระหว่างคู่แพลตฟอร์ม

5.2 Similarity functions

Normalized Levenshtein similarity:

$$s_{lev}(a,b)=1-\frac{d_{lev}(a,b)}{\max(|a|,|b|,1)}$$

Cosine similarity สำหรับ vector representation:

$$s_{cos}(x,y)=\frac{x\cdot y}{\|x\|_2\|y\|_2}$$

Jaccard similarity สำหรับ set ของ URL/domain/mention:

$$s_J(A,B)=\frac{|A\cap B|}{|A\cup B|}$$

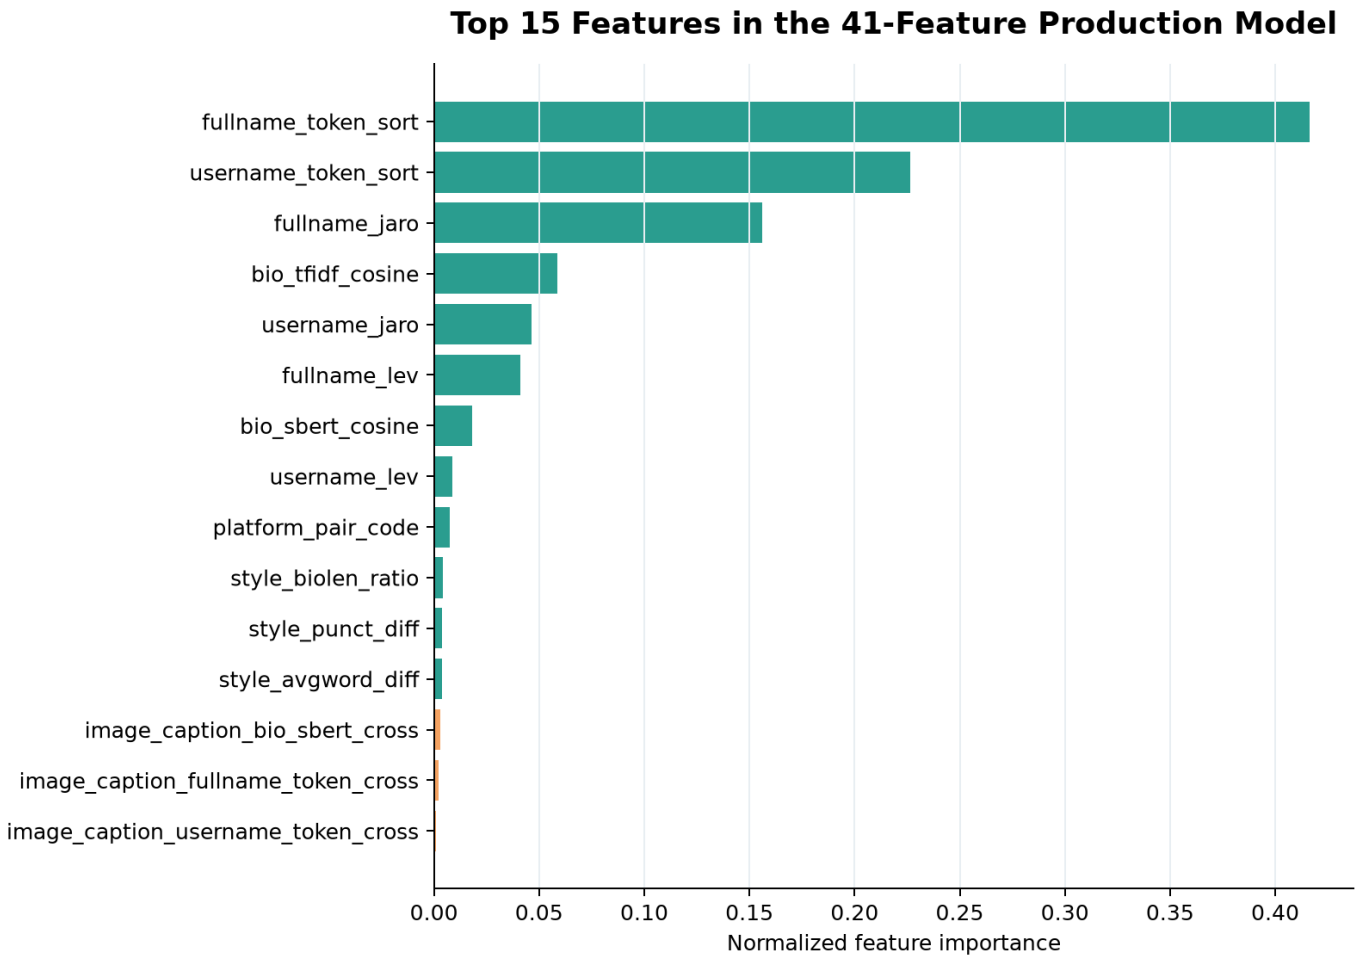
5.3 Missingness-aware representation

คะแนน similarity เป็นศูนย์อาจหมายถึง “ต่างกันจริง” หรือ “ไม่มีข้อมูล” ซึ่งเป็นคนละสถานการณ์ ระบบ feature-aware จึงใช้ mask $m_k\in\{0,1\}$ แยกจาก score s_k และคำนวณ weighted evidence ต่อคู่เป็น:

$$E_{ij}=\frac{\sum_k m_{ijk}w_ks_{ijk}}{\sum_k m_{ijk}w_k}$$

เมื่อ denominator เป็นศูนย์ คู่จะไม่มี evidence สำหรับ promotion/demotion และคงอยู่ใน REVIEW แทนการถูกตีความเป็น NO_MATCH

5.4 Feature importance ของ production model



Feature importance

รูปที่ 2 Top-15 feature importance ของ model 41 features

อันดับ	Feature	Normalized importance
1	fullname_token_sort	0.4165
2	username_token_sort	0.2263
3	fullname_jaro	0.1561
4	bio_tfidf_cosine	0.0588
5	username_jaro	0.0464
6	fullname_lev	0.0409
7	bio_sbert_cosine	0.0183

name-related features รวมกันครองสัดส่วนสูงสุด ขณะที่ image features ส่วนใหญ่ต่ำมาก ผลนี้สอดคล้องกับ data coverage และไม่ได้หมายความว่าภาพไม่มีประโยชน์ใน dataset ที่สมบูรณ์กว่า

6. Pair Construction และ Leakage Control

6.1 ประเภทคู่สำหรับ train

- Positive pairs: user_folder เดียวกันและข้ามแพลตฟอร์ม
- Random negatives: ต่าง entity และสุ่มจาก profile pool เดียวกัน
- Hard negatives: ต่าง entity แต่มีชื่อหรือข้อมูลบางส่วนคล้ายกัน

การมี hard negatives สำคัญเพราะ random negatives ส่วนใหญ่แยกง่ายเกินไปและทำให้ metric สูงโดยไม่สะท้อนความเสี่ยง false merge

6.2 Entity-aware split

split ถูกทำในระดับ entity ไม่ใช่ระดับ pair เพื่อป้องกัน profile ของบุคคลเดียวกันไปอยู่ทั้ง train และ test:

```
flowchart LR
  E[Unique entities] --> ASSIGN[Deterministic seeded assignment]
  ASSIGN --> TR[Train entities]
  ASSIGN --> VA[Validation entities]
  ASSIGN --> TE[Test entities]
  TR --> TP[Train pairs only within train]
  VA --> VP[Validation pairs only within validation]
  TE --> EP[Test pairs only within test]
```

N-series artifacts ยืนยัน component overlap เป็นศูนย์ทุกคู่ split:

Check	Result
Train-Val entity overlap	0
Train-Test entity overlap	0
Val-Test entity overlap	0
Self pairs	0

6.3 Split sizes ของ feature matrix

Split	Pairs	Positive	Negative
Train	41,803	20,470	21,333
Validation	8,580	4,386	4,194
Test	8,313	4,387	3,926
รวม	58,696	29,243	29,453

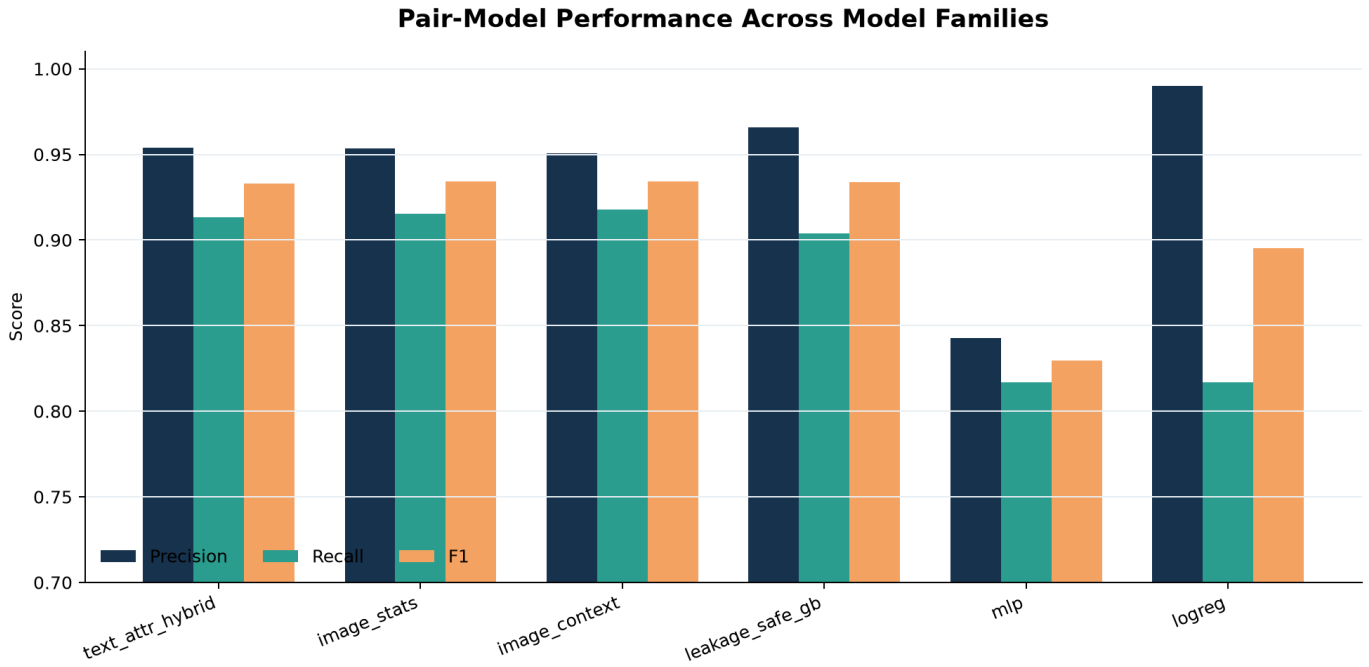
6.4 Sealed-test rule

- train model บน train
- เลือก model/calibrator/threshold/policy บน validation
- freeze configuration
- ประเมิน test หนึ่งครั้ง
- ห้ามย้อนกลับไปปรับจาก test แล้วอ้าง test เดิมเป็น unbiased result

7. Model Training และ Calibration

7.1 Model families

ระบบเปรียบเทียบ Logistic Regression, Random Forest, Gradient Boosting, neural MLP และ reference models อื่น โดย production-selected run เป็น Gradient Boosting เพราะให้ validation composite score และ test balance ดีที่สุดใน multimodal suite



Model comparison

รูปที่ 3 Precision, Recall และ F1 ของ model configurations ที่มี artifact เปรียบเทียบได้

ข้อควรระวัง: แถว strict_* ใช้ protocol/reference ที่ต่างจาก multimodal suite บางส่วน จึงใช้เป็น diagnostic ไม่ใช่ ranking เดียวกันทั้งหมด

7.2 Calibration

หลัง Gradient Boosting fit เสร็จ จะไม่มีการเปลี่ยนพารามิเตอร์ของ classifier ในขั้น GA ลำดับจริงคือ:

- fit classifier บน train แล้วสร้าง raw probability
- fit isotonic calibrator บน validation เพื่อแปลง raw probability เป็น calibrated probability
- เลือก threshold 0.35 บน validation เพื่อประเมิน binary pair classifier ด้วย F1 โดยใช้ Precision เป็น tie-break
- freeze และบันทึก model, scaler, calibrator, feature schema และ calibrated probabilities
- ส่ง calibrated probability เดิมเข้าสู่ downstream decision policy

Isotonic calibration เป็น post-training mapping ที่เรียนจาก validation จึงนับเป็นส่วนหนึ่งของ frozen scoring pipeline แต่ไม่ได้ retrain Gradient Boosting หลังเห็นผล GA

```
flowchart LR
  X[Pair features] --> M[Frozen Gradient Boosting]
  M --> R[Raw probability]
  R --> C[Frozen isotonic calibrator]
  C --> P[Calibrated probability]
  P --> EVAL[Binary evaluation at 0.35]
  P --> POLICY[GA decision policy]
  G[Available evidence guard] --> POLICY
```

```
POLICY --> D[MATCH / REVIEW / NO_MATCH]
```

เส้นทาง 0.35 และ GA จึงเริ่มจาก probability เดียวกันแต่ตอบคนละคำถาม: 0.35 ใช้วัดความสามารถจำแนกคู่แบบ MATCH/NO_MATCH ส่วน GA ใช้สร้าง operating policy สามระดับตาม business cost และ quality constraints

Threshold/policy	เลือกจาก	ใช้ทำอะไร	เปลี่ยน model หรือไม่
0.35	Validation F1	binary pair-model benchmark บน test	ไม่เปลี่ยน
0.98/0.95	Manual operational baseline	แบ่ง MATCH/REVIEW/NO_MATCH ใน	ไม่เปลี่ยน
GA genome	Validation decision cost + gates	เลือก MATCH/REVIEW/NO_MATCH โดยใช้ probability และ evidence	ไม่เปลี่ยน

7.3 Pair-model result

บน test 8,313 คู่ เมื่อ apply frozen calibrated probability ที่ binary threshold 0.35:

Metric	Value
Average Precision	0.9789
Precision	0.9507
Recall	0.9179
F1	0.9340
False positive	209
False negative	360

$$Precision=\frac{TP}{TP+FP},\quad Recall=\frac{TP}{TP+FN},\quad F_1=\frac{2PR}{P+R}$$

ตัวเลขนี้วัด pair classification บน labeled test set ไม่รวมคู่ที่ blocking พลาด จึงไม่ควรถูกเรียกว่า end-to-end production F1

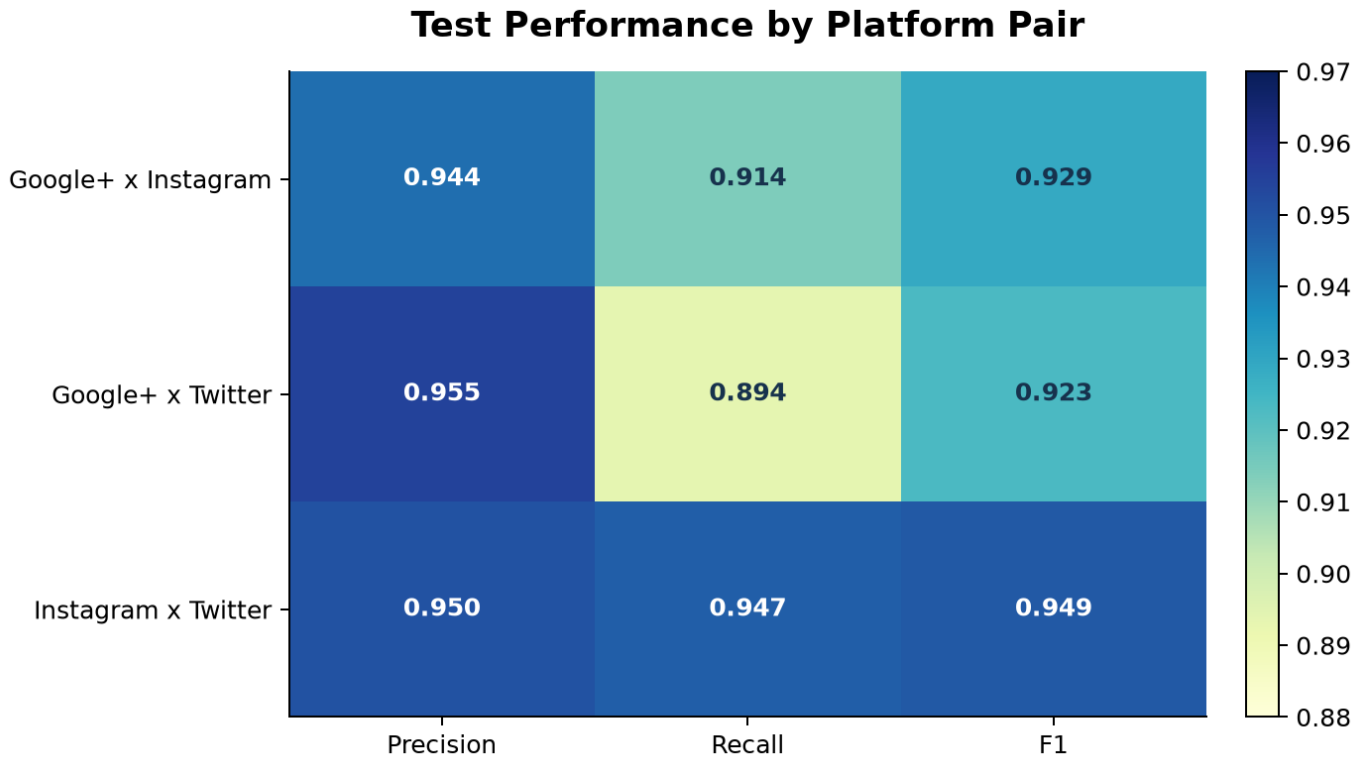
ตัวเลขนี้เป็น benchmark ของ scoring model และไม่ใช่ผลหลัง GA เมื่อเข้าสู่ GA:

- model/scaler/calibrator และ probability ถูก freeze ไม่เปลี่ยน
- GA ไม่เรียก .fit() และไม่แก้ model weights
- GA เรียน threshold [t_match,t_review,c_promote,c_demote] จาก validation
- evidence เช่น name/bio/URL/image/style ใช้เฉพาะคู่ที่มี availability mask
- ผลลัพธ์เปลี่ยนจาก binary prediction เป็น MATCH, REVIEW หรือ NO_MATCH

ดังนั้น GA อาจให้ Precision/Recall ต่างจากตารางนี้ได้ แม้ใช้ probability ชุดเดิม เพราะเปลี่ยน operating rule ไม่ได้เปลี่ยน pair model

8. ผลตาม Platform และ Difficulty

8.1 Platform-pair performance



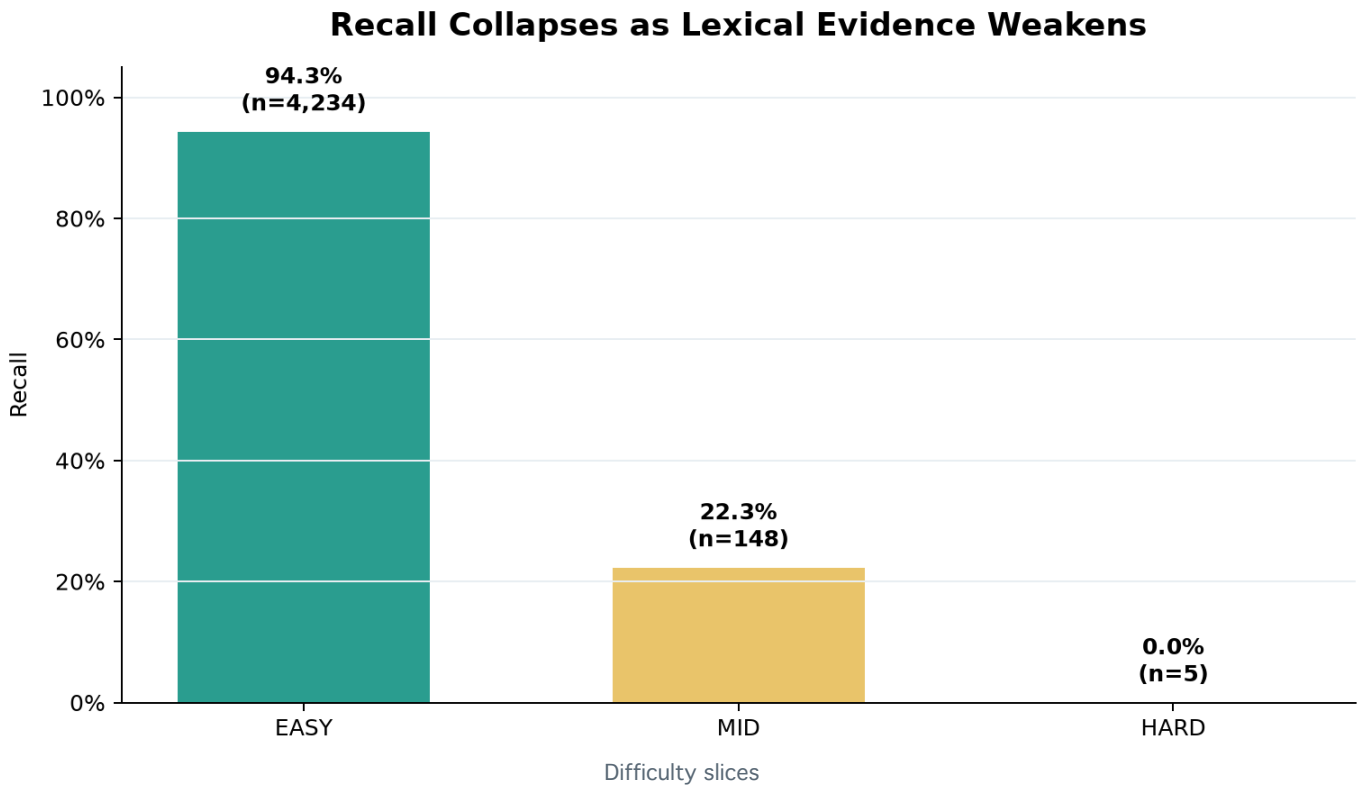
Platform performance

รูปที่ 4 ผลบน test แยกตามคู่แพลตฟอร์ม

Platform pair	Precision	Recall	F1	Positive pairs
Google+ × Instagram	0.9439	0.9138	0.9286	975
Google+ × Twitter	0.9548	0.8936	0.9232	1,795
Instagram × Twitter	0.9504	0.9474	0.9489	1,617

Google+ × Twitter มี recall ต่ำสุดและสร้าง FN 191 จาก FN ทั้งหมด 360 คู่ บ่งชี้ platform/domain shift ที่ควรตรวจแยก

8.2 Difficulty slices



รูปที่ 5 Recall ลดลงอย่างมากเมื่อ lexical name evidence อ่อน

Slice	Positive pairs	Recall	FN
EASY	4,234	0.9433	240
MID	148	0.2230	115
HARD	5	0.0000	5

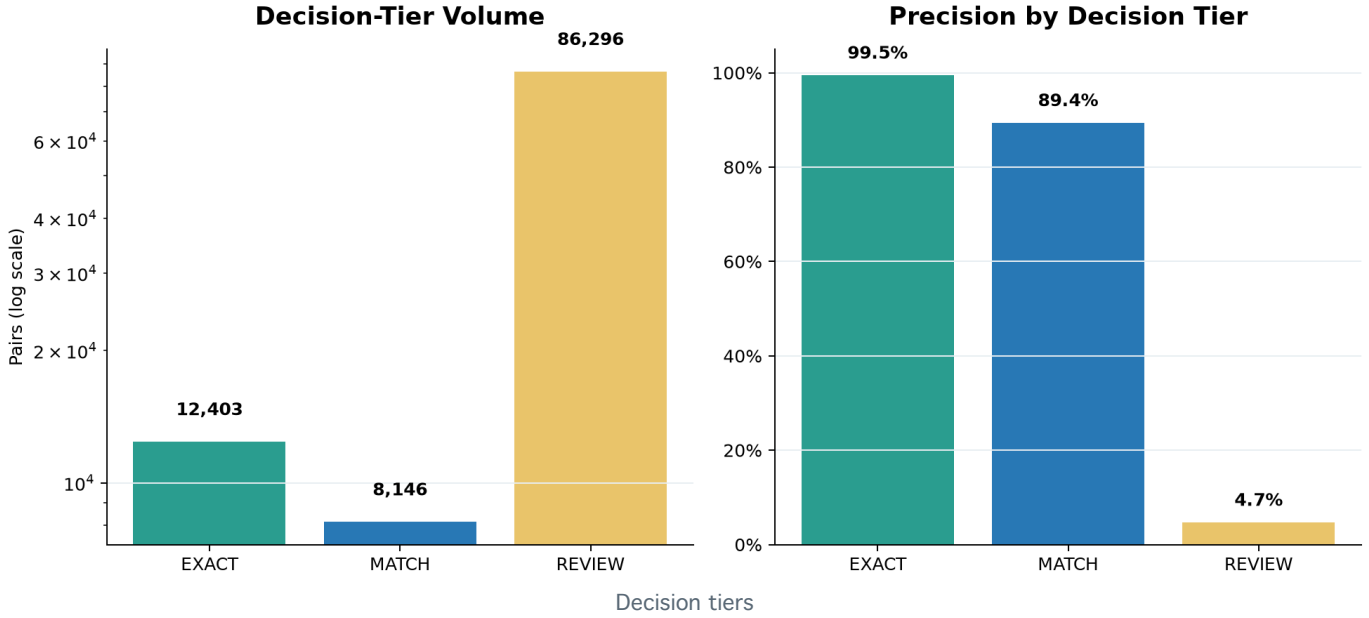
ผลนี้ชี้ว่า overall F1 สูงเกิดจาก easy slice เป็นสัดส่วนใหญ่ ขณะที่ hard cases ยังไม่ถูกแก้ การรายงานเฉพาะ overall metric จึงปิดบังจุดอ่อนสำคัญ

9. Full-Candidate Decision Pipeline

9.1 Decision tiers

production-oriented baseline ใช้ MATCH threshold 0.98 และ REVIEW threshold 0.95:

$$
\begin{cases}
\text{MATCH}, & p \ge 0.98 \\
\text{REVIEW}, & 0.95 \le p < 0.98 \\
\text{NO_MATCH}, & p < 0.95
\end{cases}
$$



รูปที่ 6 ปริมาณและ precision ของ exact, match และ review tiers

threshold 0.98/0.95 เป็น manual operational policy อีกชุดหนึ่ง ไม่ใช่ threshold 0.35 ของ binary model evaluation และไม่ใช่ GA genome เมื่อรัน GA ค่า t_match และ t_review จะถูกเลือกใหม่บน validation โดย calibrated probability ยังเป็นค่าจาก frozen scorer เดิม

Tier	Count	True positive	Precision	Global recall contribution
Exact	12,403	12,340	0.9949	0.4220
Match	8,146	7,284	0.8942	0.2491
Review	86,296	4,065	0.0471	0.1390

review queue มี precision เพียง 4.71% หมายความว่าผู้ตรวจต้องเปิดประมาณ 21 คู่เพื่อพบ true match หนึ่งคู่ เป็น operational bottleneck ที่ชัดเจน

9.2 End-to-end baseline

Metric	Full baseline
TP	19,624
FP	925
FN รวม blocking miss	5,558
REVIEW	86,296
Precision	0.9550
Recall	0.6710

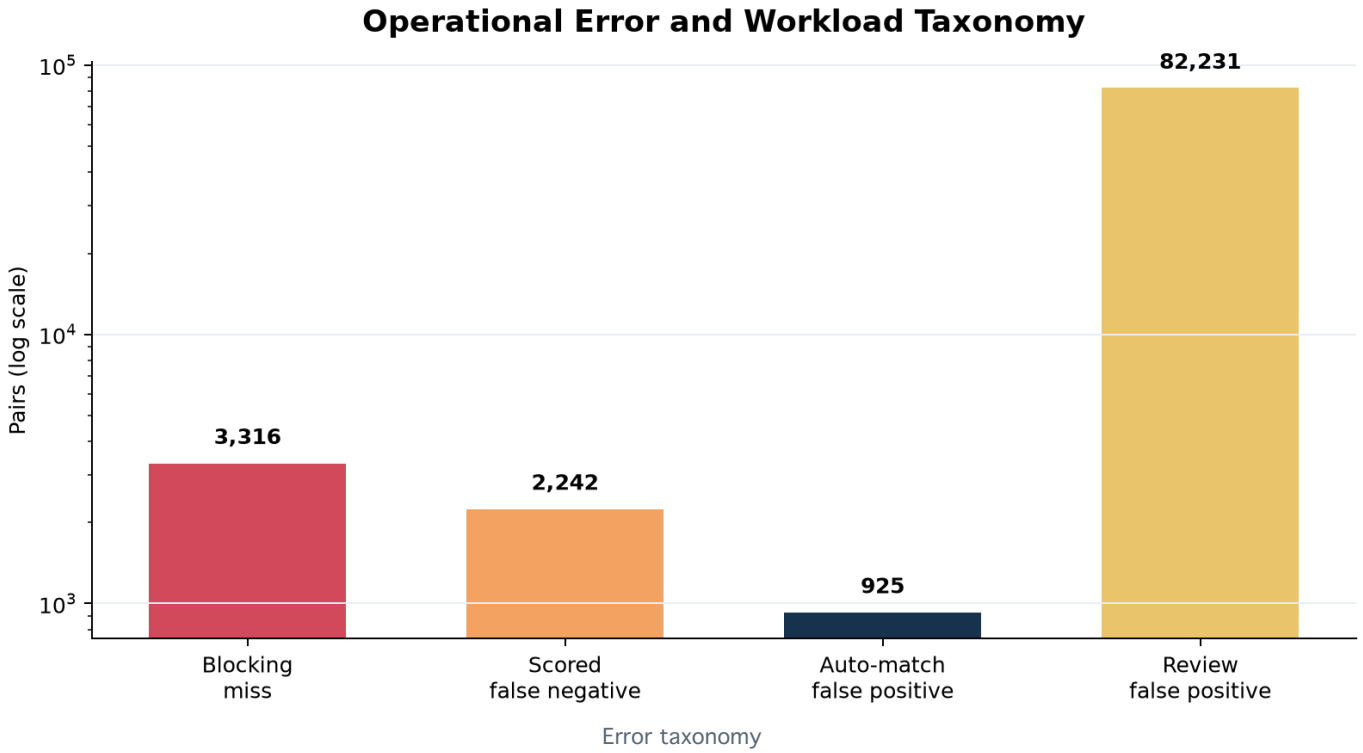
F1	0.7882

9.3 เหตุผลที่ pair-model F1 0.934 ไม่เท่ากับ full F1 0.788

ระดับ	สิ่งที่วัด	สิ่งที่ยังไม่รวม
Pair-model test	จำแนกคู่ใน labeled feature matrix	blocking misses และ workload เต็มระบบ
Retrieval	candidate generation ครอบคลุม true pairs	classifier/decision errors
Full decision	exact + scored + blocking miss + thresholds	entity-level transitive errors
Entity/CRM	ผลหลัง connected components และ canonicalization	ต้องมี entity-level output จริง

ดังนั้น metric ทั้งสองถูกต้องในบริบทของตนเอง แต่ตอบคนละคำถาม

10. Error Analysis



รูปที่ 7 แหล่งความผิดพลาดและภาระงานในระดับ operational

10.1 False positives

พบ MATCH ที่ actual เป็น negative 925 คู่:

- 862 คู่มาจาก model AUTO_HIGH
- 63 คู่มาจาก AUTO_EXACT
- median score ของ FP เท่ากับ 0.9954 แสดงว่า tail calibration หรือ candidate composition ทำให้ model มั่นใจเกินในบางกรณี
- Google+ × Twitter มี FP มากที่สุด 431 คู่

False positive มีความเสี่ยงสูงเพราะทำให้ graph merge คนละคน และความผิดพลาดอาจแพร่ผ่าน transitive closure

10.2 Scored false negatives

มี true pairs 2,242 คู่ที่ผ่าน blocking และถูก score แต่ถูกตัดเป็น NO_MATCH:

- median score 0.8316
- 25th percentile 0.6061
- 75th percentile 0.9286
- Google+ × Twitter เป็นกลุ่มใหญ่สุด 993 คู่

คู่กลุ่มนี้แก้ได้ด้วย model representation, calibration หรือ re-decision policy เพราะมี candidate อยู่แล้ว

10.3 Blocking misses

research harness พบ 3,316 true pairs ที่ไม่เข้า candidate set จึงไม่มี score และไม่สามารถแก้ด้วย threshold/GA ที่ปลายทาง การแก้ต้องอยู่ที่ candidate retrieval เช่น semantic blocking, additional

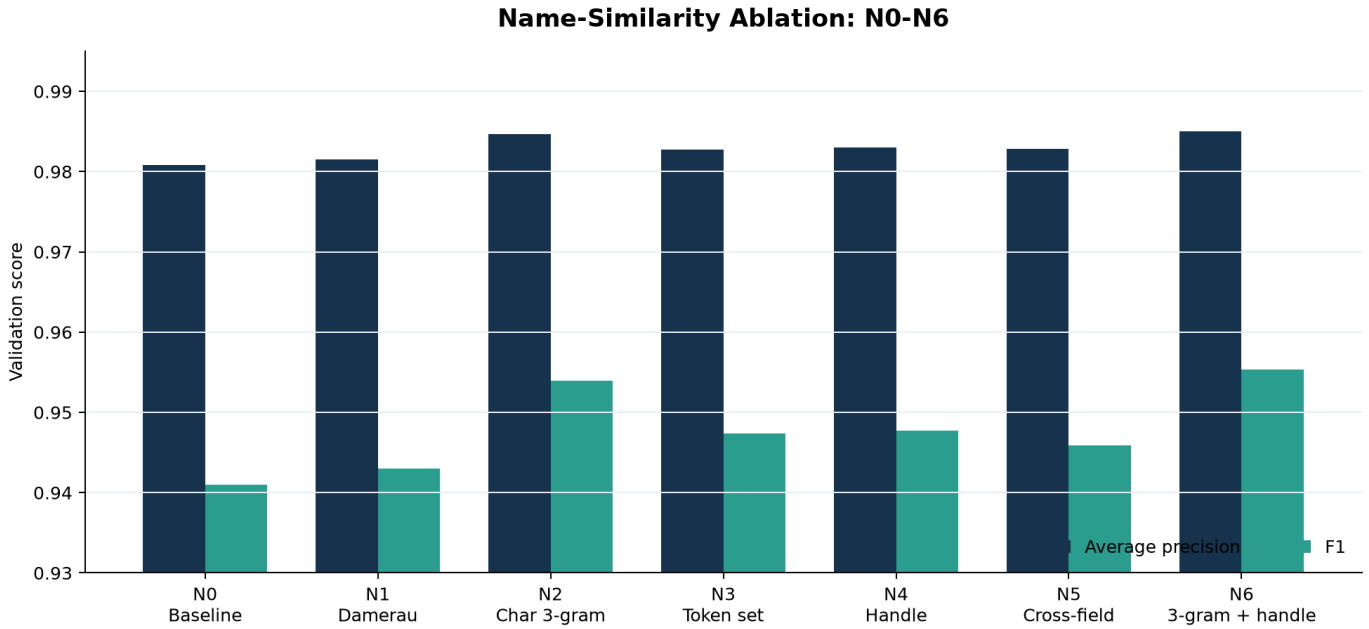
keys หรือ approximate-nearest-neighbor retrieval

10.4 Review burden

REVIEW มี 86,296 คู่ แต่เป็น positive เพียง 4,065 คู่ ขณะที่ negative 82,231 คู่ ช่วง score 0.95-0.98 จึงไม่ได้แยก identity ได้ดีพอใน population จริง การลด review queue เป็น business objective ที่สำคัญพอ ๆ กับ F1

11. Name-Similarity Ablation N0-N6

การทดลองนี้เปลี่ยนหรือเพิ่ม representation ของชื่อภายใต้ split และ training protocol เดียวกัน ผลทั้งหมดเป็น validation result และยังไม่ใช่ sealed-test ranking



รูปที่ 8 ผล validation ของ name-similarity variants

Run	Feature change	AP	Precision	Recall	F1
N0	Baseline name features	0.98086	0.9727	0.9113	0.9410
N1	Damerau-Levenshtein	0.98152	0.9669	0.9202	0.9430
N2	Character 3-gram cosine	0.98468	0.9847	0.9250	0.9539
N3	Token-set similarity	0.98273	0.9793	0.9175	0.9474
N4	Handle-oriented features	0.98300	0.9708	0.9257	0.9477
N5	Cross-field name matching	0.98282	0.9725	0.9207	0.9459
N6	Character 3-gram + handle	0.98501	0.9808	0.9311	0.9553

N6 เพิ่ม F1 จาก N0 ประมาณ 0.0143 และเพิ่ม AP ประมาณ 0.00415 หลักฐานนี้สนับสนุนการเพิ่ม char n-gram และ handle features เข้า candidate model แต่ต้องทำ sealed-test evaluation ก่อนประกาศเป็น production replacement

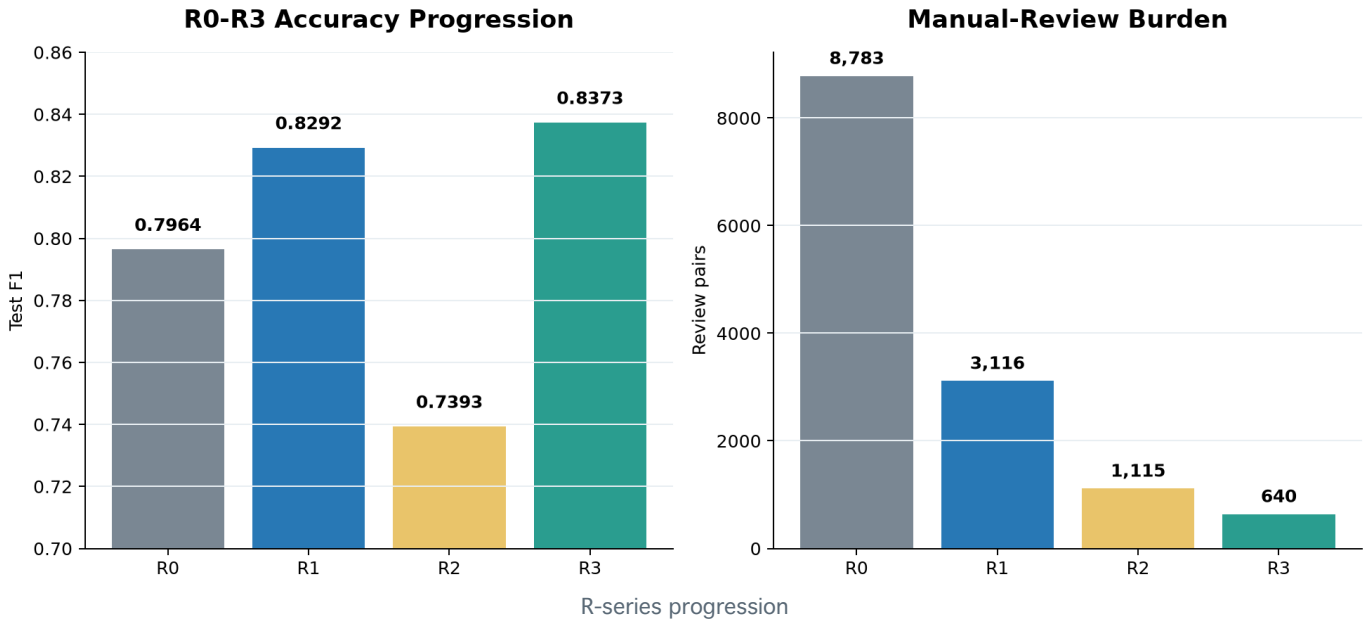
12. การทดลอง Representation × Decision: R0-R6

12.1 แนวคิดการทดลอง

R-series แยกคำถามสองแกน:

- Representation: feature เดิม, BERT cosine, privacy-preserving Bloom, BERT-ER
- Decision: threshold มือ หรือ GA re-decision

การแยกสองแกนนี้ทำให้เห็นว่า representation ใหม่อาจไม่ดีขึ้นหากใช้ threshold เดิมที่ไม่เข้ากับ probability scale ใหม่



รูปที่ 9 Test F1 และ manual-review burden ของ R0-R3

12.2 ผล test

Exp	Representation	Decision	Precision	Recall	F1	REVIEW
R0	baseline score	0.98/0.95	0.9852	0.6683	0.7964	8,783
R1	baseline score	GA	0.9963	0.7101	0.8292	3,116
R2	+ BERT cosine	manual	0.9963	0.5877	0.7393	1,115
R3	+ BERT cosine	GA	0.9940	0.7233	0.8373	640
R5 L=2000	Bloom-Dice	GA	0.9910	0.7183	0.8329	700
R6	frozen BERT-ER	manual	0.9950	0.4350	0.6053	224
R6-GA	frozen BERT-ER	GA	0.9977	0.6405	0.7801	3,712

12.3 R3 full projection

Metric	R0 baseline	R3 projection	Change
Precision	0.9550	0.9786	+0.0236
Recall	0.6710	0.7274	+0.0564
F1	0.7882	0.8345	+0.0463
FP	925	465	-49.7%
REVIEW	86,296	2,751	-96.8%

R3 เป็นผลดีที่สุดใน R-series แต่เป็น research projection บน frozen full scores ไม่ใช่ policy ที่ wire เข้า canonical production workflow แล้ว

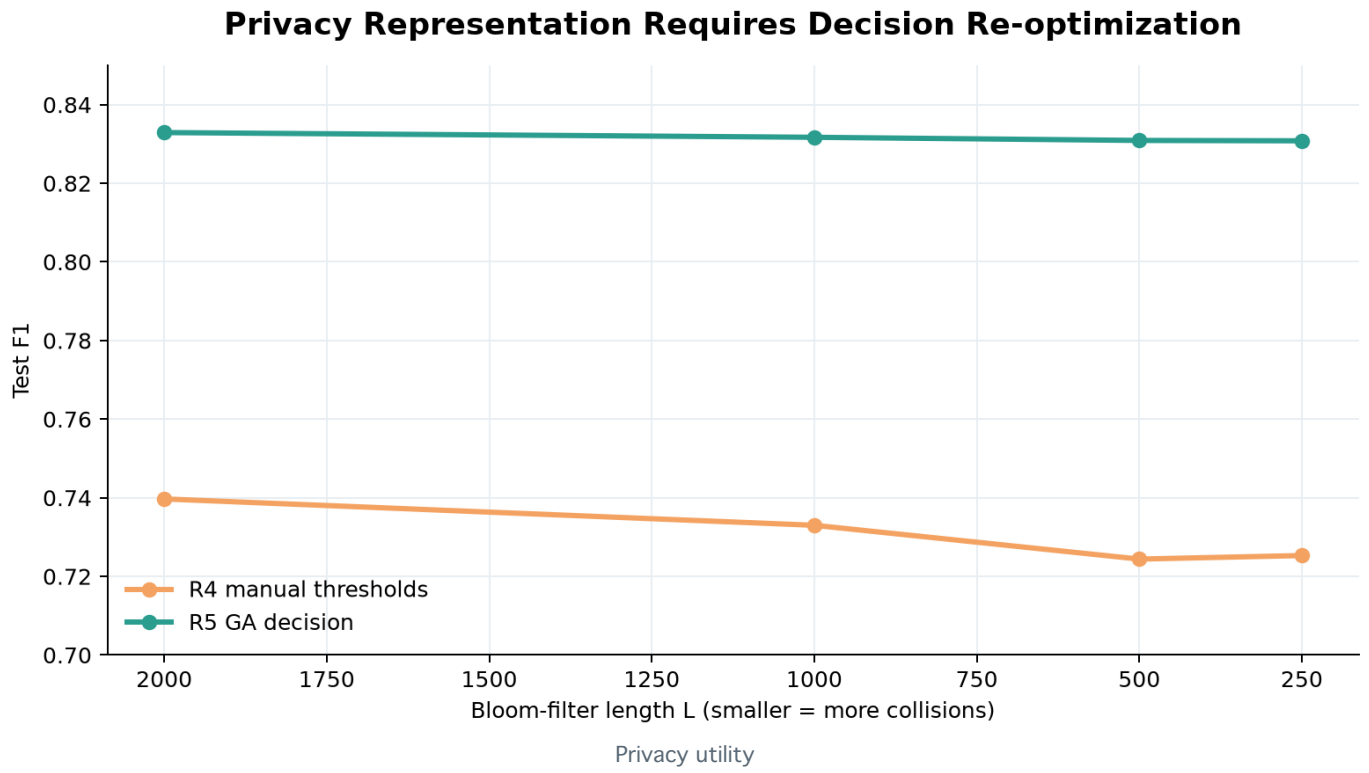
12.4 FN recovery

จาก scored FN เดิม 2,242 คู่:

Strategy	MATCH หรือ REVIEW	MATCH เท่านั้น
R2	282 (12.6%)	37
R3	728 (32.5%)	214

GA ทำให้ representation BERT ถูกใช้งานได้ดีขึ้น เพราะ threshold เดิมไม่เหมาะกับ probability distribution ใหม่

12.5 Privacy-utility trade-off



รูปที่ 10 Bloom representation เมื่อใช้ manual threshold เทียบกับ GA

R5 ที่ Bloom length 2,000 ให้ Test F1 0.8329 ต่างจาก R3 เพียง 0.0044 จึงเป็นทางเลือกที่น่าสนใจเมื่อข้อกำหนด privacy สำคัญกว่าความแม่นยำสูงสุด แต่ Bloom filter ไม่ได้ให้ privacy guarantee แบบเข้ารหัสสมบูรณ์ ต้องมี threat model และ parameter governance เพิ่ม

12.6 R6 semantic blocking

R6 ใช้ frozen DistilBERT representation กับ learned hash/match heads เพื่อพยายามกู้ blocking-missed pairs:

Hamming radius	Candidate recovered	End-to-end MATCH
0	0 / 3,316	0
≤1	4 / 3,316 (0.12%)	3

ผลเป็น negative result: frozen encoder และ hash configuration ปัจจุบันยังไม่พร้อมใช้

การทดลองนี้มีคุณค่าเพราะระบุชัดว่า semantic blocking ต้องการ domain fine-tuning, hard-negative mining และ compute ที่มากกว่าเดิม

13. Genetic Algorithm และ Business-Cost Optimization

13.1 Objective function

CRM policy ปัจจุบัน derive จากค่าแรง 100 บาท/ชั่วโมง: REVIEW 1 นาที = 1.67 บาท, จัดการ FN 10 นาที = 16.67 บาท และแก้ FP 20 นาที = 33.33 บาท เมื่อ normalize ด้วยต้นทุน FN ได้:

$$C_{crm}=2FP+FN+0.1REVIEW$$

policy version คือ crm_derived_v1 และ source of truth อยู่ที่ business_cost.py ผล R1-R6 และ feature-aware artifacts ที่สร้างก่อนการเปลี่ยนนี้ optimize ด้วย historical cost 5FP+FN+0.02REVIEW จึงต้องเก็บผลเดิมไว้เพื่อ reproducibility แล้ว rerun policy selection ภายใต้ cost ใหม่ ห้ามเปลี่ยนตัวเลข artifact เก่าย้อนหลัง

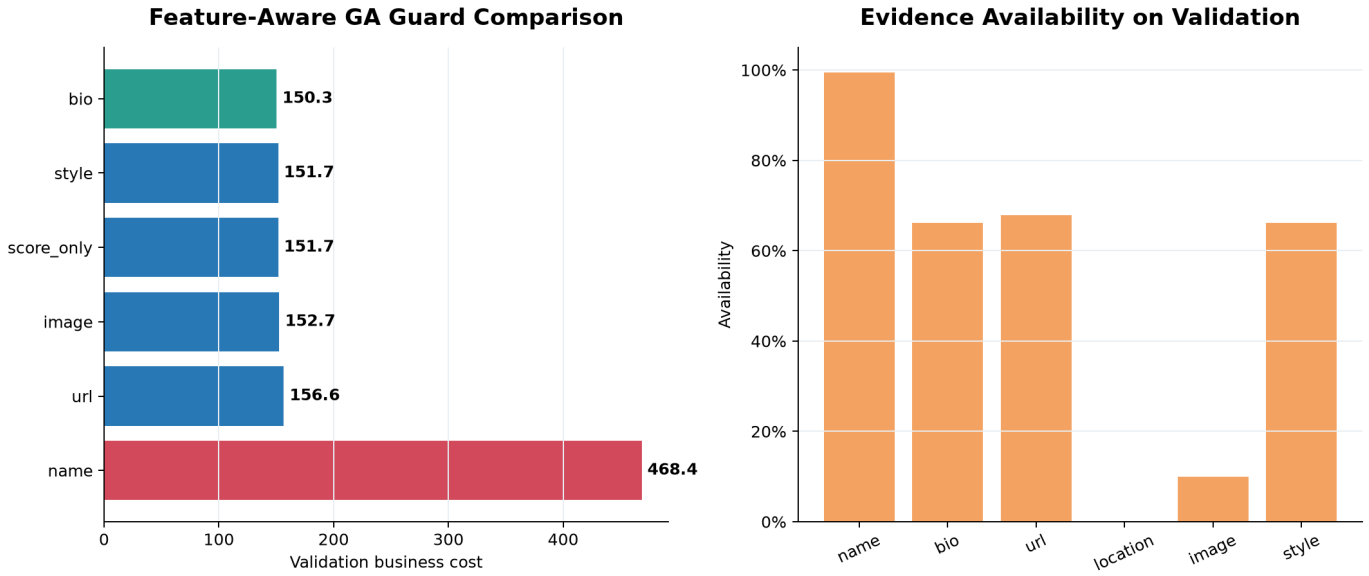
13.2 Genome ของ R1/R3

$$g=[t_{match},t_{review},c_{promote},c_{demote}]$$

ใน implementation เดิม evidence guard เป็น name_sim แบบ hard-coded ดังนั้นคำว่า “GA เลือก name” ไม่ถูกต้อง ที่ถูกคือ “ผู้ออกแบบกำหนด name ให้ GA ล่วงหน้า แล้ว GA เลือกเพียง thresholds”

13.3 Feature-aware GA

การทดลองใหม่เปรียบเทียบ score-only กับ guard จาก name, bio, URL, image และ style โดยใช้ availability mask



Feature-aware GA

รูปที่ 11 GA guard cost และ evidence coverage บน labeled validation population

Guard	Validation cost	Precision	Recall	FP	FN	REVIEW
bio	458.70	0.9989	0.6040	3	56	3,967
style	465.30	0.9988	0.5885	3	56	4,033
score only	465.60	0.9988	0.5882	3	56	4,036
image	466.40	0.9988	0.5882	3	57	4,034
URL	467.20	0.9985	0.5889	4	56	4,032
name	530.80	0.9787	0.7241	69	56	3,368

ตารางนี้ re-score policy counts เดิมด้วย crm_derived_v1; policy เหล่านี้ยังมาจาก search ภายใต้ objective เก่า จึงใช้วิเคราะห์ sensitivity เท่านั้น ไม่ใช่ผล optimization ใหม่ name guard ให้ recall สูงสุด แต่ false positives เพิ่มจาก 3 เป็น 69 และ cost สูงกว่า bio

13.4 Availability coverage

Group	Validation availability	High-score positive rate
name	99.42%	0.596
bio	66.18%	0.954
URL	67.93%	0.941
image	10.02%	1.000
style	66.18%	0.533
location	0.00%	0.000

image มี conditional precision สูงแต่ coverage ต่ำ จึงเหมาะเป็น availability-gated positive evidence มากกว่า global default

13.5 Model weights ไม่เท่ากับ GA weights

ต้องแยกสองความหมาย:

- Model feature importance: feature ช่วยจัดอันดับ pair probability มากเพียงใด
- GA policy weight/guard: evidence ช่วยลด decision cost ใน review band มากเพียงใด

name สำคัญต่อ model มากที่สุด แต่ “feature สำคัญ” ไม่เท่ากับ “policy พร้อม promote” ผล historical labeled-subset ทำให้ bio ชนะ scalar cost ขณะที่ CRM-cost full-population rerun ทำให้ name ชนะ scalar cost แต่ยังไม่ผ่าน Precision/Recall gates จึงต้องใช้ constrained policy ไม่ใช่สรุปจาก feature importance หรือ raw cost เพียงอย่างเดียว

13.5.1 Proof: feature มีผลต่อ model มากน้อยเพียงใด

ตารางนี้ใช้ permutation importance บน validation ของ Gradient Boosting feature-aware model: สลับค่าของ feature/group ทีละส่วนแล้ววัด Average Precision (AP) ที่ลดลง ค่า AP delta สูงหมายถึง model พึ่งพาสัญญาณนั้นมากกว่า ไม่ใช่ causal effect และไม่ใช่น้ำหนักที่ GA ต้องใช้

Evidence group	Sum AP delta	Std. รวม	จำนวน feature	ความหมาย
Name	0.277651	0.008046	6	สัญญาณหลักของ pair score อย่างชัดเจน
Bio	0.011153	0.000999	3	มีประโยชน์เสริมเมื่อมีข้อมูลครบทั้งสองฝั่ง
Platform/availability/other	0.004224	0.000498	4	บอก distribution และ missingness เล็กน้อย
Style	0.001577	0.000600	5	ผลเสริมขนาดเล็ก
URL	0.001100	0.000181	3	มีผลต่ำใน validation
Image	0.000908	0.000405	19	coverage จำกัด จึงยังไม่ใช่สัญญาณหลัก
Location	0.000000	0.000000	3	ไม่มี usable pair evidence ใน run นี้

Top features ที่พิสูจน์ได้จาก run เดียวกันคือ username_token_sort (0.127410), fullname_token_sort (0.071982), fullname_jaro (0.041630), username_jaro (0.021471), fullname_lev (0.009836), bio_tfidf_cosine (0.006717) และ username_lev (0.005322) ดังนั้น name token/character similarities มีผลต่อ model score สูงสุด; Bio เป็น feature รองที่มีผลจริง ส่วน

URL/style/image/location ยังไม่มีหลักฐานพอให้แทน name ใน pair scorer

หลักฐาน raw อยู่ที่ feature_permutation_importance_validation.csv และ grouped_permutation_importance_validation.csv ควรอ่านร่วมกับ coverage: full validation มี name 100%, bio/style 65.70%, URL 70.41%, image 11.16% และ location 0% จึงไม่ตีความ AP delta ต่ำว่า feature ไม่มีคุณค่าทางธุรกิจในข้อมูลที่สมบูรณ์กว่า

แผนปิดข้อสงสัยเรื่อง replacement โดยใช้ canonical experiment เดียวอยู่ที่ NAME_SIM_GA_PROOF_CLOSURE_PLAN_TH.md

13.6 Weighted GA result

Group	Learned weight
name	0.3939
style	0.3043
image	0.1833
URL	0.1186
bio	0.0000

weighted policy เดิมมี counts FP=28, FN=56, REVIEW=3,892 ซึ่งคิดเป็น CRM-derived cost 501.20 และยังแพ้ bio selector ที่ 458.70 เหตุผลที่ bio weight เป็นศูนย์แต่ bio guard ชนะไม่ใช่ contradiction: weighted aggregate และ one-guard policy เป็น hypothesis class คนละแบบ และ optimization landscape ต่างกัน

13.7 Sealed-test result

หลังเลือก bio บน validation แล้วจึงประเมิน test หนึ่งครั้ง:

Metric	Value
Precision	0.9973
Recall	0.5924
F1	0.7433
FP	7
FN	63
REVIEW	3,812
CRM-derived cost	458.20

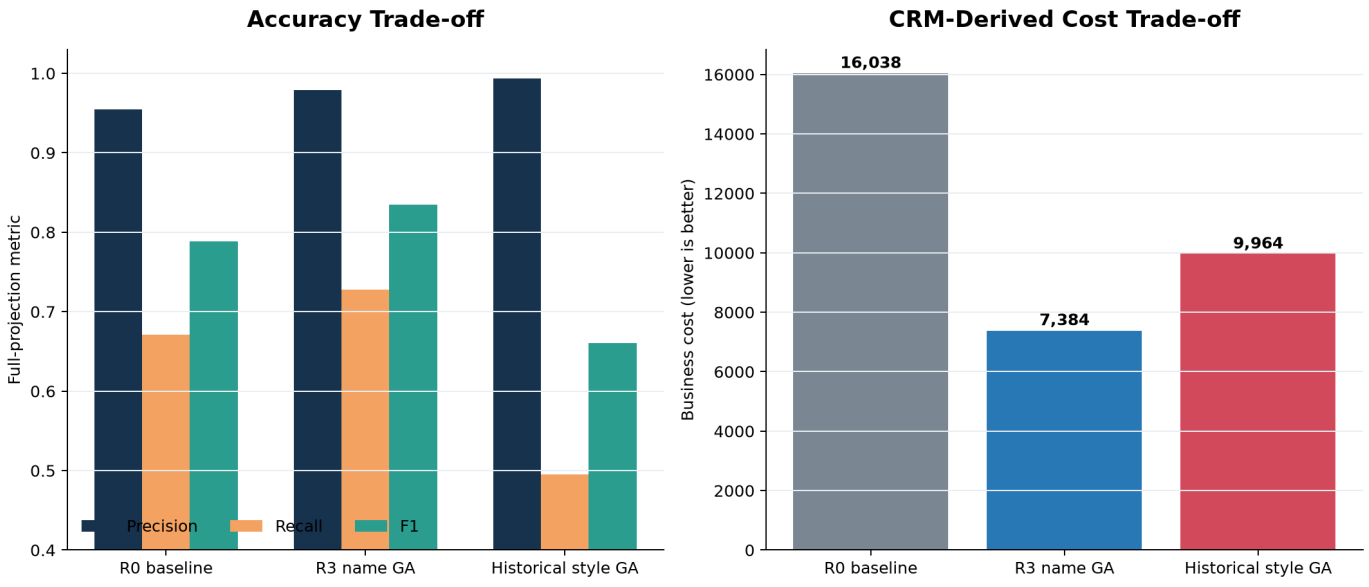
ผลนี้มาจาก labeled feature population 58,696 คู่ ซึ่ง overlap กับ full 2,073,842 scored candidates เพียง 20,757 คู่ หรือ 1.00% จึงเป็น proof of mechanism ไม่ใช่ production promotion result

13.8 ผลรันเต็ม 2.07 ล้าน scored candidates

หลังสร้าง evidence และ availability masks ครบ 2,073,842 คู่ใน 42 parquet chunks แล้ว historical-cost run เลือก style ก่อนเปิด test หนึ่งครั้ง Counts ด้านล่างเป็นผลของ policy เดิม แต่ cost ถูก re-score ด้วย crm_derived_v1 เพื่อให้เทียบกับ policy ปัจจุบันได้

Evaluation	Precision	Recall	F1	FP	FN	REVIEW	Cost
Scored sealed test	0.9985	0.1604	0.2764	1	879	4,975	1,378.50
System sealed test	0.9973	0.4995	0.6656	12	1,885	4,975	2,406.50
Full system projection	0.9937	0.4949	0.6607	92	6,284	34,955	9,963.50

system metrics รวม exact tier และ blocking-missed FN ส่วน scored metrics วัดเฉพาะ model-scored pairs ความต่างระหว่างสองแถวจึงเกิดจาก evaluation boundary ไม่ใช่การคำนวณขัดกัน



Full feature-aware trade-off

รูปที่ 12 Full projection re-score ด้วย CRM-derived cost แสดงว่า historical style GA เพิ่ม precision แต่เสีย recall/F1 และมี cost สูงกว่า R3

Full projection	Precision	Recall	F1	FP	REVIEW	Cost
R0 baseline	0.9550	0.6710	0.7882	925	86,296	16,037.60
R3 name GA	0.9786	0.7274	0.8345	465	2,751	7,384.10
Historical-cost style GA	0.9937	0.4949	0.6607	92	34,955	9,963.50

เมื่อ re-score ด้วยต้นทุน CRM ใหม่ R3 มี cost ต่ำกว่า historical-cost style GA เพราะ REVIEW แพงขึ้นจาก 0.02 เป็น 0.1 ต่อคู่ ผลนี้ยืนยันว่า policy winner ขึ้นกับ business weights และต้อง rerun search ไม่ใช่เพียงคำนวณ cost ใหม่ แนวทางต่อไปใช้ constrained optimization เช่น minimize cost ภายใต้ Recall\ge0.70 และ Precision\ge0.99

13.9 CRM-cost validation-only rerun

รอบ crm_derived_v1 reuse feature cache เดิม 2,073,842 คู่ แต่ optimize ใหม่บน validation เท่านั้น ผล selector คือ:

Guard	Validation cost	Precision	Recall	F1	FP	FN	REVIEW
name	3,498.60	0.9853	0.6240	0.7641	89	2,189	11,316
bio	3,761.40	0.9837	0.2396	0.3853	38	2,202	14,834
style	3,808.70	0.9887	0.1556	0.2688	17	2,189	15,857
score only	3,810.30	0.9886	0.1545	0.2673	17	2,189	15,873
image	3,975.50	0.9580	0.4347	0.5981	182	2,488	11,235
URL	4,943.20	0.9274	0.5398	0.6824	404	3,704	4,312

weighted GA ได้ cost 4,897.10, Precision 0.9293, Recall 0.5691 และ F1 0.7059 จึงแพ้ name selector Artifact ระบุ test_evaluated=false และ freeze policy ก่อน test อย่างไรก็ตาม winner ยังต่ำกว่า gates ที่เสนอทั้ง Precision 0.99 และ Recall 0.70 จึงเป็นผลสำหรับพัฒนา constrained objective เท่านั้น ไม่ใช่ production candidate

14. Entity Resolution และ CRM Layer

คู่ที่ตัดสินเป็น MATCH จะถูกมองเป็น edge ของ graph และรวม connected components ด้วย Union-Find:

```
flowchart LR
    A[Twitter profile] -->|MATCH| B[Google+ profile]
    B -->|MATCH| C[Instagram profile]
    A -. transitive identity .-> C
    A --> U[Unified entity]
    B --> U
    C --> U
    U --> CAN[Canonical fields]
    CAN --> CRM[Lead score and CRM export]
```

จุดเสี่ยงคือ FP เพียง edge เดียวอาจเชื่อมสอง component และทำให้หลาย profile ถูก merge ผิดพร้อมกัน จึงสมเหตุผลที่ business cost ให้น้ำหนัก FP สูง อย่างไรก็ตาม workspace ปัจจุบันไม่มี final unified-profile/lead-score artifact ที่พร้อมยืนยัน entity-level metrics รายงานจึงอธิบาย architecture แต่ไม่อ้างผล deployment หรือจำนวนลูกค้าหลัง merge

15. Reproducibility และ Engineering Controls

15.1 Environment

- Python 3.11 ผ่าน .venv/bin/python
- dependencies หลัก: NumPy, pandas, PyArrow, RapidFuzz, SciPy, scikit-learn
- training extras: PyTorch, sentence-transformers, Pillow, imagehash
- report figures: Matplotlib

15.2 Artifact lineage

ทุกผลควรมี:

- source data path และ checksum
- feature schema/version
- split manifest และ seed
- model parameters และ calibrator
- threshold/GA genome
- validation selection record
- sealed-test report
- environment/package versions

15.3 Known reproducibility risk

historical review re-decision บางสายเคยเปลี่ยน similarity implementation ตามว่ามี jellyfish ติดตั้งหรือไม่ ทำให้ SequenceMatcher และ Jaro-Winkler ให้ผลต่างกันมาก โค้ดใหม่ควรระบุ metric แบบ explicit, pin dependency และห้าม silent fallback

15.4 Figure reproducibility

กราฟในรายงานนี้สร้างจาก generate_report_figures.py:

```
.venv/bin/python manuscript/generate_report_figures.py
```

script จะ fail หาก artifact ต้นทางหาย แทนการสร้างภาพจาก default หรือค่าจำลอง

16. ข้อจำกัดของงาน

- Retrieval ceiling: blocking miss จำกัด recall สูงสุดของ R0-R5 ราว 0.8866
- Evidence-version mismatch: full candidate run แก้ population mismatch แล้ว แต่ image evidence ใช้ pHash/caption-token เพราะ legacy caption embedding cache ไม่มีและ dimension ไม่สอดคล้องกัน
- Data age: Google+ และ URL รูปจำนวนมากเป็น archival data
- Image coverage: download ใหม่ล้มเหลว 998/998; image contribution ต่ำใน model ปัจจุบัน
- Sparse hard cases: hard test slice มี positive เพียง 5 คู่ จึงมี uncertainty สูง
- Ground-truth proxy: user_folder เป็น operational ground truth แต่ไม่ใช่ independently adjudicated identity label
- Pair metric ไม่ใช่ entity metric: F1 ระดับคู่ไม่วัด cluster purity, over-merge หรือ under-merge โดยตรง
- GA objective dependency: policy ที่ดีที่สุดเปลี่ยนได้เมื่อ business weights เปลี่ยน
- Full projection ไม่ใช่ sealed test: การ apply policy บน full cache ใช้เพื่อประมาณ operational effect แต่ unbiased metric ต้องยึด held-out test
- ไม่มี deployment evidence: ไม่มีหลักฐาน production traffic, latency SLA, human-review outcome หรือ post-deployment drift

Implementation plan สำหรับแก้ข้อจำกัดทั้งสิบอยู่ที่ LIMITATIONS_REMEDIATION_IMPLEMENTATION_PLAN_TH.md

17. ข้อเสนอแนะเชิงระบบ

17.1 Priority 1: สร้าง full feature-aware cache

สถานะ: เสร็จแล้ว คำนวณ feature values และ availability masks ครบ 2,073,842 scored candidates แบบ chunked/resumable historical-cost run เคยเลือก style แต่เมื่อ re-optimize ด้วย crm_derived_v1 บน validation-only name ชนะที่ cost 3,498.60 อย่างไรก็ตาม Precision 0.9853 และ Recall 0.6240 ยังไม่ผ่าน promotion gates จึงไม่ promote policy ใดจาก scalar-cost search นี้

งานนี้มี executable runner และ WezTerm runbook แล้วที่ run_full_feature_aware_ga_pipeline.py และ FULL_2M_FEATURE_AWARE_WEZTERM_PLAN_TH.md ผล full run ต้องถูกบันทึกแยกจากผล labeled subset ในรายงานฉบับนี้

งานถัดไปคือดำเนินตาม LIMITATIONS_REMEDIATION_IMPLEMENTATION_PLAN_TH.md: เพิ่ม constraint ของ recall/precision เข้า GA objective, สร้าง fresh audit test, แก้ blocking misses และเพิ่ม entity-level/shadow evaluation

เกณฑ์ผ่าน:

- row count และ pair keys ตรงกับ frozen scored cache 100%
- ไม่มี duplicate pair
- availability audit ครบทุก group
- validation winner ถูก freeze ก่อน test
- test เปิด policy เดียว

17.2 Priority 2: ลด false auto-merge

- ตรวจ tail calibration ของ score ≥0.98
- เพิ่ม secondary-evidence guard ให้ exact username collisions
- รายงาน cluster-level over-merge หลัง Union-Find
- ใช้ expected cost หรือ constrained optimization เช่น maximize recall เมื่อ precision ≥0.99

17.3 Priority 3: แก้ blocking misses

- เพิ่ม semantic nearest-neighbor blocking เป็น union กับ blocking เดิม ไม่ใช่ replacement
- fine-tune encoder ด้วย hard negatives บน GPU
- ทดลอง hash bits/radius และวัด candidate inflation
- gate ด้วย recall gain, added candidate count และ downstream precision

17.4 Priority 4: ปรับ name representation

นำ N6 char 3-gram + handle ไปทำ sealed test และ full-candidate scoring หาก validation gain ยังคงอยู่ โดยไม่ลบ token-sort/Jaro เดิมก่อนมี ablation ยืนยัน

17.5 Priority 5: Data enrichment

- snapshot รูปและ URL ในเวลาที่เก็บข้อมูล
- normalize location ด้วย geocoding/country hierarchy
- เพิ่ม temporal metadata เพื่อป้องกันการเทียบข้อมูลคนละช่วงเวลา
- ทำ label audit แบบ stratified โดยเน้น exact FP, high-confidence FP และ weak-name FN

17.6 Priority 6: Monitoring

ควรติดตาม:

- candidate coverage และ candidate count ต่อ profile
- score distribution drift แยก platform pair
- exact collision rate
- MATCH precision จาก sampled review
- REVIEW yield และ reviewer agreement
- entity component size เพื่อจับ over-merge
- field availability drift

18. Roadmap การนำไปใช้

Phase	งาน	Output	Promotion gate
A	Freeze data/split manifests	checksums, entity split	entity overlap = 0
B	Build full feature cache	chunked parquet + masks	2,073,842 rowsครบ
C	Run coverage audit	coverage/reliability table	no silent missing->zero
D	GA validation	selector + weighted leaderboard	validation only
E	Freeze winner	policy JSON	deterministic replay
F	Sealed test	one test report	precision/cost gate
G	Full projection	operational counts	review capacity gate
H	Shadow CRM	entity-level audit	no unacceptable over-merge
I	Controlled deployment	monitored decisions	rollback available

19. สรุปผล

โครงการประสบความสำเร็จในการสร้าง pipeline ที่ครอบคลุมตั้งแต่ profile normalization, candidate retrieval, feature engineering, machine-learning scoring, probability calibration, decision policy ไปจนถึง entity resolution architecture ผล pair-model แสดงความสามารถสูงบน test set โดย F1 0.9340 แต่ full workflow ชี้ว่าคอขวดหลักอยู่ที่ candidate coverage, threshold policy และ review workload

หลักฐานจาก R-series แสดงว่า GA ช่วยใช้ probability ได้เหมาะกว่าการยึด threshold เดิม และ R3 ให้สมดุลดีที่สุดในชุดทดลอง ขณะที่ privacy-preserving Bloom representation มีศักยภาพเมื่อใช้ GA ร่วมกัน ส่วน R6 ยืนยันอย่างตรงไปตรงมาว่า frozen semantic encoder ยังไม่พอสำหรับแก้ blocking misses

ผล feature-aware analysis ตอบคำถามสำคัญว่า feature ที่สำคัญต่อ model ไม่จำเป็นต้องเพียงพอสำหรับ decision guard: permutation importance ยืนยันว่า name token/character features มีผลต่อ pair scoring สูงสุด ขณะที่ bio มีประโยชน์เสริมเมื่อข้อมูลพร้อม Historical labeled-subset เลือก bio, historical full run เลือก style และ CRM-cost full rerun เลือก name; winner เปลี่ยนตาม population และ cost policy ผล CRM run ยังต่ำกว่า Precision/Recall gates จึงปฏิเสธการ promote ทุก scalar-cost policy ในรูปปัจจุบัน

ข้อเสนอสุดท้ายคือรักษา Gradient Boosting + calibrated score เป็น baseline, ทดสอบ N6 ใน sealed protocol, ใช้ R3 เป็น research comparator และปรับ GA เป็น constrained multi-objective ที่มี availability masks พร้อมให้ความสำคัญกับ blocking misses/false merges มากกว่าการเพิ่ม model complexity โดยไม่มีข้อมูลรองรับ

20. Evidence Index

หัวข้อ	Artifact/Source
Canonical architecture	ARCHITECTURE_TH.md, GETTING_STARTED_TH.md
Production code	src/identity_resolution/
Pair-model evaluation	current_model_evaluation.json
Full blocking statistics	blocking.csv
Decision tiers	tiers.csv
Error analysis	summary.json
Model comparison	model_cmp.csv
Production feature importance	feat_imp.csv
R0-R6 report	REPORT_R0_R5.md
R-series table	r0_r5_summary_tidy.csv
FN recovery	r2_r3_fn_recovery.json
R6 blocking recovery	r6_blocking_recovery.json
Name ablations	artifacts/evaluation/name_similarity/
Feature-aware GA	DETAILED_REPORT_TH.md
Full 2M feature-aware result	FULL_2M_REPORT_TH.md, sealed_test_and_projection.json
Image acquisition status	download_report.json
Data-quality audit generated for this report	report_data_audit.json
Figure generator	generate_report_figures.py
Full 2M runner และ WezTerm plan	run_full_feature_aware_ga_pipeline.py, FULL_2M_FEATURE_AWARE_WEZTERM_PLAN_TH.md
Limitations remediation plan	LIMITATIONS_REMEDIATION_IMPLEMENTATION_PLAN_TH.md
Name-sim GA proof closure plan	NAME_SIM_GA_PROOF_CLOSURE_PLAN_TH.md

Appendix A: สถานะคำกล่าวสำคัญ

คำกล่าว	สถานะ
ระบบมี pair-model test F1 0.9340	ยืนยันจาก artifact
ระบบ full baseline มี F1 0.7882	ยืนยันจาก R-series full evaluation
R3 เป็นผลดีที่สุดใน R0-R6	ยืนยันบน common test harness
R3 ถูก deploy แล้ว	ไม่จริง/ยังไม่มีหลักฐาน
image context เพิ่ม performance มาก	ไม่รองรับ; gain ประมาณ 0.001 F1
name เป็น feature group สำคัญที่สุด	รองรับโดย production importance และ permutation importance

name เป็น GA guard ที่ดีที่สุด	ขึ้นกับ scope/objective; labeled historical validation เป็น bio, historical full run เป็น style, CRM-cost full validation เป็น name
feature-aware bio policy พร้อม production	ไม่พร้อม; เป็น historical labeled-subset winner และไม่ผ่าน full-population proof
full 2M style policy ควรถูก promote	ไม่ควร; เป็น historical-cost winner, full F1 ต่ำ และ CRM-cost rerun ไม่เลือก policy นี้
CRM-cost full name policy ควรถูก promote	ไม่ควร; Precision 0.9853 < 0.99 และ Recall 0.6240 < 0.70
semantic blocking แก้ blocking miss แล้ว	ไม่จริง; R6 กู้ candidate ได้ 0.12% ที่ radius ≤1
final CRM deployment สำเร็จ	ยังไม่มี artifact ยืนยัน

Appendix B: คำสั่งทำซ้ำรูป

```
.venv/bin/python manuscript/generate_report_figures.py
```

ผลลัพธ์อยู่ใน manuscript/figures/